

W11

실습 데이터 가이드

주식 퀴트 — 팩터와 종목 데이터를 어디서 얻나

실습: 팩터 회귀 · 페어 트레이딩 · 메타 레이블링

팩터 수익률은 학계가 무료로 공개한다. 종목 데이터도 공개다.

어려운 것은 수집이 아니라 생존편의와 시점 정합을 지키는 일이다.

이번 실습이 답해야 하는 질문

알파인가 팩터 노출인가

실습 산출물

- 펀드 1개의 CAPM · FF3 · FF5 회귀
- α 의 t값과 팩터 노출 분해
- 페어 트레이딩 스프레드와 진입·청산
- 메타 레이블링 — 1차 방향 · 2차 크기

그래서 답해야 하는 것

- 초과수익이 α 인가 β 인가 — 모형을 바꾸면 α 가 남는가
- $t > 2$ 를 넘는가, 다중검정을 감안하면 어떤가
- 페어의 공적분이 표본 밖에서도 유지되는가
- 2차 모델이 실제로 정밀도를 올리는가

데이터 설계의 원칙

- 팩터와 종목 수익률의 기간·빈도·통화를 일치시킨다 — Ken French는 미국 달러 기준이다
- 상장폐지 종목을 빼면 생존편의가 들어간다 — 백테스트에서는 당시 존재했던 유니버스를 써야 한다
- 재무 데이터는 발표일 기준으로 시점을 맞춘다 — 결산일 기준이면 미래정보 누출이다

필요한 것은 두 갈래다 — 팩터 수익률(공개) · 종목 또는 펀드 수익률(공개)

데이터 명세 — 팩터와 종목의 시점 정합

수집보다 정렬이 어렵다

항목	형식	빈도 · 기준	쓰이는 곳
date · mkt_rf · smb · hml	패널	월간 %, USD	FF3 회귀
rmw · cma · mom	패널	월간 %, USD	FF5 · 모멘텀
rf	시계열	월간 %	초과수익 계산
fund_ret · stock_ret	시계열	월간 또는 일간 %	회귀의 좌변
pair_a · pair_b	시계열	일간 증가 (조정)	스프레드 · 공적분
signal · label	패널	1차 방향 · 2차 실행여부	메타 레이블링
universe_asof	표	시점별 구성 종목	생존편의 방지

Ken French 데이터의 함정 두 가지

- 미국 달러 · 미국 시장 기준이다 — 국내 펀드에 그대로 회귀하면 통화와 시장이 어긋난다
- 국내 팩터가 필요하면 KRX 데이터로 직접 구성하거나 글로벌 팩터(Developed) 시리즈를 쓴다

어디서 구하나 — 팩터는 학계가 공개한다

등록도 결제도 필요 없다

데이터	출처	형식	비고
FF3 · FF5 · 모멘텀	Ken French Data Library (다트머스)	CSV (zip)	월간 · 일간
글로벌 · 지역 팩터	Ken French — Developed · Asia Pacific	CSV	통화 주의
153개 팩터	jkpfactors.com (JKP 공개 데이터)	CSV	W13에서 본격 사용
국내 종목 · 지수	KRX 정보데이터시스템 · FinanceDataReader	웹 · 파이썬	무료
해외 종목	yfinance — auto_adjust=True	파이썬	배당 포함
펀드 수익률	금융투자협회 전자공시 · 각 운용사 공시	웹	국내 액티브 펀드

가상 데이터는 쓰지 않는다

- 팩터도 종목도 모두 공개다 — 실제 데이터라야 t값과 다중검정 논의가 의미를 가진다
- 다만 메타 레이블링의 라벨은 규칙에 따라 생성한다 — 이것은 가상이 아니라 파생 데이터다

팩터와 수익률을 정렬하는 프롬프트

시점 정합을 지시에 명시한다

[입력] 프롬프트 · Claude Code

팩터 회귀용 데이터를 만들어줘.

- 1) Ken French 에서 월간 FF5 + 모멘텀 다운로드
(Developed 지역, 최근 15년)
- 2) 분석 대상 펀드/ETF 월간 총수익률
(yfinance, auto_adjust=True)
- 3) 두 시계열을 date 로 정렬해 병합
 - 팩터는 % 단위, 수익률도 % 로 통일
 - rf 를 빼서 초과수익 열을 따로 만든다
- 4) 결측 구간과 기간 불일치를 표로 보고

산출: fml_w11_factors.csv

각 열의 시작·종료일과 관측 수 출력

주의: 팩터는 USD 기준이다. 대상이 원화면
그 사실을 출력에 경고로 표시해줘.

이 프롬프트의 요령

- 통화 불일치를 경고하게 시킨다 — 국내 펀드에 미국 팩터를 회귀하는 실수가 흔하다
- 단위(%)를 통일하라고 명시한다 — French는 %, yfinance는 소수다
- 관측 수를 출력받아 표본이 충분한지 먼저 본다

이어지는 지시

- "CAPM · FF3 · FF5 세 모형으로 회귀하고 α 와 t값을 표로 비교해줘"
- "팩터를 늘릴 때 α 가 어떻게 줄어드는지 보여줘"
- "메타 레이블링 2차 모델을 붙여 정밀도 변화를 재줘"

숫자를 믿기 전에 확인할 것

α 가 크게 나오면 대개 데이터 문제다

반드시 맞춰볼 것

- 시장 β 가 1 부근인가 (주식형이면)
- 팩터와 수익률의 단위가 같은가 (% vs 소수)
- 초과수익에서 r_f 를 두 번 빼지 않았는가
- R^2 가 0.7 이상인가 — 너무 낮으면 시장이 어긋난 것이다

자주 나오는 오류

- 미국 팩터에 국내 펀드를 회귀하고 α 가 크다고 결론내는 것
- 상장폐지 종목을 제외한 유니버스로 백테스트하는 것 (생존편의)
- 재무 데이터를 결산일 기준으로 붙여 미래정보가 새는 것
- 다중검정 보정 없이 $t > 2$ 를 유의하다고 보는 것

이 데이터가 이후 주차에서 다시 쓰인다

- W13 — 같은 팩터 데이터로 멀티팩터 엔진을 만든다
- W16 — 알파와 팩터 기여의 분해가 TPA의 핵심 논거가 된다

팩터 데이터는 공짜지만 정렬은 공짜가 아니다 — 통화 · 빈도 · 시점 세 가지를 항상 확인한다