

W13

실습 데이터 가이드

팩터 투자 — 153개 팩터를 어디서 얻나

실습: 멀티팩터 엔진과 Integrating 방식 비교

JKP가 153개 팩터를 93개국 기준으로 무료 공개했다.

팩터 동물원을 직접 열어보고 무엇이 살아남았는지 확인하는 것이 이번 실습이다.

이번 실습이 답해야 하는 질문

발견인가 p-해킹인가

실습 산출물

- 팩터별 IC · IR · t값 계산
- Mixing과 Integrating 비교 (30%+ 우위 재현)
- 다중검정 보정 후 생존 팩터 선별
- 가중치·타이밍 실험

그래서 답해야 하는 것

- $t > 2.0$ 기준으로 몇 개가 살아남는가
- HLZ 기준($t > 3.0$)을 적용하면 어떻게 되는가
- Integrating이 정말 Mixing보다 나은가
- 발견 이후 수익이 감소했는가 (post-publication decay)

데이터 설계의 원칙

- 팩터 수가 많을수록 다중검정 문제가 커진다 — 검정 횟수를 반드시 기록한다
- 같은 기간·같은 유니버스에서 비교해야 팩터 간 순위가 의미를 가진다
- 발표 전후 구간을 나눠야 decay를 볼 수 있다 — 원논문의 표본 기간을 확인한다

필요한 것은 하나다 — 팩터 수익률 패널. 다만 검정 횟수와 표본 기간을 함께 기록한다

데이터 명세 — 팩터 패널과 메타 정보

수익률만으로는 부족하고 메타 정보가 함께 필요하다

항목	형식	단위 · 기준	쓰이는 곳
date · factor_name · ret	패널	월간 %, 룡숫 수익률	IC · IR 계산
theme	문자열	13개 테마 분류 (JKP)	테마별 집계
region · country	문자열	93개국 · 지역 구분	글로벌 검증
pub_year · original_sample	표	원논문 발표연도 · 표본기간	decay 분석
n_tests	정수	검정한 팩터 수 (누적)	다중검정 보정
stock_ret · char	패널	종목 수익률 · 특성값	직접 구성 시
port_weight	패널	Mixing · Integrating 비중	두 방식 비교

Mixing과 Integrating의 차이는 데이터 단계에서 갈린다

- Mixing은 팩터별 포트폴리오를 만든 뒤 합친다 — 팩터 수익률만 있으면 된다
- Integrating은 종목 수준에서 특성을 결합한다 — 종목별 특성값(char)이 반드시 필요하다

어디서 구하나 — JKP가 전부 공개했다

153개 팩터 × 93개국 무료 열려 있다

데이터	출처	형식	비고
153개 팩터 수익률	jkpfactors.com — Global Factor Data	CSV	월간 · 지역별
팩터 정의 · 테마	JKP (2023) 논문 부록 · 사이트 문서	PDF · 웹	13개 테마
FF3 · FF5 · 모멘텀	Ken French Data Library	CSV	벤치마크 팩터
국내 팩터	FinanceDataReader + KRX 재무데이터로 직접 구성	파이썬	직접 계산
원논문 표본기간	각 팩터 원논문 (JKP 부록에 정리)	PDF	decay 분석
NPS 국내주식 배분	fund.nps.or.kr 공시	웹	케이스 대조

가상 데이터는 쓰지 않는다

- JKP 공개 데이터가 있어 팩터 동물원을 실제로 열어볼 수 있다 — 이 실습의 전제다
- 국내 팩터가 필요하면 KRX 데이터로 직접 구성한다. 이것도 가상이 아니라 계산 결과다

팩터 패널을 받고 검증하는 프롬프트

검정 횟수 기록을 지시에 넣는다

[입력] 프롬프트 · Claude Code

팩터 검증용 데이터를 만들어줘.

- 1) JKP Global Factor Data 에서
Developed 지역 월간 팩터 수익률 다운로드
(153개 전체, 최근 30년)
- 2) 팩터별로 계산
연평균 수익 · 변동성 · IR · t값
표본 기간과 관측 수 함께
- 3) 13개 테마로 묶어 테마별 집계
- 4) 다중검정 보정
Bonferroni 와 BH(YFDR) 두 방식으로
t 임계값을 각각 표시하고 생존 팩터 수 비교
- 5) fml_w13_factors.csv 로 저장

검정한 팩터 수(n_{tests})를 출력에 명시해줘.

이 프롬프트의 요령

- n_{tests} 를 명시하게 한다 — 다중검정 논의의 출발점이다
- 보정 방식을 두 가지로 시켜 임계값 차이를 보게 한다
- 테마 집계까지 시키면 JKP 결론과 바로 대조된다

이어지는 지시

- "발표연도 전후로 나눠 수익 감소를 비교해줘" — post-publication decay
- "Mixing과 Integrating으로 각각 멀티팩터 포트폴리오를 만들어 IR을 비교해줘"
- "생존 팩터만으로 다시 구성하면 성과가 어떻게 되는가"

숫자를 믿기 전에 확인할 것

t값이 크게 나오면 검정 횟수를 먼저 본다

반드시 맞춰볼 것

- $t > 2.0$ 생존 비율이 JKP 결과(82% 복제)와 비슷한가
- Bonferroni 임계값이 검정 수에 따라 커지는가
- 팩터 수익률이 롱숏인지 롱온리인지 확인했는가
- 지역·통화가 분석 대상과 일치하는가

자주 나오는 오류

- n_tests 를 세지 않고 $t > 2$ 를 유의하다고 보는 것
- Mixing 결과를 Integrating이라고 부르는 것 — 종목 특성이 없으면 Integrating이 아니다
- 발표 이전 구간만으로 팩터를 평가하는 것
- 롱숏 팩터 수익률에 거래비용을 넣지 않는 것

이 데이터가 이후 주차에서 다시 쓰인다

- W16 — TPA의 팩터 렌즈가 이 팩터 정의를 그대로 쓴다
- W11의 회귀 결과와 대조하면 알파·팩터 분해가 완성된다

동물원을 열어보는 것이 목적이다 — 몇 개를 검정했는지 세지 않으면 무엇도 유의하지 않다