

처음 배우는 강화학습

W06 보강 1 · 3교시 ‘강화학습과 현대 동적 배분’을 읽기 위한 기초

보고



고르고



점수 받고



고친다

다섯 구획으로 3교시의 말을 모두 풀어 드립니다

01	강화학습이란	해 보고 점수로 배운다 세 가지 배우는 방식 · 에이전트와 환경의 고리
02	무엇을 키우나	당장보다 앞으로 누적 보상 · 할인 · 정책과 가치 · 벨만
03	어떻게 배우나	경험으로 고치기 탐색과 활용 · Q-러닝 · 기법 지도 · 최신 흐름
04	연기금에 쓸 때	게임과 시장은 다르다 데이터 부족 · 다섯 함정 · 사람이 주는 한도
05	정리	강의본으로 가는 다리 말 대응표 · 스스로 점검

수식은 세 줄뿐입니다. 덧셈·곱셈과 평균만 알면 끝까지 읽힙니다.

01

강화학습이란

정답을 알려 주지 않고, 해 본 결과의 점수로 배웁니다

기계가 배우는 방식은 크게 셋입니다

지도학습

정답을 보고 배운다

- 문제와 정답이 짝지어 있다
- 예: 내일 오를지 맞히기
- 선생님이 채점해 준다

비지도학습

정답 없이 묶는다

- 숨은 구조를 찾는다
- 예: 비슷한 종목끼리 묶기
- 채점이 없다

강화학습

해 보고 점수로 배운다

- 정답 행동은 아무도 모른다
- 예: 매달 비중 정하기
- 결과가 점수로 돌아온다

강화학습에는 ‘이 상황의 정답’이 주어지지 않습니다.

해 보고, 점수를 받고, 다음엔 더 잘하도록 규칙을 고칩니다.

강아지 훈련과 자전거 배우기가 강화학습입니다

① 해 본다

행동

- 앉아 보라 했더니 뜬다
- 페달을 세게 밟아 본다

② 점수를 받는다

보상

- 앉으면 간식, 뛰면 없음
- 넘어지면 아프다

③ 규칙을 고친다


학습

- 간식 받은 행동을 더 자주
- 넘어진 자세는 덜

점수가 늦게 올 수도 있다는 점이 핵심입니다. 오늘의 선택이 한 달 뒤에 결과로 옵니다.

그래서 ‘당장 점수’가 아니라 ‘앞으로 받을 점수의 합’을 봅니다.

모든 강화학습은 이 고리 하나로 설명됩니다



이 고리가 수천·수만 번 돈다 — 점수의 합이 커지도록 규칙을 고쳐 가는 것이 강화학습


※ 강의본 30쪽의 MDP 그림이 이 고리를 기호로 적은 것입니다. s = state, a = action, r = reward.

고리의 다섯 부품을 일상과 연기금 말로 옮깁니다

부품	쉬운 뜻	게임에서	연기금에서
에이전트	결정하는 쪽	게임하는 사람	운용 규칙(프로그램)
환경	나머지 세상 전부	게임 속 세계	시장 + 기금 계좌
상태	결정할 때 보는 것	지금 화면	금리·변동성·현재 비중
행동	고르는 것	왼쪽·오른쪽·점프	이번 달 주식 비중
보상	방금 한 일의 점수	얻은 점수	비용 뺀 수익 - 위험 벌점

※ 현재 비중을 상태에서 빼면 에이전트는 ‘바꾸면 거래비용이 든다’는 사실을 알 수 없습니다.


같은 고리를 기금 운용에 겹쳐 보면 이렇습니다



보상을 무엇으로 정하느냐가 곧 운용 철학이다 — 수익만? 낙폭까지? 비용까지?

※ 보상 설계는 강의본 39쪽에서 네 가지 선택지(기간수익·로그·샤프·효용)로 다룹니다.

강화학습 문제는 한 번의 예측이 아니라 이어지는 선택입니다



오늘 고른 비중이 내일의 출발점(상태)이 된다
그래서 '한 번 예측'이 아니라 '이어지는 선택'이다

목표는 한 달 점수가 아니라 끝까지 받은 점수의 합

※ 시작부터 끝까지 한 판을 에피소드(episode)라 부릅니다. 숫자는 수업용으로 지어낸 예시입니다.

02

무엇을 키우나

당장의 점수가 아니라 앞으로 받을 점수의 합을 봅니다

먼 미래의 점수는 조금 깎아서 더합니다

앞으로 받을 점수의 합 (누적 보상 · return)

$$G_t = r_{t+1} + \gamma r_{t+2} + \gamma^2 r_{t+3} + \dots$$

r

매번 받는 점수

γ (감마)

0~1 사이 할인율

$\gamma^2, \gamma^3 \dots$

멀수록 더 깎인다


G

키우고 싶은 값

예금의 현재가치 계산과 똑같은 생각입니다. $\gamma = 0.9$ 면 1년 뒤 1원은 오늘 0.9원입니다.

보상 1, 0, 2를 $\gamma = 0.9$ 로 더하면 $1 + 0 + 0.81 \times 2 = 2.62$ 입니다.

할인율 γ 가 에이전트의 시야를 정합니다



할인 무게를 그대로 그린 그림입니다

γ 가 작으면 눈앞만, 크면 먼 미래까지 봅니다.

연기금처럼 30년을 보는 투자자는 γ 를 1에 가깝게 둡니다.

강화학습은 세 가지를 배웁니다

정책 π

상황 → 행동 규칙

- ‘이럴 땐 이렇게’ 표
- 최종 목표물이다
- 강의본의 ‘동적 배분 규칙’

가치 $V \cdot Q$

앞으로 받을 점수

- V : 이 상황이 얼마나 유리한가
- Q : 이 상황에서 이 행동은?
- 오늘 손실이어도 높을 수 있다

모형 (선택)

세상의 규칙

- 이렇게 하면 어떻게 되나
- 알면 머릿속에서 연습
- 모르면 부딪혀 배운다

좋은 가치를 알면 좋은 정책은 저절로 나옵니다. 가치가 큰 쪽을 고르면 되기 때문입니다.

미로에 가치를 적어 두면 길은 저절로 보입니다

가치 V — 여기서 출발하면 앞으로 받을 점수

5.2	6.2	7.3	8.6	10.0	목표 +10
4.3	벽	6.2	벽	8.6	함정 -10
3.4	4.3	5.2	벽	7.3	6.2
2.7 출발	3.4	4.3	5.2	6.2	5.2

정책 π — 칸마다 가치가 큰 쪽으로

→	→	→	→	→	목표 +10
↑	벽	↑	벽	↑	함정 -10
↑	→	↑	벽	↑	←
↑	↑	↑	→	↑	↑

한 걸음마다 -0.4 · 할인 $\gamma = 0.9$ · 목표 +10 · 함정 -10 → 가치가 큰 칸을 따라가면 그것이 최선과 길

왼쪽은 칸마다 ‘여기서 출발하면 앞으로 받을 점수’, 오른쪽은 그 점수를 따라간 화살표입니다.

함정 바로 아래 칸은 목표가 가까워도 위로 가지 않고 돌아갑니다.

벨만 방정식은 ‘한 걸음 앞만 보라’는 말입니다

벨만 방정식 (Bellman, 1957)

$$V(s) = \max_a [r + \gamma V(s')]$$

$V(s)$

지금 칸의 가치

$\max$

행동 중 최선

r


당장 받는 점수

$\gamma \cdot V(s')$

할인한 다음 가치

먼 미래 전체를 계산하지 않아도, 다음 칸의 가치만 알면 지금 칸의 가치가 나옵니다.

미로의 한 칸에서 벨만 방정식을 직접 풀어 봅니다



지금 가치 = 행동마다 (당장 보상 + 할인한 다음 칸 가치)를 구해 가장 큰 값


※ 앞 장 미로의 3행 5열 칸입니다. 이 계산을 모든 칸에 되풀이하는 방법을 가치 반복(value iteration)이라 부릅니다.

03

어떻게 배우나

세상의 규칙을 모르는 채로, 경험에서 가치를 채워 갑니다

새로 시도하지 않으면 처음의 우연에 갇힙니다



아는 최선을 되풀이하는 활용과 새 행동을 시도하는 탐색 사이의 균형 문제입니다.

ϵ -탐욕(ϵ -greedy): 대개는 아는 최선, ϵ 의 확률로만 무작위로 시도합니다.

Q-러닝은 경험 한 번마다 점수표를 조금씩 고칩니다

Q-러닝 (Watkins, 1989)

$$Q(s, a) \leftarrow Q(s, a) + \alpha \left[r + \gamma \max_{a'} Q(s', a') - Q(s, a) \right]$$

$Q(s, a)$

지금 점수표 값

$r + \gamma \max Q'$

경험이 말한 값

$[\dots - Q]$

놀람 (TD 오차)

α

놀람의 일부만

세상의 규칙을 몰라도 됩니다. 벨만 방정식의 오른쪽을 경험 한 번으로 대신합니다.

α 가 크면 빨리 배우지만 흔들리고, 작으면 느리지만 안정적입니다.

Q-러닝은 자주 가 본 길부터 먼저 배웁니다



초록 화살표 = 최선의 행동(동점 포함) · 빨강 = 아직 틀림 · 칸 색 = 배운 가치(진할수록 높음) 1000판 뒤 — 컴퓨터로 만든 가상 실험입니다

5판 뒤에는 절반이 틀리지만, 50판이면 출발에서 목표까지의 길은 거의 다 맞습니다.

드물게 가 본 구석 칸은 1,000판 뒤에도 틀립니다. 경험이 곧 실력입니다.

수많은 기법 이름은 두 갈림길로 정리됩니다



※ 라임 칩: PPO는 지금 가장 널리 쓰는 기본값이고, GRPO는 2024년 나온 PPO의 가벼운 변형으로 추론형 AI 학습에 쓰입니다.

먼저 알아 둘 기본 기법 다섯 가지

기법	무엇을 배우나	한 줄 설명	행동
Q-러닝	가치 (표)	경험마다 점수표를 고친다	몇 개 중 고르기
DQN	가치 (신경망)	점수표가 크면 신경망으로 어림	몇 개 중 고르기
REINFORCE	정책	좋았던 행동의 확률을 높인다	무엇이든
Actor-Critic	정책 + 가치	운용역과 리스크 담당자가 짝	무엇이든
PPO	정책 + 가치	한 번에 크게 바꾸지 않는다	무엇이든


※ ‘몇 개 중 고르기’ = 방어·중립·공격처럼 정해진 선택지, ‘무엇이든’ = 주식 43.7%처럼 연속된 비중도 가능.

그 위에 쌓인 현대 기법 다섯 가지

기법	핵심 아이디어	쉬운 비유	주로 쓰는 곳
DDPG · TD3	연속 행동용 Actor-Critic	비중을 소수점까지 조절	강의본 38쪽 루프
SAC	여러 행동을 고루 시도하게 보상	편식하지 않게 용돈	로봇 · 연속 제어
모형 기반	세상을 흉내 낸 뒤 머릿속 연습	비행 시뮬레이터 훈련	MuZero · Dreamer
오프라인 RL	쌓인 기록만으로 배운다	지난 운용 일지로 공부	금융 · 의료
RLHF · GRPO	사람 선호 · 자동 채점이 보상	첨삭 받으며 글쓰기	ChatGPT · 추론 AI

※ 오프라인 RL은 실제 계좌로 시험할 수 없는 금융에 특히 맞습니다. 대신 기록에 없던 행동은 과신하기 쉽습니다.

Actor-Critic은 운용역과 리스크 담당자의 짝입니다




놀람이 +이면 그 행동을 더 자주, -이면 덜 한다
예상이라는 기준이 있어 점수 잡음이 줄고 더 빨리 배운다

PPO · SAC · DDPG가 모두 이 구조다 (강의본 3교시 38쪽 DDPG 루프)

※ ‘놀람’이 Q-러닝의 TD 오차와 같은 것입니다. 점수 자체가 아니라 예상과의 차이로 배웁니다.

강화학습은 70년 된 이론이 계산력을 만나 꽃핀 분야입니다



지금의 AI 챗봇 · 추론 모델도 마지막 단계에서 강화학습으로 다듬는다

※ DeepSeek-R1(2025, Nature)은 정답을 자동 채점하는 보상만으로 추론 능력을 키웠습니다. 바토 · 서튼은 2025년 3월 튜링상 수상자로 발표됐습니다.

2025~26년의 흐름은 세 갈래로 읽힙니다

① 채점 가능한 보상

RLVR · GRPO

- 수학 답·코드 테스트로 자동 채점
- 사람 평가 없이 추론 향상
- DeepSeek-R1 (Nature 2025)

② 세계 모형

Dreamer · MuZero

- 세상을 흉내 내 머릿속 연습
- 같은 설정으로 150여 과제
- DreamerV3 (Nature 2025)

③ 투자 쪽

직접 정책 최적화

- 계좌 회계식은 이미 안다
- 시장 경로만 흉내 낸다
- 딥헤징 · PG-DPO (2025)

세 갈래 모두 ‘무작정 부딪히기’보다 ‘아는 것은 식으로, 모르는 것만 학습으로’ 쪽입니다.


금융은 바둑보다 로봇 연구의 교훈이 더 가깝습니다. 규칙은 변하고 연습 판은 적습니다.

04

연기금에 쓸 때

게임에서 통한 방법이 시장에서 그대로 통하지 않는 이유

게임은 무한히 새로 두지만 시장의 과거는 한 번뿐입니다



10년 데이터로 에피소드를 1만 번 돌려도 10만 년치 경험이 되지 않습니다. 같은 10년일 뿐입니다.

되풀이 학습은 오히려 그 10년에만 맞는 규칙을 외우게 합니다(과적합).

금융 강화학습의 함정은 다섯 가지로 정리됩니다

함정	쉬운 말로	어떻게 막나
데이터가 적다	시장의 과거는 한 번뿐	단순한 규칙 · 적은 변수
규칙이 변한다	금리·규제·참여자가 바뀐다	구간을 나눠 앞으로만 검증
점수 잡음이 크다	하루 수익은 대부분 운	Critic · 긴 평가 기간
미래 정보가 샌다	종가 보고 그 종가에 거래	정보 시점과 체결 시점 분리
여러 번 시도	100번 돌리면 하나는 운 좋게 좋다	시도 횟수만큼 기준 높이기

※ 강의본 41쪽 ‘RL의 실무 4대 장벽’(과적합·데이터 부족·블랙박스·분포 밖)과 같은 이야기를 원인 쪽에서 본 것입니다.

연기금에서 강화학습은 운전대가 아니라 보조 장치입니다



강의본 43쪽 'RL을 혼자 두지 마라' · 53쪽 Two Sigma의 가드레일 방식

※ 가드레일 = 허용 범위를 넘는 제안을 잘라 내는 장치. 강의본 43쪽 '하이브리드'와 53쪽 Two Sigma 사례가 이 구조입니다.

도입을 검토할 때는 세 질문을 먼저 묻습니다

질문 ①

기준선을 이겼나

- 단순 규칙·밴드 리밸런싱과
- 같은 비용 조건에서 비교
- 못 이기면 복잡할 이유가 없다

질문 ②

어디서 탐색했나

- 실제 계좌가 아니라
- 과거 데이터 시뮬레이터에서
- 비용·체결 지연까지 넣었나

질문 ③

위원회에 설명되나

- 왜 이 비종인가에 답하나
- 한도는 사람이 쥐고 있나
- 끄는 조건이 정해져 있나

좋은 알고리즘보다 좋은 환경(회계·비용)과 강한 기준선이 먼저입니다.

05

정리

이 텍스트의 말을 강의본 3교시의 말로 이어 줍니다

이 텍스트의 말과 강의본의 말을 이어 둡니다

이 텍스트에서 쓴 말

강의본이 쓰는 말

강의본 쪽

보고 → 고르고 → 점수 받는 고리

MDP (S, A, P, R, γ)

30쪽

앞으로 받을 점수의 합

가치함수 · 기대 누적 보상

32쪽

도입 전에 먼저 이길 단순 규칙

기준선 · 무거래 구간 · GP

33~36쪽

기법 지도 · 기본 기법 다섯

Deep RL 알고리즘 지형

37쪽

운용역과 리스크 담당자

Actor-Critic · DDPG 루프

38쪽

점수를 무엇으로 정하나

보상 설계 · 회계

39~40쪽

다섯 함정 · 보조 장치

4대 장벽 · 검증 · 하이브리드

41~43쪽

강의본은 가운데 말을 씁니다. 이 표가 둘 사이의 다리입니다.

답을 맞춰 보고 강의본으로 넘어가십시오

스스로 점검

답

왜 그런가

보상 1, 0, 2 · $\gamma = 0.9$ 의 누적 보상은?

2.62

$1 + 0.9 \times 0 + 0.81 \times 2$

탐색을 전혀 안 하면?

첫 우연에 갇힌다

더 좋은 행동을 영영 모른다

상태에 현재 비중이 왜 필요한가?

거래비용 때문

바꾸는 폭을 알아야 비용을 안다

10년 데이터를 1만 번 돌리면?

여전히 10년

새 경험이 아니라 같은 과거

넷 다 맞았다면 강의본 3교시(29~47쪽)가 그대로 읽힙니다.

※ 이 텍스트의 수치 예제는 수업용 가상 값이고, 시뮬레이션은 컴퓨터로 만든 가상 실험입니다.

해 보고, 점수를 받고, 규칙을 고칩니다.

당장의 점수보다 앞으로의 가치를 봅니다.

금융에서는 데이터와 비용이 학습을 묶습니다.

이제 강의본
3교시로

BAF.60080

W06 · 동적 포트폴리오와 장기투자
보충교재 16 · Gârleanu-Pedersen 모델

※ 더 깊은 내용(무거래 구간 · Gârleanu-Pedersen · 합성시장 검증 · 손계산 워크북)은 보충교재 14번 폴더의 본편 II · 기초 부록 · 워크북에 있습니다.