


강화학습과 역강화학습

퀀트 금융 응용

보상을 최적화하는 문제와 보상을 추론하는 문제



강연은 RL 기초에서 시장 전체 IRL까지 다섯 단계로 나아갑니다

앞의 두 부는 기본 지식, 뒤의 세 부는 Halperin 연구진의 응용이다

01 — 왜 RL과 IRL인가

질문을 뒤집는 두 문제

Vapnik 원칙 · 피드백 루프 · 금융 RL의 출발점

02 — 강화학습 기초

MDP · 정책 · 벨만 방정식

Q-learning · SARSA · 금융 절벽 걷기

03 — 역강화학습

행동에서 보상을 읽는다

비유일성 · MaxEnt IRL · IRL from Failure · T-REX

04 — G-learner와 GIRL

목표기반 자산관리

G-learning · 2차 보상 · 실험 · 로보어드바이징

05 — 시장 전체의 IRL

보이지 않는 손의 추론

제한합리적 에이전트 · 엔트로피 규제 Markowitz

01

왜 RL과 IRL인가

같은 의사결정 과정을 두고 서로 반대 방향의 질문을 던진다

Halperin은 RL을 Vapnik 원칙의 구현으로 봅니다

강연 2번 슬라이드 「RL or IRL?」 — 로댕의 생각하는 사람과 로봇의 대비

VAPNIK'S PRINCIPLE


중간 문제를 피하라

- 예측 후 최적화 대신
- 행동을 바로 학습
- 피드백 루프 내장
- 사람처럼 배우려면 RL인가 IRL인가

원본: Halperin(2020) 강연 슬라이드 2번

목표 문제를 풀 때 더 어려운 중간 문제(정확한 수익률 예측)를 거치지 않는 것이 RL의 장점입니다

RL or IRL?



Why I like RL: 1) it implements Vapnik's principle, and 2) it incorporates a feedback loop

To learn like the humans, show we the robots use RL or IRL?

"One should avoid solving more difficult intermediate problems when solving a target problem."
(Vladimir Vapnik).

2

강화학습은 피드백 루프가 있다는 점에서 다른 학습과 구별됩니다

기본 지식 — 기계학습의 세 갈래를 과제 유형으로 나눈 것이다

SUPERVISED

지도학습

인식 과제 (Perception)

- 입력→정답 레이블
- 수익률·부도 예측
- 정답이 주어진다

UNSUPERVISED

비지도학습

구조 발견

- 레이블 없음
- 군집·차원축소
- 정답이 없다

REINFORCEMENT

강화학습


행동 과제 (Action)

- 행동이 환경을 바꾼다
- 보상으로 피드백
- 다단계 계획·예측

행동이 다음 데이터를 바꾸는 피드백 루프는 RL에만 있습니다

에이전트는 행동하고, 환경은 상태와 보상으로 답합니다

포트폴리오 예 — 오프라인 설정에서는 과거 데이터가 환경을 대신한다




목표: 누적 보상의 기대값을 최대화한다 — 지도·비지도학습에는 없는 피드백 루프

RL은 벨만의 동적계획법을 실제 문제로 일반화하려는 시도입니다

IRL은 RL의 질문을 거꾸로 던집니다


RL: 보상이 주어지면 최적 행동은? / IRL: 행동이 주어지면 그 보상은?



같은 MDP를 놓고 질문의 방향만 뒤집는다 — IRL의 보상은 일반적으로 유일하지 않다

트레이딩에서는 보상이 직접 관측되지 않으므로 IRL이 자연스러운 질문이 됩니다

트레이딩 데스크의 보상은 기록되지 않습니다



가격과 거래는 보이지만 보상은 보이지 않습니다 — IRL은 거래 기록에서 그 효용을 추론합니다

금융 RL은 Atari 게임과 출발 조건이 다릅니다

강연 7번 「How to start with RL and IRL?」 — Deep RL의 성공 조건이 금융에는 없다

VIDEO GAMES · ROBOTICS

Deep RL이 성공한 곳

- 데이터가 넘친다
- 노이즈가 낮다
- 행동 공간이 작다

수십 차원의 행동



WEALTH · PORTFOLIO

금융의 현실


- 데이터가 부족하다
- 신호 대 잡음이 낮다
- 행동이 고차원이다

자산 수백 개의 비중

기성 Deep RL 라이브러리와 딥러닝부터 시작하려는 유혹을 피해야 합니다

단순한 모델에서 시작해 신경망은 마지막에 씁니다

Halperin이 제시한 금융 RL·IRL의 출발 순서



신경망은 필요할 때만, 그리고 앞 단계를 마친 뒤에만

02

강화학습 기초

MDP · 정책 · 벨만 방정식 · Q-learning과 SARSA · 금융 절벽 걷기

MDP는 다섯 요소로 의사결정 문제를 정의합니다


기본 지식 — 마르코프 결정 과정(Markov Decision Process)의 구성

기호	의미	포트폴리오 문제의 예
$s \in S$	상태 (이산·연속)	보유 비중 · 잔액 · 시장 신호
$a \in A$	행동 (이산·연속)	매매 · 적립 · 인출
$p(s' s, a)$	전이 확률	수익률 분포 · 시장 충격
$R(s, a)$	보상 함수	수익 - 위험 벌점 - 거래비용
$\gamma \in [0, 1]$	할인율	미래 보상의 현재 가치

마르코프 성질: 다음 상태는 현재 상태와 행동에만 의존한다고 가정합니다

에이전트는 할인된 누적 보상을 최대화합니다

강연 8·9번 「Markov Decision Processes」 「Decision policy」



누적 보상 (return)

$$G_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k+1}, \quad 0 \leq \gamma \leq 1$$

정책의 목적함수

$$J(\pi) = \mathbb{E}_{\pi} \left[\sum_{t=0}^T \gamma^t R(s_t, a_t) \right], \quad \pi^* = \arg \max_{\pi} J(\pi)$$

정책 $\pi: S \rightarrow A$ 는 결정적일 수도, 확률분포일 수도 있습니다

벨만 방정식이 다단계 문제를 한 단계씩 쪼갭니다

기본 지식 — 최적 행동가치 Q^* 는 '지금 보상 + 할인된 다음 최적가치'로 재귀한다

벨만 최적 방정식

$$Q^*(s, a) = \mathbb{E} \left[R(s, a) + \gamma \max_{a'} Q^*(s', a') \mid s, a \right]$$

NOW

지금 보상 $R(s, a)$

한 단계의 결과

NEXT

할인된 최적가치

$\gamma \cdot \max Q^*(s', a')$

RECURSION

뒤에서부터 풀린다

동적계획법 = 벨만

전이확률을 알면 동적계획법, 모르면 데이터로 근사하는 것이 RL입니다

Q-learning과 SARSA는 다음 행동을 무엇으로 보느냐가 다릅니다

기본 지식 — α : 학습률, r : 관측한 보상, s' : 다음 상태

Q-learning — 다음 상태에서 가장 좋은 행동으로 갱신 (off-policy)

$$Q(s, a) \leftarrow Q(s, a) + \alpha [r + \gamma \max_{a'} Q(s', a') - Q(s, a)]$$

SARSA — 실제로 고른 다음 행동 a' 로 갱신 (on-policy)

$$Q(s, a) \leftarrow Q(s, a) + \alpha [r + \gamma Q(s', a') - Q(s, a)]$$

탐험 중의 실수까지 반영하는 SARSA가 더 보수적인 경로를 배웁니다


금융 절벽 걷기는 가장 단순한 금융 RL 문제입니다

Sutton · Barto의 cliff walking을 예금 계좌 관리로 옮긴 MLF 교재의 예제

SETUP

최소 잔액 유지

- 행동: UP · ZERO · DOWN
- 거래마다 비용
- 최소 잔액 밑은 파산
- 만기 잔액에도 벌점



Q-learning은 절벽 옆 최단 경로를, SARSA는 한 칸 떨어진 안전한 경로를 배웁니다

시장 잡음이 없어도 학습에 300~400 에피소드가 걸립니다

강연 10번 「Financial cliff walking: the RL problem」 — SARSA와 Q-learning의 학습 곡선

EPISODES


단순해도 느리다

- 확률적 요소 없음
- 결정적 전이
- 그래도 수백 회 시행
- RL for trading may not be easy!

원본: Halperin(2020) 강연 슬라이드 10번

실제 시장 잡음이 더해지면 필요한 데이터는 훨씬 많아집니다

Financial cliff walking: the RL problem



Financial cliff walking: (adaptation of the cliff walking problem from Sutton and Barto book): may be a simplest possible 'financial' problem for RL. The task is to maintain a minimum balance on a deposit account for a given period of time, then close the account. Transactions have costs, and there is a penalty if there is remaining balance at the final time.

This problem is very simple (no market randomness): Yet it takes about 300-400 episodes to learn not to overdraw the account!

RL for trading may not be easy!

Applications of RL: Optimal stock execution, option pricing (QLBS), ...

RL의 금융 응용은 집행·헤지·자산배분으로 모입니다

강연이 언급한 응용(최적 주문 집행, QLBS 옵션 가격결정)과 4부의 자산관리

OPTIMAL EXECUTION

최적 주문 집행

- 대량 주문 분할
- 시장충격 vs 위험
- Almgren-Chriss 확장

QLBS

옵션 가격·헤지

- BS 세계의 Q-learner
- Halperin(2020)
- 헤지와 가격을 동시에

WEALTH MANAGEMENT

목표기반 자산관리

- 적립·인출·리밸런싱
- G-learner (4부)
- 은퇴·TDF 문제

세 응용 모두 2차 비용·2차 위험 구조라 반해석적 해에 가깝게 풀 수 있습니다

03

역강화학습

관측된 상태·행동 기록에서 그 행동을 낳은 보상 함수를 추론한다

같은 행동을 설명하는 보상은 무수히 많습니다

기본 지식 — IRL은 해가 유일하지 않은 역문제(ill-posed problem)다 (Ng·Harada·Russell 1999)

보상 형성(reward shaping) — 임의의 함수 Φ 를 더해도 최적 정책은 그대로

$$r'(s, a, s') = r(s, a, s') + \gamma \Phi(s') - \Phi(s)$$

TRIVIAL

$r \equiv 0$ 도 해다

모든 정책이 최적

SHAPING

Φ 만큼 이동

총합이 상수만큼 변함

REMEDY

가정을 추가한다

엔트로피 · 순위 · 함수형

그래서 IRL 기법은 '어떤 가정으로 하나를 고르는가'로 구분됩니다

IRL은 상태·행동 기록만으로 보상 함수를 복원합니다

강연 11번 「IRL for Financial cliff walking」 — 우측은 시연 궤적의 총보상 분포

THREE APPROACHES


시연을 어떻게 보나

- MaxEnt: 확률적으로 최적
- IRL from Failure: 실패도 데이터
- T-REX: 순위로 의도 추론

원본: Halperin(2020) 강연 슬라이드 11번

세 접근은 '시연이 최적'이라는 가정을 점점 풀어 갑니다

IRL for Financial cliff walking



With IRL, we are given a history of states and actions, and the task is to infer the reward function from this data

Maximum Entropy (MaxEnt) IRL: data collected is assumed to correspond to an optimal stochastic policy. It assumes that sub-optimal actions are possible but infrequent encountered in data (and sampled according to the optimal policy)

IRL from Failure: One can learn not only from successful trajectories but also from failed ones

T-REX (TRajjectory-based EXtrapolation): learns the **intent** of the agent, does **not** assume optimality of demonstrations

MaxEnt IRL은 차선 행동도 확률적으로 허용합니다


Ziebart et al.(2008) — 총보상이 클수록 그 궤적이 지수적으로 자주 관측된다고 본다

궤적 확률 (볼츠만 분포)

$$P(\tau \mid \theta) = \frac{1}{Z(\theta)} \exp \left(\beta \sum_t r_{\theta}(s_t, a_t) \right)$$

학습 — 시연과 모델의 특성 기댓값을 맞춘다

$$\nabla_{\theta} \log \mathcal{L} = \mathbb{E}_{\mathcal{D}}[\mathbf{f}] - \mathbb{E}_{\tau \sim P(\cdot|\theta)}[\mathbf{f}], \quad r_{\theta} = \theta^{\top} \mathbf{f}$$



$\beta \rightarrow \infty$ 이면 최적 궤적만, $\beta \rightarrow 0$ 이면 모든 궤적이 같은 확률로 관측됩니다


MaxEnt IRL은 파산을 가끔 나오는 차선 결정으로 해석합니다

강연 12번 「MaxEnt IRL for FCW」 — 좌: 참 보상, 우: 복원된 보상 (행동별 히트맵)

RECOVERED REWARD

복원 $\neq$ 참 보상

- DOWN 상태에 높은 보상
- 최적경로 상태에 높은 보상
- 방문 빈도가 섞여 든다



원본: Halperin(2020) 강연 슬라이드 12번

복원된 보상은 참 보상과 달라도 같은 정책을 재현합니다 — 비유일성의 실제 모습입니다

T-REX는 시연의 최적성을 가정하지 않고 순위로 의도를 배웁니다

Brown et al.(2019) Trajectory-ranked Reward EXtrapolation — Bradley-Terry 쌍비교 손실

$\tau_i < \tau_j$: τ_j 가 더 낫다고 순위가 매겨진 쌍

$$\mathcal{L}(\theta) = - \sum_{\tau_i \prec \tau_j} \log \frac{\exp \sum_{s \in \tau_j} \hat{r}_\theta(s)}{\exp \sum_{s \in \tau_i} \hat{r}_\theta(s) + \exp \sum_{s \in \tau_j} \hat{r}_\theta(s)}$$

IRL FROM FAILURE

실패에서 배운다

Shiarlis et al.(2016)

T-REX

순위에서 배운다

최적 시연이 필요 없다

EXTRAPOLATION

시연자를 넘어선다

보상을 외삽한다

운용 성과 기록은 최적이지 아니므로, 순위 정보만 쓰는 T-REX가 금융에 잘 맞습니다

세 기법은 시연을 얼마나 믿는가에서 갈립니다

강연 11번의 세 접근을 원 논문 기준으로 정리한 비교

기법	시연에 대한 가정	쓰는 정보	금융에서의 함의
MaxEnt IRL	확률적으로 최적	성공 궤적	차선 결정을 잡음으로 흡수
IRL from Failure	성공·실패 구분	실패 궤적 추가	손실·파산 기록도 데이터
T-REX	최적성 가정 없음	궤적 간 순위	성과 순위만으로 의도 추론

※ 어떤 기법이든 추론된 보상은 모형 가정에 의존한다 — 행동을 설명한다고 해서 실력을 입증하지는 않는다

가정을 줄일수록 데이터 요구는 늘고, 해석의 부담은 사용자에게 넘어옵니다

04

G-learner와 GIRL

목표기반 자산관리의 정방향 RL과 역방향 IRL — Dixon · Halperin(2020)

중간 현금흐름이 있는 포트폴리오 문제를 한 틀로 품니다

강연 13번 「Introduce G-learner and GIRL」 — 은퇴 계획 · 타깃데이트펀드

ACCUMULATION

적립 단계

- 정기 납입
- 목표 대비 성장
- 리밸런싱

DE-ACCUMULATION

인출 단계

- 정기 인출
- 자산 고갈 위험
- 리밸런싱

ONE FRAMEWORK

G-learner

- 두 단계를 한 문제로
- 목표기반 접근의 RL판
- GIRL은 그 역문제

목표기반 자산관리(goal-based wealth management)를 RL 문제로 옮긴 것이 G-learner입니다

G-learning은 Q-learning에 엔트로피 규제를 더한 확률적 확장입니다

Fox·Pakman·Tishby(2016) — 사전 정책 π_0 에서 너무 멀어지지 않도록 KL 벌점을 둔다

G 함수 — 엔트로피 규제된 Q

$$G_t(x, a) = R_t(x, a) + \gamma \mathbb{E}[F_{t+1}(x_{t+1}) \mid x, a]$$

자유에너지 F — 부드러운 최대값(soft max)

$$F_t(x) = \frac{1}{\beta} \log \sum_a \pi_0(a \mid x) e^{\beta G_t(x, a)}$$

최적 정책 — π_0 의 베이즈식 갱신

$$\pi(a \mid x) = \pi_0(a \mid x) e^{\beta (G_t(x, a) - F_t(x))}$$

β 가 크면 탐욕적 Q-learning, 작으면 사전 정책 π_0 — 잡음이 큰 금융 데이터에서 β 가 과적합을 막습니다

보상은 '달리는 목표'에 못 미친 만큼 벌점을 줍니다

Dixon · Halperin(2020) — x : 자산별 보유액, u : 자산별 매매·납입액, Ω : 거래비용 행렬

1기 보상 = - 납입 현금 - 목표 미달 2차 벌점 - 거래비용

$$R_t(\mathbf{x}_t, \mathbf{u}_t) = -\mathbf{1}^\top \mathbf{u}_t - \lambda \mathbb{E}_t \left[\left(\hat{P}_{t+1} - (\mathbf{1} + \mathbf{r}_t)^\top (\mathbf{x}_t + \mathbf{u}_t) \right)^2 \right] - \mathbf{u}_t^\top \Omega \mathbf{u}_t$$

달리는 목표 (running goal)

$$\hat{P}_{t+1} = (1 - \rho) B_t + \rho \eta \mathbf{1}^\top \mathbf{x}_t$$

ρ 벤치마크 B 와 자기 성장의 가중

η 현재 포트폴리오의 목표 성장률


λ 목표 미달에 대한 위험회피

ω 매매에 따른 2차 거래비용

보상 함수의 파라미터는 모두 네 개 — GIRL이 추론할 대상입니다

2차 보상과 가우스 사전 정책이 반해석적 해를 만듭니다

1부의 '단순 모델·반해석적 해' 원칙을 그대로 따른 설계



G-learner는 '먼저 단순하게'라는 Halperin의 권고가 실제로 작동함을 보입니다

GIRL은 관측된 행동의 우도를 최대화해 보상 파라미터를 찾습니다

G-learning 정책이 확률분포이므로 행동 기록에 대한 우도를 직접 쓸 수 있다

GIRL 추정 — 정책 우도 + 전이 우도, $\theta = (\lambda, \eta, \rho, \Omega, \dots)$

$$\hat{\theta} = \arg \max_{\theta} \sum_t \left[\beta \left(G_t^{\theta}(\mathbf{x}_t, \mathbf{u}_t) - F_t^{\theta}(\mathbf{x}_t) \right) + \log p_{\theta}(\mathbf{x}_{t+1} \mid \mathbf{x}_t, \mathbf{u}_t) \right]$$

INPUT

상태·행동 기록

보상은 관측 안 됨

ESTIMATION

경사하강 최대우도

약 200회 반복에 수렴

OUTPUT

보상 파라미터 θ

투자자의 '선호'

정방향(G-learner)과 역방향(GIRL)이 같은 파라미터를 공유하므로 서로를 검증할 수 있습니다

G-learner의 시연을 GIRL이 되짚어 파라미터를 되찾습니다

강연 13·14번 내용을 정방향·역방향 흐름으로 다시 그린 것



G-learner가 만든 시연을 GIRL에 넣으면 파라미터를 되찾는다 — 이것이 실험의 검증 논리다

목표·위험회피·거래비용이 포트폴리오 결정을 만들고, 결정에서 그것을 다시 읽어 냅니다

실험은 주식 99개와 채권 1개를 30분기 동안 운용합니다

강연 16번 「Experiments with the G-learner」 — 알파 모델 기대수익과 실현수익의 약한 상관

SETUP

시뮬레이션 설계

- 자산 100개 · 30분기
- $\gamma = 0.95$ · $r_f = 2\%$
- 초기 1,000달러 동일배분
- 약한 알파 신호

원본: Halperin(2020) 강연 슬라이드 16번

Experiments with the G-learner

- The objective is to demonstrate that efficient portfolio management can be achieved with a large number of assets and for long horizons. We choose 100 assets (99 stocks and a bond) and 30 quarterly time steps for numerical illustrations
- The G-learner bases its actions on the outputs of an 'alpha-model' (a model for expected equity returns)
- We use simulations with some ad-hoc model parameters (picked to produce realistically-looking optimal installments), and with an alpha-model producing expected returns that are weakly correlated with realized returns:



임의 파라미터로 그럴듯한 납입액을 만들고, 알파 모델은 실현수익과 약하게만 맞습니다

G-learner는 약한 신호로 샤프비율을 0.21 높입니다

강연 17번 「Results」 — 시뮬레이션 결과, 비교 대상은 리밸런싱 없는 동일가중 포트폴리오

동일가중



0.208

G-learner



0.420

GIRL 재현



0.411

KEY INSIGHT

신호 수확

동일가중이 버린 알파를 활용

GIRL이 96%를 재현

샤프 개선분 0.212 중 0.203

※ 인공자료 시뮬레이션 결과 — 실제 시장 성과가 아니다

G-learner의 시연만 보고도 GIRL은 그 성과를 거의 그대로 재현합니다

두 전략의 수익률 경로는 거의 겹칩니다

강연 17번 원본 차트 — 동일가중(0.208), G-learning(0.42), GIRL(0.411)

READING THE CHART

겹친 두 선


- 붉은 실선: G-learner
- 푸른 점선: GIRL
- 30분기 표본 평균수익률

원본: Halperin(2020) 강연 슬라이드 17번

파라미터를 되찾았다는 것은 '행동의 원인'을 데이터에서 읽었다는 뜻입니다


Results for the G-learner and GIRL

- The G-learner is able to harvest weak signals from the 'alpha-model' **to boost the Sharpe ratio by 0.21** relatively to a fixed equally-weighted portfolio that ignores the signals and keeps the portfolio fixed over its lifetime.
- Once demonstrations are produced by the G-learner with fixed parameters, the IRL algorithm (GIRL) manages to infer these parameters, and hence mimic the performance of the G-learner:



추론한 보상 파라미터로 투자자를 군집화합니다

강연 19번 「G-learner and GIRL work together」 — 실제 투자자를 G-learning 에이전트로 모형화



※ 검증 단계는 강연 슬라이드에 없는 보강 — 추론된 선호가 곧 실력이나 미래 성과를 뜻하지는 않는다

행동으로 정의된 군집은 '구성상 의미 있는 군집'입니다 — 로보어드바이저의 기반

05

시장 전체의 IRL

모든 참가자의 집합적 동학을 하나의 제한합리적 에이전트로 추론한다

시장 전체를 하나의 제한합리적 에이전트로 봅니다

Halperin · Feldshteyn(2018) — '보이지 않는 손'의 역강화학습

INVISIBLE HAND

시장이 스스로 학습

- 개별 거래 데이터 불필요
- 가격 동학만 관측
- 자기대국(self-play)

원본: Halperin(2020) 강연 슬라이드 20번

개별 투자자 IRL의 데이터 한계를 시장 수준의 추론으로 우회합니다

IRL for the market as a whole

- The G-learner and GIRL are algorithms to do IRL for individual investors. Another way to use IRL is to apply it to a market-wide agent that embodies collective dynamics of all market participants. This is the IRL approach to an **Invisible Hand** of the market.
- A bounded-rational IRL agent has a Markowitz reward function regularized by entropy



- Reference: I. Halperin and I. Feldshteyn, https://papers.ssrn.com/sol3/papers.cfm?abstract_id=3174498

엔트로피 규제 Markowitz 보상에서 비선형 평균회귀가 나옵니다

BRIT-IRL(Bounded Rational Information-Theoretic IRL) — 아래 식은 구조를 보여 주는 개념적 형태다

제한합리적 시장 에이전트의 목적

$$\max_{\pi} \mathbb{E}_{\pi} \left[\mathbf{a}^{\top} \boldsymbol{\mu}(s) - \lambda \mathbf{a}^{\top} \boldsymbol{\Sigma} \mathbf{a} \right] - \frac{1}{\beta} \text{KL}(\pi \parallel \pi_0)$$

DRIVERS

세 가지 동인

신호 · 시장충격 · 잡음

EMERGENCE

평균회귀의 내생화

가정이 아닌 결과

USE

Black-Litterman 유사

신호에 대한 시장 견해

원 논문은 표준 TensorFlow로 가볍게 구현된다는 점도 강조합니다

IRL은 '무엇을 원하는가'를 데이터에서 읽는 도구입니다

강연 전체의 흐름과 실무 적용 시 점검할 것

WHAT IT GIVES

얻는 것

- 투자자 선호의 정량화
- 전략의 암묵적 효용
- 시장 견해의 추출

개인 → 시장 전체



WHAT TO CHECK

점검할 것

- 보상의 비유일성
- 가정에 대한 민감도
- 표본 외 검증

선호 ≠ 실력·미래 성과

단순한 보상, 반해석적 해, 검증 — 금융 RL·IRL의 세 원칙입니다

강연과 보강에 쓴 원 논문은 다음과 같습니다

강연: Igor Halperin, “Reinforcement Learning and its Inverse”, DataArt IT NonStop, 2020.12

- Dixon, Halperin & Bilokon (2020), Machine Learning in Finance: From Theory to Practice, Springer
- Dixon & Halperin (2020), G-Learner and GIRL: Goal Based Wealth Management with RL, SSRN 3543852
- Halperin & Feldshteyn (2018), Market Self-Learning ... Invisible Hand Inference, SSRN 3174498
- Fox, Pakman & Tishby (2016), Taming the Noise in RL via Soft Updates, UAI
- Ziebart et al. (2008), Maximum Entropy Inverse Reinforcement Learning, AAI
- Brown et al. (2019), Extrapolating beyond Suboptimal Demonstrations (T-REX), ICML
- Shiarlis, Messias & Whiteson (2016), Inverse RL from Failure, AAMAS
- Ng, Harada & Russell (1999), Policy Invariance under Reward Transformations, ICML
- Halperin (2020), QLBS: Q-Learner in the Black-Scholes(-Merton) Worlds, J. Derivatives

RL은 보상이 주어질 때 최적 행동을 찾고,

IRL은 행동이 주어질 때 보상을 찾는다.

금융에서는 둘 다 단순하게 시작한다.

다음 단계: 보충교재 14번 손계산 워크북에서
벨만·MaxEnt·T-REX·G-learning을 직접
계산