

★ WEEK 15 · 강의본 · 제2부

Measuring What Matters

Total Portfolio Approach 성과평가 — 무엇을, 어떻게 측정하나

CPP Investments Insights Institute · TPA 시리즈 제2편 리뷰

벤치마크 초과성과 하나로 판정할 수 없는 TPA 성과를 리스크 타게팅 · 익스포저 타게팅 · 투자선정의 세 가지 결정으로 분해하고, 6개 렌즈의 다차원 프레임워크로 평가하는 CPP Investments의 접근을 정리한다.

이 리포트의 세 가지 메시지

1

벤치마크만으로는 더 이상 충분하지 않다

노이즈 신호 · 카멜레온 벤치마크 · 사과-오렌지 비교의 세 한계 때문에, 의도적으로 벤치마크에서 벗어난 TPA 포트폴리오를 단일 지표로 판정할 수 없다.

2

성과는 결정(decision) 단위로 분해해 평가한다

리스크 타게팅 → 익스포저 타게팅 → 투자선정. 장기 성과 기여가 큰 순서이며, 결정마다 서로 다른 평가 렌즈(최소기여율 MCR 추이 · 실현가능 대안 분포 · 벤치마크 포트폴리오)를 쓴다.

3

벤치마크는 '판결'이 아니라 '진단 입력'이다

총수익 · 리스크배분 · 구성/분산 · 투자선정 · 결정품질 · 레짐 복원력의 6차원 프레임워크에서 벤치마크는 여러 입력 중 하나로 자리를 옮긴다.

질문은 '벤치마크를 이겼는가'가 아니라 '모든 결정이 장기 제도 목표 달성을 개선했는가'다.

제2부의 위치 — 1부는 설계했고, 2부는 평가한다

1부(강의본)에서 가져오는 것

- TPA 3원칙 — Reference · Active Risk 예산 · 사일로 해체
- 4대 기관의 경로 — CPPIB · NZ Super · GIC · Future Fund
- KFP 6단계 설계 — RP 70/30 · Active Risk 1.5%
- 제1호 안건 — '전환하느냐'의 의사결정

제2부가 더하는 것

- 전환 이후의 질문 — '작동했는가'를 무엇으로 판정하나
- 세 가지 결정 분해 — 리스크 · 익스포저 · 투자선정
- 거짓 음성의 계량 — 벤치마크 단독 판정의 한계
- 제2호 안건 — '무엇으로 평가하느냐'의 의사결정

설계가 끝나면 반드시 평가가 온다 — CPP Insights 'Measuring What Matters'(2026.7)가 그 교과서다

TPA의 신뢰성은 한 질문에 달려 있다

과거에 작동했음을 평가할 수 없다면, 미래에 작동하리라는 확신도 유지할 수 없다

“Has it worked?” — 그런데 무엇을 기준으로 답할 것인가

SAA의 세계 — 책임의 분리

- 이사회가 정책 포트폴리오(벤치마크)를 선택
- 경영진 평가 = 벤치마크 초과성과
- 정작 정책 선택 자체는 '다락방'에 방치돼 상시 평가를 벗어난다

TPA의 세계 — 책임의 통합

- 경영진이 전체 포트폴리오 결정을 소유
- 리스크 수준 · 분산 · 유동성 · 실행까지 전부 평가 범위
- 평가 기준 = 목표 대비 결정의 사전 타당성과 사후 성공


CPP Investments는 75년 계리 호라이즌의 결과에 책임을 지면서 투명성과 검증을 동시에 제공해야 한다.

책임구조의 전환 — 정책 결정을 다락방(attic)에서 꺼내다

SAA는 벤치마크 대비 부가가치를, TPA는 목표 대비 포트폴리오 성과를 평가한다

그림 읽는 법

- 왼쪽 SAA: 책임 분리
- 정책은 이사회 몫
- 정책 자체는 미평가
- 오른쪽 TPA: 책임 통합
- 경영진이 전체 소유
- 평가 질문이 바뀐다 — '벤치마크를 이겼나' → '핵심 결정이 잘 내려지고 성공했나'



단일 벤치마크가 실패하는 세 가지 이유

세 한계는 서로 독립적이며, TPA처럼 의도적으로 차별화된 포트폴리오에서 동시에 증폭된다

TPA에서 단일 벤치마크가 실패하는 세 가지 이유

Issue 1 · 노이즈 신호

가치를 더하는 전략도 운으로
장기간 벤치마크에 뒤질 수 있다

저상관 TPA에서 더 심각
→ 거짓 음성 10년에도 30%

Barras et al. (2010, 2026)
가치사슬 따라 노이즈 누적

Issue 2 · 카멜레온 벤치마크

시총가중 지수는 시장 집중과
함께 위험 성격이 계속 변한다

왜곡된 인센티브
→ 집중에 보상, 분산에 벌점

Sorensen et al. (2023)
타이트한 TE 제약의 함정

Issue 3 · 사과-오렌지 비교

비유동성 프리미엄 · 장기 현금흐름 ·
운영가치는 공모지수에 안 잡힌다

인프라 등 사모자산에서 극명
→ 공모 벤치마크로 복제 불가

Shen & Blanc-Brude (2022)
오도할 수 있는 단순 비교


결론: 벤치마크는 여전히 필수지만, TPA에서는 더 이상 그것만으로 충분하지 않다

노이즈: 가치를 더하고도 진 것처럼 보인다

음영 = 진짜 알파가 양(+)인데도 벤치마크에 뒤지는 '거짓 음성(false negative)' 영역

그림 읽는 법


- 타원 = 1σ 신뢰영역
- 점 = 기대 성과
- SAA(좌): 고상관·낮은 TE — 장기엔 크게 줄어든다(10년 6.5%)
- TPA(우): 저상관·높은 TE — 10년에도 30%
- FN은 운용이 아니라 평가 눈금의 오류 — 거짓 양성도 함께 늘어난다



거짓 음성 확률 — 10년을 기다려도 30%

알파 100bps의 TPA가 90bps의 SAA보다 '저 보일' 확률이 훨씬 높다 — 짧은 성적표로 TPA를 재단할 수 없는 이유

항목	SAA	TPA
벤치마크 상관	높음 (97%)	낮음 (61%)
기대 알파	90 bps	100 bps
FN 확률 · 1년	34.6%	43.5%
FN 확률 · 5년	17.1%	35.6%
FN 확률 · 10년	6.5%	29.8%




출처: 리포트 Figure 2 하단 표 · 부록 통계 입력값 (양 포트폴리오 변동성 10%, 벤치마크 기대수익 6.0% 가정)

장기 성과를 지배하는 세 가지 결정

높은 층위의 리스크·익스포저 결정이 장기 성과를 지배하고, 투자선정은 그 위에 증분 기여한다

무엇을 보나


- 결정 1 리스크 타게팅
 - 가장 큰 장기 영향
- 결정 2 익스포저 타게팅
 - 팩터 믹스 설계
- 결정 3 투자선정
 - 증분 부가가치
- SAA '다락방' 결정을
상시 평가 대상으로 전환



세 가지 결정, 세 가지 평가 렌즈

각 결정은 '어떤 질문에 답해야 하는가'가 다르므로 검증 도구도 달라야 한다

CPP Investments의 세 가지 핵심 의사결정과 평가 방법




검증: 투자성과가 최소기여율(MCR)을 끌어내렸다

불리한 인구구조 충격에도 투자성과가 이를 상쇄하고 남았다 — MCR 9.84%(2012) → 9.19%(최신)

읽는 법 · 핵심 발견

- 최소기여율(MCR) = 급여 지급에 필요한 최소 보험료율
- 낮을수록 재정 견고
- 9.54% → 약 9.19%
- 4회 연속 3년주기 하락
- 법정요율 9.9→9.5% 인하 제안(2027년 시행, Spring Economic Update 2026)

Despite adverse demographic surprises that would normally increase contribution rates, investment outcomes have more than offset these pressures. **The MCR declined from 9.84% in 2012 to 9.19% in the latest report.**




Source: CPP Investments Insight Institute, Office of the Chief Actuary (OCA), triennial CPP Actuarial Reports, 17th–32nd Reports (2000–2024)

검증: 약 1만 개 실현가능 대안과의 전면전

동일 리스크 목표를 다른 방식으로 달성하는 모든 설계의 실현 수익 분포 안에서 자기 위치를 확인한다

읽는 법 · 핵심 발견

- 단일 벤치마크 아님
- 동일 리스크 대안 분포
- 최근 상위 십분위 = 미국 테크 집중형
- 분산 실패가 아니라 예외적 강세장의 특성
- 목표 = 여러 사이클에서 상위 오분위 유지



단판 대결(prize fight)에서 전면전으로

**SAA는 벤치마크라는 단일 상대와의 단판 대결(prize fight),
TPA는 모든 실현가능 대안과의 전면전(battle royale)이다.**

단기 '승자'의 정체

- 단기 우승 설계는 대개 그 환경 전용 포트폴리오
- 상장주식이 기대를 크게 넘는 환경에선 집중형이 이기게 돼 있다

장기 우수 설계의 기준

- 여러 시장 사이클과 조건에서
- 분포의 상위 오분위(quintile)를 꾸준히 유지하는 설계

단일 상대만 모방하는 '벤치마크 허깅(benchmark hugging)' 유인이 사라지고, 제도 목표 달성이 다시 중심에 선다.

투자선정 — 스킬 알파를 베타에서 분리한다

세 결정 중 벤치마크 비교가 가장 유효하게 작동하는 영역

방법 — 벤치마크 포트폴리오

- 전략별로 유사한 시스템 리스크의 공모지수 벤치마크와 비교
- 전략 → 부서 → 총펀드로 집계해 '벤치마크 포트폴리오' 구성
- 설계가 만든 베타 수익과 스킬 부가가치를 구분

사모자산 — 두 가지 가치의 분리

- ① 공모 대신 사모로 투자한 '전략적 결정'의 가치
 - ② 적절한 사모 벤치마크 대비 '운용 스킬'의 가치
- 단순 공모지수 비교는 이 기여를 온전히 포착하지 못한다

경영진은 여전히 총 포트폴리오 결과에 책임진다 — 벤치마크는 개별 전략·부서의 기여를 진단하는 도구다.


다차원 평가 — 여섯 개의 렌즈

서로 다른 지표는 서로 다른 질문에 답한다 — 참조 포트폴리오 · 글로벌 시장 · 무레버리지 · 피어 비교를 결합

여섯 렌즈

- ① 총수익 성과
- ② 리스크 · 자본 배분
- ③ 구성 · 분산
- ④ 투자선정
- ⑤ 결정 품질 · 프로세스
- ⑥ 레짐 복원력

거버넌스 작동과 장기 목표
정렬도 함께 점검



통계적 기초 — 신뢰타원과 거짓 음성 확률

벤치마크·포트폴리오 수익이 이변량 정규를 따를 때, 카이제곱 통계량이 타원 신뢰영역을 만든다

$$(\mathbf{r} - \boldsymbol{\mu})' \Sigma^{-1} (\mathbf{r} - \boldsymbol{\mu}) \sim \chi_2^2, \quad \mathbf{r} = (r_R, r_A)', \quad \boldsymbol{\mu} = (\mu_R, \mu_A)'$$

$$P(\text{False Negative}) = P(r_A < r_R \mid \mu_A > \mu_R)$$

입력값 (Figure 2)	SAA 포트폴리오	TPA 포트폴리오
벤치마크 상관 ρ	97%	61%
트래킹 에러 TE	230 bps	880 bps

두 포트폴리오 변동성 10% · 벤치마크 기대수익 6.0% 가정 · 신뢰타원은 1표준편차 영역 (Shen, Pelsser & Schotman 2019 유사)

계량화 제안 — 세 결정을 숫자로 검증하는 지표 체계

'잘 내려진 결정인가'라는 정성 질문을 결정별 계량 지표와 통계 판정 기준으로 번역한다

결정	제안 지표	계산 · 판정 기준	리포트의 실제 결과
① 리스크 타게팅	MCR 투자 기여 (%p)	실현수익의 최소요구수익 초과분을 MCR 변화로 환산 — 하락이면 성공	-0.59%p (2024), 4회 연속 하락
② 익스포저 타게팅	대안 분포 백분위	$\text{percentile} = \Phi((r - \mu_{\text{alt}})/\sigma_{\text{alt}}) \geq 80\%$ (상위 오분위)	여러 사이클에서 상위 오분위 유지
③ 투자선정	부가가치(DVA) · 정보비율	$IR = DVA/TE, t = IR \times \sqrt{T} > 1.645$ (5% 유의)	벤치마크 포트폴리오 대비 집계
공통 안전장치	거짓 음성 확률	$P(FN) = \Phi(-\alpha\sqrt{T}/TE)$ — 판정 유보 폭으로 명시	약 1만 개 대안 · 통계 부록

핵심 원칙: 지표마다 '무엇이 성공인지'의 임계값을 사전에 선언해야 사후 합리화를 막을 수 있다.

손계산 전에 — 세 식을 말로 읽는다

잘했는데 진 것처럼 보일 확률, 실력을 입증하는 데 필요한 해수, 그리고 합격선

$$TE = \sigma \sqrt{2(1 - \rho)}, \quad P(FN) \approx \Phi\left(-\frac{\alpha \sqrt{T}}{TE}\right), \quad T^* = \left(\frac{1.645 TE}{\alpha}\right)^2$$

식	무엇을 말하나	SAA vs TPA
TE (트래킹 에러)	내 포트폴리오와 기준이 해마다 얼마나 다르게 움직이나 — 비슷할수록($\rho \rightarrow 1$) 작다	2.3% vs 8.8%
P(FN) (거짓 음성)	실력(α)이 있는데도 기준에 진 것으로 나올 확률 — 괄호 안 = 신호($\text{실력} \times \sqrt{\text{기간}}$) ÷ 소음 (TE)	35% vs 45% (1년)
T* (필요 해수)	5% 오류 수준으로 ‘운이 아니라 실력’이라 말하려면 몇 년 — 1.645는 그 문턱 값	약 18년 vs 210년
$t = IR \times \sqrt{T} > 1.645$	결정 3 — 정보비율 $\times \sqrt{\text{기간}}$ 이 문턱을 넘으면 실력 인정	IR 0.6: 10년 1.90 · 3년 1.04
백분위 $\geq 80\%$	결정 2 — 같은 위험의 다른 설계 약 1만 개 중 상위 20%	$(7.1 - 6.0) \div 1.2 \rightarrow 82\%$

$\Phi(x)$ = 표준정규분포에서 x보다 작을 확률 · $\Phi(0) = 50\%$ · $\Phi(1.645) = 95\%$ — 숫자 풀이는 다음 세 장

트래킹 에러와 거짓 음성 확률

두 포트폴리오 변동성 $\sigma = 10\%$ 로 같다고 가정하면 상관 ρ 하나로 TE가 결정된다

$$TE = \sigma \sqrt{2(1 - \rho)}, \quad z = \frac{\alpha \sqrt{T}}{TE}, \quad P(\text{FN}) \approx \Phi(-z)$$

구분	$TE = \sigma \sqrt{2(1-\rho)}$	$z = \alpha \sqrt{T}/TE$ (1년)	$P(\text{FN})$ 근사	리포트 값
SAA ($\rho = 0.97$)	$10\% \times \sqrt{0.06} \approx 2.45\%$	$0.90 / 2.30 = 0.39$	$\Phi(-0.39) = 34.8\%$	34.6%
TPA ($\rho = 0.61$)	$10\% \times \sqrt{0.78} \approx 8.83\%$	$1.00 / 8.80 = 0.11$	$\Phi(-0.11) = 45.5\%$	43.5%

1년 근사는 리포트와 거의 일치. 장기(10년 TPA: 근사 36.0% vs 리포트 29.8%)는 복리 수익 시뮬레이션 기반이라 차이가 난다.

α 가 100bps로 더 커도 TE가 4배 가까이 크면, '저 보일' 확률은 오히려 높아진다 — 계산 한 줄로 확인되는 사실.

검증에 필요한 기간 — 벤치마크 단독 판정의 한계

5% 유의수준(단측)에서 진짜 알파를 통계적으로 확인하는 데 필요한 최소 기간 T^*

$$T^* = \left(\frac{1.645 \times TE}{\alpha} \right)^2 \quad (95\% \text{ one-sided})$$

≈ 18년

$$\text{SAA} - (1.645 \times 2.3 / 0.9)^2 = 17.7 \text{년}$$

≈ 210년

$$\text{TPA} - (1.645 \times 8.8 / 1.0)^2 = 209.6 \text{년}$$

12배

검증 소요기간 격차 — TE 격차의
제공에 비례

TPA를 벤치마크 초과성과만으로 검증하려면 두 세기가 필요하다 — 결정 단위 분해가 '선택'이 아니라 '필연'인 계량적 이유.

결정 2 · 결정 3 판정의 손계산

가정 수치는 예시 — 실제 적용 시 대안 분포 모멘트와 부가가치 시계열을 기관 데이터로 대체한다

$$\text{pct} = \Phi\left(\frac{r_{\text{TPA}} - \mu_{\text{alt}}}{\sigma_{\text{alt}}}\right) \geq 80\%$$

$$\text{IR} = \frac{\text{DVA}}{\text{TE}}, \quad t = \text{IR} \cdot \sqrt{T} > 1.645$$

결정 2 — 대안 분포 백분위

- 대안 분포: $\mu = 6.0\%$, $\sigma = 1.2\%$ (5년 실현, 가정)
- 실현 수익 7.1% $\rightarrow z = (7.1 - 6.0)/1.2 = 0.92$
- $\Phi(0.92) = 82\% \rightarrow$ 상위 오분위(80%) 충족

결정 3 — 정보비율과 유의성

- DVA(Dollar Value-Added) — 기준 대비 더 번 몫, 여기선 수익률 60bps로 환산 · TE = 100bps (가정)
- $\text{IR} = 0.60 / 10\text{년 누적}$: $t = 0.60 \times \sqrt{10} = 1.90$
- $1.90 > 1.645 \rightarrow 5\%$ 수준에서 스킬 유의

같은 IR 0.60이라도 3년이면 $t = 1.04$ 로 판정 불가 — 판정에는 지표만이 아니라 '기간'이 함께 명시돼야 한다.

제2부 점검 질문 — 측정의 네 가지 급소

Q1 · Q2

- Q1. 알파가 더 큰 TPA가 벤치마크에 '저 보일' 확률이 더 높은 이유는? [수리]
- Q2. SAA '다락방(attic)'이란 무엇이며, TPA는 그것을 어떻게 꺼내는가? [개념]

Q3 · Q4

- Q3. 대안 분포 상위 오분위 기준이 벤치마크 허깅을 막는 메커니즘은? [설계]
- Q4. KFP의 'MCR 유사 지표'를 무엇으로 정의하겠는가? [적용]

네 질문 모두 제2호 안건의 반대심문 카드로 그대로 돌아온다

용어 해설 — 이 리포트의 핵심 개념

용어	원어	뜻
최소기여율	Minimum Contribution Rate (MCR)	급여 지급에 필요한 최소 보험료율 — 낮을수록 재정 건고
거짓 음성	False Negative	진짜 알파가 양(+)인데도 벤치마크에 뒤져 보이는 경우 — 평가의 오류
트래킹 에러	Tracking Error (TE)	벤치마크 대비 초과수익의 변동성
부가가치	Dollar Value-Added (DVA)	기준 포트폴리오 대비 더 번 금액 — 손계산에선 수익률(bp)로 환산
벤치마크 허깅	Benchmark Hugging	평가 위험을 줄이려 벤치마크와 비슷하게만 운용하는 행태
SAA 다락방	SAA Attic	정책 포트폴리오 선택이 상시 평가를 벗어난 영역
단판 대결 / 전면전	Prize Fight / Battle Royale	SAA는 한 상대와, TPA는 모든 대안과 겨룬다는 비유
실행가능 대안 분포	Feasible Alternatives	동일 리스크를 달성하는 모든 설계의 실현 수익 분포
상위 오분위	Top Quintile	분포 상위 20% — 여러 사이클에서 유지가 설계 목표

이사회와 포트폴리오 오너를 위한 세 가지

평가를 위임과 정렬

ALIGN

위임한 결정 권한의 범위와 평가의 범위를 일치시킨다. 전체를 위임했다면 전체를 평가한다.

성과를 목표와 연결

CONNECT

수익률이 아니라 제도 목표 (지속가능성·MCR·복원력) 달성 여부로 성과를 읽는다.

벤치마크는 일부로

DIAGNOSE

벤치마크를 유일한 성공 척도가 아닌 전체 평가의 한 구성요소로 사용한다.

이 도전은 연기금을 넘어선다 — 다목표·장기 호라이즌 포트폴리오라면 단일 벤치마크 성적표로 환원할 수 없다.

종합 — 측정이 어려운 것은 책임이 넓어졌기 때문이다

1

TPA 성과평가의 어려움은 성과가 덜 측정 가능해서가 아니다

책임의 범위가 넓어졌기 때문이다. 리스크 선택부터 실행까지 전 결정이 평가 대상이 된다.

2

신뢰할 만한 사후 평가 = 제도 목표 연결 + 복수 렌즈

리스크 타게팅 · 분산 · 포트폴리오 구성 · 투자선정 · 장기 지속가능성 성과를 함께 본다.

3

벤치마크는 귀속·규율·책임성의 필수 도구로 남는다

다만 TPA에서는 성공/실패의 단독 판결이 아니라 진단 입력으로 역할이 바뀐다.

'포트폴리오가 벤치마크를 이겼는가'에서 '모든 경영 결정이 장기 제도 목표의 달성을 개선했는가'로.

4교시 연결 — 제2호 안건 브리핑

제2호 안건 — 무엇을 의결하나

- KFP TPA 성과평가 프레임워크 승인(안)
- D1 벤치마크 단독 유지 · D2 3결정+6렌즈 · D3 외부 독립평가 병행
- 진행 — 2부 강의 직후 30분 약식 IC (케이스 텍 20p~)
- 산출물 — 지표·임계값·판정 유보 폭이 담긴 의결문

발언 준비 체크리스트

- FN 표 — 10년 29.8%를 정확히 인용할 수 있는가 (케이스 22p)
- T* 손계산 — 18년 vs 210년의 함의를 설명할 수 있는가
- 6렌즈 — KFP 지표로 번역했는가 (케이스 23p)
- 임계값 사전 선언 — 사후 합리화 차단 장치를 제시했는가

제1호가 '전환'의 표결이었다면 제2호는 '평가 규정'의 표결이다 — 의결문이 평가 규정 제1조가 된다