동적 포트폴리오 - 강화학습 기초

포트폴리오의 기대 수익률과 분산

1. **포트폴리오 수익률** R_P:

$$R_P = \{r_1, r_2, \ldots, r_n\}$$

이는 포트폴리오에 포함된 개별 자산의 수익률을 나타낸다.

2. **포트폴리오의 기대수익률** $E(R_P)$:

$$E(R_P) = w^T \mu$$

여기서:

- w는 포트폴리오 내 자산들의 비중 벡터이다.
- μ는 개별 자산의 기대수익률 벡터이다.

포트폴리오의 기대 수익률과 분산

3. **포트폴리오의 분산** $\mathrm{Var}(R_P)$:

$$\mathrm{Var}(R_P) = \sigma_P^2 = w^T \Sigma w$$

여기서:

- Σ는 자산 수익률의 공분산 행렬이다.
- σ_P^2는 포트폴리오의 분산이다.

4. **개별 자산** X_i**의 기대수익률과 분산**:

$$E(X_i) = \mu_i$$

$$\mathrm{Var}(X_i) = \sigma_i^2 = \Sigma_{ii}$$

- μ_i는 자산 X_i의 기대수익률이다.
- Σ_{ii}는 개별 자산 X_i의 분산이다.

이 수식들은 포트폴리오 이론에서 자산들로 구성된 포트폴리오의 기대수익률과 위험(분산)을 계산할 때 사용된다.

자산 수익률과 공분산 행렬

1. **자산의 수익률** r_{t+1}:

$$r_{t+1} = \frac{P_{t+1} - P_t}{P_t} = \frac{P_{t+1}}{P_t} - 1$$

여기서:

- P_t는 시간 t에서의 자산 가격이다.
- r_{t+1}는 t에서 $t+1$로의 수익률이다.

2. **자산 수익률의 평균** μ:

$$\mu = \frac{1}{T} \sum_{t=1}^{T} r_t$$

여기서:

- T는 전체 기간의 수이다.
- r_t는 각 기간의 자산 수익률이다.

자산 수익률과 공분산 행렬

3. **자산 간의 공분산 σ_{ij}**:

$$\sigma_{ij} = \mathrm{Cov}(r_i, r_j) = \frac{1}{T}\sum_{t=1}^{T}(r_{i,t} - \mu_i)(r_{j,t} - \mu_j)$$

여기서:

- r_i, r_j는 각각 자산 i와 j의 수익률이다.
- μ_i, μ_j는 각각 자산 i와 j의 평균 수익률이다.

4. **개별 자산 X_i와 X_j의 기대수익률**:

$$E(X_i) = \mu_i$$

$$E(X_j) = \mu_j$$

자산 수익률과 공분산 행렬

5. **공분산 행렬 Σ:**

$$\Sigma = \begin{pmatrix} \sigma_{11} & \sigma_{12} & \cdots & \sigma_{1n} \\ \sigma_{21} & \sigma_{22} & \cdots & \sigma_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{n1} & \sigma_{n2} & \cdots & \sigma_{nn} \end{pmatrix}$$

여기서:

- σ_{ii}는 자산 i의 분산이다.
- σ_{ij}는 자산 i와 자산 j 간의 공분산이다.

이 수식들은 자산의 수익률과 공분산 행렬을 이해하고 계산하는 데 사용된다.

평균 분산 최적화

1. **목표 1: 포트폴리오의 기대수익률 최대화**:

   최적화 문제:

$$\max_{w} \; w^T \mu$$

   제약 조건:

$$w^T \Sigma w \leq \sigma_P^2$$

$$w^T \mathbf{1} = 1$$

   여기서:

   - w는 자산의 비중 벡터이다.
   - μ는 자산의 기대수익률 벡터이다.
   - Σ는 자산의 공분산 행렬이다.
   - σ_P^2는 포트폴리오의 허용 가능한 최대 분산이다.
   - $\mathbf{1}$는 모든 원소가 1인 벡터로, 비중의 합이 1이 되어야 한다는 의미이다.

평균 분산 최적화

2. **목표 2: 주어진 기대수익률에 대해 포트폴리오의 위험 최소화**:

   최적화 문제:

$$\min_{w} \ w^T \Sigma w$$

   제약 조건:

$$w^T \mu = \mu_P$$

$$w^T \mathbf{1} = 1$$

   여기서:

   - μ_P는 포트폴리오가 목표로 하는 기대수익률이다.
   - 다른 기호들은 위와 동일하다.

이 수식들은 평균-분산 최적화(mean-variance optimization)를 수행할 때 사용되는 두 가지 접근법을 나타낸다. 첫 번째는 주어진 위험 한도 내에서 기대수익률을 최대화하는 것이고, 두 번째는 목표로 하는 기대수익률을 달성하기 위해 위험을 최소화하는 것이다.

마르코프 의사결정 프로세스

1. **상태** S_t:

$$S_t = \begin{pmatrix} P_t \\ I_t \\ W_{t+1} \end{pmatrix}$$

여기서:

- P_t는 현재의 자산 가격이다.
- I_t는 현재의 추가적인 정보(예: 경제 지표)이다.
- W_{t+1}는 다음 시점에서의 포트폴리오 가치이다.

마르코프 의사결정 프로세스

2. **마코프 결정 과정 (MDP)의 구성 요소:**

$$(S, A, P, R, \gamma)$$

여기서:

- S는 상태 공간이다.
- A는 행동 공간이다.
- P는 상태 전이 확률이다.
- R는 보상 함수이다.
- γ는 할인 요인(discount factor)이다.

마르코프 의사결정 프로세스

3. 상태 전이 확률 $P(S_{t+1}|S_t, a_t)$:

$$P(S_{t+1}|S_t, a_t)$$

- 현재 상태 S_t와 행동 a_t에 따라 다음 상태 S_{t+1}가 결정되는 확률이다.

마르코프 의사결정 프로세스

4. 행동 a_t:

$$a_t = \begin{pmatrix} w_{1,t} \\ w_{2,t} \\ \vdots \\ w_{n,t} \end{pmatrix}$$

- $w_{i,t}$는 각 자산 i에 할당된 비중이다.
- 제약 조건: $\sum_i w_i = 1$

마르코프 의사결정 프로세스

5. 최적 정책 π^*:

$$\pi^* = \arg\max_{\pi} \mathbb{E}\left[\sum_{t-0}^{T} \gamma^t R(S_t, a_t)\right]$$

- 여기서 π는 정책(policy)이며, 특정 상태에서 어떤 행동을 취할지 결정하는 함수이다.
- $R(S_t, a_t)$는 상태 S_t와 행동 a_t에 따른 보상이다.
- π^*는 전체 보상을 최대화하는 최적 정책이다.

이 수식들은 마코프 결정 과정을 이용한 포트폴리오 최적화 문제를 설명한다. 목표는 주어진 상태에서 최적의 자산 비중을 결정하여 장기적으로 기대 보상을 최대화하는 것이다.

학습 환경

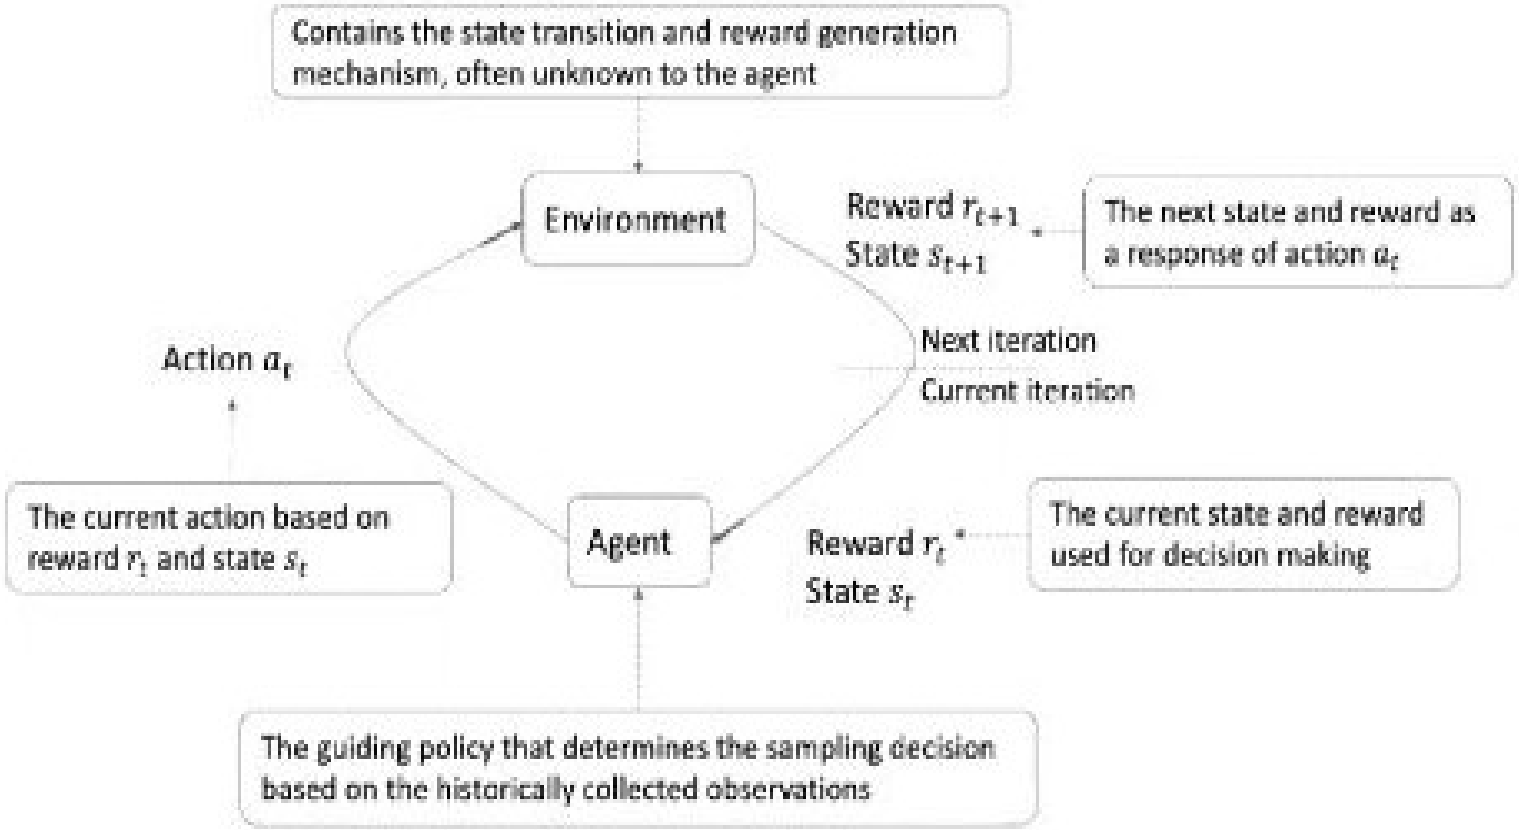


Figure 1.1: Iterative interaction between the agent and the environment.

- 이 그림은 에이전트가 환경에서 반복적으로 학습하고, 최적의 정책을 찾아가는 과정을 시각적으로 설명하고 있다. 에이전트는 환경에서 얻은 정보를 바탕으로 바탕으로 활동을 선택하며, 환경의 반응을 통해 새로운 정보를 얻고 이를 바탕으로 더 나은 결릿을 내리기 위해 학습을 계속한다.

학습 환경 개념

이 그림은 에이전트와 환경 간의 반복적인 상호작용을 나타낸다. 이 과정은 강화 학습이나 마코프 결정 과정과 같은 학습 시스템에서 자주 사용되는 개념이다.

1. **환경 (Environment)**:
   - 상태 전이 및 보상 생성 메커니즘을 포함한다.
   - 이는 종종 에이전트에게는 알려지지 않은 상태로 남아 있다.
2. **에이전트 (Agent)**:
   - 현재 상태 S_t와 보상 r_t를 바탕으로 행동 a_t를 선택한다.
   - 이 행동은 에이전트의 정책에 따라 결정되며, 정책은 이전에 수집된 관찰 데이터를 기반으로 한다.
3. **행동 a_t (Action a_t)**:
   - 에이전트가 현재 상태에서 선택하는 행동이다.
   - 이 행동은 환경에 영향을 미쳐 다음 상태와 보상을 결정하게 된다.
4. **다음 상태와 보상 (Next State and Reward)**:
   - 환경은 에이전트의 행동 a_t에 응답하여 다음 상태 S_{t+1}와 보상 r_{t+1}을 생성한다.
5. **현재 상태와 보상 (Current State and Reward)**:
   - 에이전트는 현재 상태 S_t와 보상 r_t를 바탕으로 다음 행동을 결정한다.
   - 이 과정은 반복적으로 수행되며, 에이전트는 환경과 상호작용하면서 학습한다.

누적 보상

1. 누적 보상 G_t:

$$G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots$$

이를 재귀적으로 표현하면:

$$G_t = R_{t+1} + \gamma G_{t+1}$$

여기서:

- R_{t+1}는 시점 $t+1$에서의 보상이다.
- γ는 할인 인자(discount factor)이다.

상태 가치 함수

2. 상태 가치 함수 $V^{\pi}(s)$:

$$V^{\pi}(s) = \mathbb{E}_{\pi}[G_t \mid S_t = s] = \mathbb{E}_{\pi}[R_{t+1} \mid S_t = s] + \gamma \mathbb{E}_{\pi}[G_{t+1} \mid S_t = s]$$

이를 벨만 방정식(Bellman equation)으로 표현하면:

$$V^{\pi}(s) = \sum_{a} \pi(a \mid s) \sum_{s'} P(s' \mid s, a) \left[R(s, a) + \gamma V^{\pi}(s') \right]$$

여기서:

- $\pi(a \mid s)$는 상태 s에서 행동 a를 선택할 확률이다.
- $P(s' \mid s, a)$는 상태 s에서 행동 a를 선택했을 때 다음 상태 s'로 전이될 확률이다.
- $R(s, a)$는 상태 s에서 행동 a를 선택했을 때의 보상이다.

상태 행동 가치 함수

3. 상태-행동 가치 함수 $Q^{\pi}(s, a)$:

$$Q^{\pi}(s, a) = \mathbb{E}_{\pi}[G_t \mid S_t = s, A_t = a]$$

이를 벨만 방정식으로 표현하면:

$$Q^{\pi}(s, a) = \sum_{s'} P(s' \mid s, a) \left[R(s, a) + \gamma \sum_{a'} \pi(a' \mid s') Q^{\pi}(s', a') \right]$$

여기서:

- $Q^{\pi}(s, a)$는 상태 s에서 행동 a를 했을 때의 기대되는 누적 보상을 나타낸다.
- 나머지 기호들은 위에서 설명한 것과 동일하다.

이 수식들은 강화 학습에서 중요한 두 가지 가치 함수인 상태 가치 함수 $V^{\pi}(s)$와 상태-행동 가치 함수 $Q^{\pi}(s, a)$를 설명하고 있다. $V^{\pi}(s)$는 특정 정책 π에 따라 상태 s에서 얻을 수 있는 기대되는 총 보상을 나타내고, $Q^{\pi}(s, a)$는 특정 상태 s에서 특정 행동 a를 선택했을 때의 기대되는 총 보상을 나타낸다.

정적 및 동적과 강화학습 포트폴리오 최적화

1. 정적 포트폴리오 최적화

1. 기본적인 포트폴리오 최적화 문제

먼저, 정적 포트폴리오 최적화 문제를 간단히 설명합니다. 투자자는 n개의 자산으로 구성된 포트폴리오를 최적화하고자 합니다. 투자자의 목표는 주어진 리스크 수준에서 기대수익률을 최대화하거나, 주어진 기대수익률을 달성하면서 리스크를 최소화하는 것입니다.

기대수익률과 분산

포트폴리오의 기대수익률 $E(R_P)$는 다음과 같이 표현됩니다:

$$E(R_P) = w^T \mu$$

여기서:

- w는 자산 비중 벡터 $[w_1, w_2, \ldots, w_n]^T$입니다.
- μ는 각 자산의 기대수익률 벡터 $[\mu_1, \mu_2, \ldots, \mu_n]^T$입니다.

1. 정적 포트폴리오 최적화

포트폴리오의 리스크(분산)는 다음과 같이 표현됩니다:

$$\sigma_P^2 = w^T \Sigma w$$

여기서:

- Σ는 자산 수익률의 공분산 행렬입니다.

정적 최적화 문제

주어진 리스크 수준 σ_P^2에서 기대수익률을 최대화하려는 문제는 다음과 같이 표현됩니다:

$$\max_w \; w^T \mu \quad \text{subject to} \quad w^T \Sigma w \leq \sigma_P^2, \quad w^T \mathbf{1} = 1$$

여기서 $\mathbf{1}$은 모든 원소가 1인 벡터로, 자산 비중의 합이 1이 되도록 제약 조건을 표현한 것입니다.

2. 동적 포트폴리오 최적화

2. 동적 포트폴리오 최적화 문제

동적 포트폴리오 최적화는 시장이 시간에 따라 변화한다고 가정하고, 이 변화에 대응하여 포트폴리오를 지속적으로 재조정하는 문제입니다. 이를 위해서는 각 시점 t에서 최적의 포트폴리오 w_t를 선택해야 합니다.

시간에 따른 상태 변수

시간 t에서의 상태 변수 S_t는 시장 상황을 나타내며, 예를 들어 자산 가격, 금리, 변동성 등을 포함할 수 있습니다.

동적 최적화 목표

동적 포트폴리오 최적화의 목표는 여러 시점에 걸쳐 포트폴리오의 총 기대 수익을 최대화하는 것입니다. 이 문제는 벨만 방정식(Bellman equation)으로 표현할 수 있습니다:

$$V(S_t) = \max_{w_t} \mathbb{E}\left[R_t + \gamma V(S_{t+1}) \mid S_t, w_t\right]$$

여기서:

- $V(S_t)$는 상태 S_t에서의 포트폴리오의 기대가치 함수입니다.
- R_t는 시점 t에서의 포트폴리오 수익률입니다.
- γ는 할인 요인으로, 미래 수익의 현재 가치 반영을 위한 계수입니다.

3. 강화학습을 통한 동적 포트폴리오 최적화

동적 제약 조건

포트폴리오 최적화에서 각 시점 t마다 다음의 제약 조건을 고려합니다:

$$w_t^T \Sigma_t w_t \leq \sigma_t^2, \quad w_t^T \mathbf{1} = 1$$

여기서 Σ_t는 시점 t에서의 자산 공분산 행렬이며, σ_t^2는 해당 시점에서의 허용 가능한 최대 리스크 수준입니다.

3. 강화학습을 통한 동적 포트폴리오 최적화

3. 강화학습을 통한 동적 포트폴리오 최적화

강화학습은 동적 포트폴리오 최적화를 구현하는 한 가지 방법입니다. 강화학습 에이전트는 시간에 따른 포트폴리오의 변화를 학습하면서, 최적의 투자 전략을 찾아냅니다.

강화학습 기반 최적화

강화학습에서 에이전트는 상태 S_t를 관찰하고, 이에 따라 행동 w_t를 선택합니다. 에이전트의 목표는 총 보상을 최대화하는 정책 π를 학습하는 것입니다:

$$\pi^* = \arg\max_{\pi} \mathbb{E}_{\pi} \left[\sum_{t=0}^{T} \gamma^t R(S_t, w_t) \right]$$

여기서:

- π^*는 최적 정책으로, 각 시점에서 최적의 자산 비중을 선택합니다.
- $R(S_t, w_t)$는 시점 t에서 선택된 포트폴리오 w_t에 대한 보상입니다.

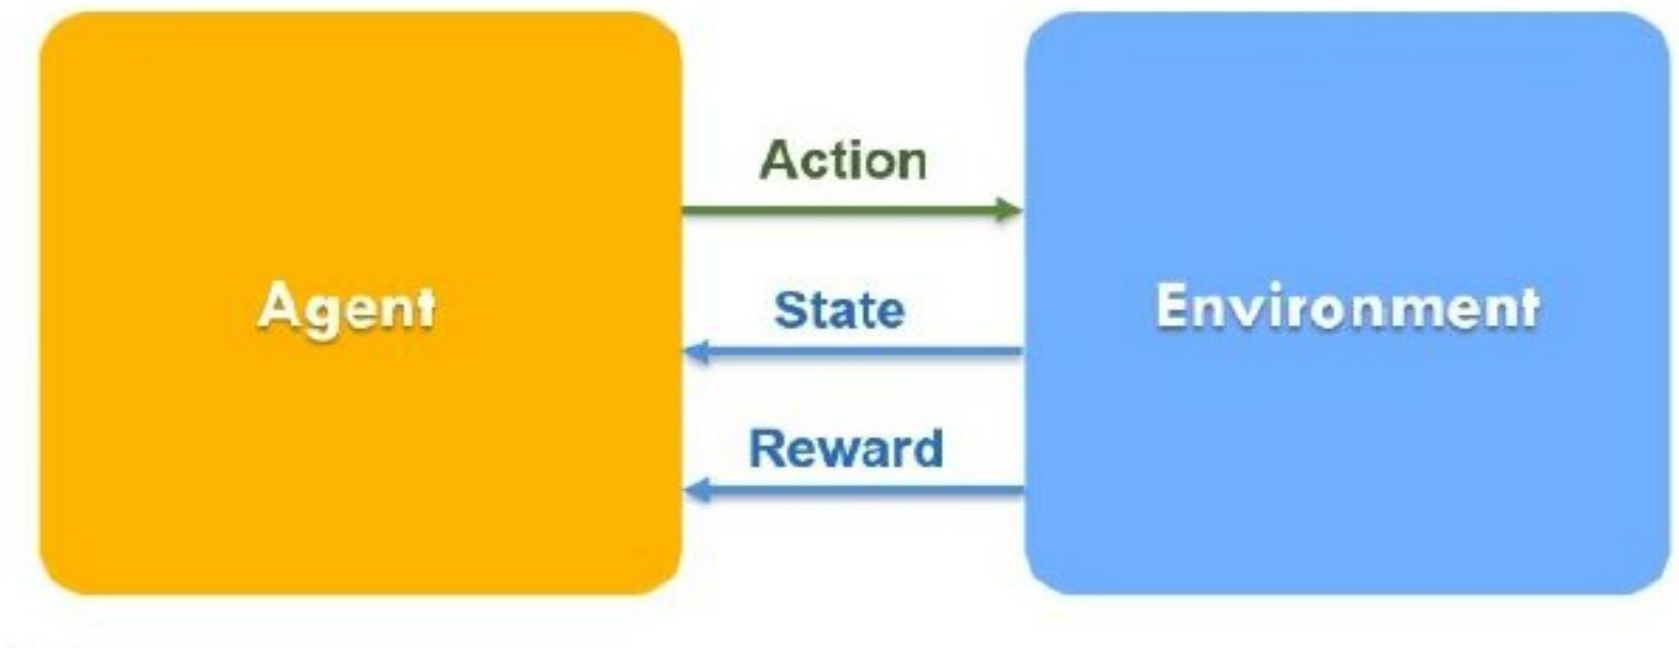
강화학습 에이전트는 이 목표를 달성하기 위해 탐색(exploration)과 착취(exploitation)을 통해 학습을 진행합니다. 탐색은 새로운 전략을 시도하여 더 나은 수익을 찾는 과정이며, 착취는 현재까지 학습한 정보를 바탕으로 최선의 결정을 내리는 과정입니다.

동적 포트폴리오 - 강화학습 + Transformer

강화학습

- 강화학습은 명시적인 목표 값을 정의하기 어려운 순차적 의사결정 문제에 대한 솔루션을 제공한다. 예를 들어 로봇 보행, 온라인 포트폴리오 재조정 등이 있다.

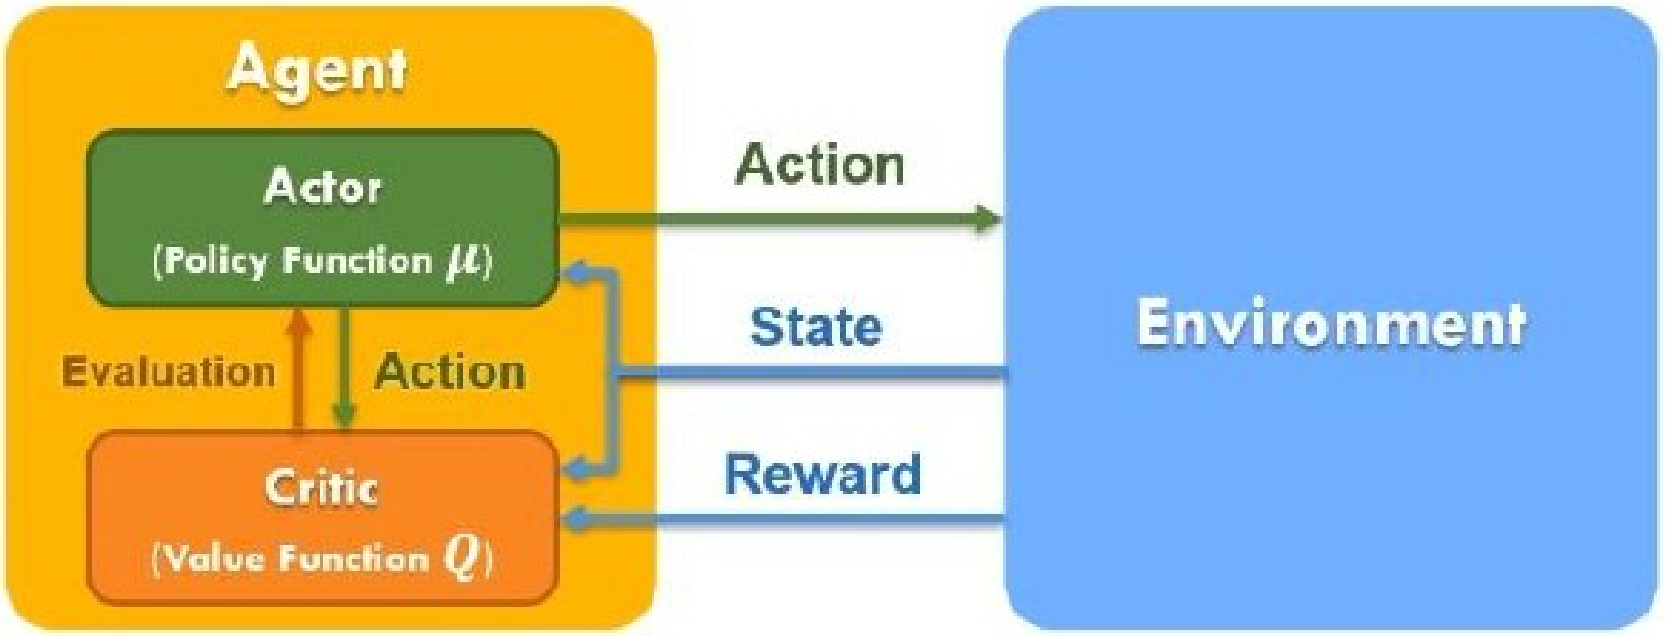
- 에이전트는 환경으로부터 기대 누적 보상을 최대화하여 결국 최적의 의사결정 순서를 학습한다.



강화학습

- 강화학습은 명시적인 목표 값을 정의하기 어려운 순차적 의사결정 문제에 대한 솔루션을 제공한다. 예를 들어 로봇 보행, 온라인 포트폴리오 재조정 등이 있다.

- 에이전트는 환경으로부터 기대 누적 보상을 최대화하여 결국 최적의 의사결정 순서를 학습한다.



강화학습을 활용한 포트폴리오 최적화

- 행동 at

- 시점 t에서 보유한 자산의 재조정된 '비율'이다. 이산적 행동을 사용하는 것은 행동 공간의 기하급수적 증가로 인해 대규모 포트폴리오에 일반화하기 어렵기 때문이다.

...	Sell 2 Asset A	Sell 1 Asset A	Hold Asset A	Buy 1 Asset A	Buy 2 Asset A	...

- 보상 rt

- 거래 비용이 적용된 상태에서 행동 at에 대한 리스크 조정 수익이다.

- 상태 st

- 시점 t까지의 과거 가격과 거래량과 같은 관찰을 통해서만 부분적으로 관찰 가능한 금융 상태이다.

- 즉, 부분적으로 관찰 가능한 마르코프 결정 프로세스 (POMDP)이다.

강화학습을 활용한 강화학습의 문제점

- 연속적인 행동 공간
- 느린 학습 속도
- 부분 관찰 가능성의 장기 의존성
- 강화 학습(RL)에서의 수렴 문제
- 3차원 데이터



강화학습을 활용한 강화학습의 문제점

- 연속적인 행동 공간: 심층 결정론적 정책 그래디언트법*(Deep Deterministic Policy Gradient)
- 느린 학습 속도: 비동기 학습 (Asynchronous Training)
- 부분 관찰 가능성의 장기 의존성: 트랜스포머 (Transformer)
- 강화 학습(RL)에서의 수렴 문제: 트랜스포머의 게이팅 레이어 (Gating Layer in Transformer)
- 3차원 데이터: 2D 상대 위치 인코딩 (2D Relative-positional Encoding)

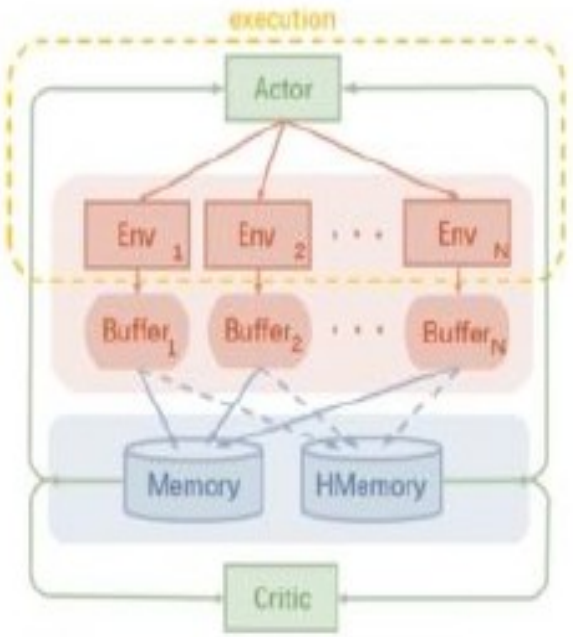


심층 결정론적 정책 경사법 (Deep Deterministic Policy Gradient)**

- 심층 결정론적 정책 그래디언트법 (Deep Deterministic Policy Gradient)
- 심층 신경망을 정책 함수 근사기로 사용하여 결정론적인 방식으로 연속적인 행동을 제공합니다. (Lillicrap et al., 2016)

$$a_t = \mu(s_t|\theta^\mu)$$

- 단일 액터와 그 환경 시뮬레이터를 사용하여 DDPG를 위한 비동기적 에피소드 학습 (Zhang et al. 2019)

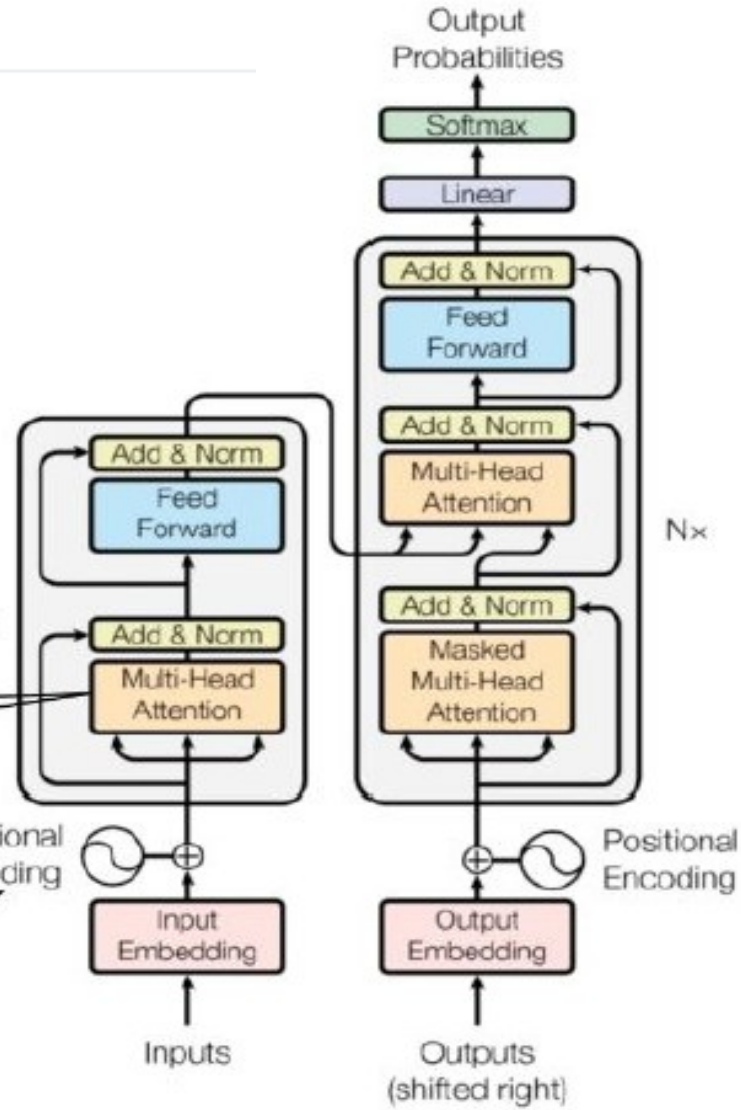


▢ 트랜스포머 (Transformer)**

▢ 장기 의존성에 대한 강력한 아키텍처로, 멀티헤드 셀프 어텐션(multi-head self-attention)과 절대적 위치 인코딩 (absolute positional encoding)으로 구성된다. (Vaswani et al. 2017)

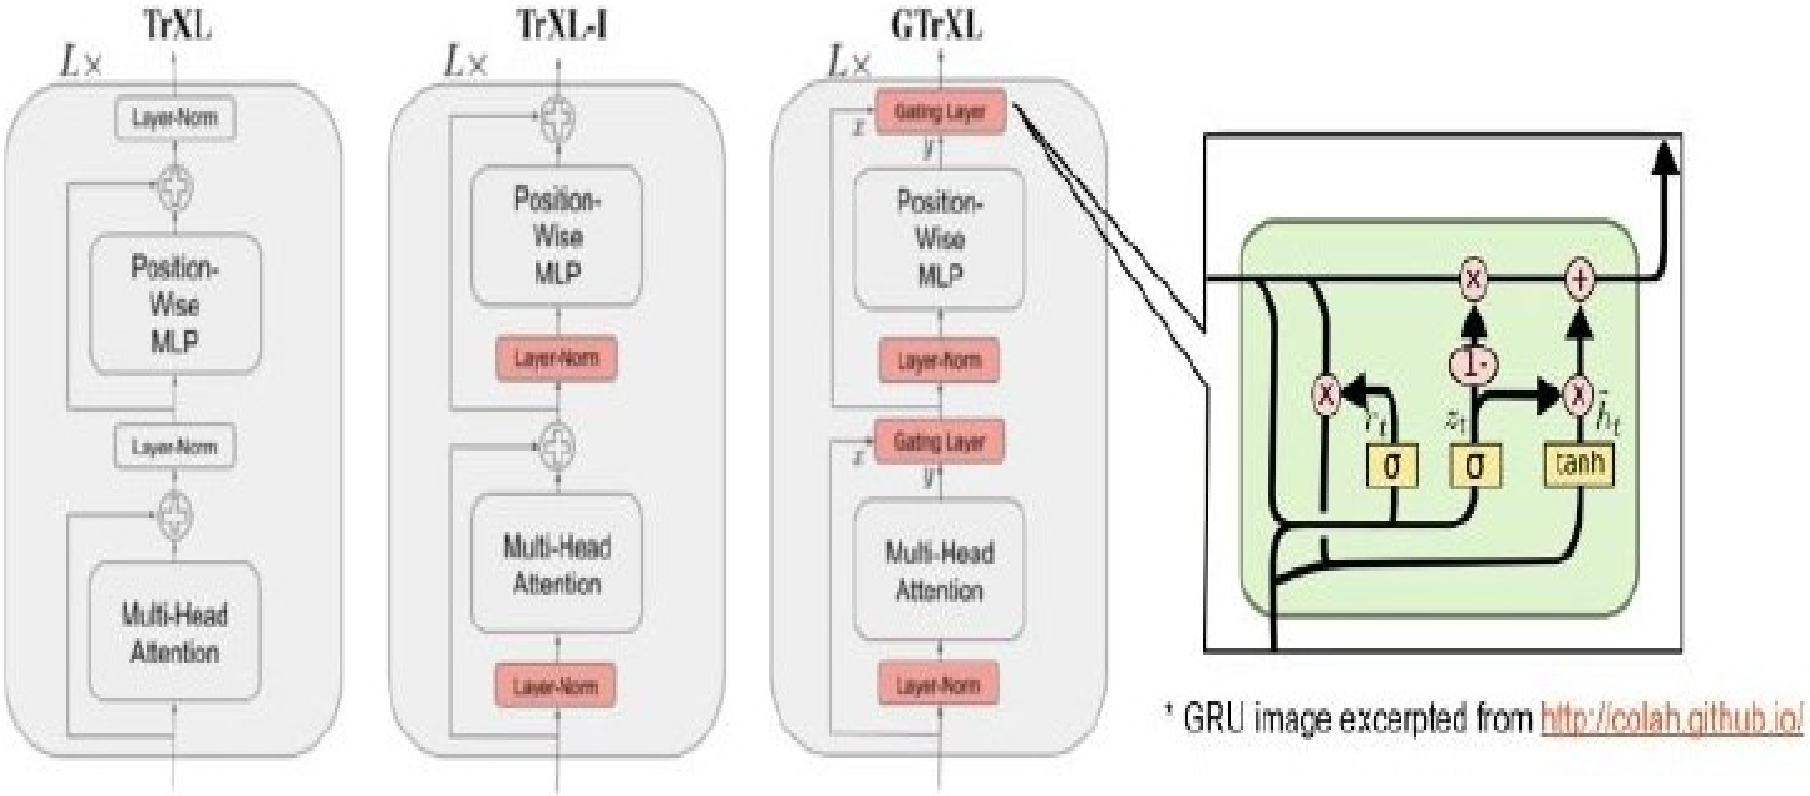
$$\text{Attention}(Q^h, K^h, V^h) = \text{Softmax}\left(\frac{Q^h K^{h\top}}{\sqrt{D_h}}\right) V^h$$

$$PE_{(pos,2i)} = sin(pos/10000^{2i/d_{\text{model}}})$$
$$PE_{(pos,2i+1)} = cos(pos/10000^{2i/d_{\text{model}}})$$



게이티드 트랜스포머 (Gated Transformer)

- RL 환경에서 레이어 재배열(layer reordering)과 "GRU 유형" 게이팅 레이어("GRU-type" gating layers)로 안정화된 트랜스포머 구조를 사용한다 (Cho et al., 2014; Parissotto et al., 2019)

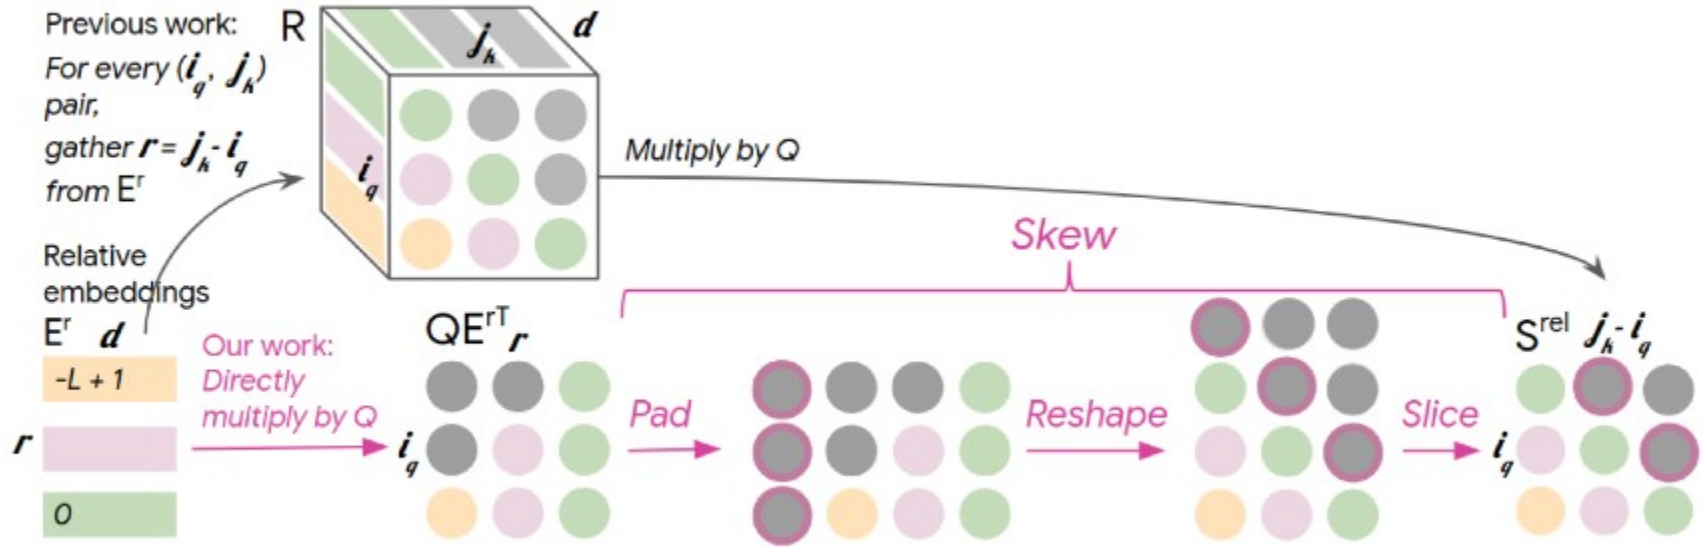


상대적 위치 인코딩 (Relative Positional Encoding)

- 학습 가능한 상대적 위치 임베딩은 쿼리와 키 위치 쌍 사이의 거리에 대한 정보를 어텐션에 제공한다. (Shaw et al., 2018)

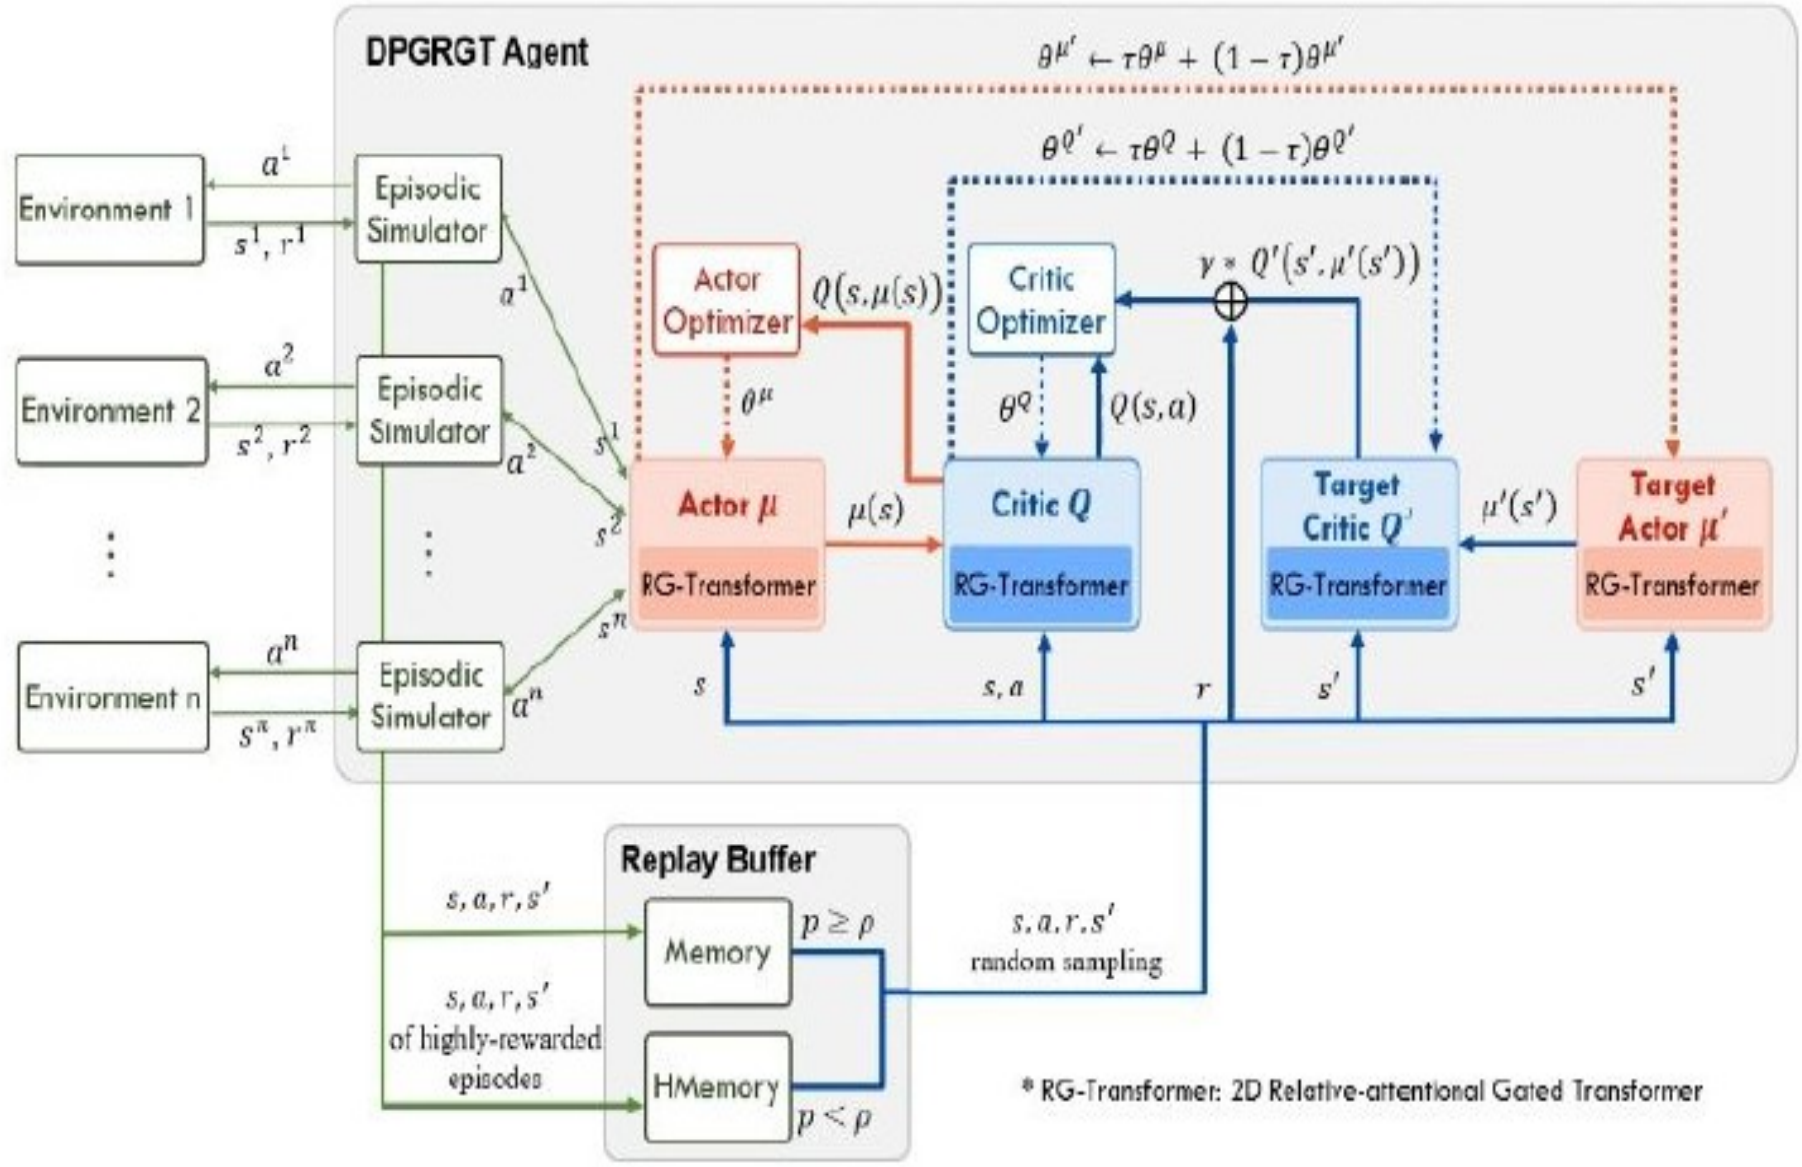
$$\text{RelativeAttention} = \text{Softmax}\left(\frac{QK^{\top} + S^{rel}}{\sqrt{D_h}}\right)V.$$

- 상대적 인코딩을 위한 메모리 효율적인 계산은 "skewing" 절차를 통해 이루어진다. (Huang et al., 2018)

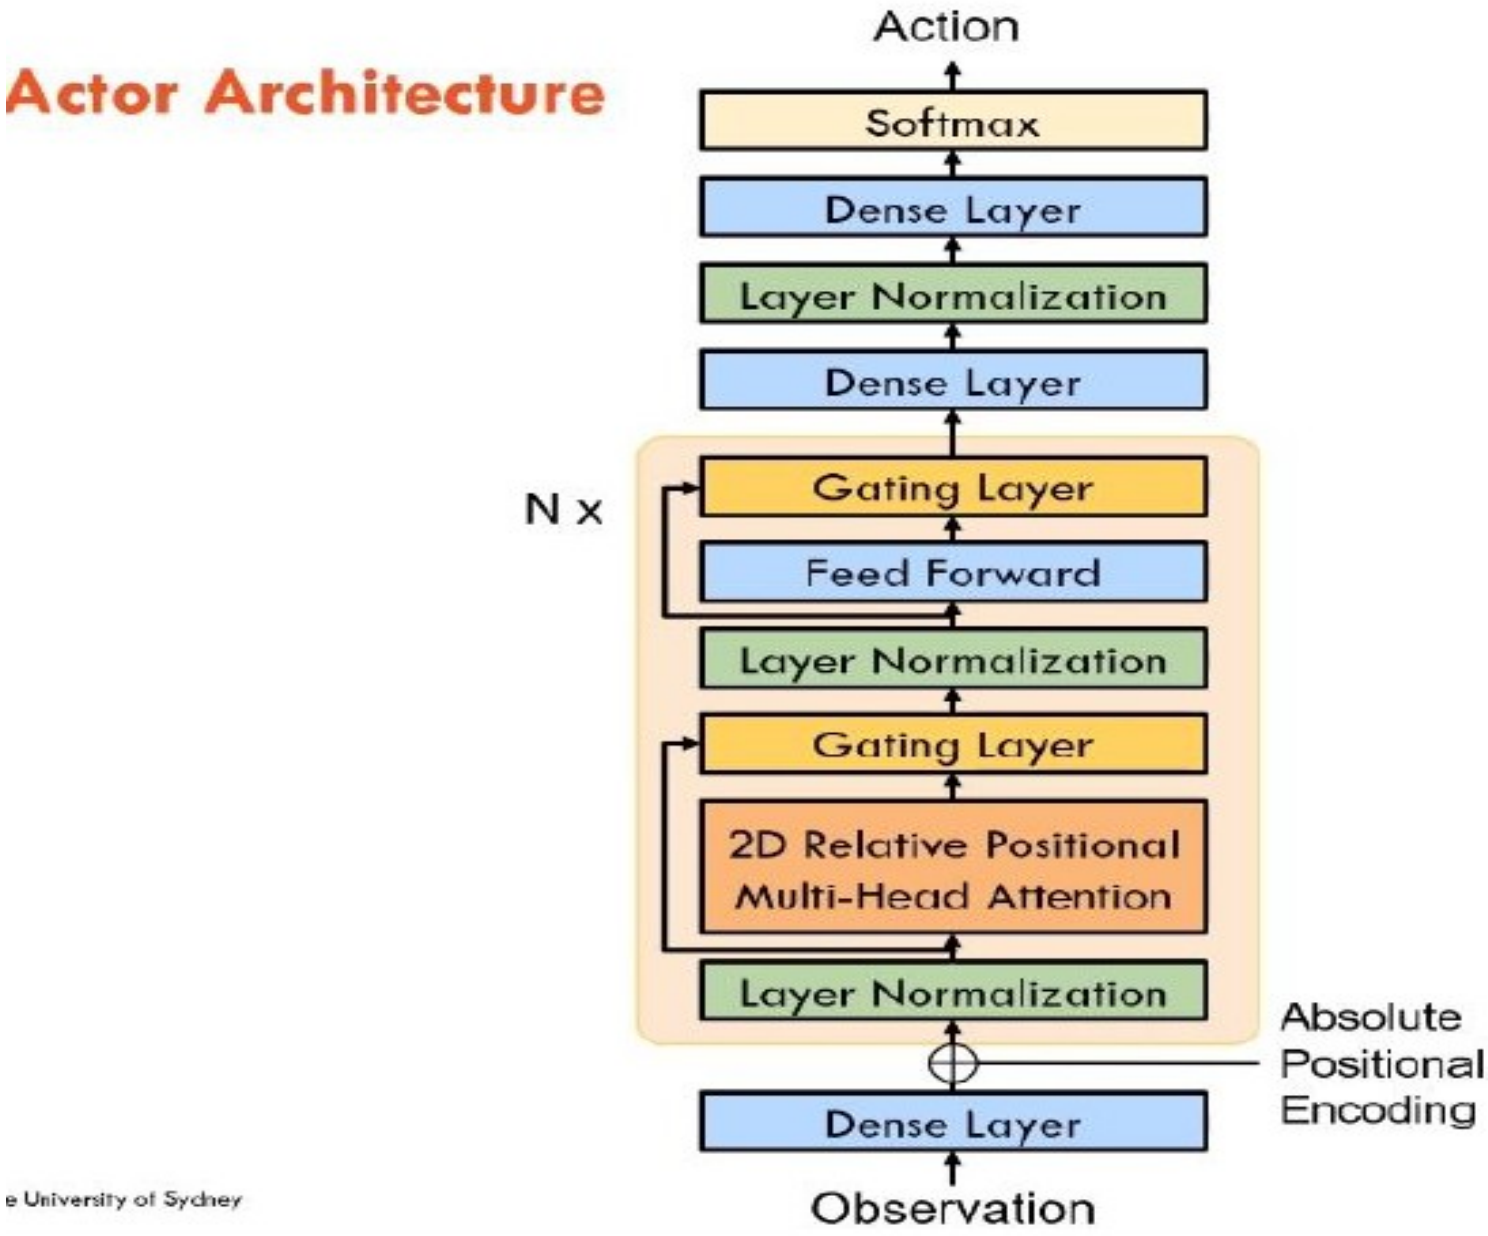


전체 구조

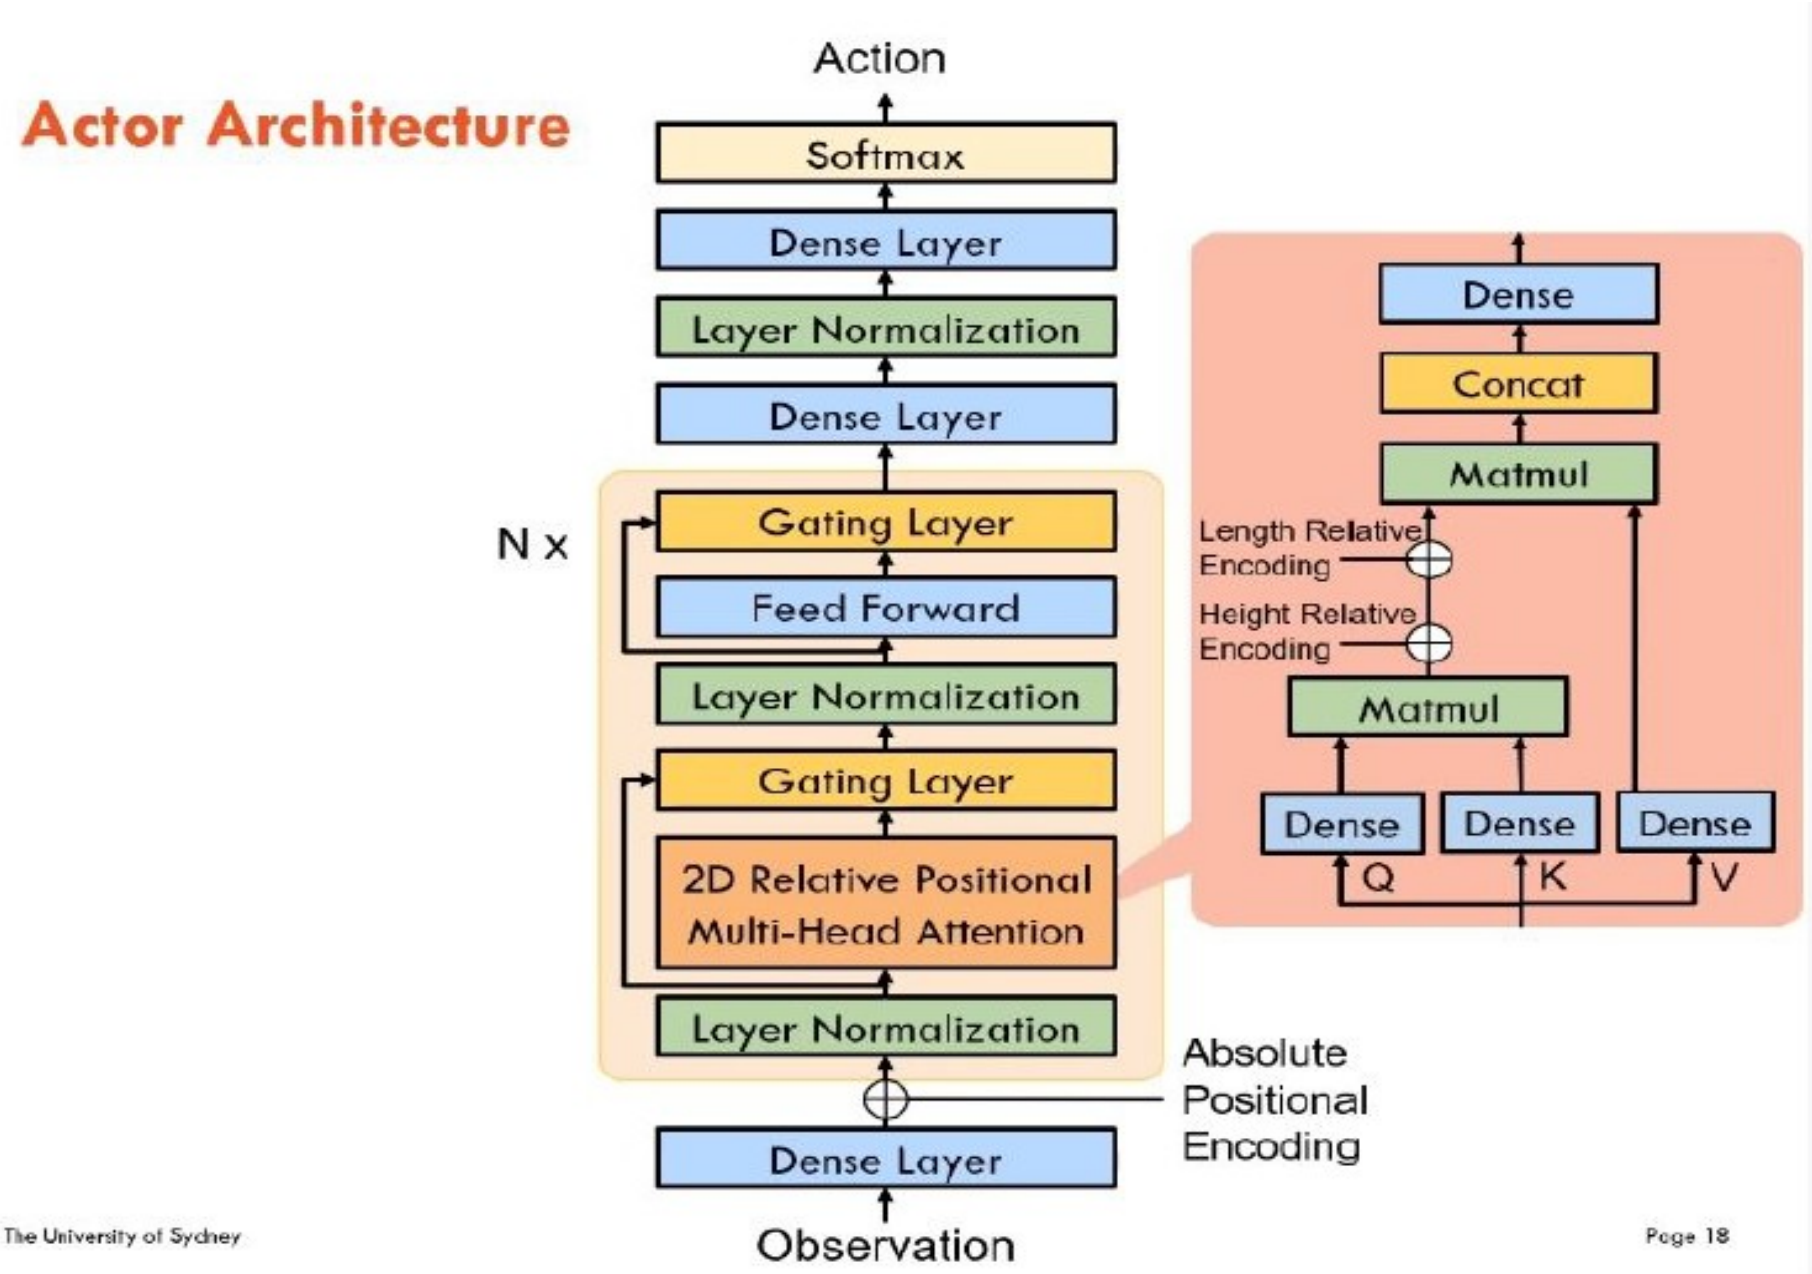
- DPGRGT


DPGRGT Agent
$\theta^{\mu'} \leftarrow \tau\theta^{\mu} + (1-\tau)\theta^{\mu'}$
$\theta^{Q'} \leftarrow \tau\theta^{Q} + (1-\tau)\theta^{Q'}$
Environment 1
Environment 2
Environment n
a^1
s^1, r^1
a^2
s^2, r^2
a^n
s^n, r^n
Episodic Simulator
Episodic Simulator
Episodic Simulator
a^1
a^2
a^n
s^1
s^2
s^n
Actor Optimizer
$Q(s,\mu(s))$
Critic Optimizer
$\gamma * Q'(s', \mu'(s'))$
θ^{μ}
θ^{Q}
$Q(s,a)$
Actor μ
RG-Transformer
$\mu(s)$
Critic Q
RG-Transformer
Target Critic Q'
RG-Transformer
$\mu'(s')$
Target Actor μ'
RG-Transformer
s
s, a
r
s'
s'
Replay Buffer
s, a, r, s'
Memory
$p \geq \rho$
s, a, r, s' of highly-rewarded episodes
HMemory
$p < \rho$
s, a, r, s' random sampling
* RG-Transformer: 2D Relative-attentional Gated Transformer

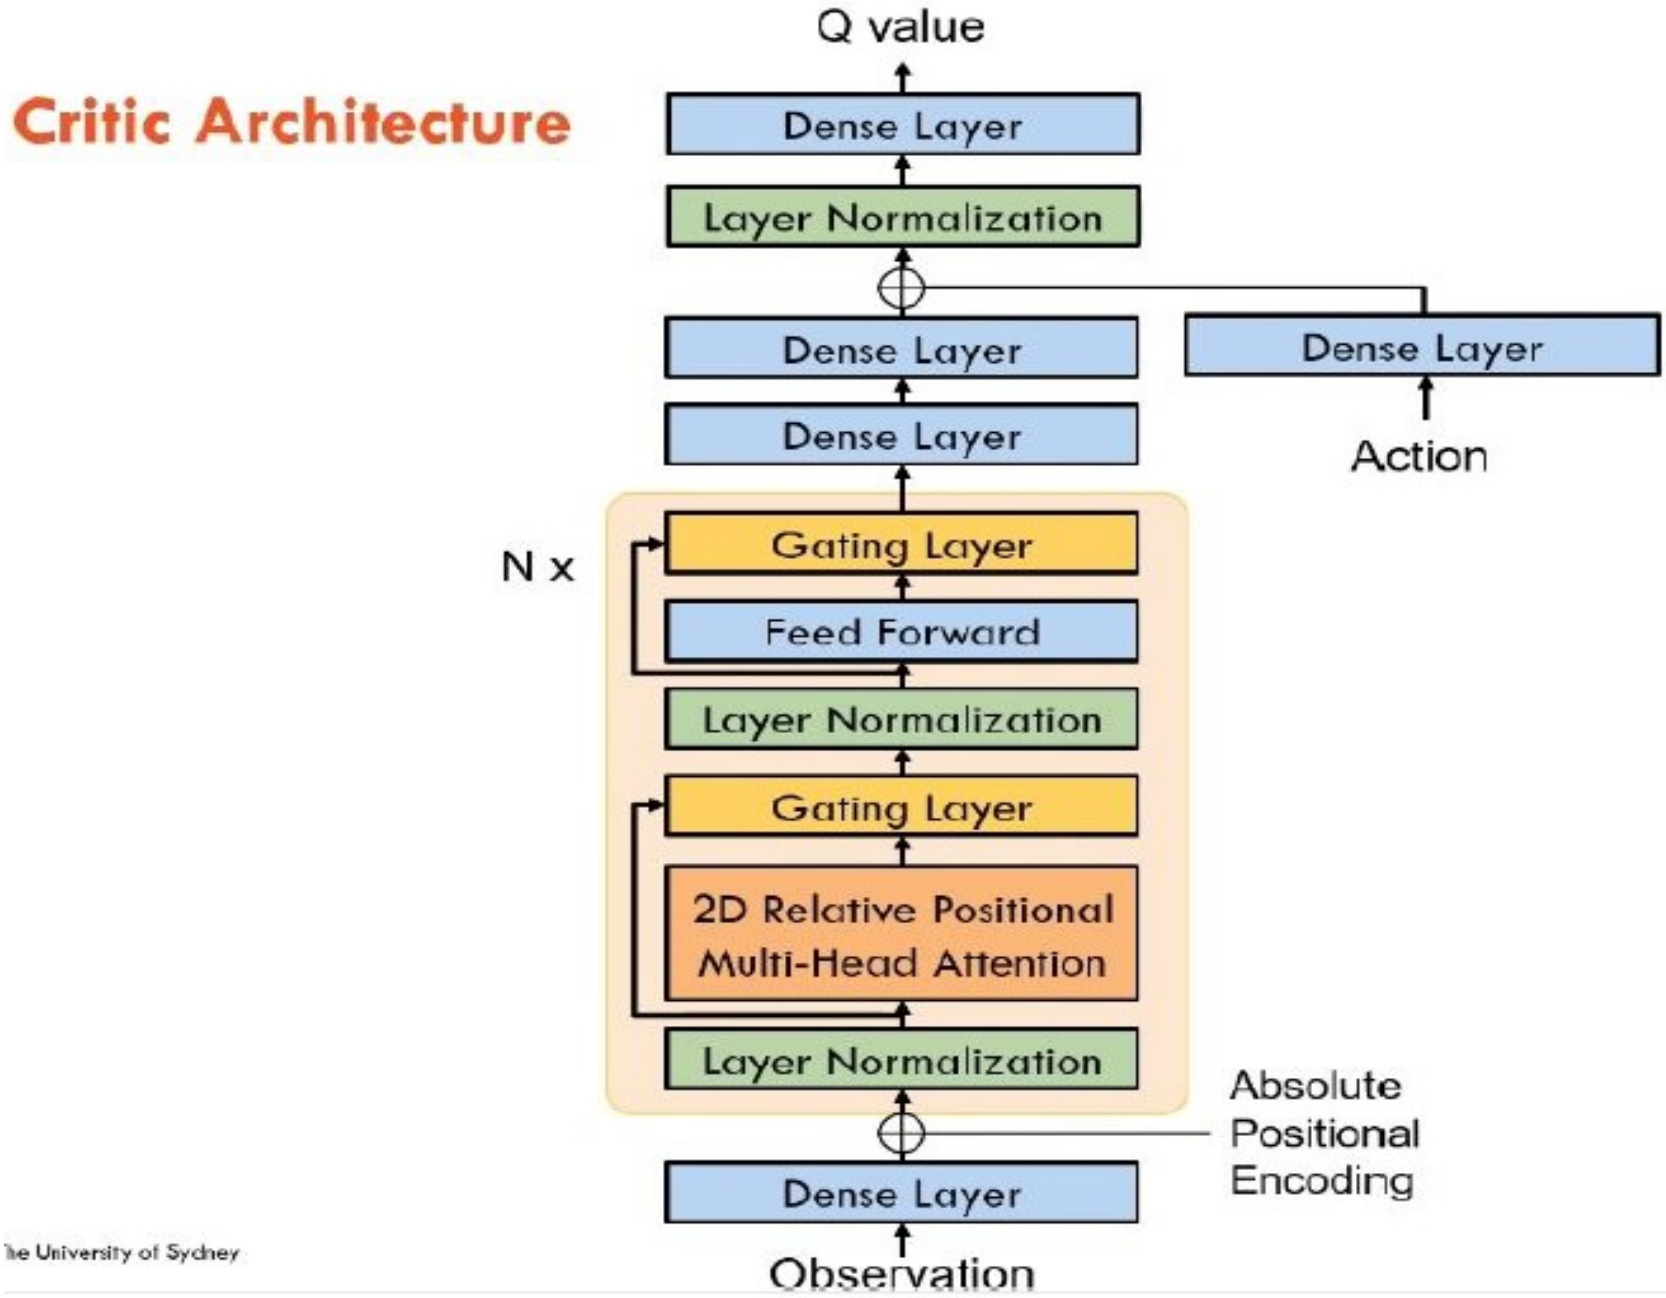
Actor 구조


Actor Architecture
Action
Softmax
Dense Layer
Layer Normalization
Dense Layer
N x
Gating Layer
Feed Forward
Layer Normalization
Gating Layer
2D Relative Positional Multi-Head Attention
Layer Normalization
Absolute Positional Encoding
Dense Layer
Observation
e University of Sydney

Actor 구조


Actor Architecture
Action
Softmax
Dense Layer
Layer Normalization
Dense Layer
N x
Gating Layer
Feed Forward
Layer Normalization
Gating Layer
2D Relative Positional Multi-Head Attention
Layer Normalization
Absolute Positional Encoding
Dense Layer
Observation
Dense
Concat
Matmul
Length Relative Encoding
Height Relative Encoding
Matmul
Dense
Dense
Dense
Q
K
V

Critic 구조


Critic Architecture
Q value
Dense Layer
Layer Normalization
Dense Layer
Dense Layer
Dense Layer
Action
N x
Gating Layer
Feed Forward
Layer Normalization
Gating Layer
2D Relative Positional
Multi-Head Attention
Layer Normalization
Absolute
Positional
Encoding
Dense Layer
Observation

실험

□ 데이터

Nine assets of *Dow Jones* companies representing each sector

- Industrials (MMM)
- Financials (JPM)
- Consumer Services (PG)
- Technology(AAPL)
- Health Care (UNH)
- Consumer Goods (WMT)
- Oil & Gas (XOM)
- Basic Materials (DD)
- Telecommunications (VZ)

OHLC prices and **trading volume** data collected from *Yahoo Finance*

- **Train:** 2000.01.01 ~ 2017.12.31
- **Test:** 2018.01.01 ~ 2020.04.31

환경 – 관찰과 보상

- 관찰 (Observation)
  - 부분적으로 관찰 가능한 상태: 50일간의 자산 이력 데이터
  - 로그 차분된 가격과 과거 행동(가중치)을 포함한 거래량
  - 에피소드당 최대 50일

- 보상 (Reward)
  - 소르티노 비율 (Sortino Ratio): 하락 변동성을 고려한 리스크 조정 수익 측정 지표

$$SortinoRatio = \frac{R_p - R_f}{\sigma_p}$$

- 여기서 Rp는 기대 수익률, R_f는 무위험 수익률(여기서는 0으로 설정됨), σp는 음수 수익률의 표준 편차입니다.

환경 - 고려된 제약 조건 (Environment - Constraints Considered)

- 거래 수수료 (Transaction Fee)

- 20 베이시스 포인트 (0.2%)

- 슬리피지 (Slippage)

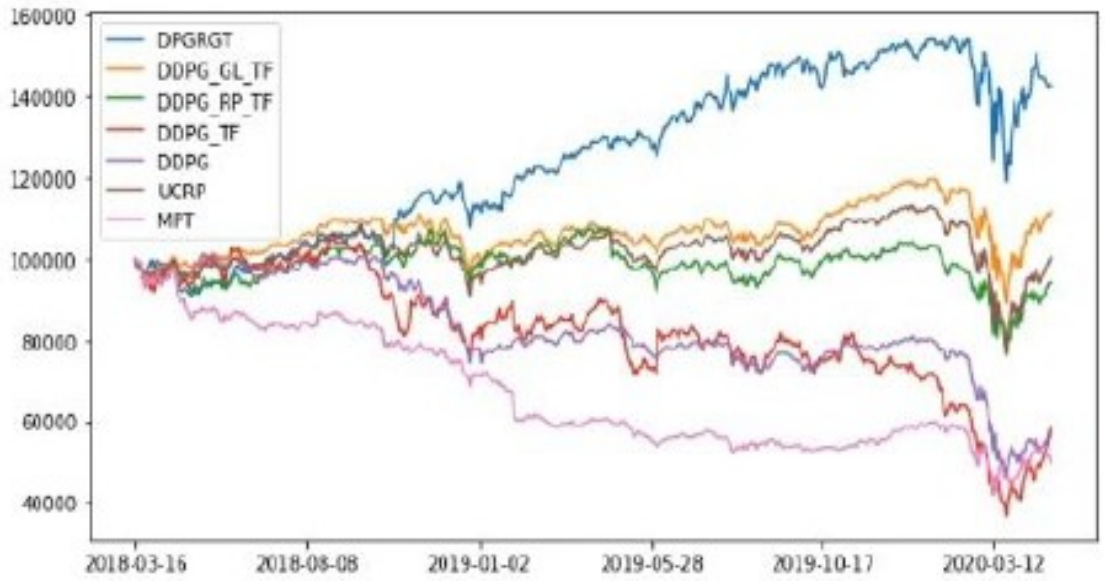
- 매수자와 매도자 간의 호가 차이(bid-ask spread)의 절반, 즉 매수 호가와 매도 호가 간의 가격 차이

- 비례적 호가 차이(spread)는 일일 종가 로그 가격(c)과 일일 고가 및 저가 로그 가격의 평균(η)을 사용하여 추정되었다 (Abdi and Ranaldo, 2017).

$$Spread = 2\sqrt{E[(c_t - \eta_t)(c_t - \eta_{t+1})]}$$

포트폴리오 결과

ㅁ 모델 비교



	Cumulative Return (%)	Annualized Sharpe Ratio
DPGRGT (Ours)	43.16	0.6418
DDPG_GL_TF	11.93	0.2813
DDPG_RP_TF	-5.45	-0.1343
DDPG_TF	-41.71	-0.8191
DDPG	-42.91	-1.2194
UCRP	0.53	0.0125
MPT	-50.07	-1.5840

- **MPT**: Modern Portfolio Theory strategy (baseline)
- **UCRP**: Uniform Constant Rebalancing Portfolio strategy (baseline)
- **DDPG_TF**: DDPG with Transformer
- **DDPG_RP_TF**: DDPG with 2D Relative-attentional Transformer
- **DDPG_GL_TF**: DDPG with Gated Transformer
- **DPGRGT**: Deterministic Policy Gradient with 2D Relative-attentional Gated Transformer

보완점

- 기여 (Contributions)

- 포트폴리오 최적화를 위한 강화 학습에서 트랜스포머를 채택한 사례이며, 실험에서 2D 상대적 어텐션 및 게이팅 메커니즘을 사용한 베이스라인 모델을 능가했다.
- 이전 연구들이 고려하지 않았던 거래 수수료와 슬리피지와 같은 현실적인 제약 조건을 통합했다 (Meng et al., 2019).

- 향후 과제 (Future Works)

- 모델의 어텐션 가중치를 사용하여 모델을 해석하는 것
- 멀티-GPU 환경에서 다양한 유형의 자산을 대상으로 테스트 수행