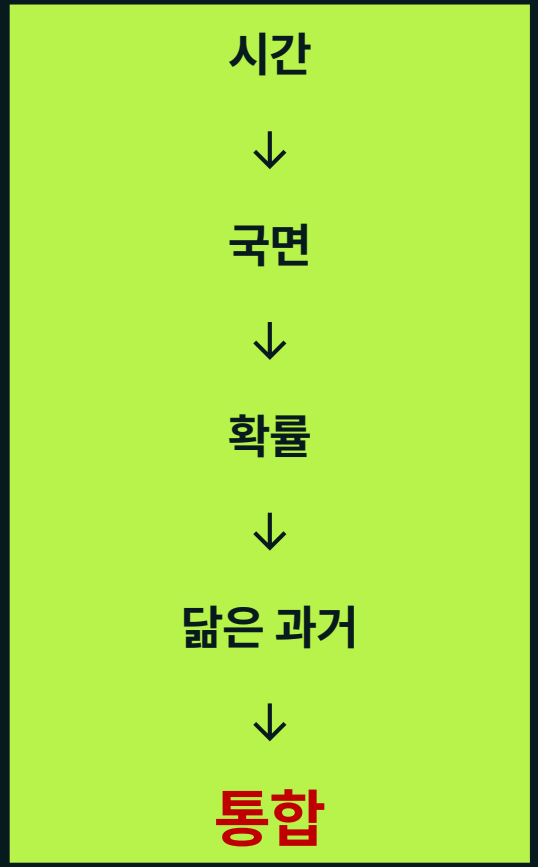
국면 기반 TDF 자산배분 레벨별 종합 강의

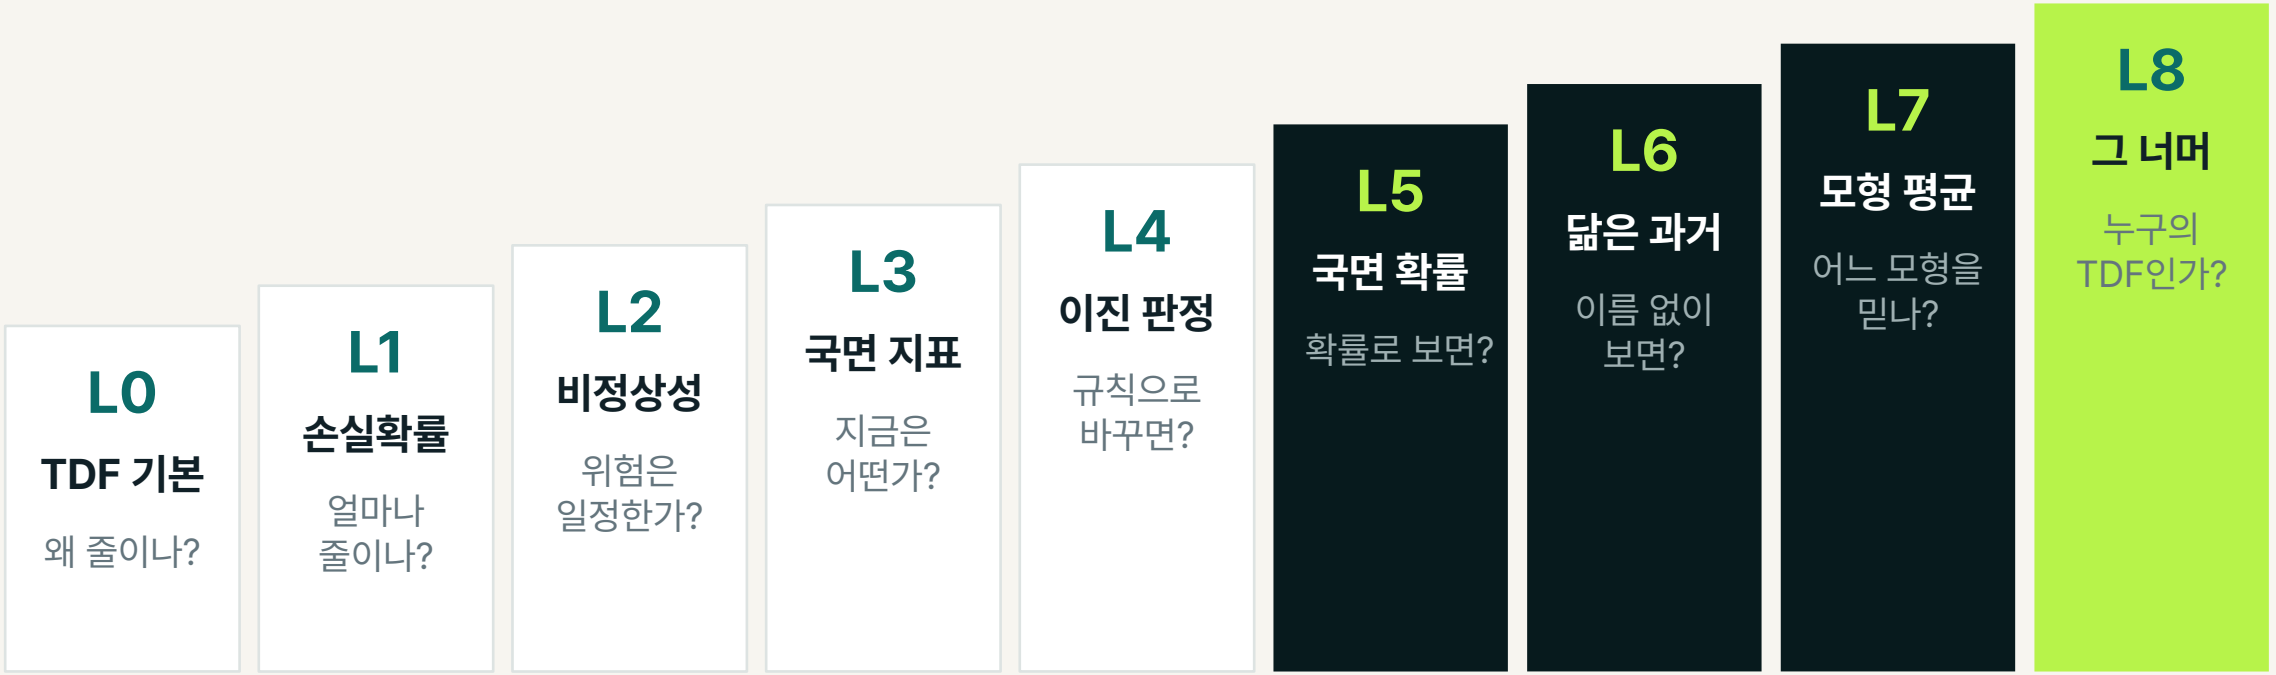
시간표에서 출발해 국면 확률과 모형 평균까지 한 단계씩 올라간다



손실확률에서 모형 평균까지

아홉 단계로 국면 기반 TDF의 설계를 쌓아 올립니다

각 레벨은 앞 레벨이 남긴 한계 하나를 풀면서 올라간다



L0~L2는 '왜', L3~L4는 '무엇으로', L5~L8은 '어떻게 더 잘'에 답합니다

L0

TDF와 글라이드패스

TDF가 무엇이고, 왜 은퇴가 가까울수록 주식 비중을 줄이는지부터 정리한다

TDF는 은퇴 시점에 맞춰 위험자산 비중을 자동으로 줄이는 펀드입니다

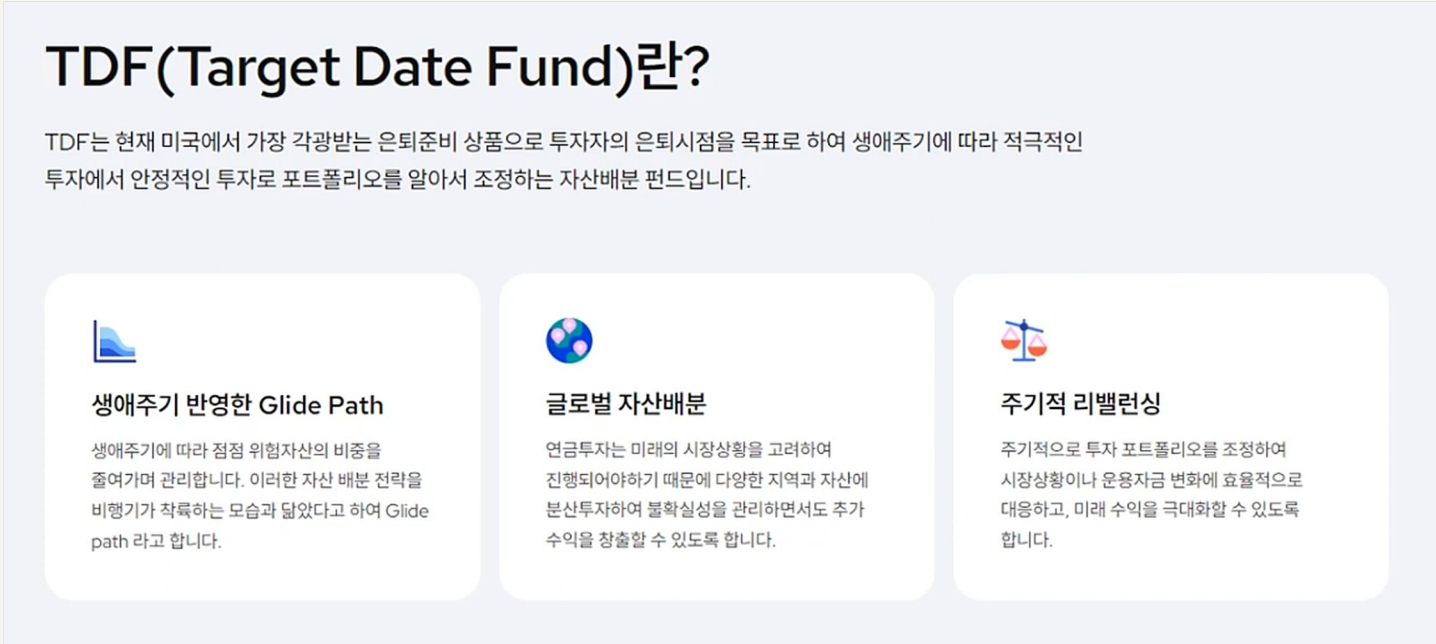
Target-Date Fund — 목표 연도(예: 2045)를 정하면 배분이 시간표대로 바뀐다

기본 지식

TDF의 세 요소

- 글라이드패스
- 글로벌 분산
- 주기적 리밸런싱

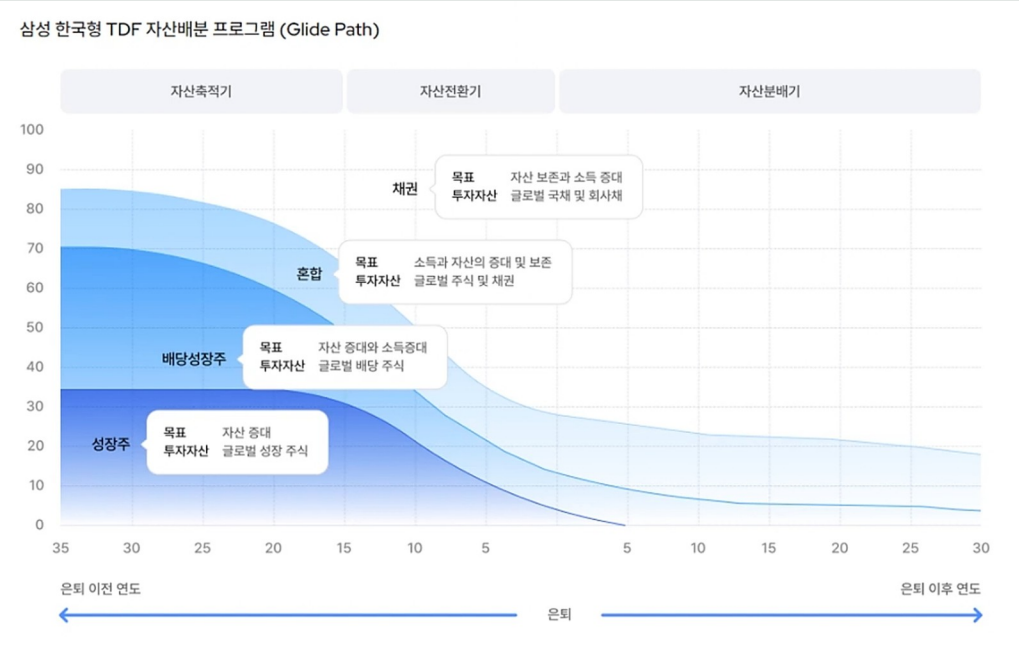
핵심은 비중의 경로

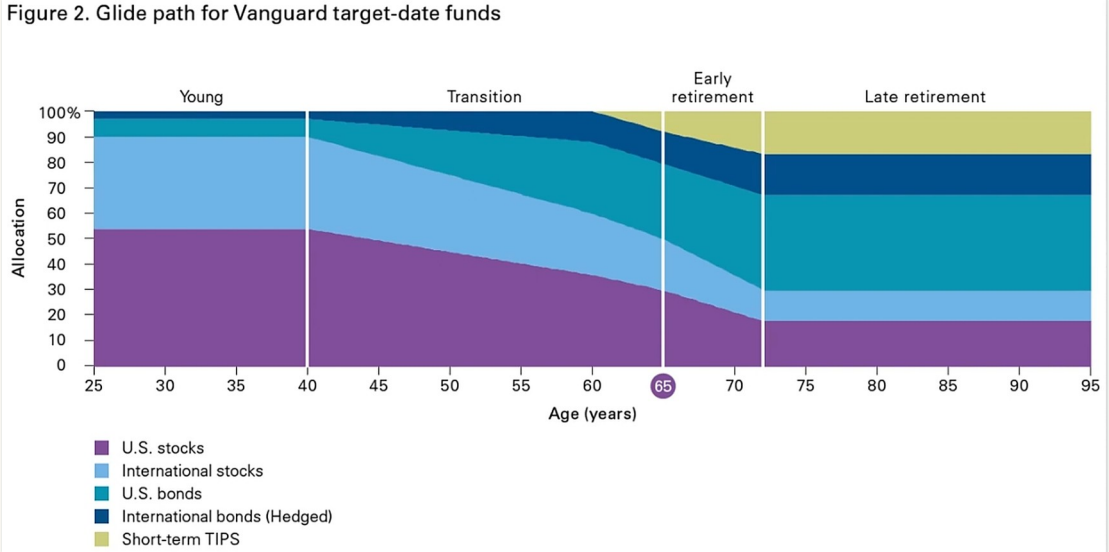


글라이드패스(glide path)는 남은 기간별 위험자산 비중표입니다

실제 글라이드패스는 축적기·전환기·분배기를 거치며 주식을 줄입니다

왼쪽은 삼성 한국형 TDF(은퇴 35년 전~은퇴 후 30년), 오른쪽은 Vanguard TDF의 연령별 자산 구성





삼성은 주식 약 85%에서 20% 이하로, Vanguard는 90%(40세)에서 30%(72세 이후)로 낮춥니다

모양은 비슷하지만 어디서 얼마나 줄이는지는 운용사가 정합니다

같은 은퇴 시점이라도 운용사마다 주식 비중이 크게 다릅니다

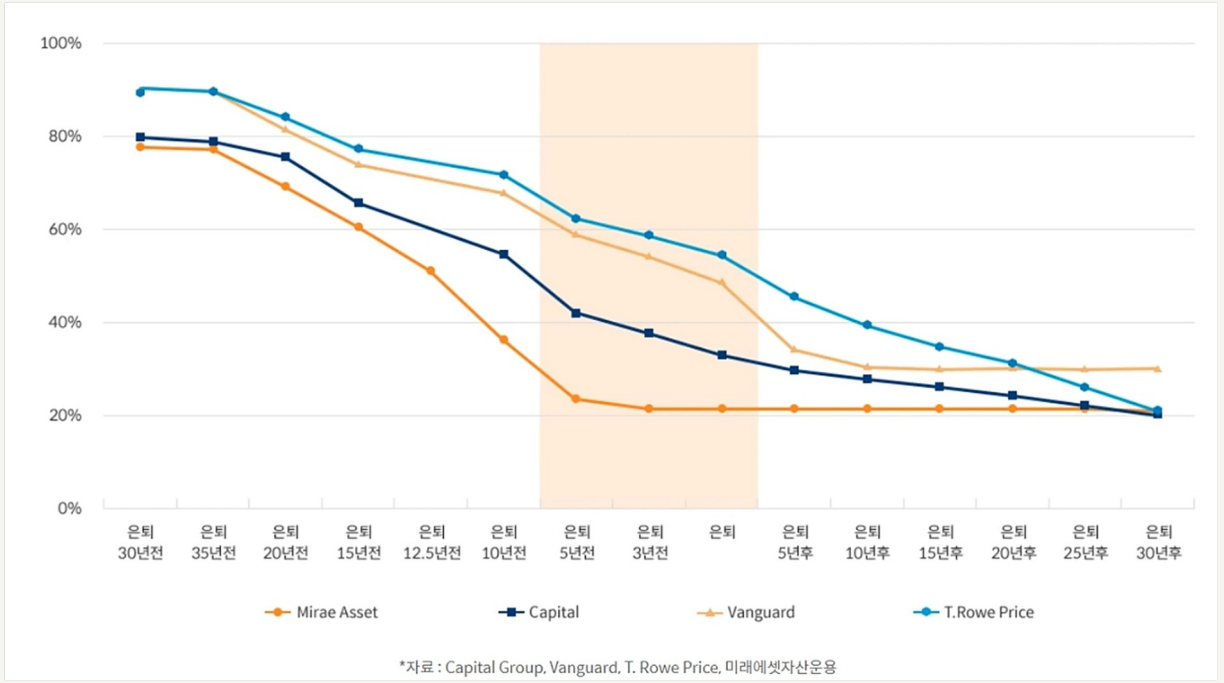
주요 TDF 운용사의 자산배분곡선 — 음영은 은퇴 5년 전부터 은퇴까지

은퇴 시점 주식 비중

세 운용사

- 미래에셋 21%
- Capital 33%
- T. Rowe 55%

경로 선택 기준이 필요



이 강의는 그 기준을 손실확률에서 시작해 국면과 모형 불확실성까지 넓힙니다

젊을수록 주식을 더 담는 근거는 인적자본입니다

인적자본(human capital) = 앞으로 노동으로 벌 미래 소득의 현재가치

젊을 때

인적자본이 크다

- 미래 소득이 채권처럼 작동한다
- 금융자산은 주식을 더 담는다
- 만회할 시간이 길다

공격적 배분이 균형

은퇴가 가까울 때

인적자본이 줄어든다

- 완충이던 미래 소득이 사라진다
- 금융자산이 안전자산을 채운다
- 만회할 시간이 짧다

방어적 배분이 균형

총자산 = 인적자본 + 금융자산 — 인적자본이 줄면 금융자산이 위험을 덜 져야 합니다

기간별 최적 주식비중을 이으면 그대로 글라이드패스가 됩니다

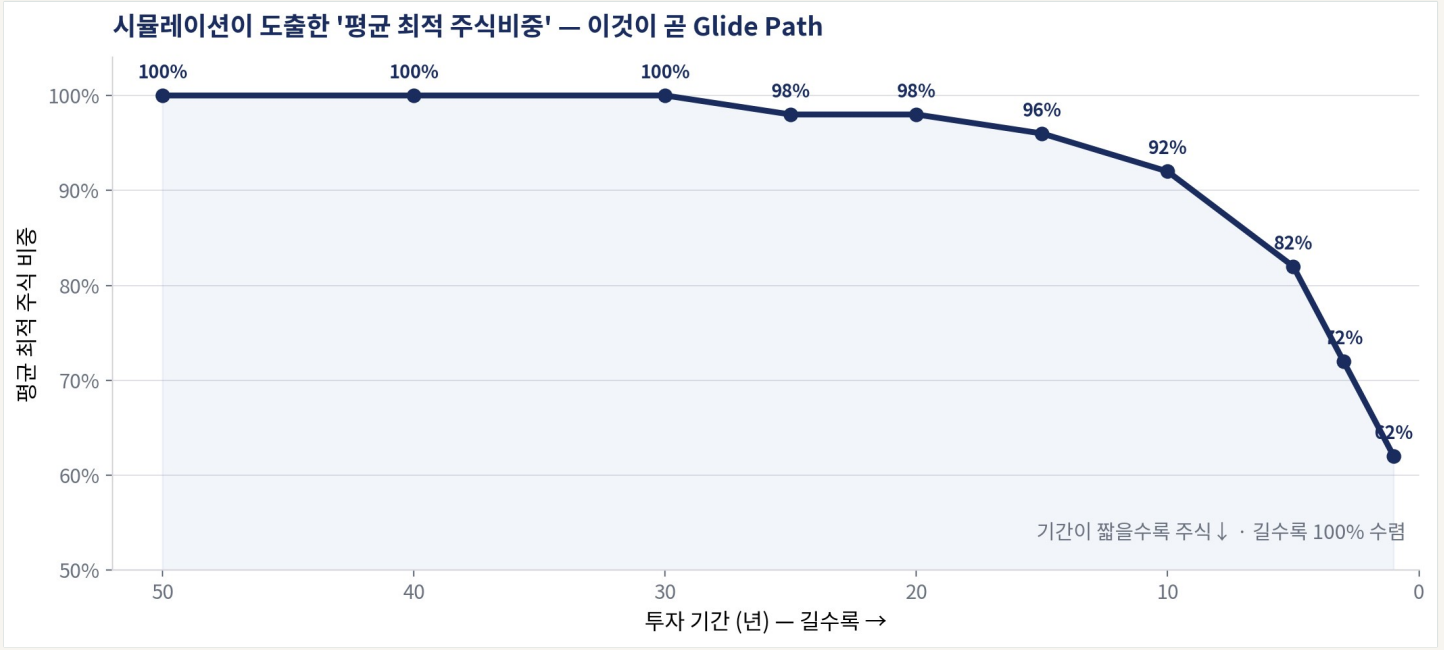
미국 주식·채권 11개 배분 · 1995~2024 분포 · 몬테카를로와 부트스트랩의 평균 최적 비중

평균 최적 주식비중

길수록 높다

- 1년이면 62%
- 10년이면 92%
- 30년 이상 100%

하위 10% 기준도 같다



TDF는 임의의 상품이 아니라 기간별 최적 배분을 자동화한 도구입니다

기존 글라이드패스는 두 가정 위에 서 있습니다

Kritzman(2017)의 문제 제기 — 첫째 가정은 받아들이고 둘째 가정을 고친다

가정 ① · 타당하다

시간이 손실 노출을 정한다

- 기간이 짧으면 노출이 크다
- 만회할 시간도 줄어든다

안전자산으로 옮길 근거

가정 ② · 경험과 어긋난다

위험은 기간 내내 일정하다

- 장기 10%면 매 시기 10%?
- 실제 변동성은 출렁인다

어느 정도 예측은 된다

시간 효과는 그대로 두고 '위험이 일정하다'는 가정을 고치는 것이 이 강의 전체의 출발점입니다

L1

손실확률로 설계한 글라이드패스

목표 손실확률을 고정하면 위험자산 비중이 식 하나로 정해진다

손실확률은 기간별로 더할 수 있는 연속복리 수익률로 계산합니다

기본 지식 — 로그수익률은 더하면 기간 누적 수익률이 되므로 T년 분포를 바로 구할 수 있다

로그수익률과 T년 누적 분포

$$\underbrace{r_t = \ln(1 + R_t)}_{\text{연속복리(로그) 수익률}} \qquad \sum_{t=1}^{T} r_t \sim \mathcal{N}\Big(\underbrace{\mu T}_{\text{누적 평균}} , \underbrace{\sigma^2 T}_{\text{누적 분산}} \Big)$$

평균

기간 T에 비례

표준편차

기간의 제곱근에 비례

손실 기준 L

ln(1+L)로 비교

평균과 위험이 다른 속도로 자라는 것이 시간 효과의 정체입니다

Equation 1은 표준화한 손실 기준을 정규분포 누적확률에 넣는 식입니다

투자기간 말 수익률이 손실 기준 L보다 나쁠 확률 — L = 0이면 원금 손실 확률

Equation 1 · 투자기간 T의 손실확률

$$\underbrace{P}_{\text{손실확률}} = \underbrace{N}_{\text{정규 누적분포}}\left[\frac{\overbrace{\ln(1+L)T}^{\text{손실 기준}} - \overbrace{\mu T}^{\text{누적 기대수익}}}{\underbrace{\sigma\sqrt{T}}_{\text{누적 표준편차}}}\right]$$

제곱근 법칙 — z값은 커지고 연율 위험은 줄어든다

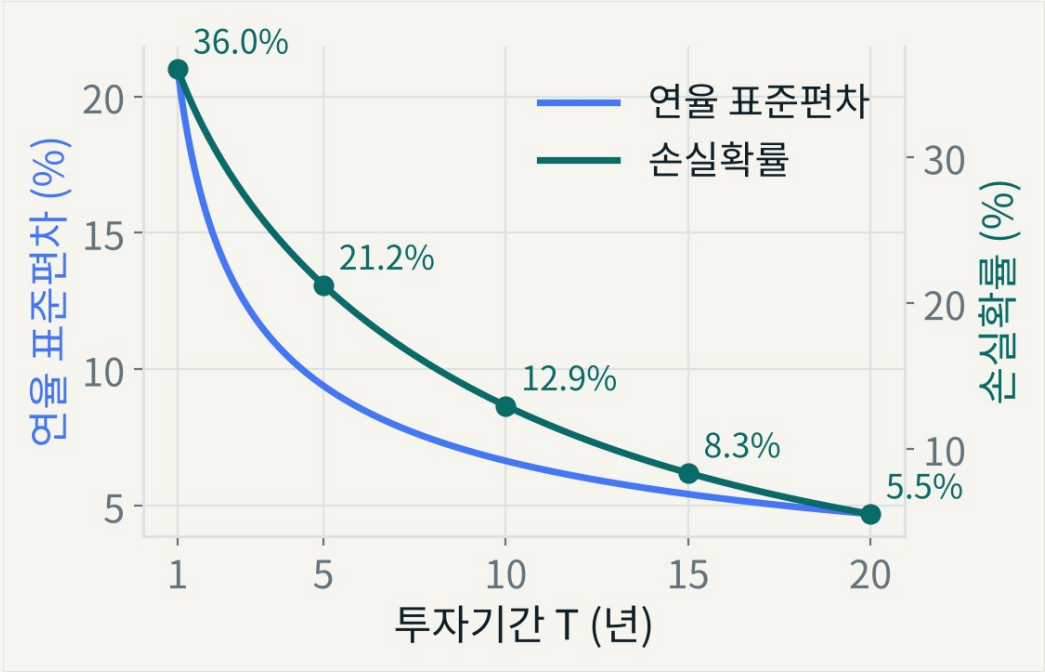
$$\frac{\mu T}{\sigma\sqrt{T}} = \frac{\mu}{\sigma}\sqrt{T} \qquad \sigma_{\text{연율}}(T) = \frac{\sigma\sqrt{T}}{T} = \frac{\sigma}{\sqrt{T}}$$

같은 자산이라도 1년과 20년의 손실확률은 전혀 다릅니다

투자기간이 짧아질수록 연율 위험과 손실확률이 함께 커집니다

Exhibit 1 · 기대수익 7.5% · 표준편차 21% · 손실 기준 L = 0

투자기간	연율 표준편차	손실확률
20년	4.7%	5.5%
15년	5.4%	8.3%
10년	6.6%	12.9%
5년	9.4%	21.2%
1년	**21.0%**	**36.0%**



1년 손실확률(36.0%)은 20년(5.5%)의 6.5배 — 초기 공격·만기 방어의 근거입니다

다만 손실의 '확률'이 줄어도 손실의 '크기'는 줄지 않습니다

시간 분산(time diversification) 논쟁 — Exhibit 1은 연율 기준이라는 점을 함께 읽는다

표가 보여 주는 것

연율 위험과 손실확률

- 기간이 길수록 둘 다 준다
- 장기 투자자가 위험을 더 진다

손실 가능성은 줄어든다

같은 분포

표가 숨기는 것

누적 금액 위험

- 누적 표준편차는 계속 커진다
- 한 번 잃으면 금액이 크다

손실 크기는 따로 본다

TDF는 손실확률을 관리 지표로 택한 설계입니다 — 손실 크기는 별도로 점검해야 합니다

안전자산을 늘리면 손실확률에 서로 반대인 두 효과가 생깁니다

Equation 2 — Equation 1의 μ와 σ를 위험·안전 두 자산 포트폴리오 값으로 바꾼다

Equation 2 · 두 자산 포트폴리오의 손실확률

$$P = N\left[\frac{\ln(1+L)\,T - \left(\mu_R \underbrace{W_R}_{\text{위험자산 비중}} + \underbrace{\mu_S}_{\text{안전자산 수익}} (1-W_R)\right)T}{\sigma_R W_R \sqrt{T}}\right]$$

효과 ① 위험 축소

분모가 줄어 손실이 준다

효과 ② 기대수익 축소

분자가 0쪽으로 가 손실이 는다

표준편차만 맞추면 부족합니다 — 손실확률을 직접 맞춰야 합니다

목표 손실확률을 정하면 위험자산 비중이 식 하나로 결정됩니다

Equation 3 — Equation 2를 위험자산 비중에 대해 푼다 (도출은 워크북 W1-2)

Equation 3 · 손실확률을 고정하는 위험자산 비중

$$\underbrace{W_R}_{\text{위험자산 비중}} = \frac{\ln(1+L)\,T - \mu_S T}{\underbrace{Z}_{\text{목표 손실확률의 z값}}\,\sigma_R\sqrt{T} + \mu_R T - \mu_S T}$$

목표 손실확률 → 표준정규 z값

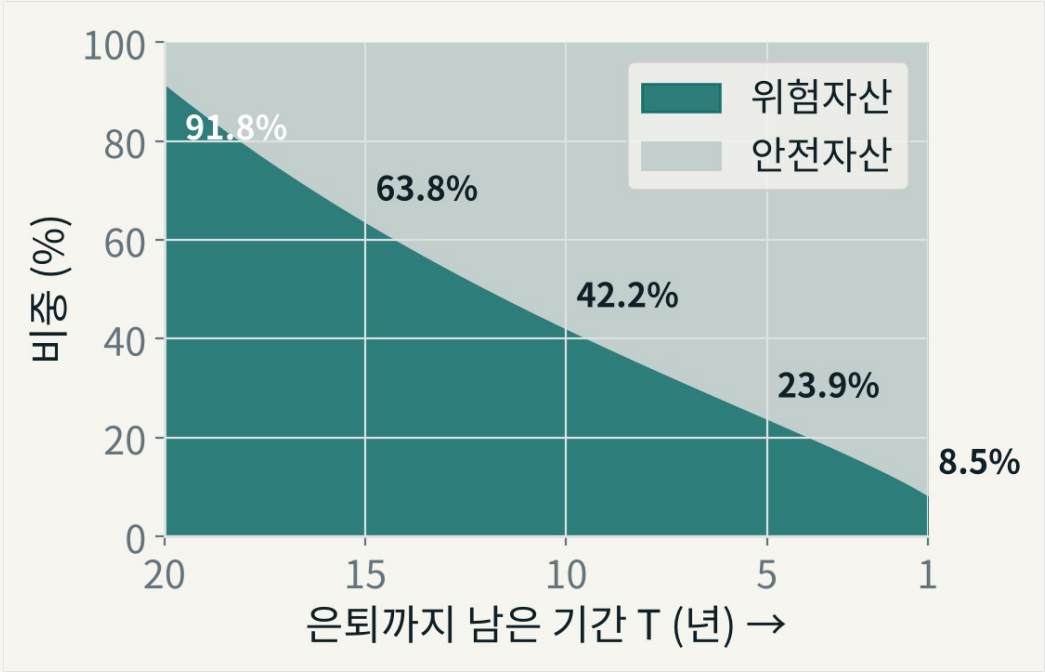
$$P^* = 5\% \;\Rightarrow\; Z = N^{-1}(0.05) = -1.645$$

z는 손실확률과 일대일로 대응하므로, 목표 확률만 정하면 휴리스틱 없이 비중표가 나옵니다

손실확률 5% 제약이 91.8%에서 8.5%로 내려가는 글라이드패스를 만듭니다

Exhibit 3 · 위험자산 7.5%·21%, 안전자산 2.5% 확정 · Z = −1.645 · L = 0

투자기간	위험자산	안전자산
20년	**91.8%**	**8.2%**
15년	63.8%	36.2%
10년	42.2%	57.8%
5년	23.9%	76.1%
1년	8.5%	91.5%



매년 같은 손실확률을 지키는 위험예산형 경로입니다 — 연 4~6%p씩 꾸준히 줄입니다

이 비중표는 실제 TDF의 위험 수준을 재는 잣대가 됩니다

구간별 축소 폭과, 목표 시점 직전(T = 1)에 위험자산 40%를 둘 때의 손실확률

20 → 15년	15 → 10년	10 → 5년	5 → 1년
−28.0%p	**−21.6%p**	**−18.3%p**	**−15.4%p**

실제 TDF 예시

T = 1에 위험자산 40%

기대수익 4.5% · 표준편차 8.4%

Equation 1로 계산

1년 손실확률 약 30%

5% 경로(8.5%)보다 위험이 크다

운용사 곡선의 차이는 결국 '목표 손실확률을 몇 %로 두었는가'의 차이입니다

L2

위험은 국면마다 다르다

L1의 모든 표는 변동성이 일정하다고 가정했다 — 그 가정이 깨지는 증거를 본다

60/40 포트폴리오의 연 변동성은 3.3%에서 18.6%까지 움직였습니다

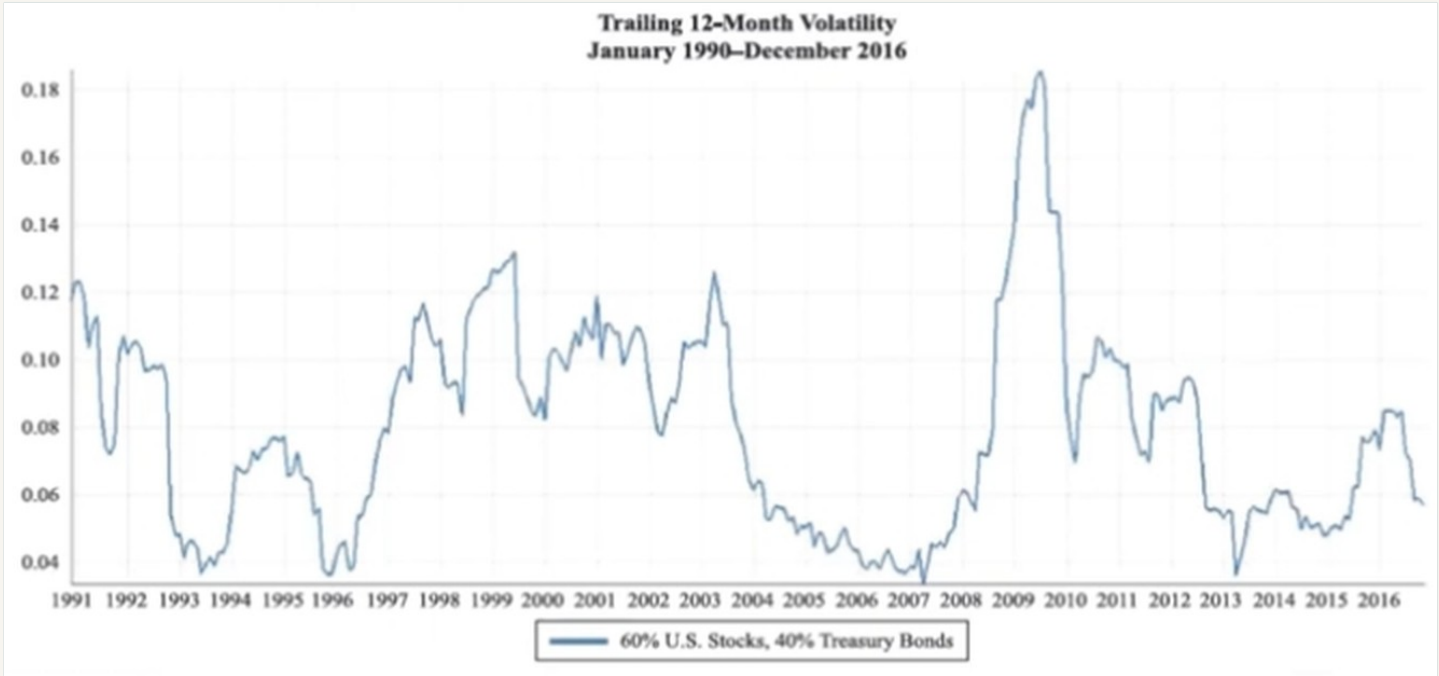
Exhibit 4 · 미국 주식 60%·국채 40% · 1990.1~2016.12 · 12개월 이동 변동성 (원 논문 그림)

그림에서 읽을 값

변동성의 범위

- 평균 8.0%
- 최저 3.3% (2007.5)
- 최고 18.6% (2009.8)

최고는 평균의 2.3배



변동성은 정상(stationary)이 아닙니다 — 비정상성(non-stationarity)이 이 강의의 두 번째 축입니다

이동 변동성은 직전 12개월 월수익률의 표준편차를 연율화한 값입니다

기본 지식 — 매월 창을 한 칸씩 밀며 다시 계산하므로 위험의 시간 변화를 직접 보여 준다

12개월 이동 변동성

$$\sigma_t^{(12)} = \sqrt{12}\sqrt{\frac{1}{11}\sum_{i=0}^{11}\left(r_{t-i} - \bar{r}_t\right)^2}, \qquad r_t = 0.6\, r_t^{\text{주식}} + 0.4\, r_t^{\text{국채}}$$

고변동 (2009.8)

평균의 2.3배

저변동 (2007.5)

평균의 0.4배

TDF에서의 의의

σ 입력을 바꾼다

고정 경로는 고변동기에 위험을 과소평가하고 저변동기에는 위험예산을 남깁니다

다만 이동 변동성은 후행 지표입니다 — L3에서 선행 지표를 찾습니다

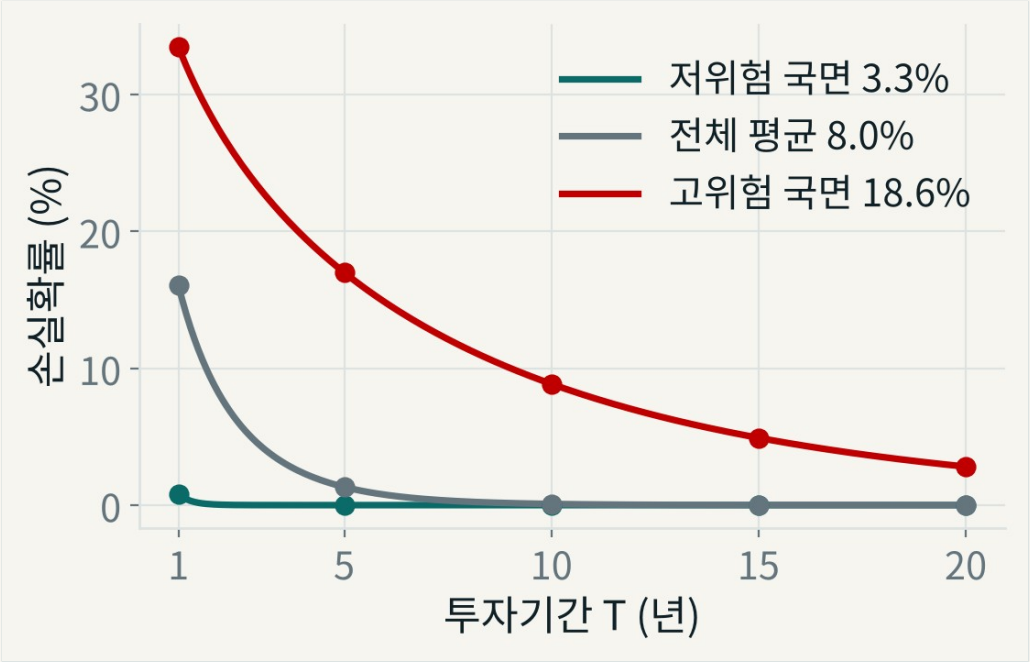
같은 60/40이라도 국면 변동성에 따라 손실확률이 수십 배 달라집니다

Exhibit 5 · 기대수익 7.94% 고정 · 변동성만 Exhibit 4의 최저·평균·최고로 바꾼다

국면별 손실확률

$$P(T;\sigma_k) = N\left[\frac{-0.0794\,T}{\underbrace{\sigma_k}_{\text{국면별 변동성}}\sqrt{T}}\right], \qquad \sigma_k \in \{3.3\%,\ 8.0\%,\ 18.6\%\}$$

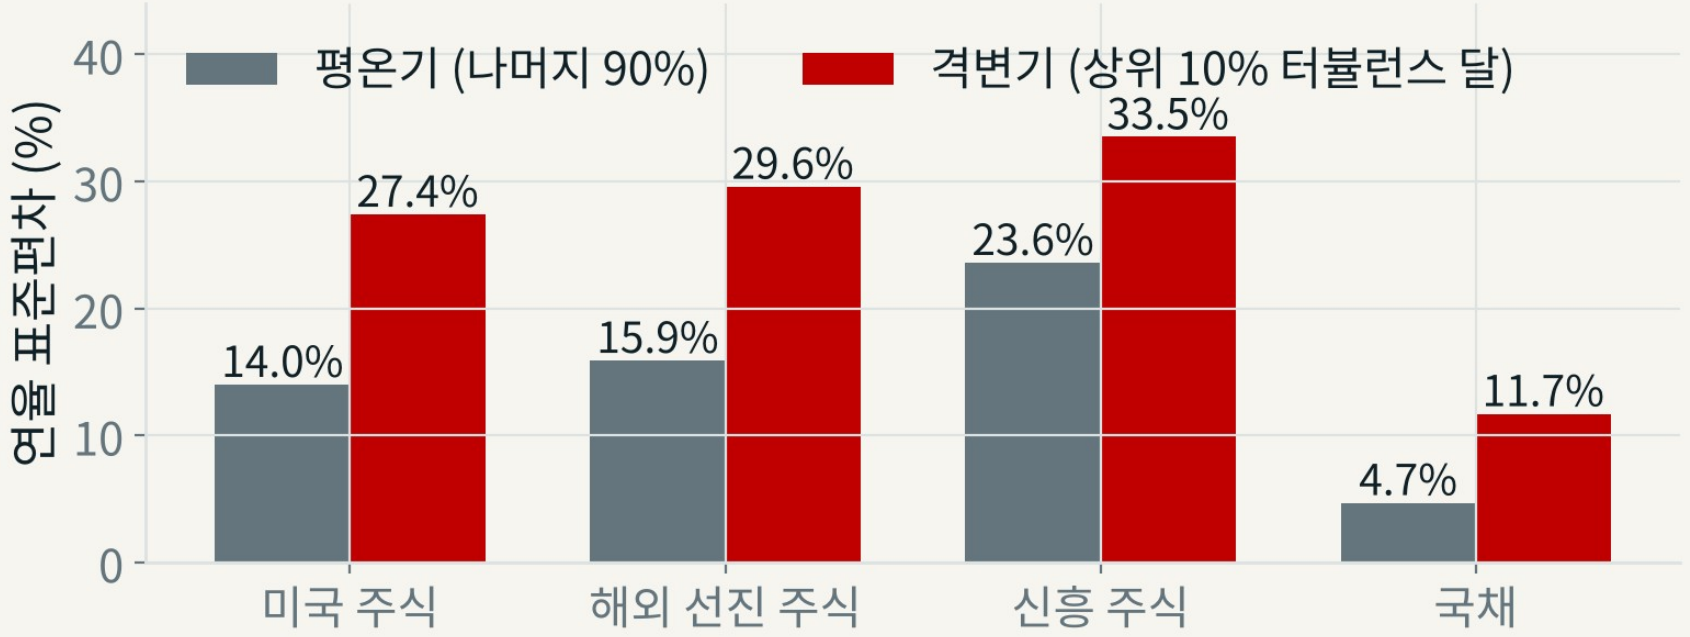
기간	저위험 3.3%	평균 8.0%	고위험 18.6%
20년	0.0%	0.0%	2.8%
10년	0.0%	0.1%	8.8%
5년	0.0%	1.3%	16.9%
1년	0.9%	16.0%	33.4%



1년 손실확률이 0.9%에서 33.4%까지 — 국면이 기간보다 큰 변수입니다

격변기에는 모든 자산의 변동성이 함께 오르고 분산효과가 약해집니다

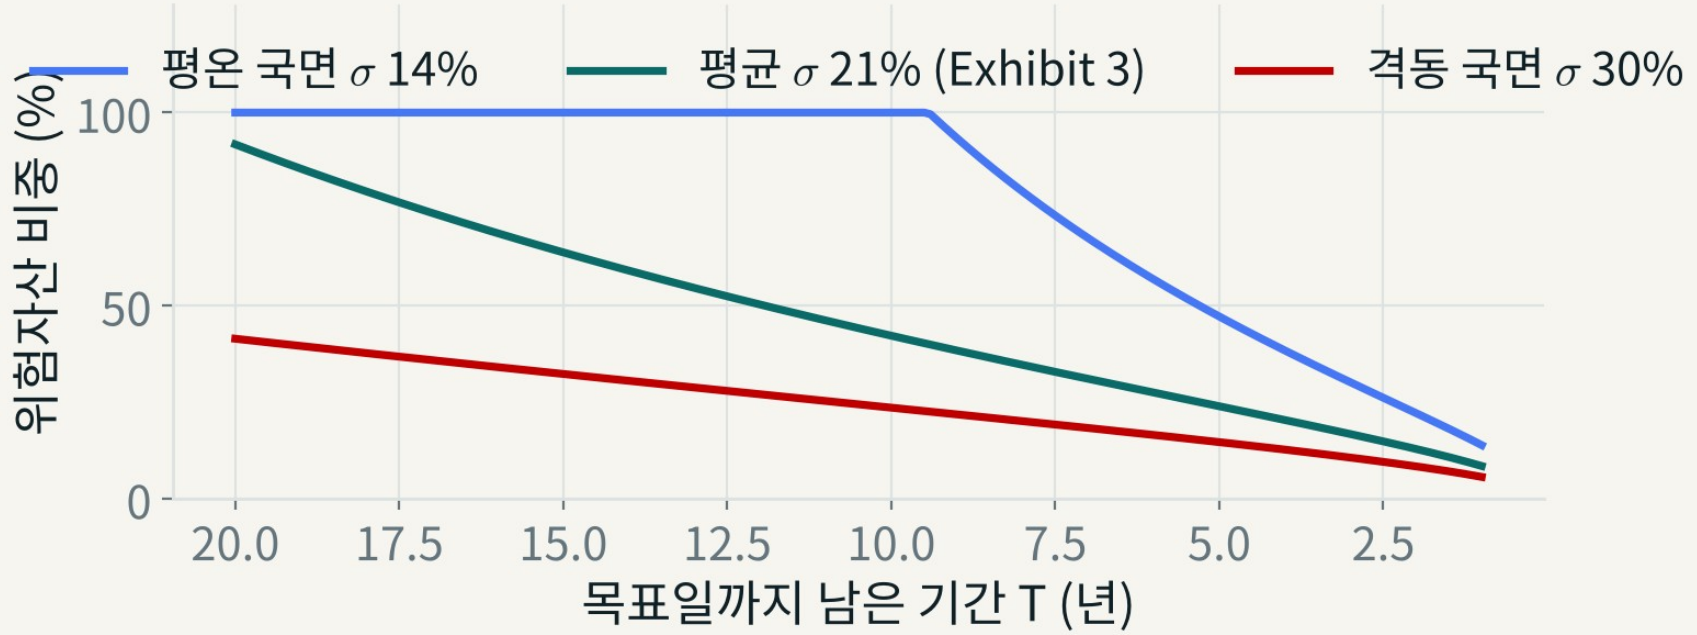
Exhibit 7 · 터뷸런스 상위 10% 달과 나머지 90% 달의 연율 표준편차 비교



분산이 가장 필요한 순간에 상관도 오릅니다 — 평균 공분산은 위기 위험을 과소평가합니다

국면마다 Equation 3을 다시 풀면 글라이드패스가 국면별로 갈라집니다

예시 계산 · 손실확률 5% · 위험자산 기대수익 7.5% · 국면 변동성만 14%·21%·30%로 바꾼 경우



고정 경로는 평온기에 위험예산을 남기고 격동기에는 목표 손실확률을 넘깁니다

그래서 비중은 '남은 기간'과 '지금 국면'의 두 축 함수가 되어야 합니다

L3

국면을 재는 지표

후행하는 이동 변동성 대신, 지금 시장이 얼마나 이례적이고 얼마나 묶여 있는지를 잰다

터뷸런스는 이번 달 수익률의 이례성을 한 숫자로 잽니다

Financial Turbulence — 마할라노비스 거리(Mahalanobis distance) · Kritzman·Li(2010)

Equation 4 · 금융 터뷸런스

$$\underbrace{d_t}_{\text{터뷸런스}} = \frac{1}{N}\Big(\underbrace{x_t}_{\text{이번 달 수익률}} - \underbrace{\mu}_{\text{평균}}\Big)^{\top} \underbrace{\Sigma^{-1}}_{\text{공분산 역행렬}} \big(x_t - \mu\big)$$

평소 관계를 감안

공분산 역행렬

상관 붕괴도 포착

크기 + 상관

역사적 급등

1987 · 1998 · 2008

채권 5% 하락은 주식 5% 하락보다 훨씬 이례적이고, 1/N로 나눠 기댓값을 1로 맞춥니다

약점: 이차형식이라 부호가 사라집니다 — 급락과 급등을 구분하지 못합니다

흡수비율은 소수의 공통 요인이 전체 분산을 얼마나 흡수하는지 잽니다

Absorption Ratio · Kritzman·Li·Page·Rigobon(2011) — 시장이 한 덩어리로 묶인 정도

Equation 5 · 흡수비율과 표준화 변화

$$\underbrace{AR_t}_{\text{흡수비율}} = \frac{\sum_{i=1}^{n} \sigma_{E_i}^2}{\sum_{j=1}^{N} \sigma_{A_j}^2} \qquad \underbrace{\Delta AR_t}_{\text{표준화 변화}} = \frac{\overline{AR}_{15\text{일}} - \overline{AR}_{1\text{년}}}{\sigma_{AR,1\text{년}}}$$

$\sigma_{E_i}^2$: 상위 i번째 고유벡터의 분산 $\sigma_{A_j}^2$: 자산 j의 분산 $n \approx N/5$

AR이 높다

결합이 강해 충격이 퍼진다

ΔAR ≥ 1σ

최근 15일이 1년보다 높다

터뷸런스가 '지금의 이례성'이라면, 흡수비율은 '시스템의 취약성'을 미리 보여 줍니다

고유벡터 수는 자산 수의 약 5분의 1이 기본입니다

Kritzman 외(2011)는 미국 51개 업종에 상위 10개 고유벡터를 썼다 · 하나만 쓰면 평균 상관과 같아진다

모든 상관이 ρ로 같을 때 첫 고유값

$$\lambda_1 = 1 + (N-1)\rho \qquad \frac{\lambda_1}{N} = \rho + \frac{1-\rho}{N}$$

두 자산: $AR = \frac{1+|\rho|}{2}$

PC1 하나만 쓰면

해석이 쉽고 안정적

자산 5~10개 TDF에 충분하다

N/5개를 쓰면

하위 요인까지 본다

금리로 묶인 주식·채권도 잡는다

AR 시계열은 n을 조금 바꿔도 모양이 크게 변하지 않으니 강건성 점검으로 비교합니다

국면 신호는 이례성·결합도·방향이라는 세 질문에 답해야 합니다

터뷸런스만으로는 방향을 모른다 — 세 신호를 z값으로 표준화해 상태 세 칸으로 묶는다

상태 벡터

세 칸으로 본다

- 상관 서프라이즈
- 흡수비율 변화 ΔAR
- 고점 대비 낙폭

방향은 ΔAR·낙폭이 준다

터뷸런스

지금 얼마나 이례적인가

평균·공분산에서 떨어진 거리

크기 + 상관 surprise

동시적 · 부호 없음

Kritzman·Li 2010

흡수비율

시장이 얼마나 묶였는가

상위 주성분의 분산 비중

오르면 충격이 빨리 번진다

선행적 · 구조

Kritzman 외 2011

낙폭·거품 단계

어느 방향인가

고점 대비 하락폭

상승 초기인가, 정점인가

경로 · 방향 있음

Kritzman 외 2024

이 세 칸이 L5(HMM의 관측치)와 L6(relevance의 상태변수)의 공통 입력이 됩니다

[케이스] 1,000억 TDF에 두 달 모두 같은 터뷸런스 경보가 울렸습니다

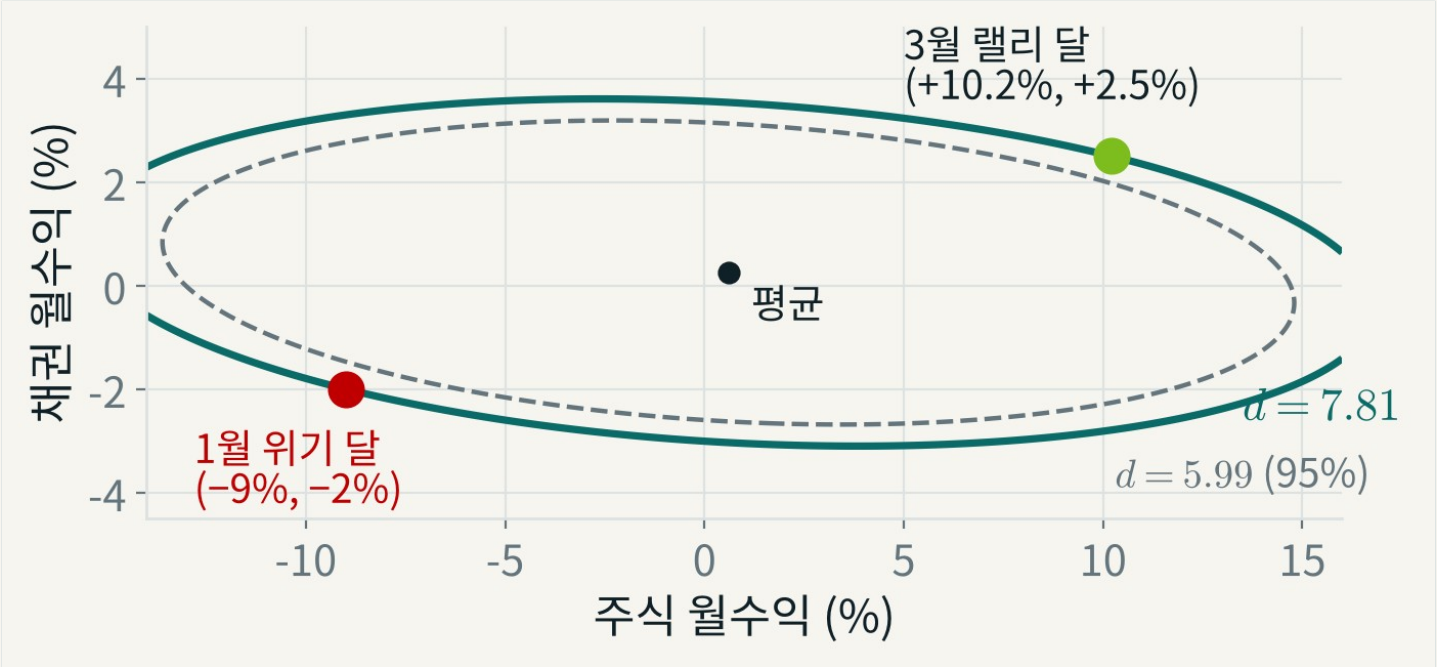
TDF 2036 · 목표일 10년 전 · 글라이드 비중 50% · 현재 주식 52% · 숫자는 설명용 가정

두 달의 수익률

d = 7.81로 같다

- 1월 주식 −9%, 채권 −2%
- 3월 주식 +10.2%, 채권 +2.5%

타원 위의 정반대 두 점



※ '위기 달'·'랠리 달'은 수익률 부호를 보고 붙인 설명용 이름입니다 — 지표가 판정한 국면이 아닙니다

질문은 하나입니다 — 같은 경보에 같은 답을 해야 하는가?

터뷸런스를 크기와 상관으로 나누면 무엇이 이례적인지 드러납니다

Kinlaw·Turkington(2014) · 월간 주식 0.6±5.8%, 채권 0.25±1.2%, 상관 −0.2 (손계산 워크북 W3-1)

터뷸런스 분해

$$\underbrace{d_t}_{\text{터뷸런스}} = \underbrace{z_t^\top z_t}_{\text{크기(magnitude)}} \times \underbrace{\frac{z_t^\top R^{-1} z_t}{z_t^\top z_t}}_{\text{상관 서프라이즈}}$$

z_t = 표준화 수익률, R = 상관행렬

1월 위기 달 (3월 랠리 달도 부호만 반대라 같은 값)

$$7.81 = \underbrace{(-1.66)^2 + (-1.88)^2}_{6.26} \times \underbrace{1.25}_{\text{상관 서프라이즈}}$$

상관 서프라이즈 1.25 > 1은 상관이 깨졌다는 뜻으로, 2022년형 주식·채권 동반 하락의 신호입니다

그러나 두 달은 크기도 상관도 같습니다 — 터뷸런스만으로는 둘을 가를 수 없습니다

두 달의 상태 좌표는 흡수비율 변화와 낙폭에서 갈립니다

상태 = (상관 서프라이즈, ΔAR, 낙폭)의 z값 — 국면을 판정한 값이 아니라 '평소보다 얼마나 벗어났나'를 잰 좌표

칸	1월	3월	어떻게 정했나
상관 서프라이즈 z	1	1	계산값 1.25가 두 달 같다 — 이차형식이라 부호가 사라진다
ΔAR z	**+1**	**−1**	**위기에는 자산이 묶여 AR이 오르고, 랠리에는 풀려 내린다 (다자산·15일 대 1년 기준 가정)**
낙폭 z	+2	−2	고점 대비 9%와 0% — 평균 4.5%, 표준편차 2.25%로 표준화

Kritzman 외(2011) — 위기 전후에는 흡수비율이 올라 자산들이 같은 방향으로 움직입니다

같은 7.81이어도 결합이 강해지는 달과 풀리는 달은 다른 좌표에 놓입니다

z값은 국면이 아니라 상태의 좌표이며, 국면을 다루는 방식은 방법마다 다릅니다

같은 세 칸의 z값을 어떤 방법은 판정 기준으로, 어떤 방법은 관측치로, 어떤 방법은 검색 좌표로 쓴다

방법	국면을 정하는가	z값의 역할	3월 달의 결과
Kritzman(2017) 이진	정한다 — 두 지표 z ≥ 1이면 취약, 아니면 평상	판정 기준	ΔAR z = −1이라 평상 → 팔지 않는다
HMM	확률로 정한다 — 평상·취약·반등	관측치	ΔAR 하락이 반등 쪽 우도를 높인다
relevance	**정하지 않는다**	**닮은 과거를 찾는 좌표**	**가장 닮은 과거가 상승기 사례다**

Kritzman 모형에는 '랠리 국면'이 없습니다 — 취약과 평상뿐이고 흡수비율이 방향을 거릅니다

'위기 달·랠리 달'은 설명용 이름이고, 모형의 출력은 판정·확률·좌표 가운데 하나입니다

L4

이진 국면 TDF — Kritzman(2017)

두 지표가 모두 1표준편차를 넘으면 취약 국면 비중으로 바꾸는 규칙과 그 성과

국면 반영 TDF는 국면별 공분산으로 손실확률 5% 비중을 미리 구해 둡니다

Target-Date Funds: A Regime-Based Approach (The Journal of Retirement, 5(1), 2017)

① 국면 측정
매일 두 지표 z값 → ② 공분산 추정
취약·평상 따로 → ③ 비중 결정
손실확률 5% 이내 → ④ 재배분
전환 시·매년 초

구분	구성	기대수익(가정)
위험자산	글로벌 주식 80% + 부동산 10% + 원자재 10%	6.5%
안전자산	글로벌 국채 (Citi WGBI)	4.0%

재배분 직후 10일은 거래하지 않아 회전율을 통제합니다

판정 규칙은 두 지표가 모두 1표준편차를 넘을 때만 취약 국면으로 봅니다

임계값 판정 — 국면은 0 또는 1이고, 비중은 국면별로 미리 구한 두 값 중 하나다

Kritzman식 판정 규칙

$$w_t = \begin{cases} w^*_{\text{취약}}(\tau) & z(d_t) \geq 1 \text{ 그리고 } z(\Delta AR_t) \geq 1 \\ w^*_{\text{평상}}(\tau) & \text{그 외} \end{cases}$$

장점

설명이 쉽다

장점

계산이 가볍다

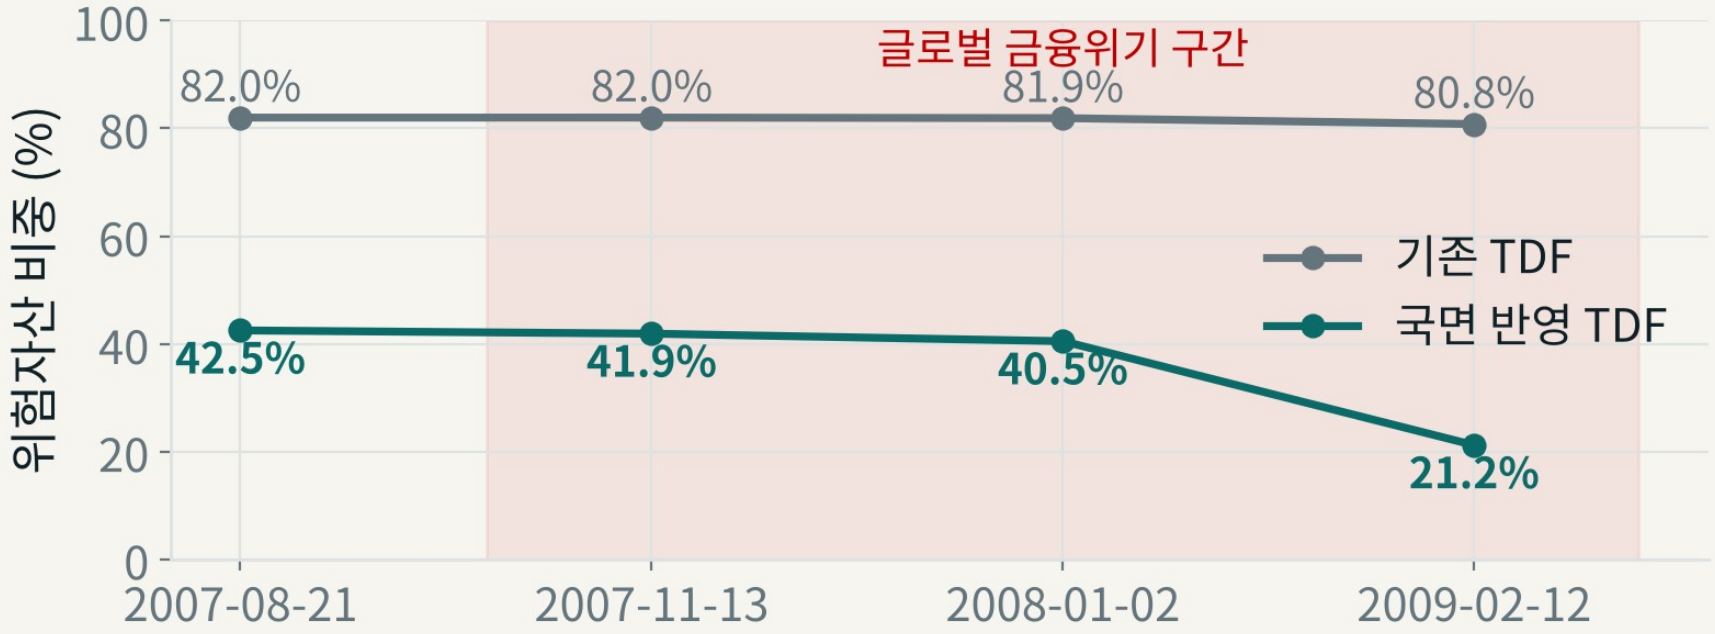
약점

경계에서 왕복한다

'그리고' 조건 덕분에 터뷸런스의 방향 맹점을 흡수비율이 일부 걸러 줍니다

국면 반영 TDF는 금융위기 전에 위험자산을 먼저 줄였습니다

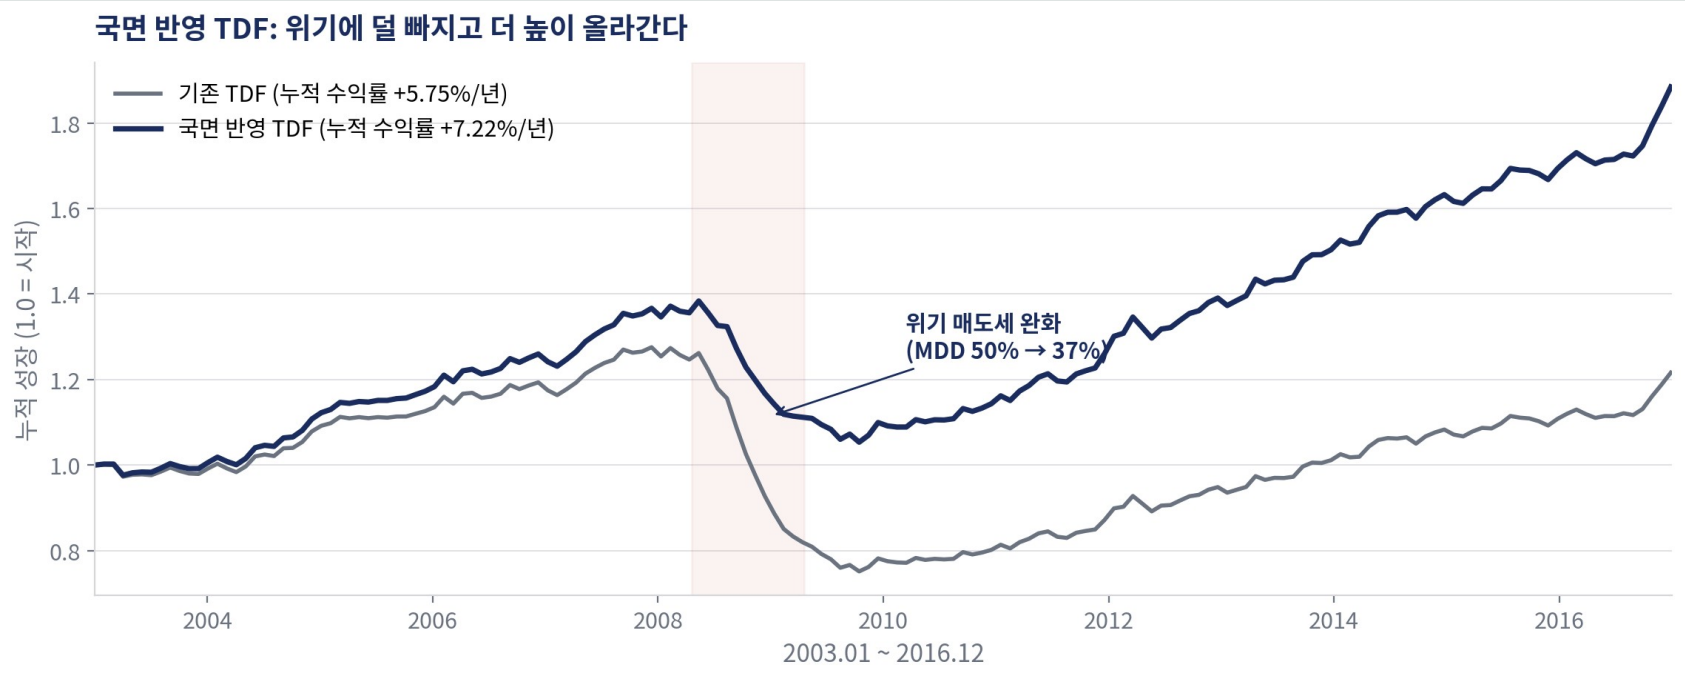
Exhibit 8 · 주요 재배분 시점의 위험자산 비중 · 사전 정보만 쓴 표본 외 결과



기존 TDF는 위기 내내 82%를 유지했고, 국면 반영 TDF는 2007년 8월에 이미 42%로 낮췄습니다

국면 반영 TDF는 위기에 덜 빠지고 더 높이 올라갔습니다

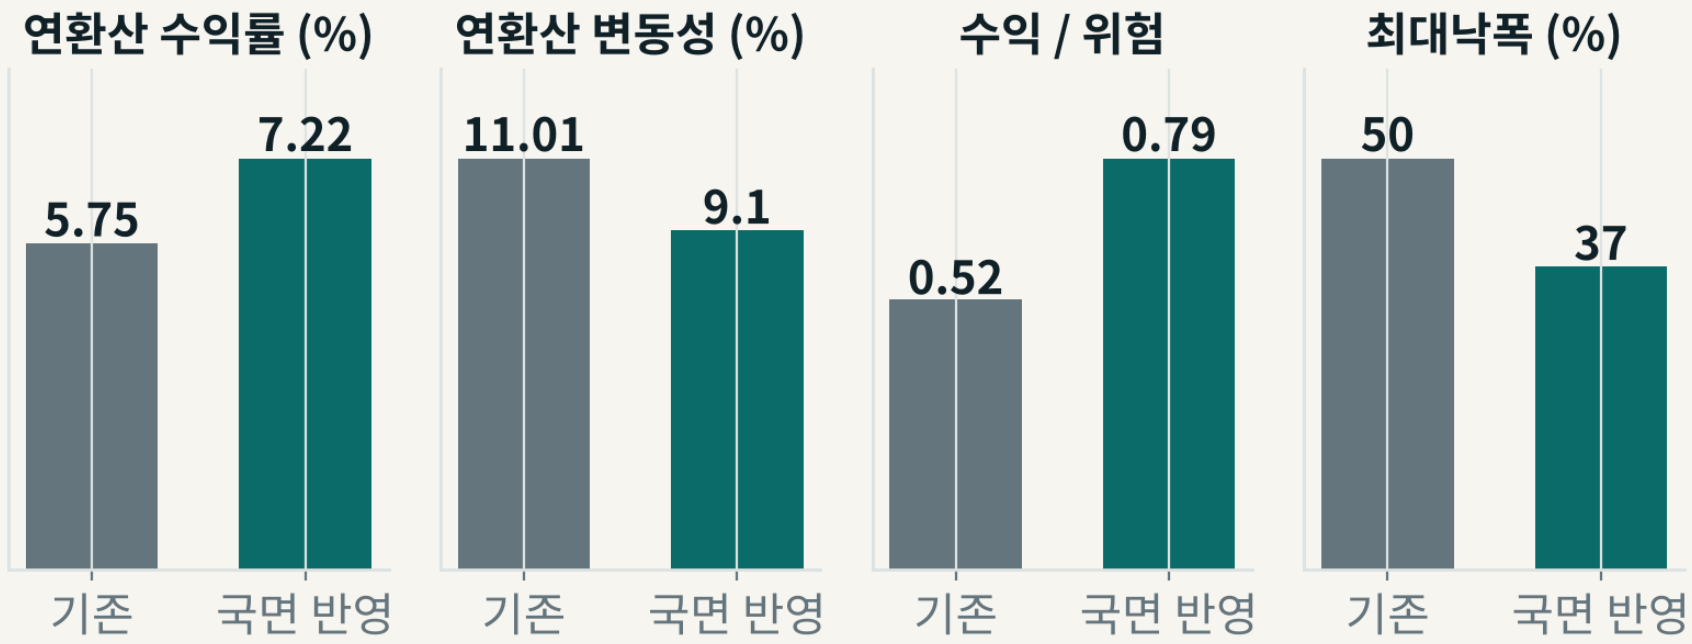
Exhibit 9 · 2003.01~2016.12 누적 성과(가상) · 초기에는 비슷하다가 금융위기에서 격차가 벌어진다



최대낙폭이 50%에서 37%로 줄었습니다 — 매도세가 시작되기 전에 방어로 돌아섰기 때문입니다

수익·변동성·효율·낙폭 네 지표가 모두 나아졌습니다

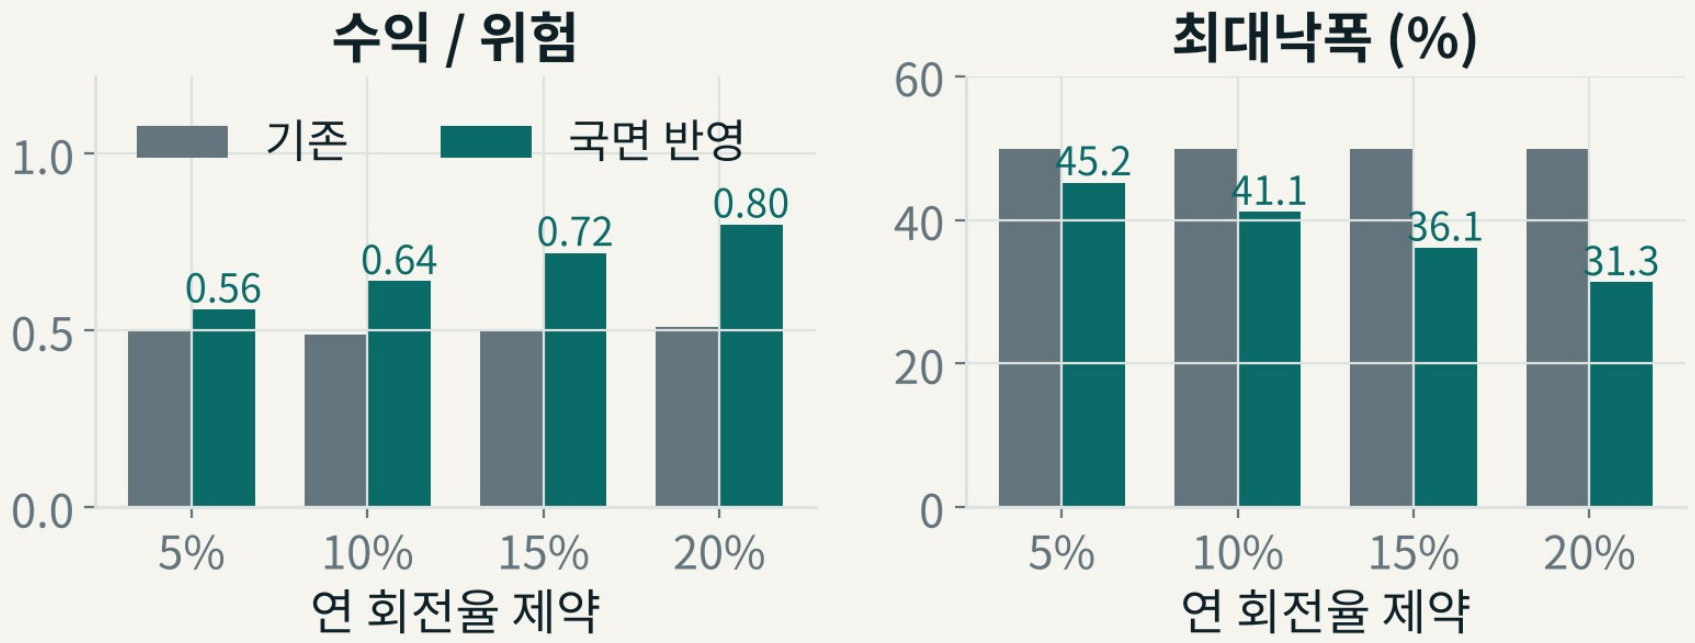
Exhibit 10 · 2003.01~2016.12 가상 성과



더 낮은 변동성과 더 작은 낙폭에도 수익률이 더 높았습니다 — 수익/위험 0.52 → 0.79

회전율을 묶어도 우위는 유지되고, 제약이 느슨할수록 커졌습니다

Exhibit 11 · 동일한 연 회전율 제약(5~20%) 아래 비교



회전율 5%로 묶어도 수익/위험(0.56 대 0.50)과 최대낙폭(45.2% 대 49.9%) 모두 앞섰습니다

[케이스] 흡수비율을 함께 보면 랠리 달에는 팔지 않습니다

취약이면 목표 40%, 평상이면 글라이드 50% · 조준점 공식과 ±4%p 밴드 · 현재 52% (워크북 W4-1)

1월 · 어느 규칙이든

취약 → 14.5억 매도

두 지표 모두 1 이상

3월 · 터뷸런스 단독

취약 → 14.5억 매도

d > 5.99로 판정 · 오경보

3월 · Kritzman 두 지표

평상 → 거래 없음

ΔAR z = −1이 막는다

'그리고' 조건의 흡수비율이 랠리 달의 오경보를 걸러 냅니다

그래도 판정은 0과 1뿐입니다 — 1월에 신호가 1.01σ든 4σ든 똑같이 14.5억을 팝니다

임계값 판정이 버린 정보를 L5부터의 처방이 하나씩 되살립니다

버리는 정보마다 증상과 처방이 하나씩 대응한다

버리는 정보	증상	처방	레벨
판정의 확신도	1.01σ와 4σ를 같게 취급한다	우도로 신호 강도를 반영한다	L5
국면의 지속성	한 달 신호로 즉시 전환한다	전이확률로 끈적함을 반영한다	L5
경계의 모호함	경계에서 비중이 왕복한다	확률 가중과 무거래 구간을 둔다	L5·L6
방향과 사례	터뷸런스만 보면 랠리 달에도 판다	ΔAR을 함께 보고, 닮은 과거를 직접 본다	L4·L6

판정(0/1) → 확률(π) → 관련성(r) → 모형 확률(q): 정보는 남기고 거래는 줄이는 것이 목표입니다

L5

국면을 확률로 — HMM과 베이지안 갱신

보이지 않는 국면을, 보이는 수익률과 지표로 매달 다시 추론한다

은닉 마르코프 모형은 국면을 숨은 상태로, 지표를 그 그림자로 봅니다

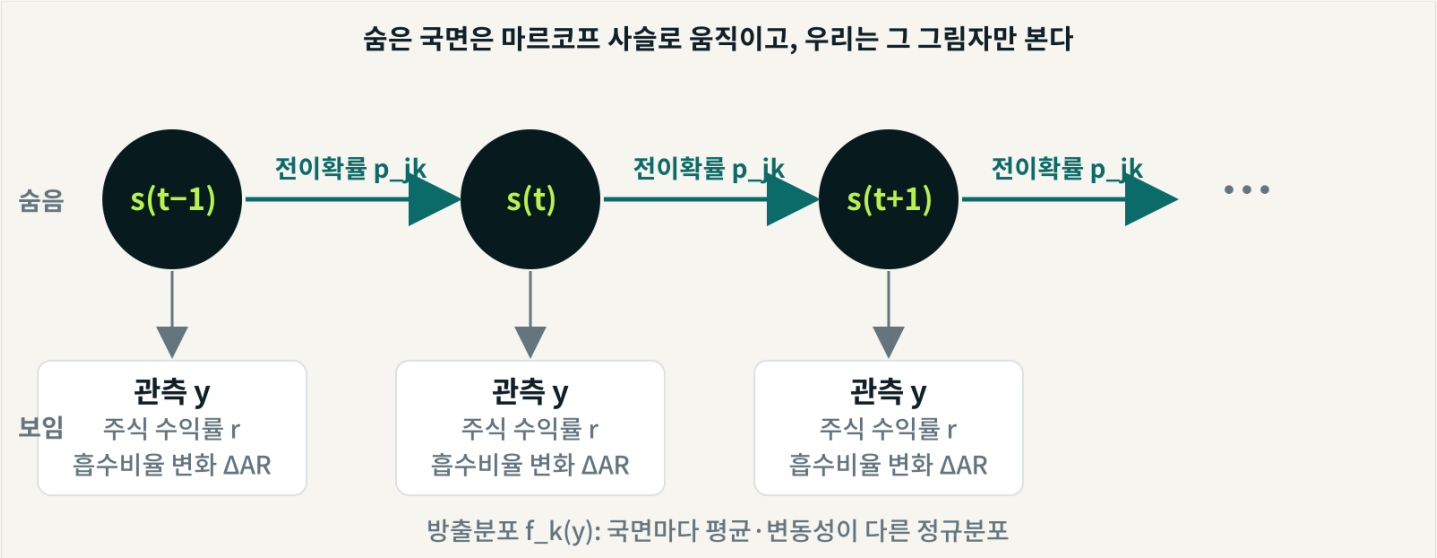
Hidden Markov Model — 상태는 관측되지 않고 관측치의 분포만 상태에 따라 바뀐다

두 가지 가정

HMM의 구조

- 국면은 마르코프로 바뀐다
- 관측은 그달 국면만 따른다

L3 지표가 관측치



판정 규칙만 확률 추론으로 바뀌고, 입력은 Kritzman의 지표 그대로입니다

베이즈 정리를 매달 반복하는 것이 해밀턴 필터입니다

Hamilton(1989) — 이산 상태의 베이지안 필터 · 연속 상태의 칼만 필터를 이산으로 옮긴 것

국면에 대한 베이즈 정리

$$\underbrace{p(s_t \mid y_{1:t})}_{\text{사후확률}} \propto \underbrace{p(y_t \mid s_t)}_{\text{우도}} \times \underbrace{p(s_t \mid y_{1:t-1})}_{\text{사전확률}}$$

① 예측 — 지속성(끈적함) 담당

$$\underbrace{\pi_{t|t-1}(k)}_{\text{예측(사전)}} = \sum_{j=1}^{K} \underbrace{p_{jk}}_{\text{전이확률}} \pi_{t-1}(j)$$

② 갱신 — 새 증거 담당

$$\underbrace{\pi_t(k)}_{\text{갱신(사후)}} = \frac{\overbrace{f_k(y_t)}^{\text{국면 } k\text{의 우도}} \pi_{t|t-1}(k)}{\sum_m f_m(y_t)\, \pi_{t|t-1}(m)}$$

Kritzman의 임계값 판정은 이 확률을 0 또는 1로 반올림한 특수한 경우입니다

−8% 한 달이 오면 취약 확률은 12%에서 52%로 오릅니다

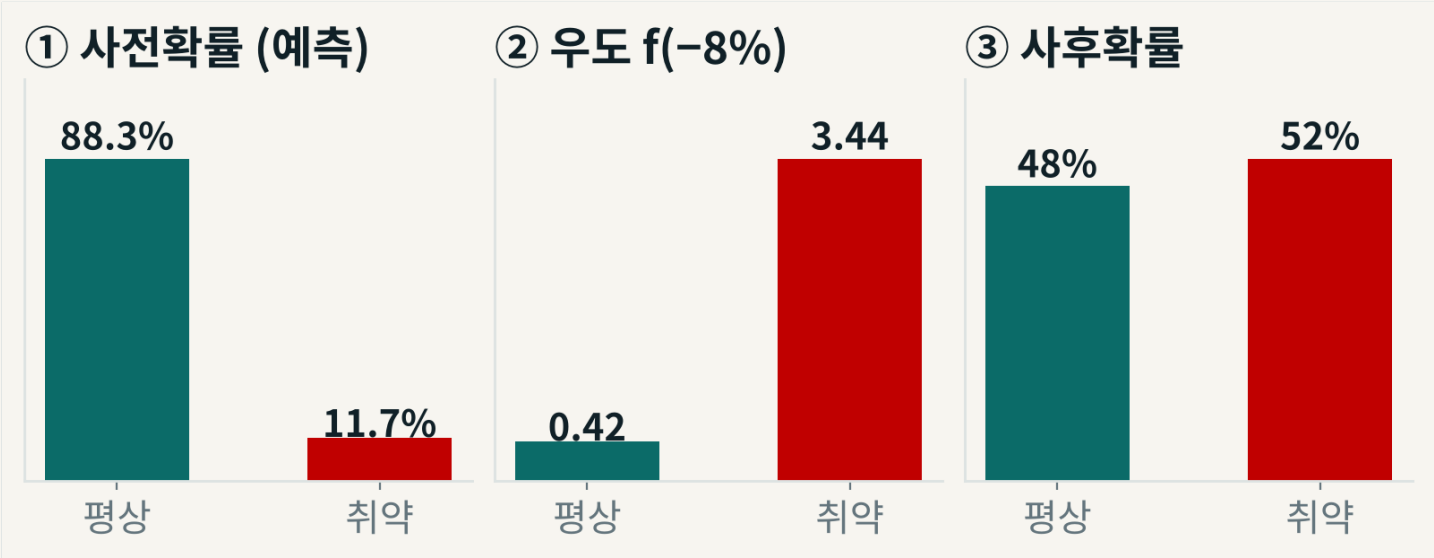
가상 월간 모수: 평상 1%·3.5%, 취약 −1%·7.5% · 유지확률 0.97/0.90 · 지난달 평상 90% (워크북 W5-1)

읽는 법

우도 대 사전확률

- 취약 우도가 8배 크다
- 사전확률은 7.5배 열세

그래서 52%에서 멈춘다



한 달 신호만으로 국면을 선언하지 않습니다 — 증거가 쌓이는 만큼만 확률이 움직입니다

관측 벡터에 흡수비율 변화를 넣으면 붕괴와 반등을 구분할 수 있습니다

수익률은 방향을, ΔAR은 결합을 알려 준다 — 국면마다 평균과 분산이 다른 정규분포

방출분포 (이 시리즈의 가상 실험 설정)

$$y_t = \begin{pmatrix} r_t^{\text{주식}} \\ \Delta AR_t \end{pmatrix} \Big| \; s_t = k \;\sim\; \mathcal{N}\big(\mu_k,\; \mathrm{diag}(\sigma_k^2)\big)$$

평상	취약	변동성 반등
수익 +, ΔAR ≈ 0	수익 −, ΔAR 상승	수익 +, ΔAR 하락

관측 벡터가 방향과 결합을 함께 담아 '좋은 쪽 이탈'을 가려냅니다

전이확률에 사전분포를 주면 모수 자체도 베이지안으로 갱신됩니다

Baum–Welch(EM)는 점추정 · 베이지안 HMM은 디리클레 사전분포로 사후분포를 얻는다 (워크북 W5-3)

전이행렬 행마다 디리클레 사전분포 — 관측된 전이 횟수를 더한다

$$(p_{k1},\dots,p_{kK}) \sim \mathrm{Dir}(\alpha_{k1},\dots,\alpha_{kK}) \;\Rightarrow\; \mathbb{E}[p_{kj} \mid n] = \frac{\alpha_{kj} + \overbrace{n_{kj}}^{\text{관측 전이 횟수}}}{\sum_m (\alpha_{km} + n_{km})}$$

유지확률이 정하는 평균 지속 기간과 장기 비중

$$\mathbb{E}[\text{지속 기간}_k] = \frac{1}{1-p_{kk}} \qquad \bar{\pi}_{\text{평상}} = \frac{p_{21}}{p_{12}+p_{21}}$$

유지확률 0.97이면 평균 33개월, 0.90이면 10개월 지속됩니다

표본이 적을 때 극단적인 전이확률이 나오는 것을 사전분포가 막습니다

실시간 배분에는 평활 확률이 아니라 필터 확률만 쓸 수 있습니다

평활(smoothed) 확률은 미래 관측까지 써서 과거 국면을 되짚는다 — 가상 20년 · 음영 = 실제 취약

두 확률의 용도

모수와 배분

- 평활은 미래를 쓴다
- 배분엔 필터·예측만

백테스트 누수 주의

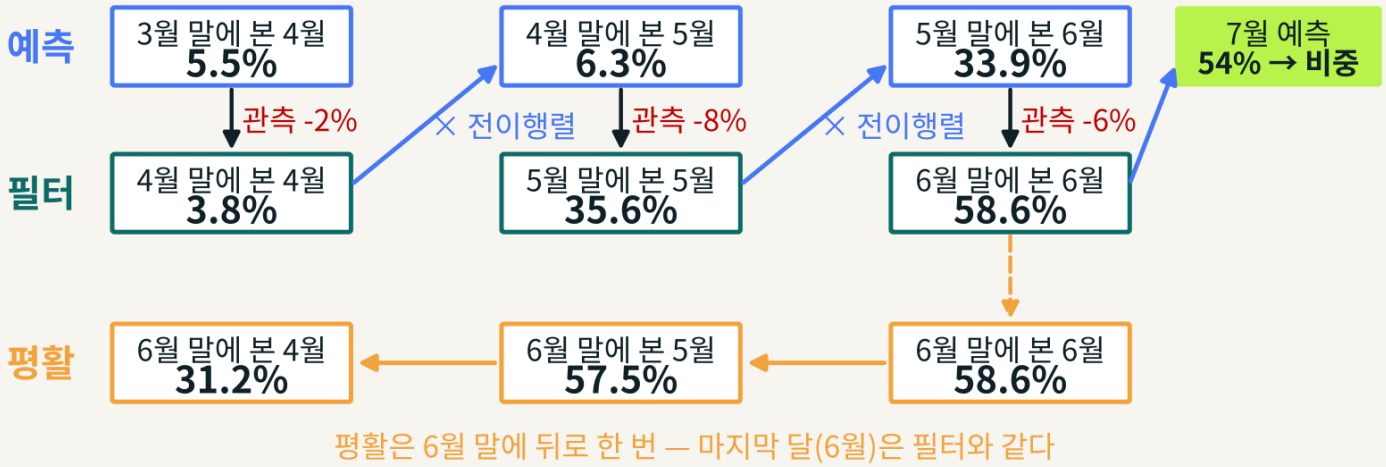


평활 확률로 백테스트하면 성과가 과대평가됩니다

매달 예측과 필터가 번갈아 돌고, 비중은 다음 달 예측으로 정합니다

가상 12개월 경로의 4~6월 · 숫자는 취약 확률 · 평활은 6월 말에 뒤로 한 번 돌린 값





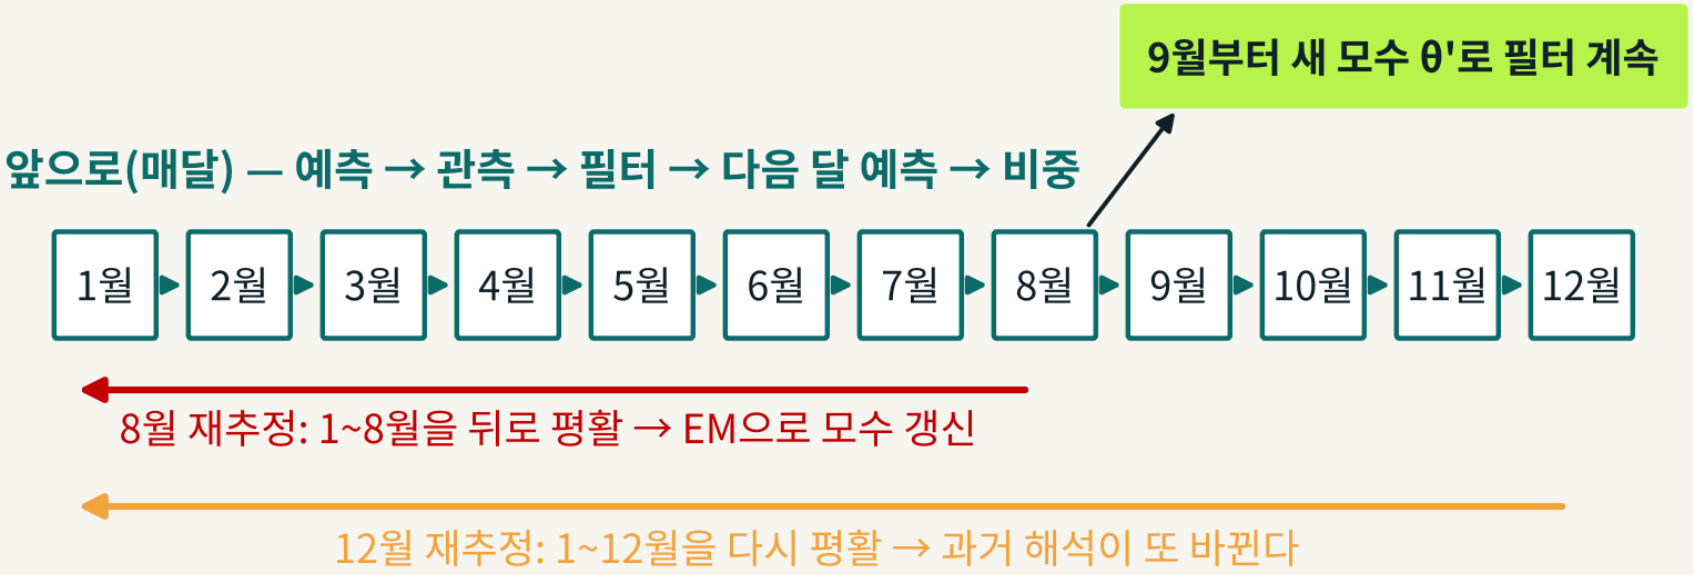
평활은 6월 말에 뒤로 한 번 — 마지막 달(6월)은 필터와 같다

필터는 이번 달, 예측은 다음 달을 봅니다 — 비중은 다음 달에 들고 가므로 예측으로 정합니다

평활은 비중에 쓰지 않습니다 — 지나간 달을 다시 읽어 모수를 고치는 데 씁니다

평활은 재추정 때만 뒤로 돌아가 모수를 고칩니다

매달 도는 고리 = 예측 → 관측 → 필터 → 다음 달 예측 · 재추정 때 도는 고리 = 평활 → EM → 새 모수



8월에 고친 모수는 9월 예측부터 쓰입니다 — 과거 비중을 소급해 바꾸지 않습니다

−8%였던 1월의 취약 확률은 이후 두 달을 보고 52%에서 26%로 다시 읽힙니다

Kim(1994) 평활 · W5-1·W5-2와 같은 가상 모수 · 1월 −8%, 2월 +2%, 3월 +2% (워크북 W5-6)

평활 — 마지막 달부터 뒤로 한 달씩

$$\underbrace{\pi_{k|T}(j)}_{\text{평활 확률}} = \underbrace{\pi_{k|k}(j)}_{\text{필터 확률}} \sum_i p_{ji} \frac{\overbrace{\pi_{k+1|T}(i)}^{\text{다음 달 평활}}}{\underbrace{\pi_{k+1|k}(i)}_{\text{다음 달 예측}}}$$

취약 확률	전달 말 예측	그달 필터	2월 평활	3월 평활
1월 (−8%)	**11.7%**	**52.2%**	**35.9%**	**25.5%**
2월 (+2%)	48.4%	29.6%	29.6%	17.7%
3월 (+2%)	28.8%	15.3%	—	15.3%
4월	16.3%	—	—	—

※ 여기서 평활은 과거 국면 확률의 재해석으로, L6에서 비중을 늦추는 지수평활과는 다릅니다

1월 말 비중은 2월 예측 48.4%로 정했습니다 — 1월이 26%로 다시 읽혀도 결정은 그대로입니다

4월의 국면은 3월 말에 예측되고, 4월 말에 필터되고, 그 뒤로 계속 평활됩니다

가상 12개월 경로 · 추정 대상 = 4월(−2%)의 취약 확률 · 조건은 각 시점 말까지 실제로 이용 가능했던 관측

$$\underbrace{\pi_{t+1|t} = P(s_{t+1} \mid Y_{1:t})}_{\text{예측: 다음 달은?}} \qquad \underbrace{\pi_{t|t} = P(s_t \mid Y_{1:t})}_{\text{필터: 지금은?}} \qquad \underbrace{\pi_{t|T} = P(s_t \mid Y_{1:T}),\ T > t}_{\text{평활: 그때는 어땠나?}}$$

정보를 확인하는 시점	새로 이용할 수 있는 정보	4월 취약 확률	구분
3월 말	3월까지의 수익률과 지표	5.5%	예측 — 아직 오지 않은 4월
4월 말	**4월 −2%**	**3.8%**	**필터 — 현재인 4월 · 5월 예측 6.3%**
5월 말	5월 −8%	19.5%	평활 — 지나간 4월을 재추정
6월 말	6월 −6%	31.2%	평활 — 다시 재추정
8월 말	7월 −1%, 8월 −7%	38.2%	평활 — 재추정 시점의 값
12월 말	9~12월 반등	24.8%	평활 — 반등을 보고 다시 낮춘다

4월 말엔 평상으로 보였지만, 5~8월을 보고 4월부터 취약이 시작됐다고 다시 판단하는 것이 평활입니다

5월 말 −8% 하나가 현재·과거·미래의 국면 추정에 동시에 쓰입니다

같은 새 관측이 세 방향으로 퍼진다 — 비중 결정에 들어가는 것은 다음 달 예측이다

현재 · 필터

5월 취약 36%

π(5|5) · 예측의 출발점

현재 판단

과거 · 평활

4월 3.8% → 19.5%

π(4|5) · 지난달 재해석

모수 추정

미래 · 예측

6월 취약 34%

π(6|5) · 6월 비중

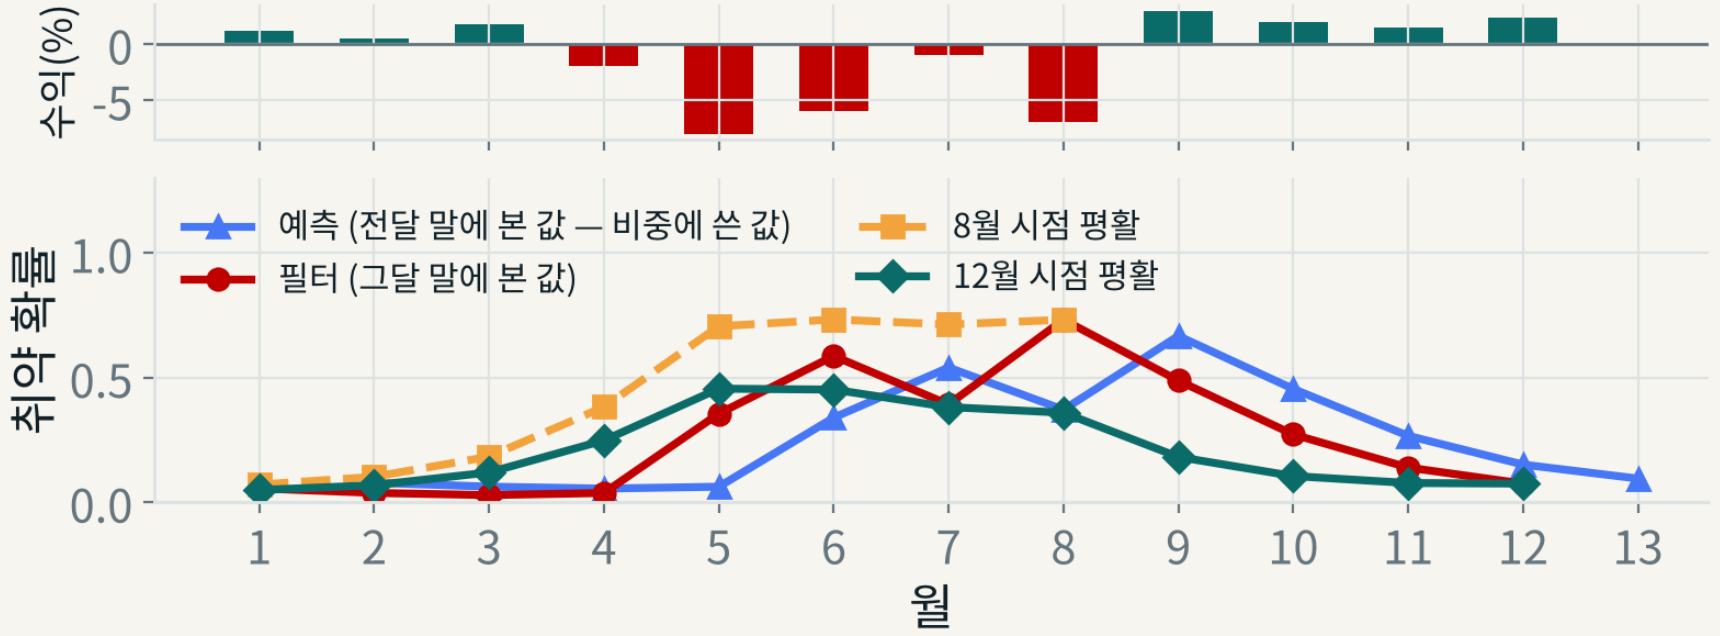
비중 결정

어느 달을 추정하느냐와 필터·평활·예측은 일대일로 대응하지 않습니다 — 기준은 관측 시점입니다

백테스트에는 그날 알 수 있던 값만 씁니다 — 사후 평활 값을 쓰면 미래정보 편향입니다

같은 달의 해석은 시점마다 바뀌지만, 비중에는 그때 알던 예측만 씁니다

가상 12개월 · 평상 1%·3.5%, 취약 −1%·7.5% · 유지확률 0.97/0.90 · 8월과 12월에 재추정



4월 −2%는 그때 취약 4%였지만 8월에 다시 보니 38%입니다 — 평활은 국면의 시작을 더 일찍 잡습니다

그 38%로 백테스트하면 4월에 미리 판 것처럼 보입니다 — 평활 확률 누수가 성과를 부풀리는 이유입니다

국면 확률로 국면별 평균과 공분산을 섞어 다음 달 예측분포를 만듭니다

π(t+1|t) = 이번 달 필터 확률에 전이행렬을 한 번 곱한 다음 달 국면 확률

혼합 예측분포의 평균과 공분산

$$\hat{\mu}_{t+1} = \sum_k \pi_{t+1|t}(k)\,\mu_k \qquad \hat{\Sigma}_{t+1} = \sum_k \pi_{t+1|t}(k)\left(\Sigma_k + \mu_k\mu_k^\top\right) - \hat{\mu}_{t+1}\hat{\mu}_{t+1}^\top$$

실무 근사 — 국면별 최적 비중을 확률로 가중평균 (워크북 W5-4)

$$w_t \approx \sum_k \underbrace{\pi_{t+1|t}(k)}_{\text{다음 달 국면 확률}} \underbrace{w_k^*}_{\text{국면별 최적 비중}}$$

공분산의 μμᵀ 항 때문에 국면이 불확실할수록 위험이 더 커 보입니다
국면의 불확실성 자체가 위험자산을 줄이는 근거가 됩니다

기본 글라이드를 최적해로 만드는 위험회피를 역산해 앱커로 씁니다

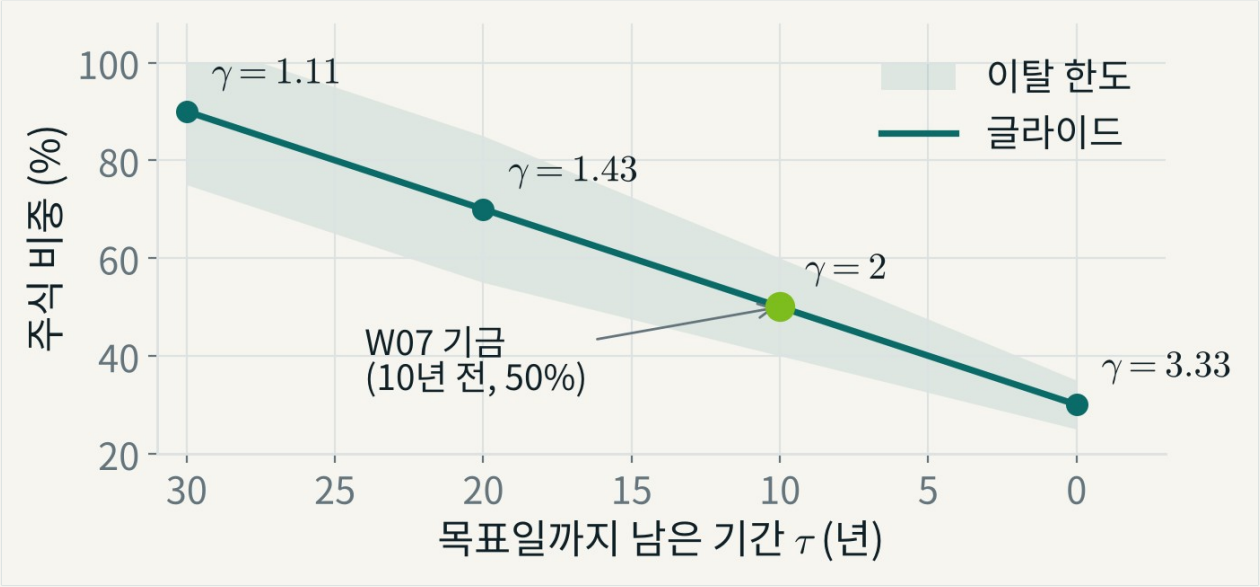
케이스 설정 — 초과수익 4%p와 분산 0.04가 같아 위험회피가 비중의 역수가 된다 (워크북 W5-5)

글라이드와 역산 위험회피

$$\underbrace{w_G(\tau)}_{\text{기본 글라이드}} = 0.30 + 0.02\,\underbrace{\tau}_{\text{남은 기간}} \qquad \underbrace{\gamma(\tau)}_{\text{위험회피}} = \frac{\mu - r}{\sigma^2\, w_G(\tau)} = \frac{1}{w_G(\tau)}$$

앱커의 뜻

국면 정보가 없으면 정확히 기본 글라이드가 최적해다



30년 전 γ = 1.11에서 목표일 γ = 3.33으로 — 목표일에 가까울수록 같은 신호에도 덜 움직입니다

일반형에서는 무조건부 입력으로 λ를 역산하고 조건부 입력으로 목표를 구합니다

국면 정보가 없으면 e*가 정확히 기본 글라이드가 되도록 λ(τ)를 고른다 (워크북 W5-5)

위험회피 역산과 조건부 목표 비중

$$\lambda(\tau) = \frac{\bar{\mu}_s - \bar{\mu}_b}{w_G(\tau)\,\bar{V} + \bar{\sigma}_{sb} - \bar{\sigma}_b^2} \qquad e_t^* = \frac{\hat{\mu}_s - \hat{\mu}_b - \lambda(\tau)\left(\hat{\sigma}_{sb} - \hat{\sigma}_b^2\right)}{\lambda(\tau)\,\hat{V}}$$

국면 정보 없음

e* = 기본 글라이드

국면 정보 있음

e*가 조건부로 이동

앵커의 효과

기본 경로를 못 뒤엎는다

조정분은 오직 국면 정보에서만 나옵니다 — 국면 모형이 TDF의 약속을 뒤엎지 못하게 하는 장치입니다

이탈 폭은 밴드 안으로 부드럽게 누르고, 작은 변화는 거래하지 않습니다

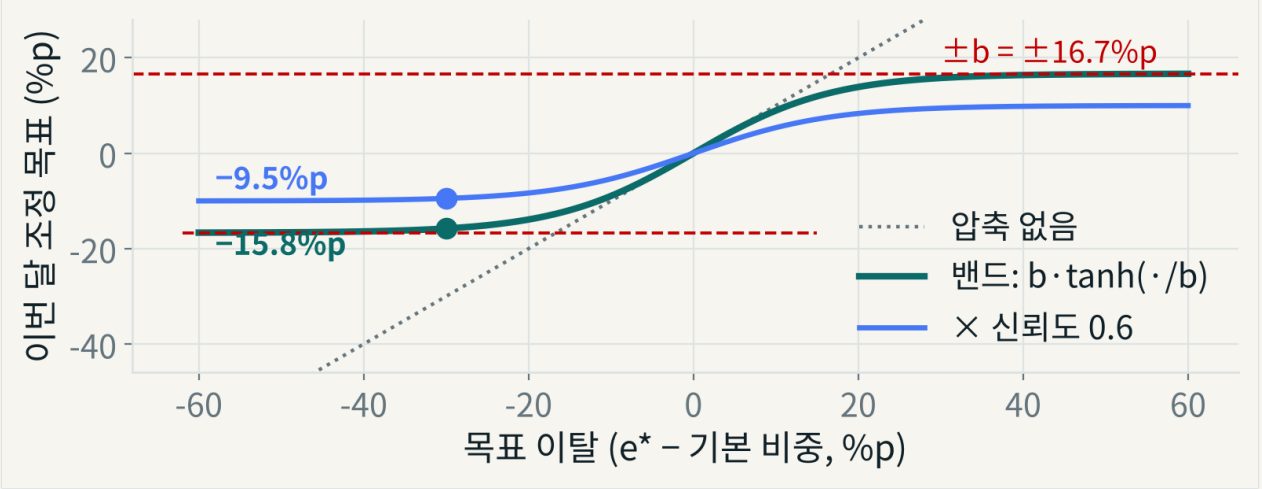
b(τ) = 허용 이탈 폭(초기 ±20%p → 목표일 ±10%p) · δ = 무거래 폭 2%p

tanh 밴드 — 큰 신호는 ±b에서 포화

$$w_t = w_G(\tau) + \underbrace{b(\tau)}_{\text{허용 이탈 폭}} \tanh\left(\frac{e_t^* - w_G(\tau)}{b(\tau)}\right)$$

무거래 구간 — 변화가 δ보다 작으면 유지

$$w_t = \begin{cases} w_{t-1} & \left|w_t^{\text{목표}} - w_{t-1}\right| < \underbrace{\delta}_{\text{무거래 폭}} \\ w_t^{\text{목표}} & \text{그 외} \end{cases}$$



밴드는 모형이 틀렸을 때의 최대 손해를 제한합니다

확률 가중 비중은 취약 국면에서 내려가고 반등 국면에서는 올라갑니다

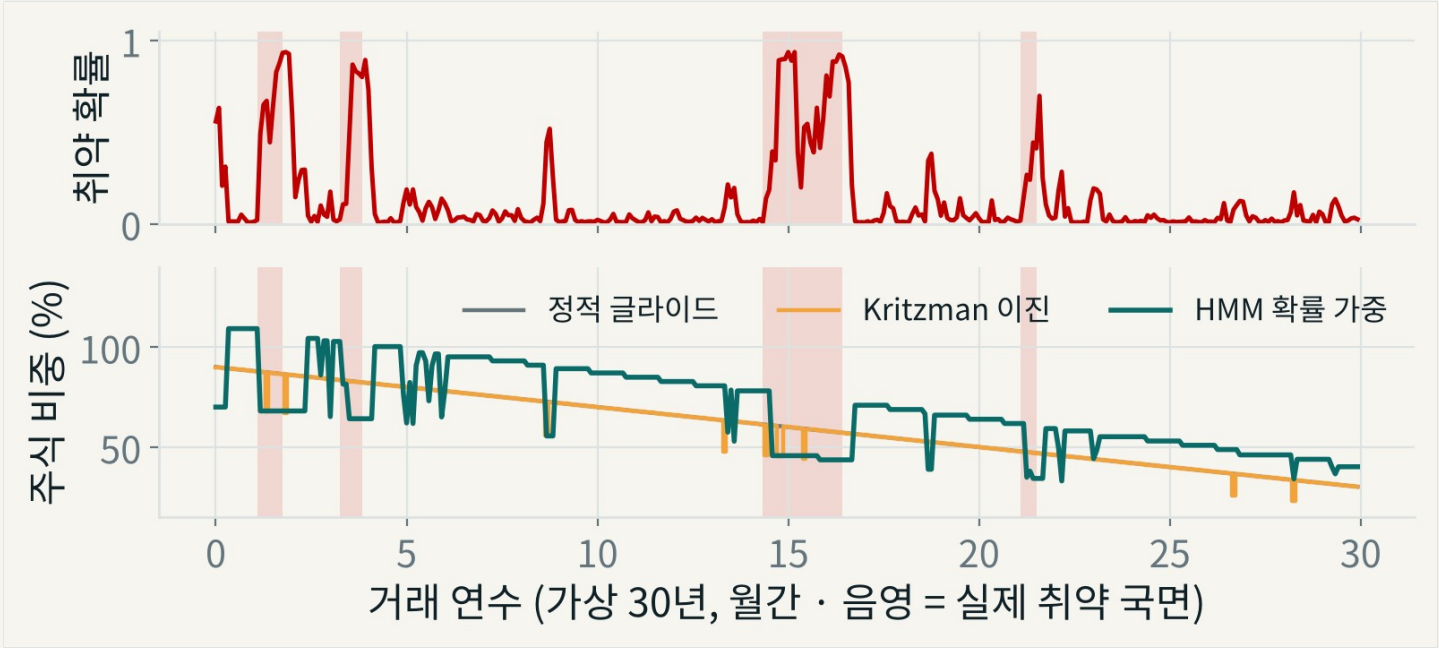
세계 A의 가상 30년 한 경로 · 위: 필터가 추정한 다음 달 취약 확률 · 아래: 세 규칙의 주식 비중

관찰

정보와 거래

- 이진은 자주 놓친다
- 확률은 대부분 잡는다
- 대신 매달 움직인다

회전율이 높아진다



정보를 더 쓰면 거래가 늘어납니다 — 이 긴장이 L6·L7을 끌고 갑니다

모형이 맞는 세계와 틀린 세계를 함께 만들어 같은 조건으로 비교합니다

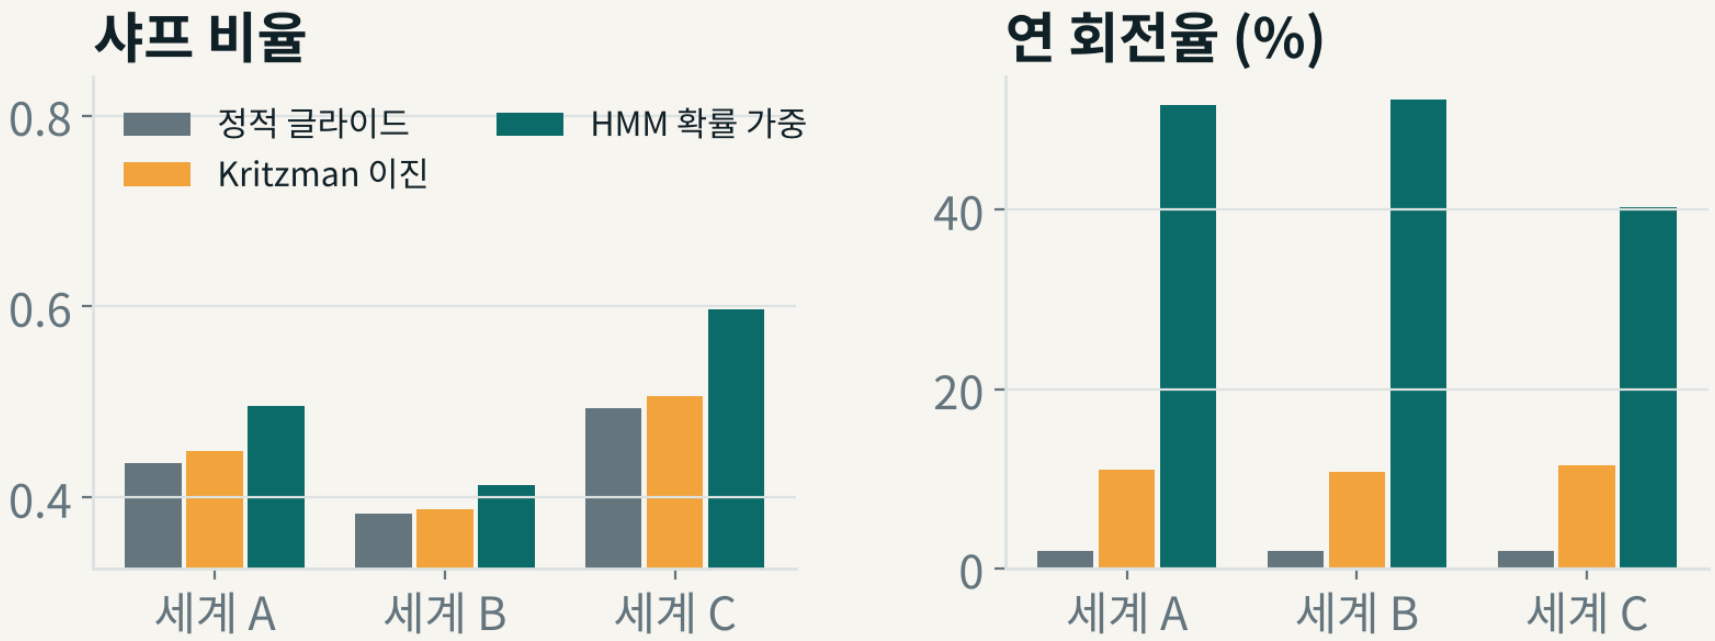
모든 수치는 수업용 가상 실험(시드 고정) — 실제 시장의 성과 예측이 아니다

세계	설정	유리한 쪽
A	3국면(평상·취약·반등) 마르코프 전환 — 모형 그대로	HMM
B	A와 같되 거래 5년차부터 취약 국면이 주식·채권 동반 하락형	적응하는 쪽
C	국면 없이 연속 상태가 수익·변동성·상관을 정한다	모형 무가정 쪽
공통	사전 이력 20년 + 거래 30년 · 경로 150개 · 편도 10bp	—

세계 B·C는 HMM의 가정이 깨지는 세계입니다 — 모형 위험을 일부러 넣었습니다

확률 가중은 세 세계 모두에서 샤프를 높였지만 회전율을 크게 늘렸습니다

세 세계 × 150개 가상 경로 평균 · 편도 10bp 차감 후



세계 A 샤프: 정적 0.436 · 이진 0.449 · 확률 가중 0.496 — 대가는 연 52%의 회전율입니다

확률 가중은 취약 국면을 더 많이, 더 깊게 잡아냅니다

세계 A · 취약 조정 = 실제 취약 달의 평균 비중 조정 · 포착률 = 그 달 중 1%p 이상 줄인 비율

전략	샤프	최대낙폭	연 회전율	취약 조정	포착률
정적 글라이드	0.436	−41.8%	2%	+0.0%p	0%
Kritzman 이진	0.449	−40.7%	11%	−2.0%p	13%
HMM 확률 가중	**0.496**	**−37.7%**	**52%**	**−7.6%p**	**77%**

HMM은 반등 국면에서 평균 +2.1%p 늘려 터뷸런스의 방향 맹점을 줄였습니다

그래도 반등 달의 43%에서는 비중을 줄였습니다 — 확률은 오경보를 없애지 못합니다

[케이스] HMM은 위기 달에 목표 46.8%로 0.6억만 팝니다

고변동 확률 0.77 · 같은 조준점 공식과 ±4%p 밴드 · 현재 52%

이진 판정 · 1월

목표 40%

14.5억 매도

확신도 무시

HMM 확률 가중 · 1월

목표 46.8%

0.6억 매도

확신도 반영

HMM · 3월

반등 쪽 우도 상승

수익 +, ΔAR 하락이 관측됨

방향 반영

HMM은 '얼마나'를 확률로, '어느 방향'을 ΔAR이 들어간 방출분포로 반영합니다

※ 3월의 정확한 비중은 방출분포 모수에 따라 달라 이 케이스에서는 수치를 두지 않습니다

HMM의 한계는 국면 모형을 미리 정해야 한다는 데서 나옵니다

한계마다 대응이 있고, 가장 근본적인 대응은 국면 모형을 아예 두지 않는 것이다

한계	내용	대응
모형 오설정	국면 수와 분포 형태를 미리 정한다	BIC로 고르거나 sticky HDP-HMM을 쓴다 (L8)
모수 불안정	구조가 바뀐 뒤에도 옛 모수를 쓴다	주기적으로 재추정한다 (L7)
식별 지연	국면이 시작된 뒤에야 확신한다	선행 지표(ΔAR)를 관측에 넣는다
회전율	확률이 매달 움직인다	부분 매매와 비용 기반 무거래 구간 (L7)

국면에 이름을 붙이지 않는 방법이 relevance입니다 — L6에서 다룹니다

L6

국면 이름 없이 — relevance

지금과 닮은 과거를 찾아 그다음에 일어난 일로 직접 예측한다

국면을 표현하는 방식은 라벨, 확률, 점수의 세 가지입니다

Kritzman과 State Street 연구진의 흐름 — 임계값 판정에서 relevance로

접근	국면 표현	예측 방법	대표 연구
임계값 판정	0/1 라벨	라벨별 평균	Kritzman (2017)
HMM	K개 상태의 확률	상태별 분포 혼합	Kritzman·Page·Turkington (2012)
relevance	**시점별 연속 점수**	**관련성 가중평균**	**Czasonis·Kritzman·Turkington (2023)**

Kritzman·Kulasekaran·Turkington(2023): 한 시점이 여러 국면에 동시에 정보를 줄 수 있습니다

국면을 고르지 않으면 경계에서 왕복할 일도 없습니다

닮음은 변수 간 상관까지 고려한 마할라노비스 거리로 잽니다

Ω = 상태변수의 공분산 행렬 — 함께 움직이는 변수의 중복을 덜어 낸다

두 시점 사이의 거리와 상태벡터 예

$$\mathrm{dist}(x_i, x_t) = (x_i - x_t)^\top \Omega^{-1} (x_i - x_t) \qquad x_t = \left[\mathrm{Turb}_t^{mag},\ \mathrm{Turb}_t^{corr},\ \Delta AR_t,\ \mathrm{Warp}_t\right]$$

터뷸런스 분해

크기와 상관

무엇이 평소와 다른가

흡수비율 변화

결합도

얼마나 묶였는가

거품 단계 warp

경로의 위치

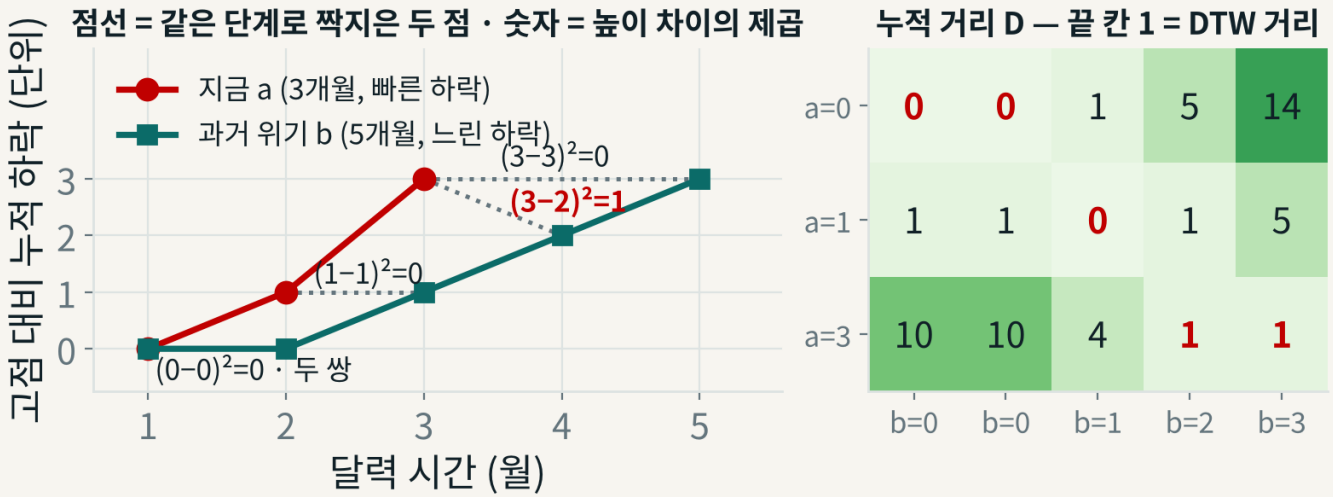
거품 경로의 어느 단계인가

warp는 동적 시간 왜곡으로 현재 경로를 과거 거품 경로에 맞춰 단계를 추정합니다 (Kritzman·Song·Turkington)

warp는 속도가 다른 두 경로를 같은 단계끼리 맞춥니다

Dynamic time warping — 누적 거리가 최소가 되도록 한쪽이 기다리거나 함께 나아간다 (워크북 W6-6)

$$\underbrace{D(i,j)}_{\text{누적 거리}} = \big(a_i - b_j\big)^2 + \min\Big\{\underbrace{D(i-1,j)}_{\text{b가 기다림}},\ \underbrace{D(i-1,j-1)}_{\text{함께 진행}},\ \underbrace{D(i,j-1)}_{\text{a가 기다림}}\Big\}$$



달력으로 맞추면 3개월 하락과 5개월 하락의 거리가 2~5지만, warp로 맞추면 1입니다

같은 위기라도 빨리 오는 위기와 천천히 오는 위기를 같은 단계로 비교할 수 있습니다

Dynamic Warp Analysis는 거품을 21단계로 맞춰 지금의 단계를 찾습니다

Kritzman·Song·Turkington (JPM, 2024) · S&P 500 종목 거품 2,638개 · 1973~2023 · 특성은 횡단면 백분위

단계별 평균과 공분산에 대한 마할라노비스 거리가 가장 작은 단계

$$d_s(x_t) = \left(x_t - m_s\right)^\top S_s^{-1}\left(x_t - m_s\right), \qquad \underbrace{\hat{s}_t}_{\text{거품 단계}} = \arg\min_{s \in \{0\%, 5\%, \ldots, 100\%\}} d_s(x_t)$$

warp 단계	0%	50%	정점
정점까지 남은 상승 (중앙값)	89%	54%	13%

거래 규칙 (표본 외)	연 수익	위험	IR
상승 국면 규칙	2.2%	5.7%	0.39
과잉 반응 규칙	5.4%	10.1%	0.53
결합	**2.9%**	**3.9%**	**0.74**

※ 원 논문은 개별 종목 거품을 다뤘고 relevance와 결합하지 않았습니다

단계 추정도 마할라노비스 거리입니다 — 비교 대상이 과거 시점이 아니라 단계별 평균일 뿐입니다

relevance에 warp를 넣는 방법은 두 가지입니다

① 단계 추정치를 상태변수에 더한다 · ② 한 달의 점 대신 최근 L개월의 경로를 DTW로 비교한다

① 단계를 네 번째 좌표로

$$x_t^{+} = \left[\mathrm{Turb}_t^{corr},\ \Delta AR_t,\ DD_t,\ \underbrace{\hat{s}_t}_{\text{warp 단계}} \right]$$

② 경로 relevance

$$\underbrace{r_{it}^{\text{경로}}}_{\text{경로 relevance}} = -\,\mathrm{DTW}\Big(\underbrace{x_{t-L+1:t}}_{\text{최근 } L\text{개월 경로}},\ \underbrace{x_{i-L+1:i}}_{\text{과거 } L\text{개월 경로}} \Big)$$

방법	닮은 과거를 고르는 기준	얻는 것	대가
① 단계 좌표	같은 거품 단계에 있던 과거	계산이 그대로이고 해석이 쉽다	단계 추정 오차가 그대로 들어간다
② 경로 relevance	**속도와 무관하게 같은 모양의 경로**	**'몇 달째인가'(지속성)를 담는다**	**계산량이 크고 L을 골라야 한다**

①은 이 시리즈의 상태벡터 예에 이미 들어 있던 방법이고, 가상 실험과 케이스에는 아직 쓰지 않았습니다

②는 relevance의 약점이던 지속성 무시를 직접 보완합니다 — 이 강의의 확장 제안입니다

relevance는 지금과 닮았을수록, 평소와 다를수록 높습니다

Czasonis·Kritzman·Turkington — 정규분포 우도와 정보 이론에서 유도한 점수

두 성분

유사도 + 정보량

- 평범한 달은 약하다
- 닮은 이례가 이끈다

가중치를 데이터가 정한다



relevance는 '어떤 과거를 믿을지'를 데이터가 정하게 하는 방법입니다

유사도와 정보량을 더하면 두 편차 벡터의 내적 하나로 정리됩니다

과거와 현재를 각각 평균에서 잰 편차로 바꾸면 이차항이 서로 상쇄된다 (워크북 W6-1)

정의 — 유사도(거리의 음수) + 두 시점 정보량의 평균

$$r_{it} = \underbrace{-\tfrac{1}{2}(x_i - x_t)^\top \Omega^{-1}(x_i - x_t)}_{\text{유사도}} + \underbrace{\tfrac{1}{2}\left[(x_i - \bar{x})^\top \Omega^{-1}(x_i - \bar{x}) + (x_t - \bar{x})^\top \Omega^{-1}(x_t - \bar{x})\right]}_{\text{정보량}}$$

정리형 — 계산식

$$\underbrace{r_{it}}_{\text{관련성}} = \underbrace{(x_i - \bar{x})^\top}_{\text{과거 편차}} \Omega^{-1} \underbrace{(x_t - \bar{x})}_{\text{현재 편차}}$$

현재와 같은 방향으로 평균에서 멀리 떨어진 과거가 가장 높은 점수를 받습니다

평균 근처의 평범한 달은 현재와 가까워도 점수가 낮습니다

relevance 상위만 남기고 그 가중으로 조건부 평균과 공분산을 만듭니다

부분 표본 회귀(partial sample regression) · y(i+1) = 과거 시점 i 다음 달의 주식·채권 수익

부분 표본과 가중치 — 최솟값을 빼서 0부터 가중한다

$$\underbrace{\mathcal{S}_t}_{\text{부분 표본}} = \{\, i : \; r_{it} \geq r_t^{(q)} \,\} \qquad \omega_{it} = \frac{r_{it} - \min_{j \in \mathcal{S}_t} r_{jt}}{\sum_{j \in \mathcal{S}_t} \left(r_{jt} - \min r \right)}$$

조건부 평균과 공분산

$$\underbrace{\hat{\mu}_t}_{\text{조건부 평균}} = \sum_{i \in \mathcal{S}_t} \omega_{it}\, y_{i+1} \qquad \underbrace{\hat{\Sigma}_t}_{\text{조건부 공분산}} = \sum_{i \in \mathcal{S}_t} \omega_{it}\, (y_{i+1} - \hat{\mu}_t)(y_{i+1} - \hat{\mu}_t)^\top$$

상위 q%만 남겨야 관련 없는 과거가 '지금 같은 때'의 결과를 묻지 않습니다

국면 확률을 따로 계산하지 않습니다 — 닮은 과거가 곧 국면 혼합 역할을 합니다

fit은 이번 예측을 얼마나 믿을지 알려 주는 신뢰도입니다

원 논문의 fit = 가중치와 실현 결과의 상관 제곱 · 이 시리즈는 그 과거 순위를 신뢰도로 쓴다

fit과 신뢰도 순위

$$\mathrm{fit}_t = \rho^2\left(r_{it},\, y_{i+1}\right)_{i\in\mathcal{S}_t} \qquad \underbrace{c_t}_{\text{신뢰도}} = \mathrm{rank}\left(\mathrm{fit}_t \mid \mathrm{fit}_{1:t-1}\right) \in [0,1]$$

fit 높음

결과가 일관

한 방향을 가리킨다

fit 낮음

결과가 엇갈림

서로 말이 다르다

처음 보는 상황

기본 경로로 복귀

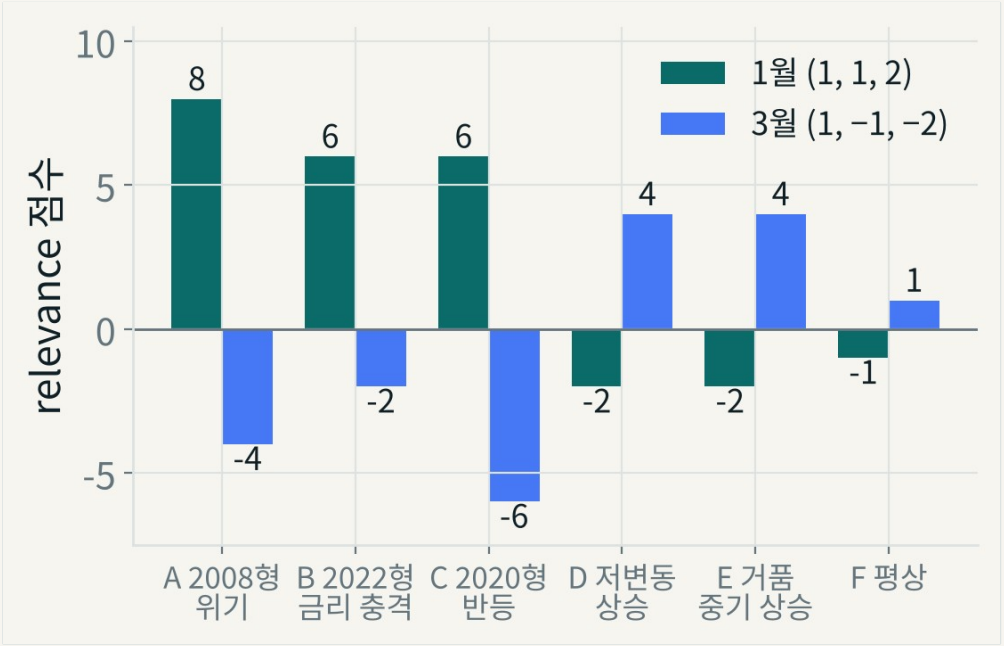
신뢰도가 이탈 폭을 줄인다

낯선 상황에서는 스스로 덜 움직이는 것이 relevance의 안전장치입니다

[케이스] 1월과 3월은 닮은 과거가 정반대로 갈립니다

1월 좌표 (1, 1, 2) · 3월 좌표 (1, −1, −2) · 점수 = 좌표 내적 · 상위 세 달만 쓴다 (워크북 W6-3)

과거 달	상태	1월	3월	다음 달
A 2008년형 위기	**(2, 2, 2)**	**8**	**−4**	**−3%**
B 2022년형 금리 충격	**(2, 0, 2)**	**6**	**−2**	**−1%**
C 2020년형 반등	**(0, 2, 2)**	**6**	**−6**	**+3%**
D 저변동 상승	(1, −1, −1)	−2	4	+1%
E 거품 중기 상승	(1, 1, −2)	−2	4	+2%
F 평상	(0, −1, 0)	−1	1	+0.5%



1월은 A·B·C(가중 0.4·0.3·0.3), 3월은 D·E·F(가중 4:4:1)가 닮은 과거로 뽑힙니다

닮은 과거를 따라가자 1월 목표는 44%, 3월 목표는 56%가 되었습니다

기대수익은 25%만 반영(수축) · 신뢰도 0.6 · 이탈 한도 ±10%p · 손실 점검 상한 안 (워크북 W6-3)

1월 · 닮은 과거 A·B·C

목표 44%

- 초과수익 연 −7.2%를 본다
- 25%만 반영하면 1.2%
- 손실확률 9.1%로 상한 안

글라이드보다 6%p 낮게

7.81

3월 · 닮은 과거 D·E·F

목표 56%

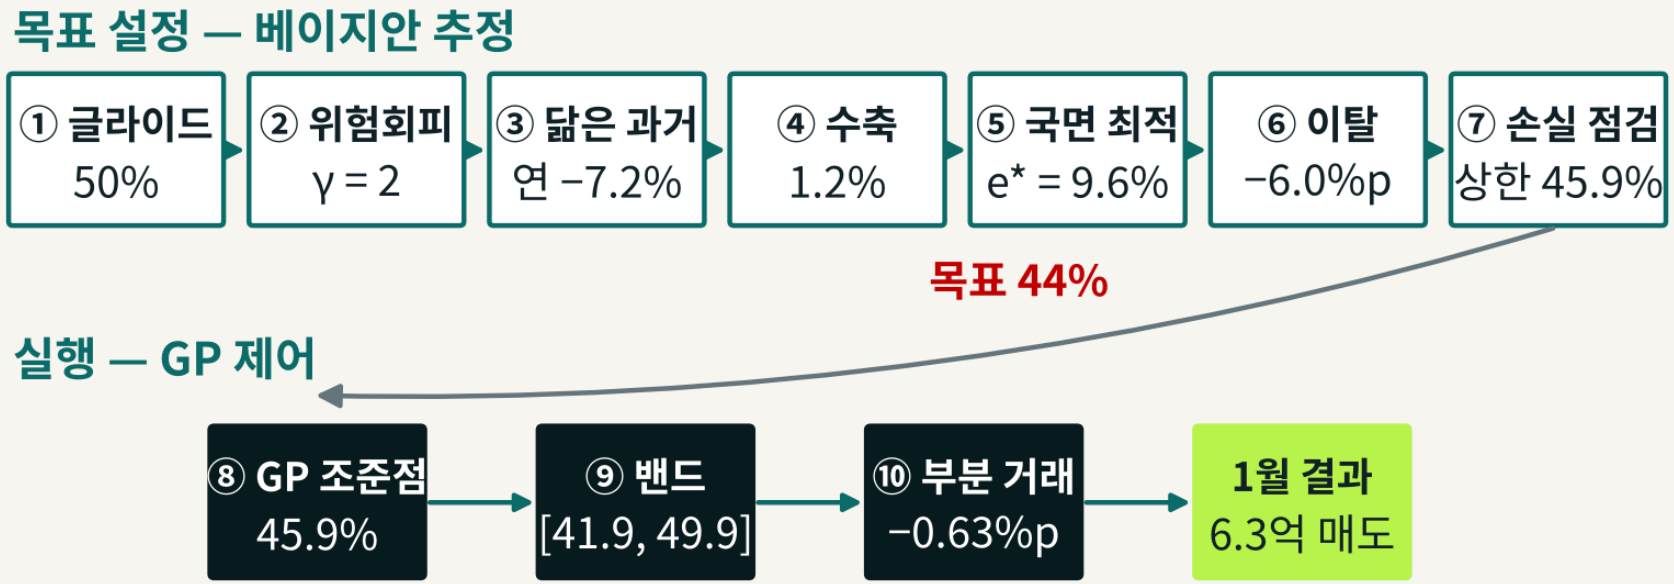
- 초과수익 연 +16.7%를 본다
- 25%만 반영하면 7.2%
- 손실확률 8.8%로 상한 안

글라이드보다 6%p 높게

같은 경보에서 목표가 12%p 벌어졌습니다 — 방향을 읽었습니다

목표는 일곱 단계로 정해지고, 실행은 세 단계로 이어집니다

1월 위기 달의 숫자 · 위 줄 = 무엇을 원하나(베이지안 추정) · 아래 줄 = 얼마나 움직이나(GP 제어)



목표는 글라이드를 앵커로 두고 닮은 과거의 정보만큼만 벗어납니다

목표가 정해져도 바로 가지 않습니다 — 조준점·밴드·부분 거래가 실제 움직임을 정합니다

목표 비중은 국면 최적 비중을 글라이드 주변으로 눌러 담은 값입니다

국면 최적 비중은 단기 Merton 비중이고, 위험회피는 글라이드에서 역산한다 (워크북 W6-3·W6-7)

① 국면 최적 비중

$$\underbrace{e^*}_{\text{국면 최적 비중}} = \frac{\overbrace{\mu_c}^{\text{수축한 초과수익}}}{\underbrace{\gamma(\tau)}_{\text{역산 위험회피}} \quad \underbrace{\sigma_k^2}_{\text{국면 분산}}}$$

② 목표 비중

$$\underbrace{w}_{\text{목표 비중}}^{\text{목표}} = \min\left\{ \underbrace{w_G}_{\text{글라이드}} + \underbrace{c}_{\text{신뢰도}} \underbrace{b}_{\text{이탈 한도}} \tanh\left(\frac{e^* - w_G}{b}\right), \underbrace{w_k^{\max}}_{\text{손실 점검 상한}} \right\}$$

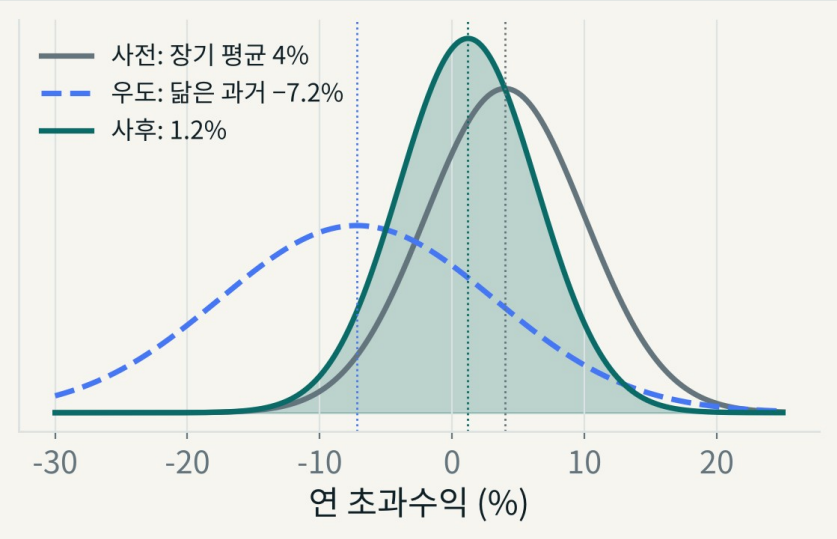
구성 요소	역할	1월 위기 달	3월 랠리 달
γ(τ) = 1 ÷ 글라이드	글라이드에서 위험회피를 역산한다	γ = 2	γ = 2
e* (국면 σ 사용)	그 국면만 보면 원하는 비중	9.6% (σ 25%)	90% (σ 20%)
c·b·tanh(·)	**이탈을 ±b 안으로 누르고 신뢰도만큼 줄인다**	**−6.0%p**	**+6.0%p**
손실 점검 상한	1년 손실확률 10%를 넘지 않는 상한	45.9% (통과)	59.3% (통과)

e*가 9.6%든 90%든 목표는 44%·56% — Merton 비중은 방향만, 크기는 tanh와 상한이 정합니다

25% 수축은 베이지안 사후 평균입니다

정규 사전(장기 평균)과 정규 우도(닮은 과거의 가중평균)의 사후 평균 · ω = relevance 가중치 (워크북 W6-7)

$$\underbrace{\mu \sim \mathcal{N}(\bar{\mu}, \tau^2)}_{\text{사전: 장기 평균}} \quad \underbrace{\hat{\mu} \mid \mu \sim \mathcal{N}\left(\mu,\ \sigma^2/n_{\text{eff}}\right)}_{\text{우도: 닮은 과거}} \Rightarrow \underbrace{\mu_c = \bar{\mu} + \kappa(\hat{\mu} - \bar{\mu})}_{\text{사후 평균}}$$



반영 비율 κ — 사전의 무게는 두 분산의 비율

$$\underbrace{\kappa}_{\text{반영 비율}} = \frac{n_{\text{eff}}}{n_{\text{eff}} + n_0} \qquad \underbrace{n_{\text{eff}}}_{\text{실효 표본}} = \frac{1}{\sum_i \omega_i^2}$$

	1월	3월
실효 표본 n_eff	2.94	2.45
κ (사전 무게 8.8개월)	0.25	0.22
사후 초과수익 → 목표	1.2% → 44%	6.8% → 56%

25%는 닮은 과거 약 3개월 대 장기 평균 약 9개월의 무게 비율입니다 — 표본에서 나옵니다

조준점과 밴드를 거치면 1월은 6.3억만 팔고 3월은 거래하지 않습니다

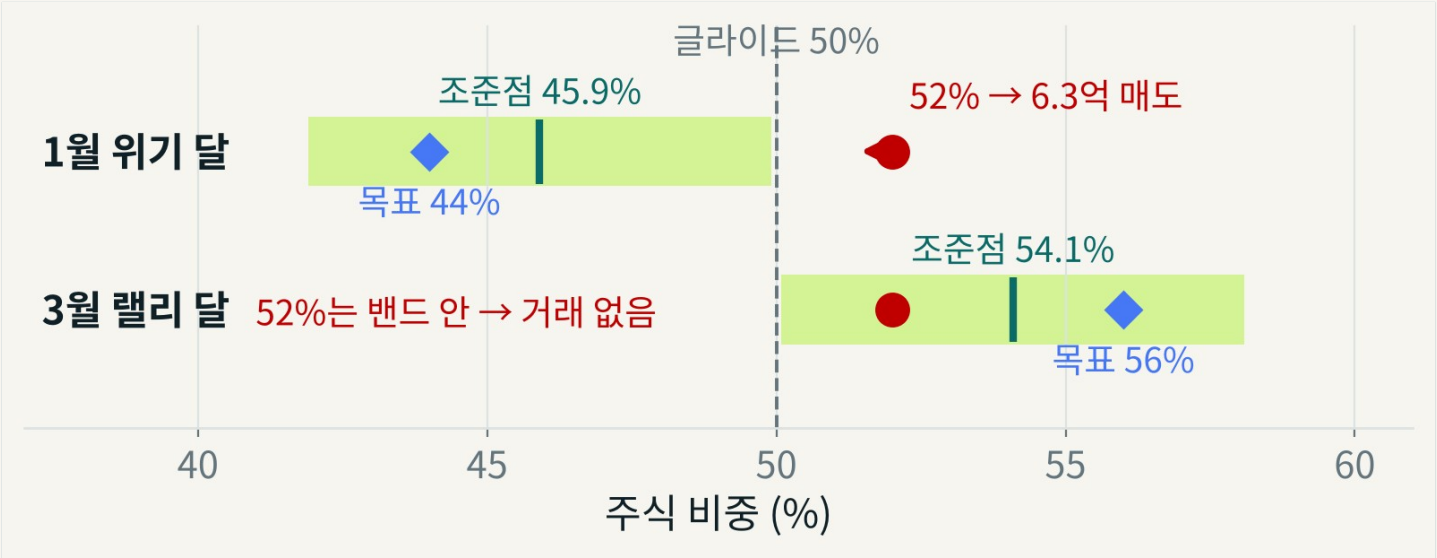
조준점 = 글라이드 + (목표 − 글라이드) × 0.682 · ±4%p 밴드 · 밴드 밖이면 경계까지의 30%만 거래

결정의 세 층

누가 정하나

- 목표는 닮은 과거가
- 거래 여부는 밴드가
- 거래량은 비용이

120억도 14.5억도 아니다



1월 조준점 45.9%는 밴드 [41.9, 49.9] 밖이라 매도하고, 3월 조준점 54.1%는 밴드 안이라 그대로 둡니다

조준점과 부분 거래는 Gârleanu·Pedersen의 동적 최적화 해입니다

Gârleanu·Pedersen (JF, 2013) · 신호 f가 수익을 예측하고 서서히 사라진다

목적 — 할인된 평균-분산 효용에서 이차 거래비용을 뺀다

$$\max_{\{x_t\}} \ \mathbb{E}\sum_t (1-\rho)^t \Big(\underbrace{x_t^\top \mu_t - \frac{\gamma}{2} x_t^\top \Sigma x_t}_{\text{평균-분산 효용}} - \underbrace{\frac{\lambda}{2} \Delta x_t^\top \Sigma \, \Delta x_t}_{\text{이차 거래비용}} \Big)$$

해 — 오늘 비중은 지난 비중과 조준점 사이의 가중평균

$$\underbrace{x_t = x_{t-1} + \frac{a}{\lambda}\big(\text{aim}_t - x_{t-1}\big)}_{\text{목표 쪽으로 일부만}} \qquad \underbrace{\text{aim}_t = (\gamma\Sigma)^{-1} B \left(I + \Phi\, a/\gamma\right)^{-1} f_t}_{\text{신호의 지속성을 반영한 조준점}}$$

조준점은 '지금 신호의 Markowitz 비중'이 아니라 '앞으로 사라질 신호까지 평균한 비중'입니다

그래서 조준점은 목표보다 덜 가고(φ < 1), 실제 비중은 조준점보다 덜 갑니다(a/λ < 1)

케이스의 0.682와 30%는 신호의 감쇠와 거래비용에서 나옵니다

위험회피 1로 정규화 · 거래비용 λ/γ ≈ 7.8 · 국면 신호의 월 감쇠 Φ = 0.2 (반감기 약 3.5개월) (워크북 W6-8)

$$\underbrace{\frac{a}{\lambda}}_{\text{거래 속도}} = \frac{-\gamma + \sqrt{\gamma^2 + 4\gamma\lambda}}{2\lambda} \quad (\rho \to 0) \qquad \underbrace{\phi}_{\text{조준 비율}} = \frac{1}{1 + \Phi\, a/\gamma}$$



비례 비용은 무거래 밴드를, 이차 비용은 부분 거래를 만듭니다 — 케이스는 둘을 함께 씁니다

국면 추정과 GP 실행은 LQG 제어처럼 따로 풀어도 됩니다

선형·이차·정규(LQG)에서는 추정과 제어를 나눠 풀어도 최적이다 — 분리 원리(separation principle)

추정은 필터가, 제어는 GP가 맡는다

$$\underbrace{\hat{s}_t = \hat{s}_{t|t-1} + K_t\left(y_t - \hat{y}_{t|t-1}\right)}_{\text{추정: 칼만·해밀턴 필터}} \quad \longleftrightarrow \quad \underbrace{x_t = x_{t-1} + \frac{a}{\lambda}\left(\text{aim}_t - x_{t-1}\right)}_{\text{제어: GP 거래}}$$

LQG 구성	이 강의에서	레벨
상태 추정 (칼만 필터)	해밀턴 필터 · relevance · 모형 평균이 다음 달 μ와 Σ를 낸다	L5~L7
목표 (기준 궤적)	글라이드 앵커 + 압축한 이탈 + 손실 점검 상한	L1·L6
제어 규칙 (LQR)	**조준점 φ와 거래 속도 a/λ — 비용이 정한다**	**L6·L7**
비용 함수	평균-분산 효용 − 거래비용	L7

※ 국면 전환 모형은 선형-정규가 아니라 분리 원리는 근사입니다 — 불확실할수록 조준 비율을 낮춥니다

같은 52%에서 국면을 읽는 법에 따라 이번 달 거래가 0에서 14.5억까지 갈립니다

1,000억 TDF 2036 · 같은 조준점 공식과 ±4%p 밴드 · 숫자는 설명용 가정

방법	국면 신호	1월 위기 달	3월 랠리 달
터뷸런스 단독 이진	d = 7.81 > 5.99	목표 40% · 14.5억 매도	목표 40% · 14.5억 매도
Kritzman 두 지표 (L4)	터뷸런스 z와 ΔAR z	목표 40% · 14.5억 매도	평상 판정 · 거래 없음
HMM 확률 (L5)	고변동 확률 0.77	목표 46.8% · 0.6억 매도	반등 쪽 우도 상승
relevance (L6)	**닮은 과거 석 달**	**목표 44% · 6.3억 매도**	**목표 56% · 거래 없음**

흡수비율을 보면 랠리 달의 오경보가 사라지고, relevance는 위기 달의 매도 규모까지 조절합니다

같은 경보를 판정·확률·좌표 중 무엇으로 읽느냐가 거래를 정합니다

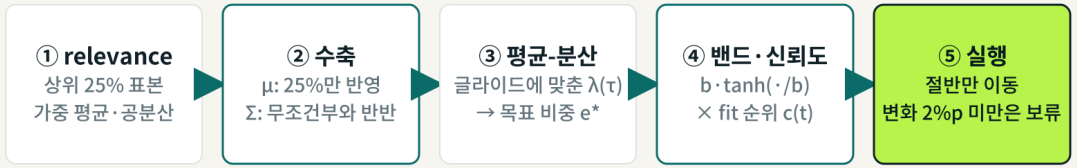
목표 비중은 글라이드에 묶인 비용 벌점 평균-분산 문제로 정합니다

λ(τ) = L5와 같은 역산 위험회피 · κ = 거래비용 벌점 · b(τ) = 허용 이탈 폭 · 실제 계산은 다섯 단계로 근사

원칙형 — 글라이드 앵커 + 이탈 제약 + 거래 벌점

$$w_t^* = \arg\max_{w} \ \hat{\mu}_t^\top w - \frac{\lambda(\tau)}{2} w^\top \hat{\Sigma}_t w - \underbrace{\kappa \, \|w - w_{t-1}\|_1}_{\text{거래비용 벌점}} \quad \text{s.t.} \quad |w - w_G(\tau)| \le b(\tau)$$

조건부 추정을 비중으로 옮기는 다섯 단계 — 각 단계가 과잉 반응을 한 겹씩 덜어 낸다



노이즈 억제 장치: ② 수축 · ④ 밴드와 신뢰도 · ⑤ 평활과 무거래 구간

연속 반영 자체는 회전율을 줄이지 않는다 — ⑤가 없으면 매달 조금씩 사고팔게 된다

②·④는 '얼마나 믿을까', ⑤는 '얼마나 빨리 따라갈까'를 정합니다

기대수익은 4분의 1만 반영하고, 비중 변화는 절반씩만 따라갑니다

조건부 평균은 추정오차가 커서 무조건부 쪽으로 강하게 수축(shrinkage)한다 (워크북 W6-2·W6-4)

② 수축

$$\mu_t^c = \bar{\mu} + 0.25\,(\hat{\mu}_t - \bar{\mu})$$

평균은 25%만 반영

$$\Sigma_t^c = 0.5\,\hat{\Sigma}_t + 0.5\,\bar{\Sigma}$$

공분산은 50%만 반영

④·⑤ 신뢰도 · 밴드 · 지수평활 — 이 뒤에 무거래 구간 2%p

$$\theta_t = \tfrac{1}{2}\,\theta_{t-1} + \tfrac{1}{2}\,c_t\,b\tanh\left(\frac{e_t^* - w_G}{b}\right) \qquad w_t = w_G(\tau) + \theta_t$$

위기 표본은 몇 건뿐이라 공분산을 반드시 무조건부와 섞어야 합니다

지수평활이 없으면 연속 신호가 매달 조금씩 거래를 만듭니다

연속 반영이 회전율을 줄이는 것은 평활이 있을 때뿐입니다

Δ = 국면 신호가 만드는 비중 차이 · N = 연간 전환 횟수 · Δp = 연속 신호의 월별 변화 (워크북 W6-5)

회전율의 두 가지 근사

$$TO_{\text{이진}} \approx \Delta \times N_{\text{전환}} \qquad TO_{\text{연속}} \approx \Delta \times \sum_{t} \left|\Delta p_t\right|$$

이진 · 연 4회 전환

120%p

연속 · 평활 있음 (월 0.08)

28.8%p

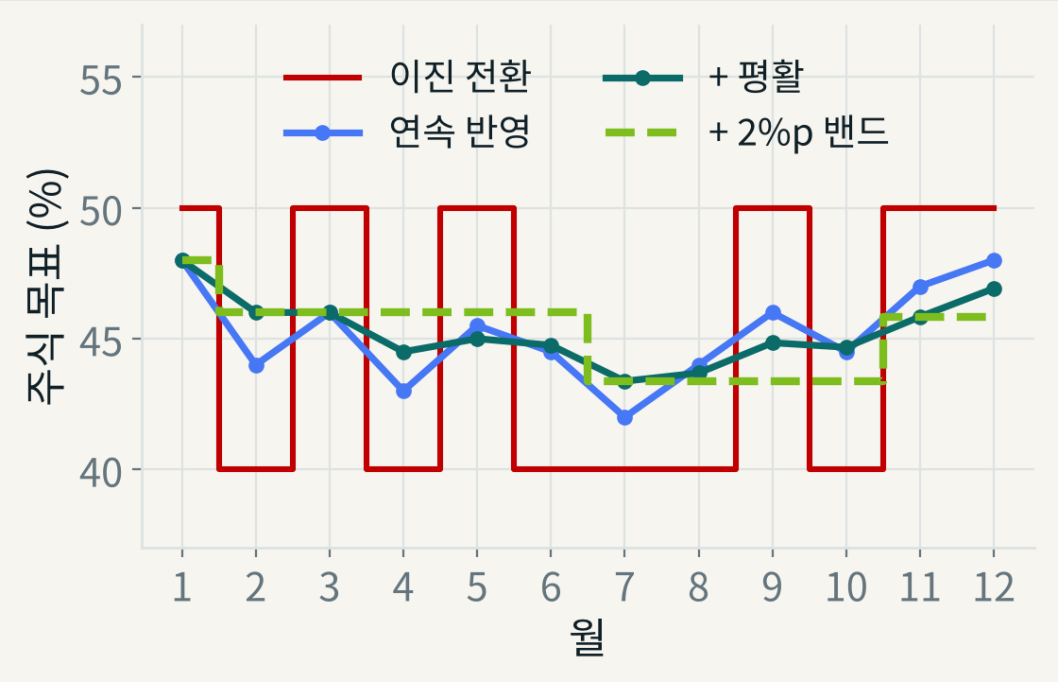
연속 · 평활 없음 (월 0.40)

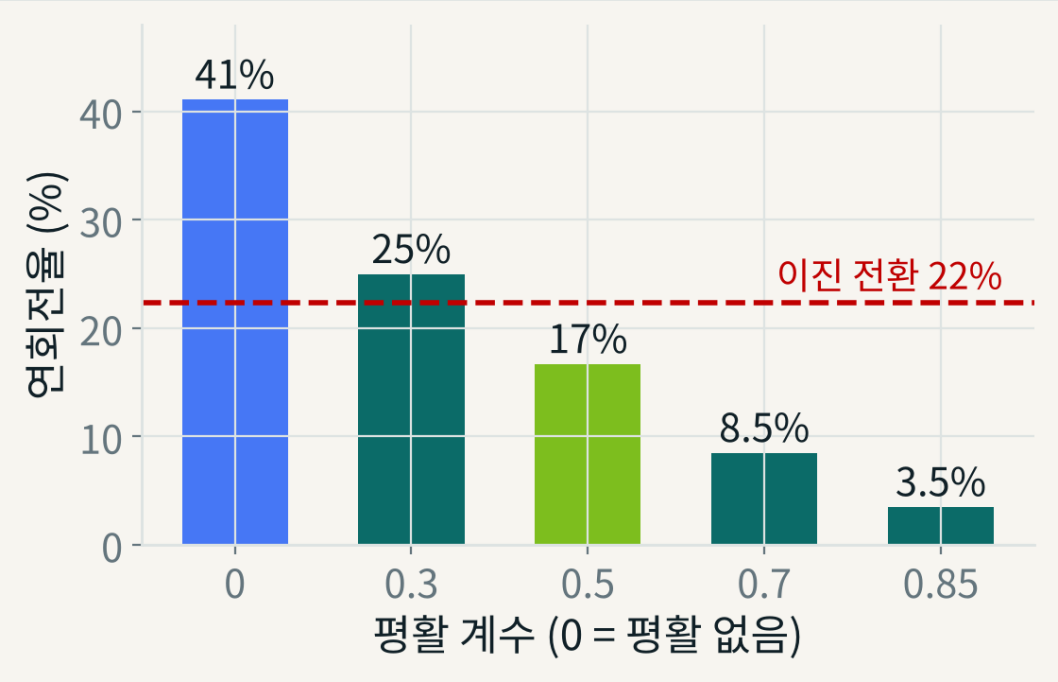
144%p

'연속이라 거래가 적다'는 말은 평활이 있을 때만 맞습니다

평활과 밴드가 회전율을 실제로 줄이는 장치입니다

왼쪽: 확률이 0.5 근처에서 흔들리는 12개월 손계산 · 오른쪽: 실데이터 평활 계수별 relevance 연 회전율

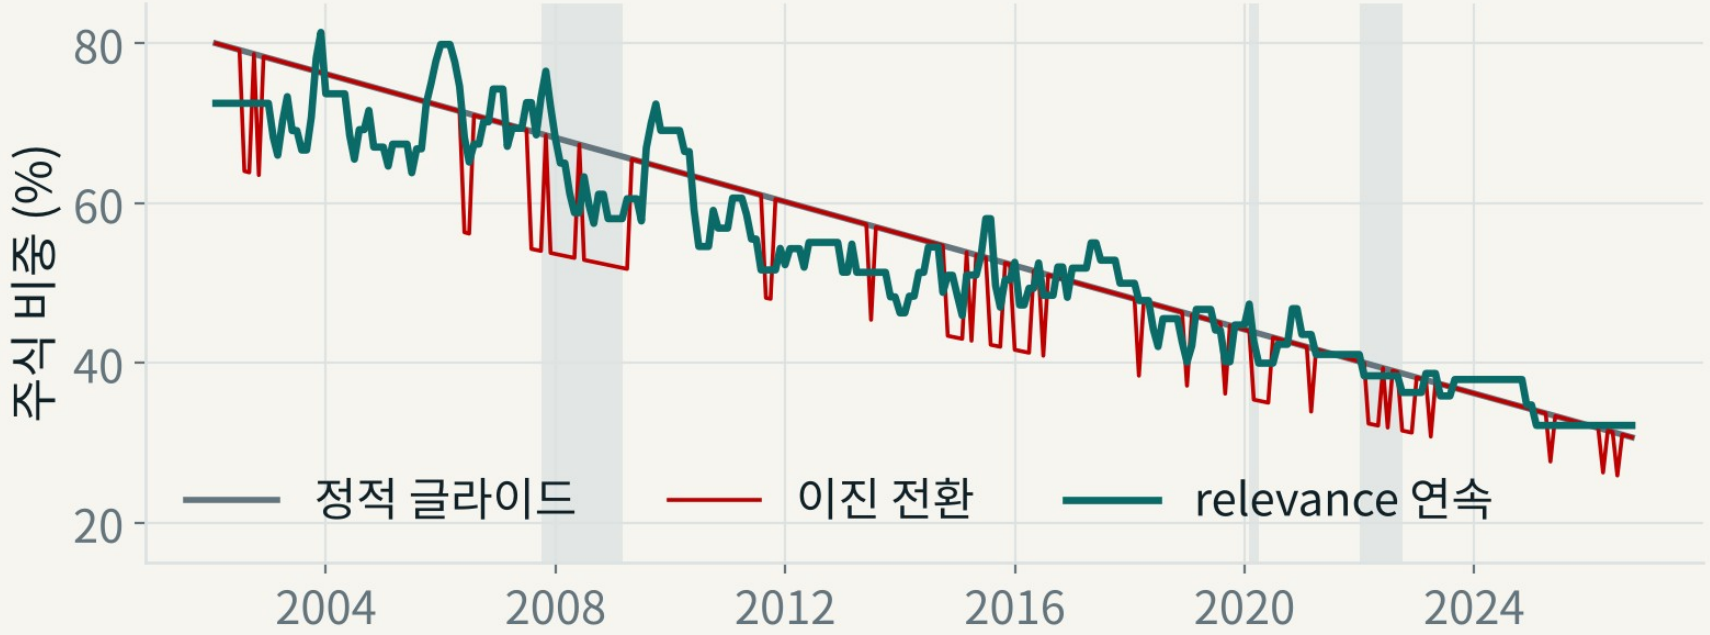




손계산에서 이진 80%p → 연속 24%p → 평활 9.5%p → 밴드 7.1%p, 실데이터에서 평활 없으면 41%입니다

25년 실데이터에서 relevance는 글라이드 곁을 완만하게 움직였습니다

Vanguard 펀드 7종(1996~) · 가상 TDF 2027 · 거래비용 10bp · 이탈은 평균 3.8%p, 최대 12%p



이진은 신호마다 계단처럼 꺾이고, relevance는 위기 직후 반등기에 오히려 비중을 늘렸습니다

실데이터에서 위기는 이진이 더 잘 막았고, 회전율은 평활이 낮췄습니다

2002~2026년 296개월 · 평활 0.5 기준 · 편도 10bp

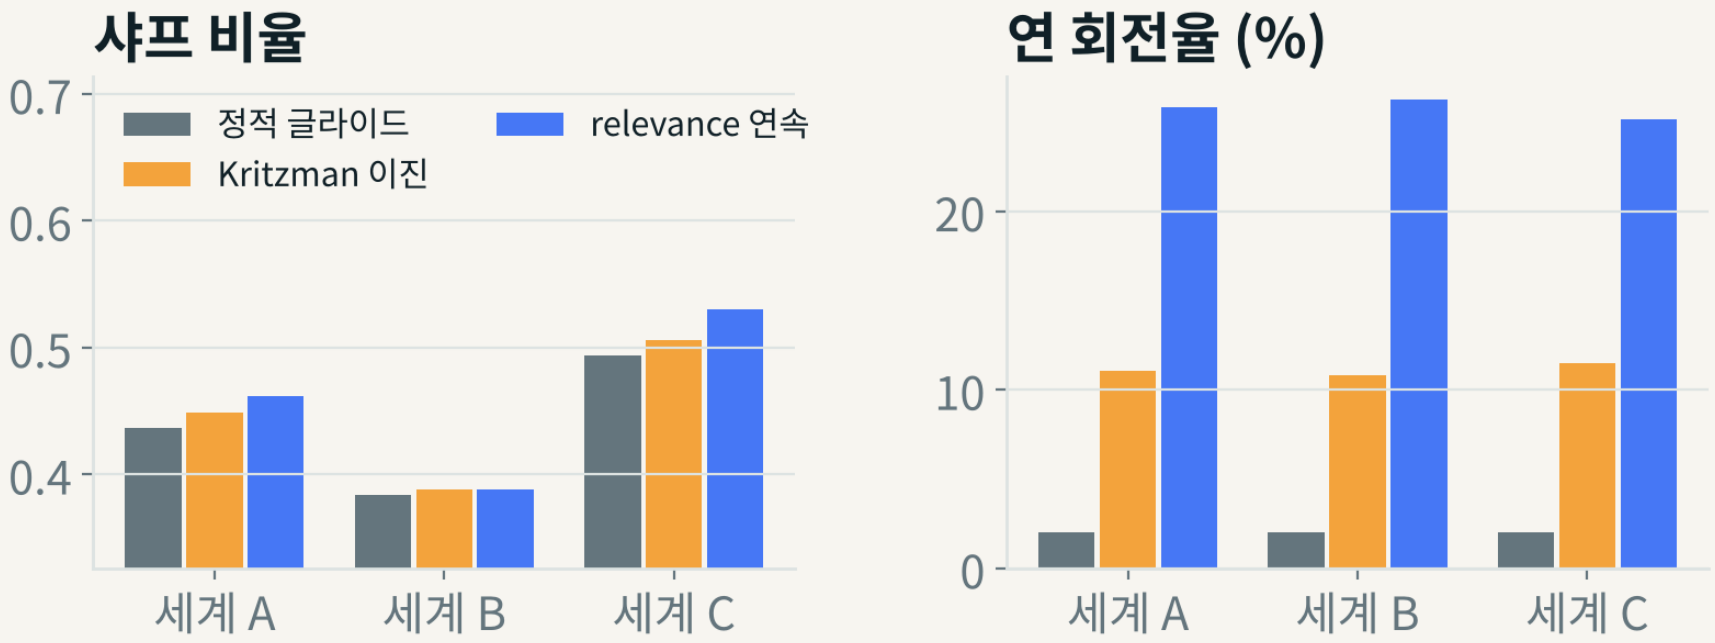
전략	샤프	최대낙폭	연 회전율	GFC 손실
정적 글라이드	0.65	−43%	2%	−33%
이진 전환	**0.71**	**−36%**	**22%**	**−28%**
relevance 연속	0.68	−40%	17%	−31%
평활 없는 relevance	0.68	−40%	41%	−31%

※ 한 번의 실데이터 경로는 우연의 몫이 큽니다 — 상태변수와 상위 비율은 홀드아웃에서 따로 검증합니다

그래서 가상 세계 150개 경로로 다시 봅니다

가상 세계에서 relevance는 정적 경로를 이겼지만 개선 폭은 작았습니다

세 세계 × 150개 가상 경로 평균 · 편도 10bp 차감 후



샤프(A·B·C) relevance 0.462·0.388·0.530 대 정적 0.436·0.383·0.494 — 강한 수축 탓입니다

relevance의 약점은 반등 국면의 오경보입니다

세계 A · 취약/반등 조정 = 그 국면 달의 평균 비중 조정(정적 글라이드 대비)

전략 (세계 A)	샤프	변동성	연 회전율	취약 조정	반등 조정
정적 글라이드	0.436	10.8%	2%	+0.0%p	+0.0%p
Kritzman 이진	0.449	10.7%	11%	−2.0%p	−0.4%p
relevance 연속	**0.462**	**10.2%**	**26%**	**−4.9%p**	**−3.5%p**

relevance는 반등 국면에서도 평균 −3.5%p 줄였습니다 — 반등 달의 71%에서 오경보입니다

지속성을 모르는 사례 기반 예측의 한계입니다

relevance를 쓸 때는 네 가지를 점검해야 합니다

원 논문과 실데이터 백테스트에서 확인된 주의점

주의점	문제	대응
표본 겹침	결과 구간이 겹치면 실효 표본이 줄어든다	비중첩 표본을 쓰고 Newey–West로 본다
극단 희소	위기 표본 몇 건으로 공분산을 추정한다	무조건부 공분산으로 수축한다
변수 과적합	상태변수와 q를 성과를 보고 고른다	adjusted fit과 홀드아웃으로 고른다
지속성 무시	**한 달 상태만 보고 판단한다**	**HMM 확률을 상태변수로(L7), 또는 경로 relevance(warp)**

마지막 줄의 처방이 L7 통합 설계의 첫 번째 장치입니다

L7

통합 — 모형 평균과 비용 인지 실행

두 예측기를 경쟁시키고 잘 맞힌 쪽에 비중을 주며, 거래는 비용이 정한다

HMM과 relevance는 '지금과 닮은 과거'를 모으는 방식만 다릅니다

HMM은 과거를 K개 국면 원형으로 압축하고, relevance는 N개 사례를 그대로 둔다

엇갈리는 약점

그래서 묶는다

- HMM은 끈적함을 안다
- relevance는 가정이 없다

약점이 서로 보완된다

같은 질문, 다른 기억 방식 — '지금과 닮은 과거'를 어떻게 모으는가

HMM · 베이지안 필터



과거를 K개 원형으로 압축

지금 각 원형일 확률 π로 섞는다

강점: 지속성(전이확률)을 안다

약점: 원형의 수·모양을 미리 정해야 한다

relevance (사례 기반)



과거 N개 사례를 그대로 둔다

지금과의 relevance로 가중평균

강점: 국면 정의·개수를 가정하지 않는다

약점: 지속성을 모르고, 드문 상황에 약하다

공통 약점은 회전율입니다 — 예측 쪽이 아니라 실행 쪽에서 따로 다룹니다

두 예측은 모두 과거의 가중 혼합이라 같은 틀로 채점할 수 있습니다

HMM의 가중치는 다음 달 국면 확률, relevance의 가중치는 관련성 — 둘 다 예측분포(μ, Σ)를 낸다

같은 형태의 두 혼합 예측

$$\underbrace{\hat{\mu}_{t+1}^{HMM} = \sum_{k=1}^{K} \pi_{t+1|t}(k)\,\mu_k}_{\text{K개 원형의 혼합}} \quad \longleftrightarrow \quad \underbrace{\hat{\mu}_{t+1}^{rel} = \sum_{i \in \mathcal{S}_t} \omega_{it}\, y_{i+1}}_{\text{N개 사례의 혼합}}$$

기준	HMM · 베이지안 필터	relevance
사전 가정	국면 수와 분포 형태를 정한다	상태변수만 고른다
강점	지속성과 전이 구조를 안다	모형 무가정이고 투명하다
약점	오설정되고 모수가 낡는다	끈적함을 모르고 희소 상황에 약하다

실현 수익으로 매달 두 예측분포를 채점해 비중을 정하는 것이 베이지안 모형 평균입니다

통합 구조는 네 가지 장치로 이루어집니다

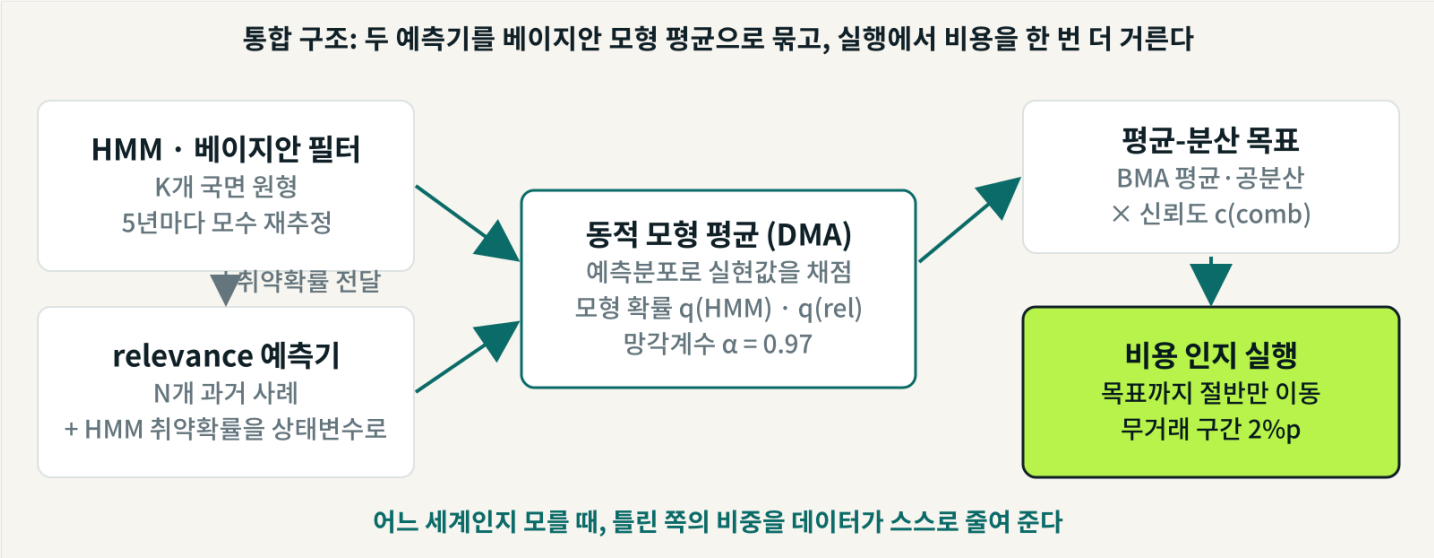
① 상태변수 확장 · ② 모수 재추정 · ③ 동적 모형 평균 · ④ 비용 인지 실행

역할 분담

고치고 묶고 거른다

- ①·②는 각각을 고친다
- ③은 둘을 묶는다
- ④는 거래를 거른다

L5의 갱신을 모형에



국면 확률을 갱신하던 베이즈 정리를 '모형 확률'에 한 층 끌어올린 구조입니다

취약 확률은 relevance에 넘기고, HMM 모수는 주기적으로 다시 추정합니다

relevance에 없던 지속성을 상태변수로 전달하고, HMM에 없던 적응성을 재추정으로 보탠다

① 필터 확률을 네 번째 상태변수로 · ② 5년마다 확장 창으로 재추정

$$x_t^+ = \left[\, x_t,\ \pi_{t|t}(\text{취약}) \,\right] \qquad \theta^{(j)} = \arg\max_{\theta}\ \log p\left(y_{1:t_j} \mid \theta\right),\quad t_j = t_0 + 60j$$

① 상태변수 확장

사례 검색이 끈적함을 본다

취약 확률이 '몇 달째인가'를 요약한다

② 모수 재추정

구조 변화를 따라간다

세계 B 같은 성격 변화에 대응한다

재추정은 L5의 평활 → EM 고리입니다 — 완전한 베이지안 HMM이라면 모수 사후분포를 매달 갱신합니다

동적 모형 평균은 두 모형의 확률을 매달 베이즈 정리로 갱신합니다

Raftery·Kárný·Ettler(2010) Dynamic Model Averaging · x(t) = 실현된 주식−채권 초과수익 (워크북 W7-2)

③ 모형 확률의 예측(망각)과 갱신

$$q_{t|t-1}(m) = \frac{q_{t-1}(m)^{\alpha}}{\sum_l q_{t-1}(l)^{\alpha}} \qquad q_t(m) = \frac{q_{t|t-1}(m)\, p_m(x_t \mid \mathcal{F}_{t-1})}{\sum_l q_{t|t-1}(l)\, p_l(x_t \mid \mathcal{F}_{t-1})}$$

α = 1

고정 가중 BMA

α = 0.97

약 33개월 기억

α가 작으면

빠르지만 잡음

L5의 해밀턴 필터와 똑같은 구조를 '국면' 대신 '모형'에 적용한 것입니다

모형 평균의 공분산에는 두 모형의 의견 차이가 위험으로 더해집니다

within = 각 모형이 보는 위험 · disagreement = 두 예측 평균이 서로 다른 정도 (워크북 W7-3)

모형 평균 예측분포의 공분산

$$\Sigma^{BMA} = \underbrace{\sum_m q(m)\,\Sigma_m}_{\text{모형 내 위험}} + \underbrace{\sum_m q(m)\,(\mu_m - \bar{\mu})(\mu_m - \bar{\mu})^\top}_{\text{모형 간 의견 차이}}$$

신뢰도 — HMM 몫은 그대로, relevance 몫은 fit 순위로 할인

$$c_t^{\text{통합}} = q_t(\text{HMM}) \cdot 1 + q_t(\text{relevance}) \cdot c_t$$

두 모형이 서로 다른 말을 할수록 위험이 커 보여 비중을 덜 움직입니다

모형 불확실성이 그대로 보수성으로 바뀝니다

실행은 목표까지 일부만 이동하고, 비용이 클수록 무거래 폭을 넓힙니다

L6의 GP 조준점을 통합 예측에 그대로 쓴다 · 비례 비용의 무거래 폭은 비용의 세제곱근에 비례 (워크북 W7-4)

④ 부분 매매 (이 실험은 κ = 0.5)와 무거래 폭

$$w_t = w_{t-1} + \kappa\left(\mathrm{aim}_t - w_{t-1}\right), \quad 0 < \kappa \le 1$$

$$\underbrace{\delta^*}_{\text{무거래 폭}} \propto \left(\frac{\overbrace{c}^{\text{거래비용}}}{\lambda}\right)^{1/3}$$

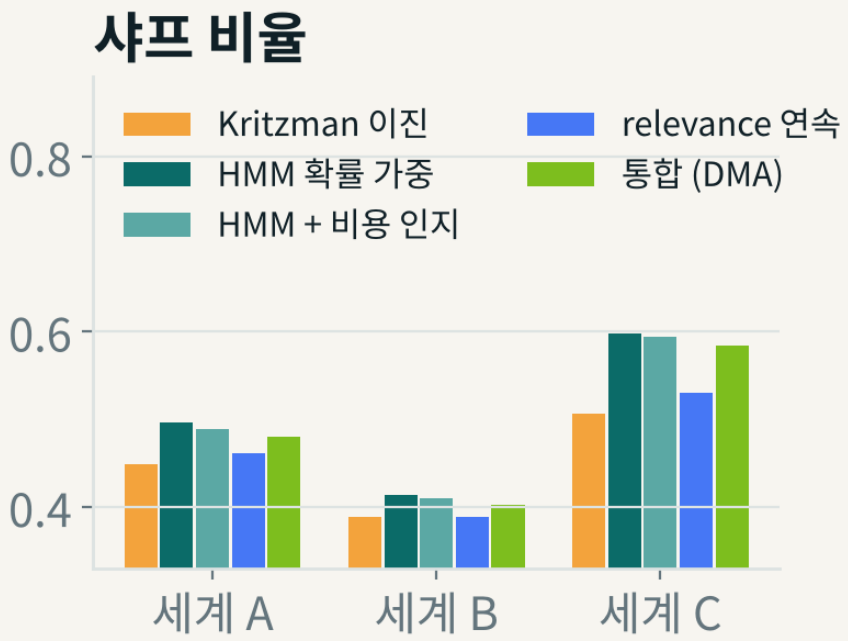
비용 3배	비용 8배	비용 27배
폭 1.44배	**폭 2배**	**폭 3배**

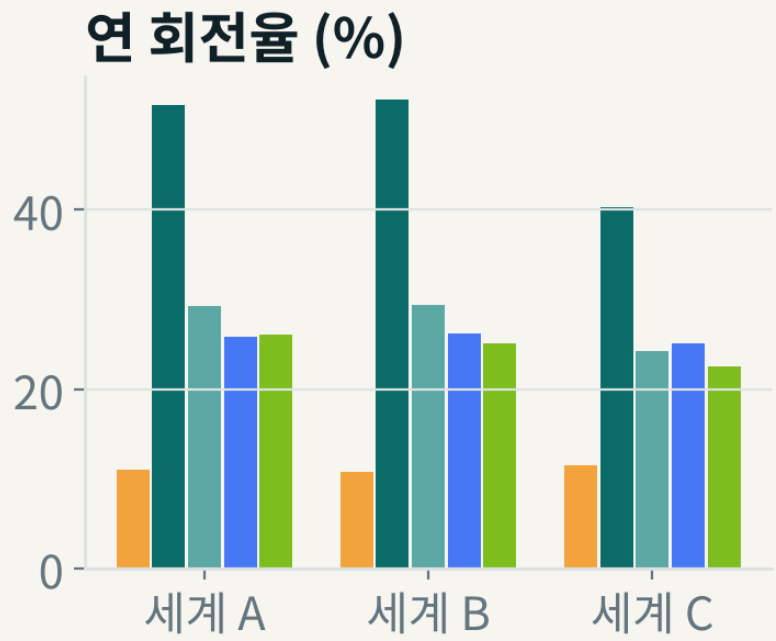
10bp에서 2%p였다면 80bp에서는 4%p가 적정 폭입니다

거래 빈도는 신호 품질이 아니라 비용 구조가 정해야 합니다

HMM이 샤프 최고였고, 통합은 그 근처에서 회전율을 절반으로 줄였습니다

세 세계 × 150개 가상 경로 평균 · 편도 10bp 차감 후





세계 A 샤프: HMM 0.496 · HMM+비용 0.488 · 통합 0.480 — 회전율 52% → 29% → 26%

통합은 어느 세계에서도 최고와의 차이가 작았습니다

최대 손실 = 세 세계 중 '그 세계 최고 샤프 − 이 규칙의 샤프'가 가장 큰 값 (minimax regret)

규칙	샤프 A	샤프 B	샤프 C	회전율 A	최대 손실
정적 글라이드	0.436	0.383	0.494	2%	0.103
Kritzman 이진	0.449	0.388	0.506	11%	0.091
HMM 확률 가중	0.496	0.413	0.597	52%	0.000
HMM + 비용 인지	0.488	0.410	0.594	29%	0.008
relevance 연속	0.462	0.388	0.530	26%	0.067
통합 (DMA)	**0.480**	**0.403**	**0.584**	**26%**	**0.016**

HMM의 최대 손실 0은 이 실험의 세계가 대부분 HMM에 가까웠기 때문입니다

relevance 단독(0.067)보다 통합(0.016)이 훨씬 안전합니다 — 모형을 모를 때의 보험입니다

모형 확률은 시기마다 움직이며 한쪽으로 쏠리지 않았습니다

같은 시드의 가상 경로 하나 · 망각계수 0.97 · 위로 갈수록 HMM 예측을 더 믿는다

해석

교체보다 분산

- 한 달로는 구분이 약하다
- 확률이 천천히 움직인다

모형 간 분산 투자



모형 평균은 '승자 교체'라기보다 '모형에 대한 분산 투자'로 작동합니다

실험의 교훈은 세 가지이며, 통합이 이기지 못한 부분도 그대로 적습니다

결과를 과장하지 않기 위한 정리

교훈	근거	실무 함의
실행 개선이 가장 싸다	HMM 회전율 52% → 29%, 샤프 차이 0.008	부분 매매부터 도입한다
모형이 맞으면 HMM이 강하다	세 세계 모두 HMM 샤프가 최고였다	국면 구조가 뚜렷한 자산군에 쓴다
모를 때는 묶는다	최대 손실 0.016 대 0.067	그림자 운영으로 확인한다

※ relevance는 보수적 설정(평균 25%만 반영)이라 과소평가됐을 수 있습니다 — 설정 민감도 점검이 남아 있습니다

L8

그 너머 — 세 축 글라이드패스

국면의 개수와 바뀌는 시점, 그리고 가입자 자신의 자산 수준까지 비중의 입력으로 삼는다

다섯 가지 확장이 세 축 글라이드패스로 모입니다

위 줄은 국면 추론을 고치고, 아래 줄은 목적함수를 넓힌다



위 줄은 '처음 보는 국면'에 대한 답이고, 아래 줄은 '누구의 TDF인가'에 대한 답입니다

국면의 개수와 바뀌는 시점도 데이터가 정하게 할 수 있습니다

sticky HDP-HMM (Fox 외, 2011) · Bayesian Online Changepoint Detection (Adams·MacKay, 2007)

sticky HDP-HMM — κ = 자기 전이에 더하는 가중으로 끈적함을 사전분포에 넣는다

$$p(s_t = j \mid s_{t-1} = k) \;\sim\; \mathrm{DP}\left(\alpha + \kappa,\; \frac{\alpha\beta + \kappa\,\delta_k}{\alpha + \kappa}\right)$$

BOCPD — run length ℓ = 마지막 변화점 이후 경과 기간의 사후분포

$$p(\ell_t \mid y_{1:t}) \;\propto\; \sum_{\ell_{t-1}} p\left(y_t \mid \ell_{t-1}, y^{(\ell)}\right) p(\ell_t \mid \ell_{t-1})\, p(\ell_{t-1} \mid y_{1:t-1})$$

세계 B처럼 국면의 성격이 바뀌면 새 상태를 만들거나 변화점을 선언합니다

'고정된 K개 국면'이라는 HMM의 가장 큰 가정을 푸는 방법입니다

도착점은 남은 기간·목표 대비 자산·국면 확률의 세 축 글라이드패스입니다

적응형 글라이드패스(Forsyth·Vetzal, 2019)와 국면 확률의 결합 · 신경망 정책으로 직접 학습할 수 있다

세 축 비중 함수

$$w_t = w\left(\underbrace{\tau}_{\text{남은 기간}},\ \underbrace{W_t/W^*}_{\text{목표 대비 자산}},\ \underbrace{\pi_{t+1|t}}_{\text{국면 확률}} \right)$$

τ · L1의 시간 축

회복할 시간

W / W* · 목표와의 거리

앞서면 위험을 줄인다

π · L3~L7의 국면 축

지금 시장의 상태

국면 정보는 세 축 중 하나일 뿐입니다 — 목적함수가 결과를 정합니다

Kritzman 계열의 후속 연구는 국면 정의와 글라이드의 정당성을 다듬었습니다

Kritzman 본인과 공동 연구자의 흐름

연구	핵심
Estrada·Kritzman (2019)	실패율 대신 coverage ratio를 쓰면 대부분 국가에서 공격적 배분(평균 주식 91%)이 최적이었다
Estrada·Kritzman (2020)	근로기간 마지막 25년간 위험회피가 약 두 배 커진다면 감소형 글라이드가 정당화된다
Kritzman·Kulasekaran·Turkington (2023)	국면을 이분법이 아니라 relevance로 정의해 연속적으로 섞는다
Kritzman·Turkington (2026)	제로금리 같은 정책 국면은 경제 국면과 깔끔히 대응하지 않아 SAA를 복잡하게 만든다

케이스의 위험회피 1.25(25년 전) → 3.33(목표일)은 2020년 논문의 '약 두 배' 조건과 같은 방향입니다

외부 연구는 상태에 반응하는 TDF의 근거를 쌓고 있습니다

같은 방향의 동적 글라이드패스 연구

연구	상태 변수	핵심 결과
Forsyth·Vetzal (2019) 'Are TDFs dinosaurs?'	현재 자산	HJB로 푼 적응형 전략이 최적 결정적 글라이드와 고정비율을 모두 크게 앞섰다
Gomes·Michaelides·Zhang (2019) Tactical TDF	분산위험프리미엄	주식수익 예측력을 단순 선형 규칙으로 비중에 반영한다
Clare·Seaton·Smith·Thomas (2019)	절대 모멘텀	인출률을 최대 연 50% 높이고 은퇴 초기 나쁜 수익 순서의 왼쪽 꼬리를 줄였다

공통 결론: 글라이드패스의 입력은 나이 하나가 아니라 '지금의 상태'까지 넓어지고 있습니다

[에피소드] 2022년처럼 주식과 채권이 함께 빠지면 피할 곳이 없습니다

2022년 1~10월 · 1,000억 TDF 케이스의 세 전략 모두 −13~14% · 안전자산이 국채·회사채뿐이었다

이번 강의가 푼 것

방향을 읽었다

- 위기 44% · 랠리 56%
- 6.3억 매도와 거래 없음

경보에 다른 답을 했다

2022년의 교훈

피할 곳이 없었다

- 정적 −13%, 이진 −14%
- relevance도 −14%

안전자산 바구니가 문제

국면 모형은 '얼마나 줄일지'만 정합니다 — 현금·물가연동채를 안전자산에 넣는 문제는 따로 남습니다

도입은 한 단계씩, 앞 단계를 이길 때만 올라갑니다

채택 조건 = 같은 비용 조건의 홀드아웃 구간에서 앞 단계보다 샤프와 최대낙폭이 모두 나을 것

단계	얹는 것	점검 지표	대응 레벨
1	정적 글라이드와 리밸런싱 밴드	추적 오차	L1
2	HMM 필터 확률과 부분 매매	회전율과 오경보율	L5·L7
3	relevance 예측기를 그림자로 운영	fit 분포와 예측 점수	L6
4	동적 모형 평균으로 통합	모형 확률과 최대 손실	L7
5	세 축 글라이드패스	목표 미달 확률	L8

각 단계는 설명 가능한 형태로 투자위원회 승인을 받아야 합니다 — 복잡도는 이길 때만 늘립니다

아홉 레벨은 위험을 무엇의 함수로 볼지를 한 단계씩 넓혀 왔습니다

레벨마다 질문 · 도구 · 이 강의의 답

레벨	질문	도구	답
L0	왜 주식을 줄이나	인적자본과 시뮬레이션	기간별 최적 비중이 곧 글라이드패스
L1	얼마나 줄이나	Equation 1~3	손실확률 5%면 91.8%에서 8.5%로
L2	위험은 일정한가	이동 변동성과 Exhibit 5	3.3~18.6% — 국면이 기간보다 크다
L3	지금 시장은 어떤가	터뷸런스·흡수비율·낙폭	이례성·결합도·방향의 세 칸
L4	규칙으로 바꾸면	임계값 판정	MDD 50% → 37%, 대신 오경보
L5	확률로 다루면	HMM과 해밀턴 필터	샤프 최고, 회전율 52%
L6	이름 없이 하면	relevance·베이지안 수축·GP	목표 44%·56%, 6.3억과 0
L7	모형을 모르면	동적 모형 평균과 aim	최대 손실 0.016, 회전율 절반
L8	누구의 TDF인가	세 축·HDP·BOCPD	τ · W/W* · π의 함수

시간은 위험을 줄이고, 국면은 그 위험을 다시 바꾸며, 모형 불확실성은 보수성으로 갚습니다

참고문헌 (1/4)

강의에서 인용한 논문과 책 — 레벨 순서

L0~L2 · TDF와 손실확률

Kritzman, M. (2017). Target-Date Funds: A Regime-Based Approach. The Journal of Retirement, 5(1), 96–105.

Estrada, J., & Kritzman, M. (2019). Toward Determining the Optimal Investment Strategy for Retirement. The Journal of Retirement, 7(1).

Estrada, J., & Kritzman, M. (2020). Target-Date Funds, Glidepaths, and Risk Aversion. Working paper, IESE Business School (SSRN).

Merton, R. C. (1969). Lifetime Portfolio Selection under Uncertainty: The Continuous-Time Case. Review of Economics and Statistics, 51(3), 247–257.

L3~L4 · 국면 지표와 이진 판정

Kritzman, M., & Li, Y. (2010). Skulls, Financial Turbulence, and Risk Management. Financial Analysts Journal, 66(5), 30–41.

Kritzman, M., Li, Y., Page, S., & Rigobon, R. (2011). Principal Components as a Measure of Systemic Risk. The Journal of Portfolio Management, 37(4), 112–126.

참고문헌 (2/4)

강의에서 인용한 논문과 책 — 레벨 순서

L3~L4 · 국면 지표와 이진 판정 (계속)

Kinlaw, W., & Turkington, D. (2014). Correlation Surprise. Journal of Asset Management, 14(6), 385–399.

L5 · HMM과 베이지안 갱신

Hamilton, J. D. (1989). A New Approach to the Economic Analysis of Nonstationary Time Series and the Business Cycle. Econometrica, 57(2), 357–384.

Kim, C.-J. (1994). Dynamic Linear Models with Markov-Switching. Journal of Econometrics, 60(1–2), 1–22.

Kritzman, M., Page, S., & Turkington, D. (2012). Regime Shifts: Implications for Dynamic Strategies. Financial Analysts Journal, 68(3), 22–39.

Nystrup, P., Madsen, H., & Lindström, E. (2018). Dynamic Portfolio Optimization across Hidden Market Regimes. Quantitative Finance, 18(1), 83–95.

참고문헌 (3/4)

강의에서 인용한 논문과 책 — 레벨 순서

L6 · relevance · warp · 베이지안 수축 · GP

Czasonis, M., Kritzman, M., & Turkington, D. (2022). Prediction Revisited: The Importance of Observation. Wiley.

Kritzman, M., Kulasekaran, C., & Turkington, D. (2023). Portfolio Construction When Regimes Are Ambiguous. The Journal of Portfolio Management.

Kritzman, M., Song, H., & Turkington, D. (2024). Dynamic Warp Analysis: A New Approach for Detecting and Timing Bubbles. The Journal of Portfolio Management, 50(6).

Gârleanu, N., & Pedersen, L. H. (2013). Dynamic Trading with Predictable Returns and Transaction Costs. The Journal of Finance, 68(6), 2309–2340.

L7~L8 · 통합과 확장

Raftery, A. E., Kárný, M., & Ettler, P. (2010). Online Prediction under Model Uncertainty via Dynamic Model Averaging. Technometrics, 52(1), 52–66.

Fox, E. B., Sudderth, E. B., Jordan, M. I., & Willsky, A. S. (2011). A Sticky HDP-HMM with Application to Speaker Diarization. Annals of Applied Statistics, 5(2A), 1020–1056.

참고문헌 (4/4)

강의에서 인용한 논문과 책 — 레벨 순서

L7~L8 · 통합과 확장 (계속)

Adams, R. P., & MacKay, D. J. C. (2007). Bayesian Online Changepoint Detection. arXiv:0710.3742.

Forsyth, P. A., & Vetzal, K. R. (2019). Optimal Asset Allocation for Retirement Saving: Deterministic vs. Time Consistent Adaptive Strategies. Applied Mathematical Finance, 26(1), 1–37.

Gomes, F., Michaelides, A., & Zhang, Y. (2022). Tactical Target Date Funds. Management Science, 68(4), 3047–3070.

Clare, A., Seaton, J., Smith, P. N., & Thomas, S. (2019). Absolute Momentum and Glidepath Investing. CAMA Working Paper 31/2019.

Kritzman, M., & Turkington, D. (2026). Policy Regimes versus Economic Regimes: Implications for Portfolio Construction. The Journal of Portfolio Management.

기본 비중은 목표일까지의 시간표가 정한다

국면은 판정하지 않고 확률과 닮은 과거로 섞는다

모를 때는 묶고, 거래는 비용이 정한다

국면 기반 TDF
레벨별 종합 강의

※ 가상 실험·케이스 수치는 설명용이다. 원 자료: Kritzman(2017, J. Retirement) · Hamilton(1989) · Czasonis·Kritzman·Turkington(2023) · Raftery 외 (2010) · Gârleanu·Pedersen(2013) · Forsyth·Vetzal(2019)