

HRP와 NCO

공분산 역행렬의 불안정을 다루는 두 가지 방법

HRP는 역행렬 없이 위에서 아래로, NCO는 군집 단위 MVO로 아래에서 위로 배분한다

HRP 3단계

RMT 디노이징

ONC 군집화

NCO 손계산

개요	HRP	디노이징	군집화	NCO	비교
----	-----	------	-----	-----	----

EXECUTIVE SUMMARY

한 장으로 보는 결론

López de Prado(2016, 2019)의 두 방법을 MVO와 비교한다.

문제	MVO의 해는 공분산 역행렬에 의존한다. 작은 고유값의 추정 오차가 가중치를 극단으로 밀어낸다
HRP	상관 트리를 따라 역분산 비율로 예산을 위에서 아래로 나눈다. 역행렬이 없고 결과는 long-only다
NCO	RMT로 잡음을 걷고 ONC로 군집을 찾은 뒤, 군집 안과 군집 사이를 따로 MVO로 푼다
결과	S&P 500 공매도 허용 GMV의 실현 변동성 20.9% → 14.6%(RMT). NCO는 짧은 표본에서 가중치 오차를 70% 줄인다

기대수익률을 믿기 어려우면 HRP, 알파 모델이 있으면 NCO가 기본 선택입니다

개요

HRP

디노이징

군집화

NCO

비교

CONTENTS

여섯 부분으로 설명합니다

01

MVO는 왜 불안정한가

역행렬 의존 · 기본 개념 · 두 대안

02

HRP

트리 군집화 · 준대각화 · 재귀적 이분

03

RMT 디노이징

마르첸코-파스투르 법칙 · S&P 500
실증

04

ONC 군집화

실루엣 계수 · 품질 점수 · 재귀 개선

05

NCO

네 단계 · 4자산 손계산 · 전체 MVO와
비교

06

무엇을 언제 쓰나

MVO · HRP · NCO 종합 비교

01

개요

평균-분산 최적화의 한계

해가 공분산 역행렬에 달려 있어 추정 오차가 증폭된다

01. MVO는 왜 불안정한가

평균-분산 최적화의 해는 공분산 역행렬에 달려 있다

MVO(Mean-Variance Optimization)의 최소분산(MV)·최대 샤프(MSR) 해.

$$w_{MV}^* = \frac{\Sigma^{-1} \mathbf{1}}{\mathbf{1}^\top \Sigma^{-1} \mathbf{1}}$$

$$w_{MSR}^* \propto \Sigma^{-1} \mu$$

역행렬 불안정 (Markowitz's curse)

- 상관이 높을수록 조건수가 커진다
- 작은 고유값이 역행렬에서 큰 값이 된다
- 작은 추정 오차가 가중치 왜곡으로 번진다

위험의 쏠림

- 상관 0.9 이상 자산 사이에 큰 롱·숏
- 위험이 특정 팩터·섹터에 몰린다
- 표본 밖에서 실현 위험이 커진다

HRP는 역행렬을 없애고, NCO는 역행렬을 작은 블록에만 씁니다

개요

HRP

디노이징

군집화

NCO

비교

01. MVO는 왜 불안정한가

네 가지 기본 개념만 알면 나머지를 따라갈 수 있다

이 자료에서 반복해서 쓰는 개념이다.

개념	뜻	쓰는 곳
공분산 행렬 Σ	N개 자산의 분산(대각)과 공분산(비대각)을 모은 $N \times N$ 표	모든 최적화의 입력
상관행렬 C	Σ 에서 변동성 크기를 걷어낸 행렬. 대각은 모두 1	디노이징 · 군집화
역행렬 Σ^{-1}	곱하면 단위행렬이 되는 행렬. 숫자로 치면 '나누기'	MVO 가중치 공식
고유값 λ · 고유벡터 e	행렬이 어느 방향(e)으로 얼마나 크게(λ) 퍼뜨리는지. 상관행렬은 합이 N	RMT 디노이징

0에 가까운 수로 나누면 결과가 폭발하듯, 0에 가까운 고유값이 역행렬을 키웁니다

01. MVO는 왜 불안정한가

| HRP는 위에서 아래로, NCO는 아래에서 위로 배분한다

두 방법 모두 입력은 공분산 행렬 Σ 다. NCO는 기대수익률 μ 도 쓸 수 있다.



갈림길은 역행렬입니다 — HRP는 쓰지 않고, NCO는 작은 블록에서만 씁니다

02

HRP

HRP — 역행렬 없는 하향식 배분

Hierarchical Risk Parity. 상관 트리를 따라 위험 예산을 나눈다

02. HRP

HRP는 세 단계로 위험 예산을 위에서 아래로 나눈다

López de Prado(2016). 거시에서 미시 순으로 배분한다. 단계별 그림 예시는 부록 A.

STEP 1**트리 군집화**

- 상관을 거리로 바꾼다
- 단일 연결법으로 묶는다
- 결과는 덴드로그램

**STEP 2****준대각화**

- 앞 순서로 Σ 를 재배치
- 비슷한 자산이 대각에 모임
- 큰 공분산이 대각 근처로

**STEP 3****재귀적 이분**

- 집합을 둘로 나눈다
- 역분산 비율로 예산 분할
- 앞까지 반복한다

분할 비율이 0과 1 사이라 가중치는 구조적으로 모두 양수입니다

개요

HRP

디노이징

군집화

NCO

비교


02. HRP

상관을 거리로 바꿔 트리를 만들고 행렬을 재배치한다

왼쪽은 0~1의 상관 거리, 오른쪽은 두 자산이 다른 자산들과 맺는 상관 패턴의 차이이다.

$$d_{i,j} = \sqrt{\frac{1}{2}(1 - \rho_{i,j})}$$

$$\tilde{d}_{i,j} = \sqrt{\sum_{n=1}^N (d_{n,i} - d_{n,j})^2}$$



준대각화 후에는 상관성이 높은 자산이 대각선 블록으로 드러납니다

※ 12자산·3팩터 블록 시뮬레이션 데이터

개요

HRP

디노이징

군집화

NCO

비교

02. HRP

두 부분의 대표 분산에 반비례해 예산을 나눈다

각 부분 k 의 역분산 가중치와 대표 분산 V_k 로 분할 비율 α 를 정한다.

$$\tilde{w}_k = \frac{\text{diag}(\Sigma_k)^{-1}}{\mathbf{1}^\top \text{diag}(\Sigma_k)^{-1} \mathbf{1}} \quad \tilde{V}_k = \tilde{w}_k^\top \Sigma_k \tilde{w}_k \quad \alpha = \frac{\tilde{V}_2}{\tilde{V}_1 + \tilde{V}_2}$$

$$W_{C_1} = \alpha W_{\text{parent}}, \quad W_{C_2} = (1 - \alpha) W_{\text{parent}}$$

분할 방식 두 가지

원 논문(2016)은 정렬된 목록을 개수 기준으로 반씩 자른다. 이후 실무 구현(Riskfolio-Lib 등)은 덴드로그램의 가지를 따라 자르는 방식을 많이 쓴다. 이 자료의 예제는 트리 기준이다.

분산이 큰 쪽이 적은 예산을 받습니다

개요

HRP

디노이징

군집화


NCO

비교

02. HRP

3자산 예제에서 HRP는 A 60.2%, B 15.1%, C 24.7%를 준다

$\sigma = (0.10, 0.20, 0.20)$, $\rho(A,B) = 0.8$, $\rho(A,C) = \rho(B,C) = 0.1$. 트리는 $(\{A, B\}, \{C\})$.



{A, B}의 대표 분산 0.01312 대 C의 0.04 $\rightarrow \alpha = 0.753$, 이어서 0.8 : 0.2로 나눕니다

개요

HRP

디노이징

군집화

NCO

비교

02. HRP

| HRP는 표본 내 분산을 조금 내주고 안정성을 얻는다

같은 Σ 로 세 방식을 계산한 결과. MVO는 제약 없는 최소분산이다.

방식	w(A)	w(B)	w(C)	포트폴리오 분산
HRP (트리 기준 분할)	60.2%	15.1%	24.7%	0.01078
HRP (원 논문, 개수 기준)	68.8%	15.6%	15.6%	0.01074
MVO 최소분산	115.3%	-30.0%	14.8%	0.00701

왜 B를 공매도하나

$\rho(A,B) = 0.8$ 이 $\sigma(A)/\sigma(B) = 0.5$ 보다 커서 최소분산 해가 B를 팔고 A에 레버리지를 건다. 상관 추정치가 조금만 바뀌어도 크게 흔들린다.

원 논문의 몬테카를로 실험에서 HRP의 표본 외 분산은 최소분산보다 낮았습니다

개요

HRP

디노이징

군집화


NCO

비교

02. HRP

추정 잡음 아래서 HRP 가중치의 흔들림은 MVO의 절반이다

같은 Σ 에서 60개월 표본을 1,000번 뽑아 가중치를 다시 추정했다.



시뮬레이션: 본문 3자산 Σ 에서 T = 60개월 표본을 1000회 추출해 추정한 가중치 분포 (상자 = 사분위, 수염 = 1.5 IQR).

자산별 표준편차 평균: MVO 8.4%p, HRP 4.1%p — HRP는 부호가 바뀌지 않습니다

※ 시뮬레이션 데이터

03

디노이징

RMT 디노이징 — 잡음 고유값 걸러내기

랜덤행렬이론(RMT)의 마르첸코-파스투르 법칙으로 신호와 잡음을 가른다

개요

HRP

디노이징

군집화

NCO

비교

03. RMT 디노이징

작은 고유값의 추정 오차가 역행렬에서 가장 크게 증폭된다

전역 최소분산(GMV) 가중치와 역행렬의 스펙트럼 분해.

$$w_{\text{GMV}} = \frac{\Sigma^{-1} \mathbf{1}}{\mathbf{1}^\top \Sigma^{-1} \mathbf{1}} \quad \Sigma^{-1} = \sum_{i=1}^N \frac{1}{\lambda_i} e_i e_i^\top$$

 $\lambda_i \rightarrow 0$

$1/\lambda_i$ 가 폭발한다. 최적화기는 그 방향을 '위험이 거의 없는 방향'으로 보고 큰 비중을 싣는다

 $N \approx T$

자산 수가 관측치 수에 비해 크면 작은 고유값은 대부분 표본 잡음이 만든 것이다

결과

예상 위험은 낮게, 실현 위험은 몇 배 높게 나온다. Michaud(1989)의 '오차 극대화기'

어느 고유값이 신호이고 어느 것이 잡음인지 가려내는 것이 디노이징입니다

개요

HRP

디노이징

군집화

NCO

비교

03. RMT 디노이징

| 순수 잡음이어도 표본 고유값은 정해진 구간에 퍼진다

$T \times N$ 원소가 독립이고 분산이 σ^2 일 때의 마르첸코-파스투르(MP) 법칙. $q = T/N$.

$$\lambda_{\pm} = \sigma^2 \left(1 \pm \sqrt{1/q} \right)^2 \quad f(\lambda) = \frac{q}{2\pi\sigma^2\lambda} \sqrt{(\lambda_+ - \lambda)(\lambda - \lambda_-)} \quad q = \frac{T}{N}$$

 $q = T/N$

자산 하나당 관측치 수
클수록 구간이 좁다

 $q = 4$ 일 때

구간 $[0.25\sigma^2, 2.25\sigma^2]$
 $0.25 \rightarrow$ 역행렬에서 4

두꺼운 꼬리

독립 $t(5)$ 수익률
표본 $[0.257, 2.235]$

판정

λ_+ 위: 신호
 λ_+ 아래: 잡음

λ_+ 보다 큰 고유값만 시장·섹터 같은 진짜 공통 요인으로 봅니다

개요

HRP

디노이징

군집화

NCO

비교

03. RMT 디노이징

| 잡음 분산 σ^2 를 1로 두면 신호를 잡음으로 잘못 가르다

시장 요인 λ_1 이 분산의 상당 부분을 가져가므로 잡음에 남는 분산은 1보다 작다.

$$\sigma^2 = 1 - \frac{\lambda_1}{N}$$

방법	계산	특징
A. 시장 요인 보정 (Laloux et al., 2000)	$\sigma^2 = 1 - \lambda_1/N$	가장 단순. 고유값 합 N에서 시장 몫을 뺀다
B. 밀도 적합 (López de Prado, 2020)	KDE와 $f(\lambda)$ 의 제곱오차 최소화	분포 전체를 쓴다. 커널 폭 선택 필요
C. 반복법	λ_+ 이하 고유값 평균을 σ^2 로 반복	λ_+ 가 가장 보수적(낮게)으로 잡힌다

신호가 뚜렷하면 세 방법의 신호 개수는 보통 같습니다

※ 모의 데이터(100자산·400관측·요인 5개): 세 방법 모두 신호 5개

개요

HRP

디노이징

군집화

NCO

비교

03. RMT 디노이징

| 디노이징은 여섯 단계로 구현한다

고유값 평탄화(eigenvalue clipping). Bouchaud & Potters(2009), López de Prado(2020).

- | | | |
|---|----------------------------------|--|
| 1 | 상관행렬 | $T \times N$ 수익률로 C 를 만든다. MP 법칙은 표준화 변수 기준이라 공분산이 아닌 상관에 적용 |
| 2 | 고유분해·정렬 | 대칭행렬용 eig로 분해하고 큰 순서로 정렬한다. eig는 순서를 보장하지 않는다 |
| 3 | $\sigma^2 \rightarrow \lambda_+$ | 방법 A~C 중 하나로 잡음 분산을 추정하고 상한 λ_+ 를 계산한다 |
| 4 | 신호 개수 k | λ_+ 보다 큰 고유값의 개수 |
| 5 | 평탄화 | $k+1$ 번째 이후 고유값을 그 평균으로 바꾼다. 고유값 합 N 이 유지된다 |
| 6 | 재조립·복원 | 행렬을 다시 만들고 대각을 1로 맞춘 뒤, 변동성을 곱해 Σ 로 되돌린다 |

파이썬 구현은 설명자료 3.2절의 `denoise_corr` 함수를 쓰면 됩니다

개요

HRP

디노이징

군집화

NCO

비교

03. RMT 디노이징

| 잡음 고유값만 평균으로 바꾸고 대각을 다시 1로 맞춘다

D 는 재조립 행렬의 대각, $\text{diag}(\sigma)$ 는 자산별 변동성 행렬이다.

$$\tilde{\lambda}_i = \begin{cases} \lambda_i, & \lambda_i > \lambda_+ \\ \bar{\lambda} = \frac{1}{N-k} \sum_{j>k} \lambda_j, & \lambda_i \leq \lambda_+ \end{cases} \quad \sum_i \tilde{\lambda}_i = \sum_i \lambda_i = N$$

$$\begin{aligned} \tilde{C} &= E \tilde{\Lambda} E^\top, & D &= \text{diag}(\tilde{C}) \\ C^{\text{dn}} &= D^{-1/2} \tilde{C} D^{-1/2}, & \Sigma^{\text{dn}} &= \text{diag}(\sigma) C^{\text{dn}} \text{diag}(\sigma) \end{aligned}$$

양정치 보장

잡음 고유값의 평균이 양수이므로 재조립한 행렬은 항상 역행렬이 존재한다. 최근접 상관행렬(nearest correlation) 보정 없이 대각 정규화만으로 충분하다.

충분산은 그대로 두고 작은 고유값만 끌어올리는 것이 핵심입니다

개요

HRP

디노이징

군집화


NCO

비교

03. RMT 디노이징

모의 데이터에서 신호 고유값 5개가 MP 상한 위로 튀어나온다

100자산 · 400관측 · 공통 요인 5개. σ^2 는 방법 C(반복법)로 적합했다.



시뮬레이션: $N = 100$, $T = 400$ ($q = 4$), 5개 공통 팩터. 잡음 분산 σ^2 를 반복 적합한 뒤, 상한 이하 고유값을 평균값으로 대체해 조건수를 낮춘다.

95개는 MP 밀도 안에 들어가고, 5개만 상한 1.43을 넘습니다

※ 시뮬레이션 데이터. 방법 B 기준 조건수 $53 \rightarrow 16$

개요

HRP

디노이징

군집화

NCO

비교

03. RMT 디노이징

| S&P 500 상관구조의 정보는 고유값 24개에 몰려 있다

364종목, 2016~2020년 일수익률($T = 1,258$, $q = 3.46$). 방법 A로 σ^2 를 보정했다.

152.6

λ_1 (시장 요인)
전체 분산의 41.9%

0.581

잡음 분산 σ^2
 $1 - \lambda_1/N$

1.373

MP 상한 λ_+
 $q = 3.46$

22 / 62

신호 고유값
설명 분산 67.7%

자료

현행 S&P 500 구성종목의 일별 수정종가(yfinance, 2016~2025)에서 결측 2% 초과 종목을 뺐다. 별도 실행 rmt_covariance_filter_lab.ipynb의 실행 결과다.

나머지 340개 고유값은 MP 밀도 안에 있어 잡음과 구별되지 않습니다

개요

HRP

디노이징

군집화


NCO

비교

03. RMT 디노이징

| 시장 요인 하나가 압도적이고 나머지는 MP 밀도 안에 있다

왼쪽: 상위 20개 고유값(로그 축). 오른쪽: 4 미만 고유값 분포와 σ^2 보정 MP 밀도.



상위 20개는 모두 λ_+ 위에 있고, 분포의 몸통은 MP 곡선을 따릅니다

개요

HRP

디노이징

군집화


NCO

비교

03. RMT 디노이징

신호 고유벡터는 실제 섹터 구조를 담고 있다

상위 4개 고유벡터의 종목별 적재값을 GICS 섹터별로 평균했다.



상위 세 요인의 의미

- PC1: 전 섹터 같은 부호 (시장)
- PC2: 방어주(+) 대 에너지(-)
- PC3: 기술(+) 대 유틸리티(-)
- ONC가 찾는 군집이 이 구조다

디노이징은 섹터 구조를 남기고 잡음만 걷어내므로 군집화가 안정됩니다

개요

HRP

디노이징

군집화

NCO

비교

03. RMT 디노이징

RMT 필터는 조건수를 표본 공분산의 1/58로 낮춘다

조건수 = 최대 고유값 ÷ 최소 고유값. 클수록 역행렬이 불안정하다.

82,916

표본 공분산
조건수

4,304

Ledoit-Wolf 수축추정
표본의 1/19

1,435

RMT 필터
표본의 1/58

왜 크게 바뀌나

개별 상관계수는 거의 바뀌지 않는다. 바뀌는 것은 작은 고유값이고, 최적화는 역행렬을 쓰므로 그 효과가 크게 나타난다.

RMT와 Ledoit-Wolf는 같은 문제를 푸는 두 가지 수축법입니다

개요

HRP

디노이징

군집화



NCO

비교

03. RMT 디노이징

필터 전후 개별 상관계수의 차이는 대부분 ± 0.1 안에 있다

왼쪽: (필터 - 원본) 상관행렬. 오른쪽: 비대각 원소 차이 분포(평균 -0.002 , 표준편차 0.039).



상관계수를 하나씩 보면 필터의 흔적이 거의 없지만 조건수는 약 58배 낮아집니다

개요

HRP

디노이징

군집화

NCO

비교

03. RMT 디노이징

| 표본 외 검증은 롤링 최소분산 포트폴리오로 한다

기대수익률 오차를 배제하고 공분산 추정의 질만 비교하려고 GMV를 쓴다.

$$\text{Bias ratio} = \frac{\sigma_{\text{realized}}}{\sqrt{w^T \Sigma^{\text{est}} w}}$$

$$\text{Turnover} = \frac{1}{2} \sum_i |w_{i,t} - w_{i,t-1}|$$

추정 창

504일(2년). $q = 504/364 \approx 1.4$ 로 표본 공분산이 특이행렬에 가까운 흔한 상황

재조정

21거래일마다 재추정하고 다음 21일 보유. 2018~2025년 95회

비교 대상

표본(Sample) · RMT · Ledoit-Wolf · 동일가중(1/N). 공매도 허용판과 롱온리판

편향비 1은 예상만큼 움직였다는 뜻이고, 1보다 크면 위험을 과소평가한 것입니다

개요

HRP

디노이징

군집화

NCO

비교

03. RMT 디노이징

공매도를 허용하면 RMT가 실현 변동성을 20.9%에서 14.6%로 낮춘다

공매도 허용 GMV, 연율. 2018~2025년 롤링 표본 외 결과.

추정량	실현 변동성	예상 변동성	편향비	월 회전을	총 노출	샤프
Sample	20.9%	4.2%	4.64	396%	15.4배	0.23
RMT	14.6%	6.8%	1.79	48%	4.8배	0.47
Ledoit-Wolf	14.6%	6.1%	2.16	114%	7.2배	0.59
1/N	20.8%	19.1%	0.98	0%	1.0배	0.68

표본 공분산은 레버리지 15배를 쓰고도 동일가중과 같은 변동성을 냈습니다

※ 현행 구성종목으로 과거를 본 생존 편향이 있어 샤프는 해석하지 않는다

개요

HRP

디노이징

군집화

NCO

비교

03. RMT 디노이징

| 롱온리 제약이 걸리면 추정량 사이의 차이가 사라진다

롱온리 GMV, 연율. 공매도 금지 제약 자체가 공분산 수축과 비슷한 효과를 낸다.

추정량	실현 변동성	예상 변동성	편향비	월 회전을	보유 종목	샤프
Sample	15.3%	11.1%	1.17	14%	35	0.55
RMT	15.4%	11.4%	1.14	13%	34	0.44
Ledoit-Wolf	15.2%	11.0%	1.17	13%	40	0.57
1/N	20.8%	19.1%	0.98	0%	364	0.68

세 추정량이 15.2~15.4%로 같습니다 — Jagannathan & Ma(2003)의 결과와 일치합니다

개요

HRP

디노이징

군집화




NCO

비교

03. RMT 디노이징

| 실현 변동성은 거의 모든 시점에서 표본 공분산이 가장 높다

왼쪽: 공매도 허용 GMV 실현 변동성(6개월 이동평균). 가운데: 편향비. 오른쪽: 롱온리 누적 가치.



RMT의 편향비도 1.79라 평탄화만으로 과소평가가 다 사라지지 않습니다

※ 비선형 수축(Ledoit & Wolf, 2020)이나 팩터모형 공분산을 추가로 검토할 이유

03. RMT 디노이징

공분산 필터링의 가치는 공매도 허용과 N/T에 달려 있다

NCO의 Step 2·4를 공매도 허용 MVO로 풀수록 디노이징의 효과가 커진다.

운용 상황		공분산 필터링의 가치
롱숏 · 리스크 패리티 · 팩터 중립 등 공매도 허용, N/T 큼		높음: 위험 예측, 레버리지, 회전율이 모두 크게 개선
리스크 모델링 · 위험예산 배분		높음: 편향비가 공분산 품질의 직접 지표
롱온리 · 비중 상한이 있는 운용		낮음: 제약이 이미 수축 역할
주의	T > N(q > 1)이 필요하다 · 자산이 수십 개 이상이어야 분포를 적합할 수 있다 · 시장 요인은 군집화를 방해할 수 있다 (디토닝)	

공매도를 허용하고 N/T가 클수록 공분산부터 필터링합니다 — RMT는 신호 요인을 명시적으로 보존합니다

04

군집화

ONC — 군집 수를 데이터가 정한다

Optimal Number of Clusters. 실루엣 계수로 분할의 품질을 잰다

개요

HRP

디노이징

군집화

NCO

비교

04. ONC 군집화

실루엣 계수는 자산이 제자리에 들어갔는지를 -1~1로 잰다

a_i = 같은 군집과의 평균 거리, b_i = 가장 가까운 다른 군집과의 평균 거리.

$$s_i = \frac{b_i - a_i}{\max(a_i, b_i)}$$

$$q_K = \frac{\text{mean}(s_1, \dots, s_N)}{\text{std}(s_1, \dots, s_N)}$$

 $s_i \approx 1$

우리 군집에 가깝고
남의 군집과 멀다

 $s_i \approx 0$

두 군집의 경계
1개짜리 군집은 0

 $s_i < 0$

다른 군집이 더 가깝다
잘못 배정

품질 점수 q

평균 ÷ 표준편차
모두 고르게 맞는 분할

평균만 보면 일부만 잘 맞는 분할도 높게 나와 표준편차로 나눕니다 — t값과 같은 모양입니다

개요

HRP

디노이징

군집화

NCO

비교

04. ONC 군집화

ONC는 여러 K를 시험하고 부진한 군집만 다시 나눈다

López de Prado(2020, 4장). 1~3은 기본 단계, 4~6은 재귀 개선 단계다.

- | | | |
|---|-----------|--|
| 1 | 거리 행렬 | (디노이징한) 상관행렬에서 $X = \sqrt{0.5(1 - C)}$. 각 행을 자산의 프로필로 쓴다 |
| 2 | 여러 K | $K = 2 \dots N-1$ 마다 K-평균을 초기값을 바꿔 여러 번(n_{init}) 돌린다 |
| 3 | 최고 분할 | 자산별 s_i 와 품질 점수 q 를 계산해 q 가 가장 큰 분할을 고른다 |
| 4 | 군집별 점검 | 군집마다 $t_k = \text{군집 안 } s_i \text{의 평균} \div \text{표준편차}$ |
| 5 | 부진 군집 재분할 | t_k 가 평균보다 낮은 군집이 2개 이상이면 그 자산만 모아 1~5를 다시(재귀) |
| 6 | 교체 판정 | 다시 나눈 결과의 평균 t 가 높을 때만 교체한다 |

크기가 다른 군집에서 작은 군집이 큰 군집에 묻히는 것을 막는 장치입니다

개요

HRP

디노이징

군집화



NCO

비교

04. ONC 군집화

12자산 시뮬레이션에서 ONC는 참 구조 3블록을 정확히 찾는다

참 구조 5·4·3개 3블록 + 공통 시장 요인, $T = 250$. K마다 K-평균을 20번 돌렸다.



시뮬레이션: 12자산(참 구조 5·4·3개 3블록 + 공통 시장 요인), $T = 250$. K마다 K-평균을 20번 돌려 가장 높은 q를 기록했다.

K = 3의 품질 점수 18.0이 다른 K(0.8~2.5)를 크게 앞섭니다

※ 시뮬레이션 데이터

05

NCO

NCO — 군집 안과 군집 사이를 나눠 푼다

Nested Clustered Optimization. 역행렬을 작은 블록에만 쓴다

개요

HRP

디노이징

군집화

NCO

비교

05. NCO

NCO는 부서별 예산 편성처럼 네 단계로 배분한다

부서를 나누고, 부서 안을 정하고, 사장은 부서 단위 예산만 정한다.

STEP 1

디노이징·군집화

- RMT로 잡음 제거
- ONC로 K개 군집



STEP 2

군집 내 MVO

- Σ_k 만 역행렬
- 군집 안 비중 w_k



STEP 3

축약

- 군집 = 합성 자산
- $W^T \Sigma W$ 로 축약



STEP 4

군집 간 MVO

- 합성 자산 비중 ω
- 최종 $w^* = W\omega$

비유

사장이 직원 수백 명의 예산을 한 명씩 정하면 작은 정보 오류가 전체 배분을 흔든다. 부서장이 부서 안을, 사장은 부서 단위만 정한다.

잡음이 큰 군집의 오차가 다른 군집 가중치로 번지지 않습니다

개요

HRP

디노이징

군집화

NCO

비교

05. NCO

기호 다섯 개가 NCO 계산의 전부다

오른쪽 값은 뒤의 4자산 예제(주식 2 · 채권 2)에서 나온 실제 값이다.

기호	뜻	크기	예제 값
Σ_k	Σ 에서 군집 k 자산의 행과 열만 잘라낸 작은 행렬	$n_k \times n_k$	2×2 두 개
w_k	군집 k 안에서의 비중. 합이 1	$n_k \times 1$	$w_1 = (0.769, 0.231)$
W	w_k 를 열로 쌓은 블록 대각 행렬. 행 = 자산, 열 = 군집	$N \times K$	4×2
$\hat{\Sigma}$	군집을 합성 자산으로 본 축약 공분산 행렬 $W^T \Sigma W$	$K \times K$	2×2
ω	군집 간 비중. 합이 1	$K \times 1$	$(0.146, 0.854)$

$\hat{}$ 은 '축약한 것', $\ast$ 은 '최종 답'이라는 표시입니다

개요

HRP

디노이징

군집화

NCO

비교

05. NCO

| 군집 간 비중 ω 는 세 가지 방식으로 구할 수 있다

Step 2 군집 내 최소분산 → Step 3 축약 → Step 4 군집 간 최적화 → 결합.

$$w_k = \frac{\Sigma_k^{-1} \mathbf{1}}{\mathbf{1}^\top \Sigma_k^{-1} \mathbf{1}} \quad \hat{\Sigma} = W^\top \Sigma W, \quad \hat{\mu} = W^\top \mu \quad \omega = \frac{\hat{\Sigma}^{-1} \mathbf{1}}{\mathbf{1}^\top \hat{\Sigma}^{-1} \mathbf{1}} \quad w^* = W \omega$$

방식	계산	쓰는 정보	특징
역분산	$\omega_k \propto 1 / (\text{군집 } k \text{ 분산})$	대각(군집 분산)만	단순·안정. 군집 간 상관 무시
최소분산 MVO	위 식의 ω	축약 행렬 전체	군집 간 상관 반영. 기본형
최대 샤프 MVO	$\omega \propto (\text{축약 행렬})^{-1} \times \mu\text{-hat}$	축약 행렬과 $\mu\text{-hat}$	알파(기대수익률) 반영

원형은 두 단계 모두 MVO이고, 역분산은 축약 행렬도 믿기 어려울 때의 보수적 변형입니다

개요

HRP

디노이징

군집화

NCO

비교

05. NCO · 손계산 예제

4자산 예제: 주식 두 개와 채권 두 개

상관: $\rho(A,B) = 0.5$, $\rho(C,D) = 0.4$, 주식-채권 0.2. 공분산 = $\rho \times \sigma \times \sigma$.

A · 대형주	B · 소형주	C · 국채	D · 회사채
$\sigma = 0.15$	$\sigma = 0.20$	$\sigma = 0.08$	$\sigma = 0.12$

$$\Sigma = \begin{pmatrix} 0.0225 & 0.0150 & 0.0024 & 0.0036 \\ 0.0150 & 0.0400 & 0.0032 & 0.0048 \\ 0.0024 & 0.0032 & 0.0064 & 0.00384 \\ 0.0036 & 0.0048 & 0.00384 & 0.0144 \end{pmatrix}$$

자산이 4개뿐이라 디노이징(Step 1-㉠)은 생략하고 군집화부터 계산합니다

개요

HRP

디노이징

군집화

NCO

비교

05. NCO · 손계산 예제

Step 1: 실루엣 품질 점수로 $K = 2$ 를 고른다상관 거리 $d(A,B) = 0.500$, $d(C,D) = 0.548$, 주식-채권 0.632 .

$$s_A = s_B = \frac{0.632 - 0.500}{0.632} = 0.209 \quad s_C = s_D = \frac{0.632 - 0.548}{0.632} = 0.134 \quad q = \frac{0.172}{0.038} = 4.55$$

후보 분할	K	실루엣 (A, B, C, D)	품질 점수 q
① {A, B} / {C, D}	2	0.209, 0.209, 0.134, 0.134	4.55
② {A, B} / {C} / {D}	3	0.209, 0.209, 0, 0	1.00
③ {A} / {B} / {C, D}	3	0, 0, 0.134, 0.134	1.00
④ {A, C} / {B, D}	2	-0.105, -0.105, -0.067, -0.067	-4.55

q가 가장 큰 ①을 택합니다 — 주식 군집 {A, B}, 채권 군집 {C, D}

개요

HRP

디노이징

군집화

NCO

비교

05. NCO · 손계산 예제

Step 2~3: 군집마다 최소분산을 풀고 두 펀드로 축약한다

군집 분산은 $1/(1^\top \Sigma_k^{-1} 1)$. 주식 펀드 0.02077(14.4%), 채권 펀드 0.00590(7.7%).

$$w_1 = \frac{\Sigma_1^{-1} \mathbf{1}}{\mathbf{1}^\top \Sigma_1^{-1} \mathbf{1}} = \frac{1}{48.15} \begin{pmatrix} 37.04 \\ 11.11 \end{pmatrix} = \begin{pmatrix} 0.769 \\ 0.231 \end{pmatrix} \quad w_2 = \frac{1}{169.48} \begin{pmatrix} 136.41 \\ 33.07 \end{pmatrix} = \begin{pmatrix} 0.805 \\ 0.195 \end{pmatrix}$$

$$\hat{\Sigma} = W^\top \Sigma W = \begin{pmatrix} 0.02077 & 0.00284 \\ 0.00284 & 0.00590 \end{pmatrix} \quad \hat{\rho}_{12} = \frac{0.00284}{\sqrt{0.02077 \times 0.00590}} = 0.26$$

두 자산 공식

$w_A = (\sigma_B^2 - \sigma_{AB}) / (\sigma_A^2 + \sigma_B^2 - 2\sigma_{AB}) = 0.025 / 0.0325 = 0.769$. 변동성이 낮은 대형주 A가 77%를 받는다.

4 × 4 문제가 변동성 14.4%와 7.7%, 상관 0.26인 2자산 문제로 줄었습니다

개요

HRP

디노이징

군집화

NCO

비교

05. NCO · 손계산 예제

Step 4: 역분산은 주식 22.1%, MVO는 14.6%를 준다

두 자산 최소분산 공식. 역분산은 군집 간 공분산을 0으로 둔 것과 같다.

$$\omega_1^{\text{MVO}} = \frac{\hat{\Sigma}_{22} - \hat{\Sigma}_{12}}{\hat{\Sigma}_{11} + \hat{\Sigma}_{22} - 2\hat{\Sigma}_{12}} = 0.146$$

$$\omega_1^{\text{IV}} = \frac{\hat{\Sigma}_{22}}{\hat{\Sigma}_{11} + \hat{\Sigma}_{22}} = 0.221$$

22.1 : 77.9

역분산 ω
분산 0.00557

14.6 : 85.4

최소분산 MVO ω
분산 0.00545

0.26

주식·채권 펀드 상관
역분산이 무시하는 값

해석

두 펀드가 같은 방향으로 조금 움직이므로 주식을 섞어 얻는 분산 효과가 역분산의 가정보다 작다. 군집 간 공분산 추정을 믿기 어렵다면 역분산이 더 보수적이다.

양(+)의 상관만큼 주식의 분산 효과가 작아 MVO가 주식 비중을 더 줄입니다

개요

HRP

디노이징

군집화

NCO

비교

05. NCO · 손계산 예제

최종 비중은 군집 간 비중과 군집 안 비중의 곱이다

 $w^*_i = \omega_k \times w_{k,i}$. 합은 1이다.

MVO 기준 최종 비중: A 11.2% · B 3.4% · C 68.7% · D 16.7%

개요

HRP

디노이징

군집화

NCO

비교

05. NCO

NCO의 분산은 전체 MVO보다 0.4% 높을 뿐이다

같은 Σ 로 네 방식을 비교했다. Σ 를 참값으로 주었으므로 전체 MVO가 표본 내 최선이다.

방식	A	B	C	D	분산	변동성
전체 MVO (4 × 4 역행렬)	13.5%	1.1%	70.1%	15.3%	0.00543	7.37%
NCO (군집 간 MVO)	11.2%	3.4%	68.7%	16.7%	0.00545	7.38%
NCO (군집 간 역분산)	17.0%	5.1%	62.7%	15.2%	0.00557	7.46%
동일가중	25.0%	25.0%	25.0%	25.0%	0.00931	9.65%

군집 간 상관이 정확히 0이면 NCO와 전체 MVO의 답은 같습니다

※ 이 예제는 주식·채권 상관이 0.2라 차이가 생겼다

개요

HRP

디노이징

군집화


NCO

비교

05. NCO

표본이 짧을수록 NCO의 가중치 오차 감소폭이 크다

50자산 · 10군집(군집 내 $\rho = 0.7$, 군집 간 $\rho = 0.2$), 최소분산, 표본 크기별 200회.



시뮬레이션: 50자산 · 10군집(군집 내 $\rho = 0.7$, 군집 간 $\rho = 0.2$), 최소분산, 표본 크기별 200회 반복. 군집 라벨은 참값 사용. T가 길면 군집 간 상관(0.2)을 단순화한 구조 편의가 드러나 MVO와 역전된다.

T = 60에서 오차를 11.3%p → 3.4%p로 70% 줄입니다

※ 시뮬레이션 데이터. T = 520에서는 구조 단순화의 편의로 MVO가 근소하게 앞선다

06

비교

무엇을 언제 쓰나

MVO · HRP · NCO를 같은 기준으로 비교한다

06. 무엇을 언제 쓰나

세 방법은 역행렬과 기대수익률을 다루는 방식이 다르다

종합 비교 ①: 구조.

평가 항목	MVO (마코위츠)	HRP	NCO
배분 방향	전역 최적화	하향식 (top-down)	상향식 (bottom-up)
역행렬	$N \times N$ 전체 Σ^{-1} 필수	불필요	군집 블록과 $K \times K$ 에만
기대수익률 μ	필수, 오차에 매우 민감	쓰지 않음 (위험 기반)	쓸 수 있음
공매도	제약식으로 조절 (QP)	구조적으로 long-only	제약에 따라 설정

HRP는 μ 를 버려 안정성을 얻고, NCO는 μ 를 유지하며 역행렬을 작게 나눕니다

06. 무엇을 언제 쓰나

표본 안에서는 MVO가, 표본 밖에서는 HRP·NCO가 낫다

종합 비교 ②: 성과와 권장 환경.

평가 항목	MVO (마코위츠)	HRP	NCO
다중공선성 내성	취약 (가중치 폭발)	우수	우수
표본 내 분산	가장 낮음	상대적으로 높음	MVO에 근접
표본 외 안정성	낮음	높음	높음
권장 환경	자산 수가 적고 추정이 안정적	공분산만 믿을 수 있는 대규모 멀티에셋	팩터 모형·알파 예측치가 있는 대규모 유니버스

기대수익률을 믿기 어려우면 HRP, 알파 모델이 있으면 NCO입니다

개요

HRP

디노이징

군집화

NCO

비교

06. 무엇을 언제 쓰나

| 두 방법 모두 공분산 추정의 품질에 기대고 있다

실무 적용 시 점검할 세 가지.

HRP

 μ 없이 쓰는 위험 분산

기대수익률 예측이 어렵고 자산 수가 많은 멀티에셋·시스템 트레이딩에서 가장 안정적이다.

알파 정보는 반영 못 함

NCO

알파를 유지하는 MVO

대규모 공분산 최적화의 수치 왜곡을 줄인다. 군집 수 K 와 디노이징 설정에 민감하다.

군집의 시간 안정성 점검

공통

전처리가 성과를 좌우

RMT 디노이징·Ledoit-Wolf 수축추정을 결합한다. 롱온리 제약이면 효과가 작아진다.

공매도 허용일수록 효과 큼

공분산을 먼저 정직하게 만들고, 그다음에 배분 방식을 고릅니다

HRP와 NCO가 답하는 질문

공분산 역행렬을 믿을 수 없을 때 어떻게 배분하는가

HRP는 역행렬을 버리고 상관 트리로 예산을 나눈다. NCO는 잡음을 건고 군집으로 문제를 쪼개 역행렬을 작게 쓴다.

어느 쪽이든 출발점은 공분산을 정직하게 추정하는 일이다.

A

부록


HRP 단계별 예시 — 원본 그림과 4자산 계산

MathWorks HRP 예제 화면으로 1·2단계를 보고, 3단계는 4자산 예시로 따라간다.

부록 A. HRP 단계별 예시 · 1단계

A-1 · 1단계는 상관을 거리로 바꿔 트리를 만든다

원본 예제는 14자산이다. 단일 연결(single linkage)로 덴드로그램을 그린다.



상관 거리 (원본 distCorr)

$$d_{ij} = \sqrt{\frac{1}{2}(1 - \rho_{ij})}$$

그림 읽는 법

- 색이 같은 가지는 먼저 묶인 군집
- 세로 높이는 합쳐질 때의 거리
- 앞 순서는 아직 정렬 전

상관이 높은 자산부터 묶여 네 개의 색 군집과 외톨이 자산 5·6이 생깁니다

개요

HRP

디노이징

군집화


NCO

비교


부록 A. HRP 단계별 예시 · 2단계

A-2 · 2단계는 앞 순서로 상관행렬을 다시 줄 세운다

준대각화(quasi-diagonalization) — 정렬된 앞 순서대로 행과 열을 재배열한다.



앞 순서로 재배열한 상관행렬



같은 순서의 덴드로그램

읽는 법

- 진한 파랑일수록 상관이 높다
- 같은 색 테두리가 한 군집
- 대각 블록 밖은 열다
- 3단계는 이 순서를 자른다

비슷한 자산이 대각 블록으로 모였으므로 3단계는 이 순서를 반씩 자르기만 하면 됩니다

개요

HRP

디노이징


군집화

NCO

비교

부록 A. HRP 단계별 예시 · 3단계

A-3 · 3단계는 네 동작을 잊까지 되풀이한다

원본은 재귀 이분을 자르기·임시 비중·반쪽 분산· α 배분의 네 동작으로 그린다.

① 순서를 반으로 자른다

$$\{2, 3, 1, 4\} \rightarrow \{2, 3\} \mid \{1, 4\}$$

② 반쪽 안 역분산 비중

$$w_i = \frac{1/Var_i}{\sum_j 1/Var_j}$$

③ 반쪽의 대표 분산

$$Var_{left} = w^T \Sigma_{left} w$$

④ α 로 예산을 나눈다

$$\alpha_{left} = \frac{Var_{right}}{Var_{left} + Var_{right}}, \quad W_i \leftarrow W_i \alpha$$

개요

HRP

디노이징

군집화




NCO

비교

부록 A. HRP 단계별 예시 · 3단계 원본

A-4 · 원본 화면은 4자산을 두 번 나눠 비중을 구한다

원본 애니메이션의 네 장면이다. 자산 순서는 2·3 | 1·4, 시작 비중은 모두 1이다.

① 반쪽마다 역분산 비중 $0.48 \cdot 0.52 / 0.51 \cdot 0.49$ ② 반쪽 분산 $0.49 \cdot 0.48 \rightarrow \alpha 0.49 \cdot 0.51$ ③ 1층 후 $W = 0.49 \cdot 0.49 \cdot 0.51 \cdot 0.51$ ④ 한 번 더 나눠 $0.24 \cdot 0.26 \cdot 0.26 \cdot 0.24$

다음 장부터

같은 흐름을 공분산 행렬 하나로 재현한다. 원본 수치는 반올림 표시다.

개요

HRP

디노이징

군집화

NCO

비교

부록 A. HRP 단계별 예시 · 4자산 예시

A-5 · 4자산 예시는 두 군집의 공분산에서 출발한다

원본 수치를 재현하도록 잡은 가상의 공분산이다. 상관은 군집 안 약 0.3, 군집 사이 약 0.07.

자산	②	③	①	④
시작 W	1	1	1	1
② 임시 w	?	?	?	?
③ 반쪽 분산				
④ α				
1층 후 W	?	?	?	?
2층 α	?	?	?	?
최종 W	?	?	?	?

공분산 행렬 (준대각화 순서)

자산	2	3	1	4
2	0.78	0.23	0.05	0.05
3	0.23	0.72	0.05	0.05
1	0.05	0.05	0.74	0.20
4	0.05	0.05	0.20	0.77

굵은 파랑 = 분산, 연파랑 칸 = 군집 안, 흰 칸 = 군집 사이

군집 사이 공분산 0.05는 3단계 계산에 쓰이지 않습니다 — 트리 구조로만 반영됩니다

원본 4자산 애니메이션의 수치(0.48·0.52, 0.49·0.48 ...)를 재현하도록 설정한 예시

개요

HRP

디노이징

군집화

NCO

비교

부록 A. HRP 단계별 예시 · ② 임시 비중

A-6 · ② 반쪽 안에서는 역분산 비율로 임시 비중을 정한다

분산이 작은 자산이 더 큰 임시 비중을 받는다. 자산 3(0.72)이 자산 2(0.78)보다 크다.

자산	②	③	①	④
시작 W	1	1	1	1
② 임시 w	0.48	0.52	0.51	0.49
③ 반쪽 분산				
④ α				
1층 후 W	?	?	?	?
2층 α	?	?	?	?
최종 W	?	?	?	?

왼쪽 반 {2, 3}

$$w_2 = \frac{1/0.78}{1/0.78 + 1/0.72} = 0.480, \quad w_3 = 0.520$$

오른쪽 반 {1, 4}

$$w_1 = \frac{1/0.74}{1/0.74 + 1/0.77} = 0.510, \quad w_4 = 0.490$$

임시 비중은 ③에서 반쪽의 분산을 구하는 데만 쓰입니다

원본 ① 장면: $w = 0.48 \cdot 0.52 \mid 0.51 \cdot 0.49$

개요

HRP

디노이징

군집화

NCO

비교

부록 A. HRP 단계별 예시 · ③ 반쪽 분산

A-7 · ③ 임시 비중으로 반쪽의 대표 분산을 구한다

임시 비중으로 만든 작은 포트폴리오의 분산이다. 반쪽 안의 분산·공분산만 쓴다.

자산	②	③	①	④
시작 W	1	1	1	1
② 임시 w	0.48	0.52	0.51	0.49
③ 반쪽 분산	0.489		0.477	
④ α	?		?	
1층 후 W	?	?	?	?
2층 α	?	?	?	?
최종 W	?	?	?	?

왼쪽 반 {2, 3}

$$\begin{aligned}\text{Var}_{\text{left}} &= 0.48^2(0.78) + 0.52^2(0.72) + 2(0.48)(0.52)(0.23) \\ &= 0.1797 + 0.1947 + 0.1148 = 0.489\end{aligned}$$

오른쪽 반 {1, 4}

$$\begin{aligned}\text{Var}_{\text{right}} &= 0.51^2(0.74) + 0.49^2(0.77) + 2(0.51)(0.49)(0.20) \\ &= 0.1925 + 0.1849 + 0.1000 = 0.477\end{aligned}$$

왼쪽 0.489가 오른쪽 0.477보다 크므로 왼쪽 반이 조금 더 위험합니다

원본 ② 장면: Var = 0.49 | 0.48 (반올림)

개요

HRP

디노이징

군집화

NCO

비교

부록 A. HRP 단계별 예시 · ④ α 배분

A-8 · ④ 분산이 작은 반쪽이 더 큰 예산을 받는다

 α 의 분자는 반대편 분산이다. 부모 예산 W 에 α 를 곱해 아래로 내려 보낸다.

자산	②	③	①	④
시작 W	1	1	1	1
② 임시 w	0.48	0.52	0.51	0.49
③ 반쪽 분산	0.489		0.477	
④ α	0.494		0.506	
1층 후 W	0.494	0.494	0.506	0.506
2층 α	?	?	?	?
최종 W	?	?	?	?

분할 비율

$$\alpha_{\text{left}} = \frac{0.477}{0.489 + 0.477} = 0.494$$

$$\alpha_{\text{right}} = 1 - 0.494 = 0.506$$

1층 후 예산

$$W_2 = W_3 = 1 \times 0.494 = 0.494$$

$$W_1 = W_4 = 1 \times 0.506 = 0.506$$

임시 비중 0.48·0.52는 버립니다 — W 에 곱해지는 것은 α 뿐입니다원본 ②·③ 장면: $\alpha = 0.49 \mid 0.51$, $W = 0.49 \cdot 0.49 \mid 0.51 \cdot 0.51$

개요

HRP

디노이징

군집화

NCO

비교

부록 A. HRP 단계별 예시 · 최종 비중

A-9 · 두 번째 분할에서 최종 비중이 확정된다

자산이 하나씩 남은 반쪽의 대표 분산은 그 자산의 분산이다.

자산	②	③	①	④
시작 W	1	1	1	1
② 임시 w	0.48	0.52	0.51	0.49
③ 반쪽 분산	0.489		0.477	
④ α	0.494		0.506	
1층 후 W	0.494	0.494	0.506	0.506
2층 α	0.480	0.520	0.510	0.490
최종 W	0.237	0.257	0.258	0.248

2층 분할 비율 — 짝의 몫은 1에서 뺀다

$$\alpha_2 = \frac{\text{Var}_3}{\text{Var}_2 + \text{Var}_3} = \frac{0.72}{0.78 + 0.72} = 0.480$$

$$\alpha_1 = \frac{\text{Var}_4}{\text{Var}_1 + \text{Var}_4} = \frac{0.77}{0.74 + 0.77} = 0.510$$

최종 비중 = 1층 후 W × 2층 α

$$W_2 = 0.494 \times 0.480 = 0.237, W_3 = 0.494 \times 0.520 = 0.257$$

$$W_1 = 0.506 \times 0.510 = 0.258, W_4 = 0.506 \times 0.490 = 0.248$$


자산이 둘뿐이면 α는 ②의 역분산 비중과 같습니다 — 네 비중의 합은 1.000입니다

원본 ④ 장면은 0.24 · 0.26 · 0.26 · 0.24로 표기한다(반올림 차이)

부록 A. HRP 단계별 예시 · 원본 결과

A-10 · 14자산에서 HRP는 모든 자산에 예산을 나눈다

원본 예제의 결과 화면이다. 같은 표본에서 평균-분산(MVO) 배분과 비교한다.



결과 읽기

- MVO는 7·8번 등 여러 자산에 0%
- HRP는 14자산 모두에 양의 비중
- 표본 위험: HRP 0.3982, MVO 0.3869
- 표본 안 최적화라 MVO가 조금 낮다

표본 안 위험은 MVO가 조금 낮지만, HRP는 역행렬 없이 고르게 분산합니다