알파 예측 · 켈리 베팅

알파 예측 공식과 켈리 베팅

알파 = IC × TE × 점수에서 켈리 비중까지

Alpha Forecasting Rule · Signal Score · Kelly Criterion

점수를 기대 액티브 수익률로 바꾸는 식을 증명하고, 점수와 확신의 차이를 짚은 뒤,
같은 식이 켈리 비중과 포트폴리오 성장률로 이어지는 과정을 도출한다.

세 가지 결론이 하나의 식으로 이어진다

IC: 정보계수 · TE: 추적오차 · 점수: 표준화한 신호

1

알파 = IC × TE × 점수는 액티브 수익률의 최선 선형 예측이다

신호와 수익률이 결합 정규분포면 조건부 기대값과 정확히 같다.

2

점수는 확신이 아니라 신호의 세기다

확신에 가까운 양은 IC × 점수, 즉 그 베팅의 예상 정보비율이다.

3

켈리 비중은 예상 정보비율을 추적오차로 나눈 값이다

켈리가 지는 위험은 예상 정보비율이고, 포트폴리오 성장률은 정보비율 제곱의 절반이다.

점수 → 알파 → 켈리 비중 → 실제 비중은 한 줄의 계산이다

01

기본 지식

용어와 켈리 기준

공식을 쓰기 전에 각 용어의 정의와 켈리 기준의 출발점을 정리한다

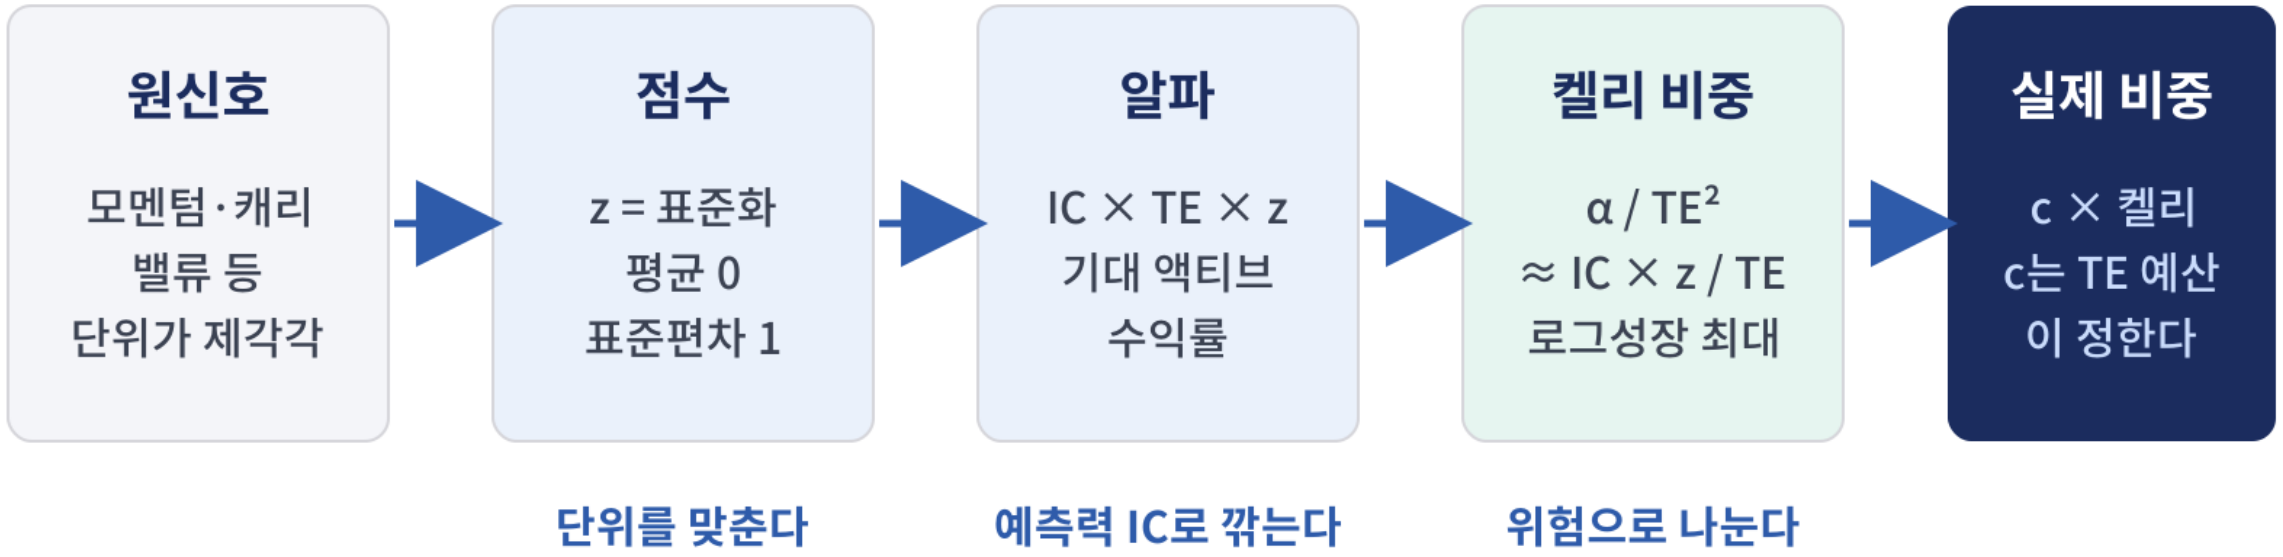
여섯 개의 용어가 이 강의의 전부를 이룬다

모든 수익률은 벤치마크 대비 액티브 수익률로 잰다

용어	정의	기호
액티브 수익률	벤치마크 대비 초과수익. 사전 기대값은 0이다	a
추적오차 (Tracking Error)	액티브 수익률의 표준편차, 즉 잔차 위험	TE
정보계수 (Information Coefficient)	신호와 다음 기간 액티브 수익률의 상관	IC
점수 (Score)	신호를 평균 0, 표준편차 1로 표준화한 값	z
정보비율 (Information Ratio)	기대 액티브 수익률을 추적오차로 나눈 값	IR
켈리 비중 (Kelly Fraction)	기대 로그성장률을 최대로 만드는 베팅 배수	f*

신호는 네 단계를 거쳐 포지션이 된다

단위를 맞추고, 예측력으로 깎고, 위험으로 나누고, 위험 예산을 적용한다



신호를 그대로 기대수익으로 쓰면 두 가지 오류가 생긴다

그래서 점수를 알파로 바꾸는 공식이 필요하다

예측은 늘 평균 쪽으로 끌려가야 한다 — 예측력이 약할수록 더 많이

오류 1 · 과대 베팅

- 예측력이 약한 신호도 큰 숫자를 내놓는다
- 최적화기는 그 숫자를 믿고 크게 건다

오류 2 · 위험 무시

- 변동성이 다른 자산을 같은 크기로 다룬다
- 같은 점수라도 위험이 큰 자산의 기대수익은 커야 한다

켈리 기준은 기대 로그성장률을 최대화하는 베팅 배수다

Kelly (1956) · 부(富)는 베팅 뒤 W(1 + f·a)가 된다

$$\underbrace{\mathbb{E}[\log(1+f\,a)]}_{\text{기대 로그성장률}} \;\approx\; f\mu - \tfrac{1}{2}f^2\,\mathbb{E}[a^2] \;\approx\; f\mu - \tfrac{1}{2}f^2\,\mathrm{Var}(a)$$

$$\frac{\partial}{\partial f}:\;\; \mu - f\,\mathrm{Var}(a) = 0 \;\Rightarrow\; \underbrace{f^*}_{\text{켈리 비중}} = \frac{\overbrace{\mu}^{\text{기대 초과수익}}}{\underbrace{\mathrm{Var}(a)}_{\text{분산}}}$$

왜 로그인가

- 로그성장률을 최대화하면 장기적으로 부가 가장 빨리 늘어난다

켈리 비중을 넘기면 성장률이 오히려 줄어든다

예: 알파 0.4%, TE 4% · 성장률은 켈리의 2배에서 0이 된다



02

알파 예측 공식

알파 = IC × TE × 점수와 그 증명

그리놀드 공식의 변동성 자리에 추적오차를 넣은 형태다

알파는 정보계수, 추적오차, 점수의 곱이다

Grinold (1994) · 예측 대상은 총수익률이 아니라 액티브 수익률이다

$$\underbrace{\alpha_i}_{\text{알파}} = \underbrace{\mathrm{IC}}_{\text{정보계수}} \times \underbrace{\mathrm{TE}_i}_{\text{추적오차}} \times \underbrace{z_i}_{\text{점수}}$$

$$\underbrace{a_i = r_i - r_{B,i},}_{\text{액티브 수익률}} \qquad \underbrace{z_i = \frac{s_i - \mathbb{E}[s]}{\mathrm{Std}(s)},}_{\text{신호 표준화}} \qquad \underbrace{\mathrm{IC} = \mathrm{Corr}(a, s)}_{\text{신호와 수익의 상관}}$$

총수익률 공식과의 관계

- 그리놀드 공식의 변동성 자리에 추적오차를 넣은 형태다

최선 선형 예측의 기울기는 공분산을 분산으로 나눈 값이다

증명 ① 평균제곱오차를 최소화하는 선형식을 구한다

$$\min_{c,\,b}\ \mathbb{E}\Big[\big(a - c - b\,(s - \mathbb{E}[s])\big)^2\Big] \ \Rightarrow\ c = \mathbb{E}[a] = 0, \qquad b = \frac{\mathrm{Cov}(a,s)}{\mathrm{Var}(s)}$$

$$\mathrm{Cov}(a,s) = \underbrace{\mathrm{IC}}_{\text{상관}} \cdot \underbrace{\mathrm{TE}}_{a\text{의 표준편차}} \cdot \underbrace{\mathrm{Std}(s)}_{\text{신호의 표준편차}}$$

읽는 법

- 사전 기대값이 0이므로 절편은 0이다
- 상관의 정의로 공분산을 세 항의 곱으로 나눈다

공분산을 대입하면 알파 예측 공식이 나온다

증명 ② 신호의 표준편차가 약분되고 점수만 남는다

$$\hat{a} = \frac{\mathrm{IC}\cdot\mathrm{TE}\cdot\mathrm{Std}(s)}{\mathrm{Var}(s)}\,(s - \mathbb{E}[s]) = \mathrm{IC} \times \mathrm{TE} \times \frac{s-\mathbb{E}[s]}{\mathrm{Std}(s)} = \mathrm{IC} \times \mathrm{TE} \times z$$

성립 조건

- 결합 정규분포면 선형 예측이 조건부 기대값과 같다
- 정규성이 없어도 최선 선형 예측으로는 성립한다

의미

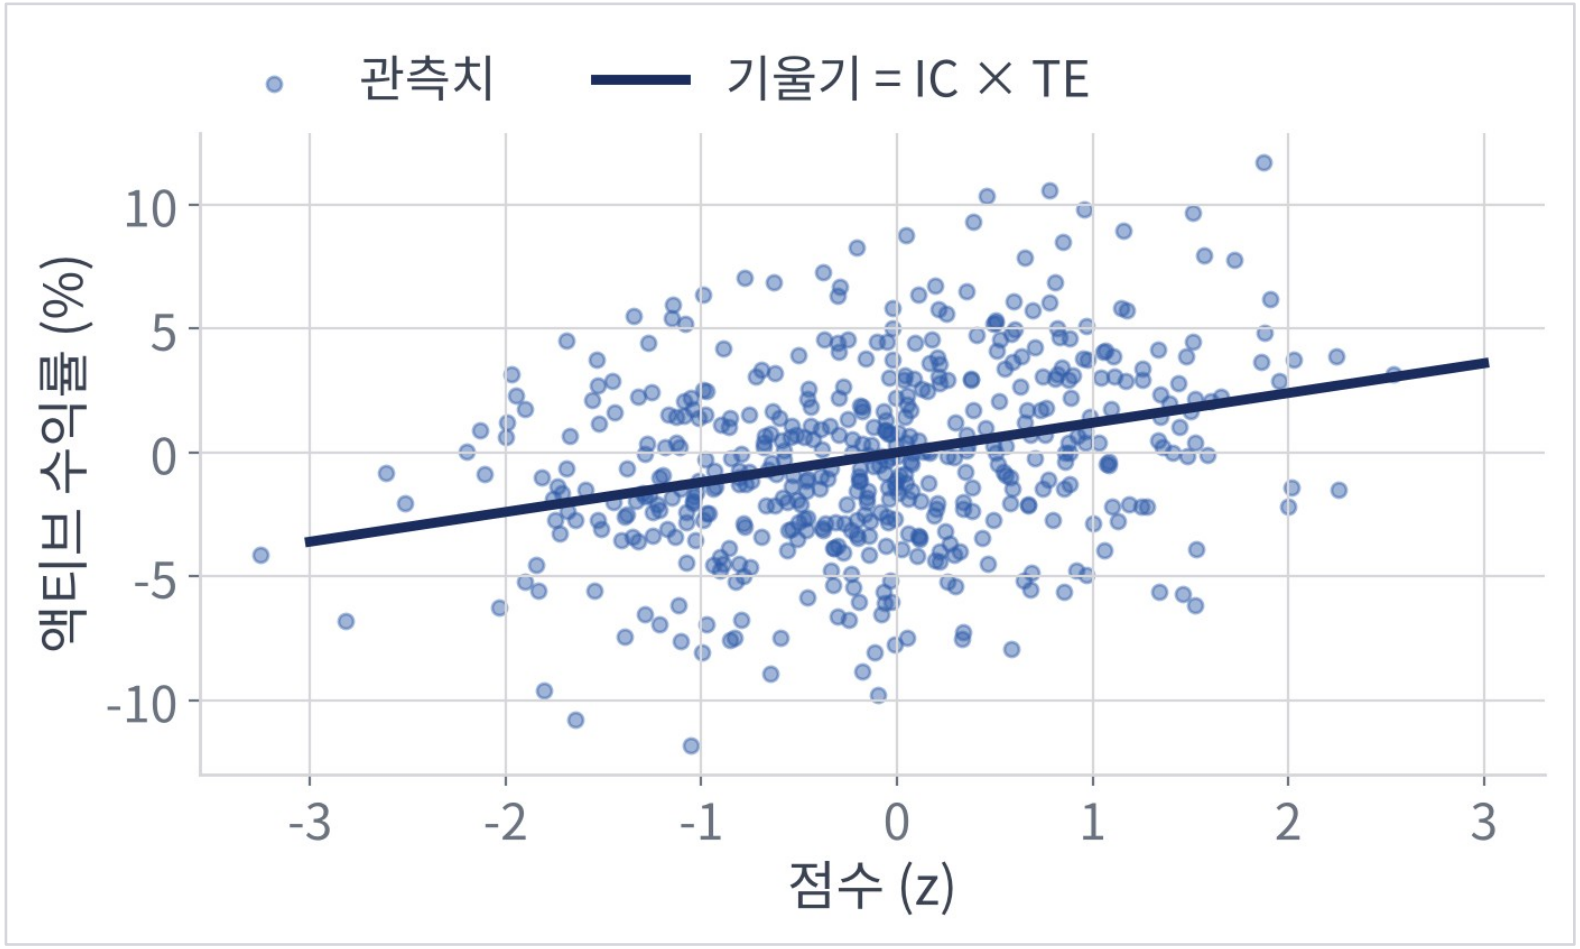
- 알파는 점수에 비례하고 비례 상수는 정보계수와 추적오차의 곱이다
- 정보계수가 0이면 점수가 커도 알파는 0이다

회귀선의 기울기가 정보계수와 추적오차의 곱이다

※ 예시 데이터 · 눈에 보이도록 IC를 0.30으로 과장했다

읽는 법

- 점 하나는 한 관측
- 직선은 조건부 평균
- 직선 높이가 알파
- 점의 폭은 남은 위험



알파의 단면 표준편차는 정보계수와 추적오차의 곱에 가깝다

Alpha scaling check · 점수의 단면 표준편차가 1이기 때문이다

$$\underbrace{\mathrm{Std}(\alpha)}_{\text{알파의 단면 표준편차}} \approx \mathrm{IC} \times \mathrm{TE}$$

왜 성립하는가

- 점수는 단면 표준편차가 1이다
- 정보계수와 추적오차가 자산 간에 비슷하면 그 곱이 알파의 폭이 된다

어떻게 쓰는가

- 제출된 알파의 폭이 이보다 크면 과신이다
- 그 비율만큼 알파 전체를 줄여 최적화기에 넣는다

03

점수와 확신

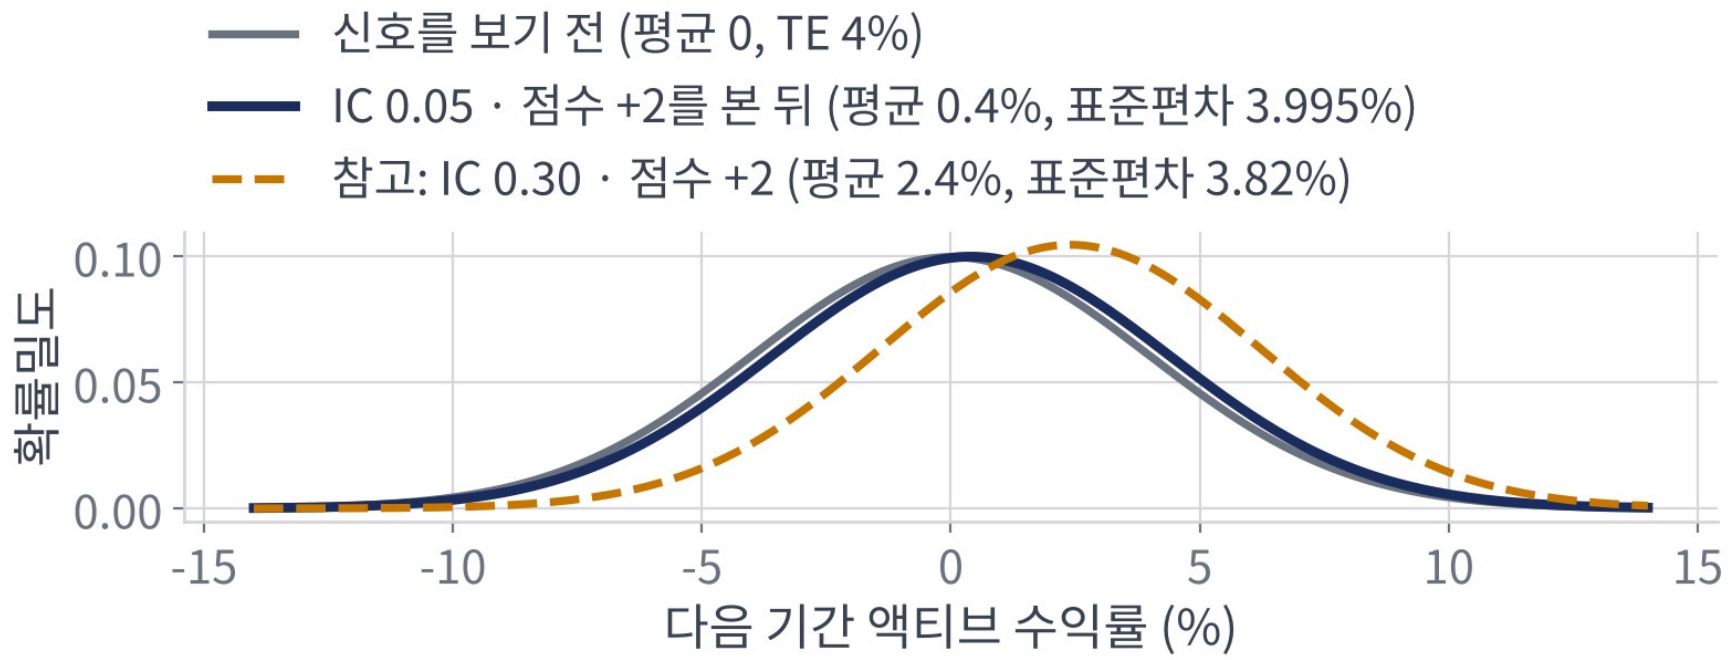
점수는 확신인가

신호를 본 뒤 달라지는 것은 평균이고, 불확실성은 거의 그대로다

점수는 평균을 옮길 뿐 불확실성을 줄이지 않는다

조건부 분산에 점수가 없다 · 그림은 IC 0.05, TE 4%, 점수 +2의 예

$$\mathbb{E}[a \mid z] = \mathrm{IC}\,\mathrm{TE}\,z, \qquad \mathrm{Var}(a \mid z) = \mathrm{TE}^2\,(1 - \mathrm{IC}^2)$$



확신에 가까운 양은 정보계수와 점수의 곱이다

그 곱은 이 베팅의 예상 정보비율이다

$$\frac{\alpha}{\mathrm{TE}} = \mathrm{IC} \times z = \underbrace{\text{그 베팅의 예상 정보비율}}_{\text{확신에 가까운 양}}$$

구성요소	말하는 것	역할
점수	이번 신호가 평소보다 얼마나 극단적인가	신호의 세기
정보계수	이 신호를 얼마나 믿을 수 있는가	예측의 신뢰도
정보계수 × 점수	이 베팅의 예상 정보비율	실무에서 말하는 확신

04

켈리 연결

알파 예측 공식에서 켈리 비중으로

켈리 공식에 신호를 본 뒤의 조건부 기대값과 조건부 분산을 넣는다

켈리에는 신호를 본 뒤 남는 분산을 넣어야 한다

액티브 수익률을 점수로 회귀하면 설명되는 부분과 남는 부분으로 나뉜다

$$a = \underbrace{\mathrm{IC}\,\mathrm{TE}\,z}_{\text{신호가 설명하는 부분}} + \underbrace{\varepsilon}_{\text{설명 못 하는 부분}}$$

$$\mathrm{Var}(\varepsilon) = \underbrace{\mathrm{TE}^2}_{\text{전체 분산}} - \underbrace{(\mathrm{IC}\,\mathrm{TE})^2}_{\text{신호가 설명한 분산}} = \mathrm{TE}^2(1 - \mathrm{IC}^2)$$

읽는 법

- 정보계수의 제곱은 이 회귀의 결정계수다

켈리 비중은 예상 정보비율을 추적오차로 나눈 값이다

IC가 0.05면 분모의 보정항은 0.9975라 1로 둔다

$$f^* = \frac{\mathrm{IC}\,\mathrm{TE}\,z}{\mathrm{TE}^2(1-\mathrm{IC}^2)} = \frac{\mathrm{IC}\,z}{\mathrm{TE}\,(1-\mathrm{IC}^2)} \approx \frac{\overbrace{\mathrm{IC}\times z}^{\text{예상 정보비율}}}{\underbrace{\mathrm{TE}}_{\text{추적오차}}}$$

분자 · 예상 정보비율

- 점수가 두 배면 비중도 두 배다

분모 · 추적오차

- 추적오차가 두 배면 비중은 절반이다
- 변동성 목표화가 식 안에 들어 있다

켈리가 지는 액티브 위험은 그 베팅의 예상 정보비율과 같다

켈리 비중에 추적오차를 곱하면 정보계수 × 점수가 된다

$$\underbrace{f^* \times \mathrm{TE}}_{\text{켈리가 지는 액티브 위험}} = \mathrm{IC} \times z = \underbrace{\frac{\alpha}{\mathrm{TE}}}_{\text{예상 정보비율}}$$

정보계수 × 점수 = 예상 정보비율 = 켈리가 감수하는 위험

예

- IC 0.05, 점수 +2면 켈리는 액티브 위험 10%를 진다

독립 베팅을 합치면 켈리 성장률은 정보비율 제곱의 절반이다

정보비율은 정보계수에 베팅 수의 제곱근을 곱한 값이라는 기본법칙과 이어진다

$$g^* = \frac{1}{2}\frac{(\mathrm{IC}\, z)^2}{1-\mathrm{IC}^2} \approx \frac{1}{2}(\mathrm{IC}\, z)^2$$

$\mathbb{E}[z^2] = 1,$ **독립 베팅** N**개 :** $G^* \approx \frac{1}{2}\mathrm{IC}^2 N = \frac{1}{2}\mathrm{IR}^2,$ $\mathrm{TE}^* = \mathrm{IR} = \mathrm{IC}\sqrt{N}$

읽는 법

- 단일 베팅의 성장률은 예상 정보비율 제곱의 절반이다
- 켈리 최적 추적오차는 포트폴리오 정보비율과 같다

알파는 추적오차의 제곱에 켈리 비중을 곱한 값이다

변동성을 한 번만 곱하면 알파가 아니라 켈리 위험이 된다

$$\alpha = \mathrm{TE}^2 \times f^* = \mathrm{TE} \times \underbrace{(f^* \times \mathrm{TE})}_{\text{켈리 위험}} = \mathrm{IC} \times z$$

$$\alpha = \mathrm{TE}^2 \left(1 - \mathrm{IC}^2\right) f^* \approx \mathrm{TE}^2 f^*$$

흔한 착각

- 추적오차 × 켈리 비중은 알파가 아니라 켈리 위험이다
- 그리놀드의 IC × 점수가 켈리 위험 자리에 그대로 들어간다

05

실무 적용

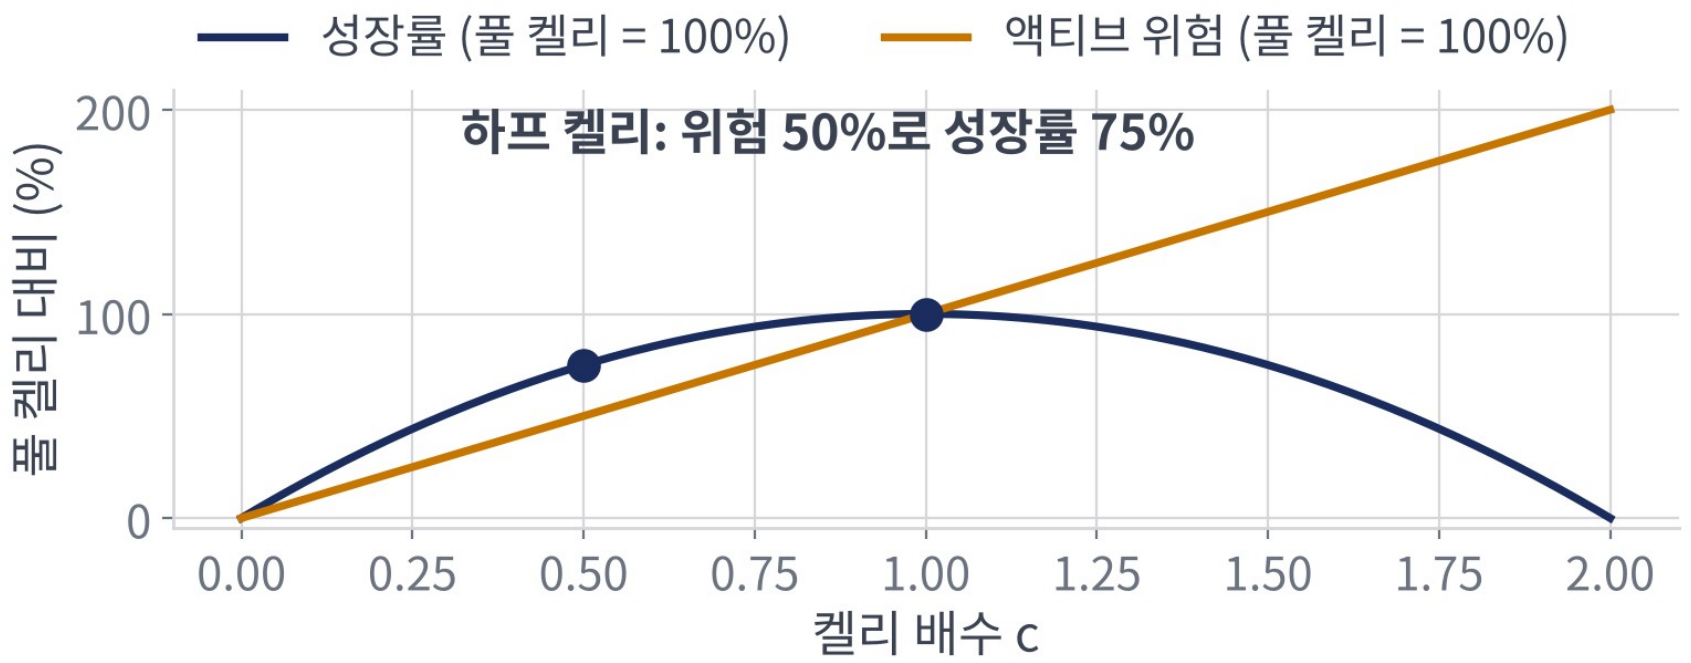
분수 켈리와 추적오차 예산

IC는 추정치다 — 풀 켈리를 그대로 쓰지 않는다

분수 켈리는 위험을 절반으로 줄이고 성장률의 75%를 지킨다

IC는 추정치이므로 풀 켈리는 과대 베팅이 되기 쉽다

$$f = c \times f^* \quad (0 < c \leq 1), \qquad g(c\,f^*) = (2c - c^2)\,g^*$$



기관 운용에서는 추적오차 예산이 켈리 배수를 대신한다

평균-분산의 위험회피계수 λ = ½이 풀 켈리에 해당한다

$$\max_w \quad w\,\alpha - \lambda\, w^2\, \mathrm{TE}^2 \;\Rightarrow\; w = \frac{\alpha}{2\lambda\,\mathrm{TE}^2}, \qquad \lambda = \tfrac{1}{2} \;\Rightarrow\; w = f^* \text{ (풀 켈리)}$$

추적오차 예산 방식

- 비중은 점수에 비례하고 추적오차에 반비례하게 둔다
- 전체 배수만 추적오차 예산에 맞춘다

추정 오차 대처

- IC를 0 쪽으로 수축해 쓴다
- 풀 켈리 대신 분수 켈리를 쓴다

06

Claude Code 구현

공식을 코드로 검산한다

데스크톱 앱 Code 탭에 프롬프트를 붙여 넣고 결과만 확인한다

알파와 켈리 비중을 한 번에 계산하고 검산한다

자산 20개 모의 데이터 · 출력은 예시이며 실행마다 값이 달라진다

[입력] 프롬프트 · Claude Code (데스크톱 앱 Code 탭)

다음을 하는 파이썬 스크립트를 만들고 실행해 줘.
1) 자산 20개의 점수 z를 표준정규로 생성
2) IC=0.05, 자산별 TE를 3~6%에서 생성
3) 알파 = IC × TE × z
4) 켈리 비중 = 알파 / (TE² × (1 − IC²))
5) 켈리 비중 × TE 가 IC × z 와 같은지 검산
6) 알파의 단면 표준편차를 IC × 평균 TE 와
비교
7) 결과를 표로 보여 주고
alpha_kelly.csv 로 저장해 줘

[출력] 결과 · 터미널 표 (예시)

```
자산  z     TE    알파   켈리
A01  +2.00 4.0%  0.40%  2.51
A02  -0.80 5.2%  -0.21% -0.77
...
검산: 켈리×TE = IC×z  (20/20)
알파 표준편차 0.21%
IC×평균 TE    0.22%
alpha_kelly.csv 저장 완료
```

분수 켈리의 성장률을 몬테카를로로 확인한다

본편의 분수 켈리 성장률 공식과 시뮬레이션 결과를 나란히 비교한다

[입력] 프롬프트 · Claude Code (데스크톱 앱 Code 탭)

켈리 성장률을 몬테카를로로 검증해 줘.
- 독립 베팅 100개, IC 0.05, TE 4%
- 매 기간 점수를 새로 뽑아 2,000기간 시뮬레이션
- 켈리 배수 c = 0.25, 0.5, 1, 1.5, 2
- c별 평균 로그성장률과 최대 낙폭 계산
- 이론값 $(2c - c^2) \times ½ \times IR^2$ 과 비교한
  그래프를 kelly_sim.png 로 저장
- 그래프를 열어서 보여 줘

[출력] 결과 · 확인할 점

c=0.5 : 성장률 ≈ 풀 켈리의 75%
　　낙폭은 크게 줄어든다
c=1　: 성장률 최대
c=2　: 성장률 ≈ 0, 낙폭 최대

시뮬레이션 점이 이론 곡선
$(2c - c^2)$ 위에 놓이는지 본다

점수에서 포지션까지 하나의 식으로 이어진다

1

알파 = IC × TE × 점수

액티브 수익률의 최선 선형 예측이며 알파의 폭은 정보계수와 추적오차의 곱에 가깝다.

2

점수는 신호의 세기, 확신은 IC × 점수

신호를 봐도 액티브 수익률의 분산은 거의 줄지 않는다.

3

켈리 비중은 예상 정보비율 ÷ 추적오차, 알파는 추적오차 제곱 × 켈리 비중

켈리가 지는 위험은 예상 정보비율이고, 포트폴리오 성장률은 정보비율 제곱의 절반이다.

IC는 추정치다 — 실무는 분수 켈리와 추적오차 예산으로 줄여 쓴다