

랜덤행렬이론 공분산 필터링

잡음 고유값 평탄화와 최소분산 포트폴리오 실증

S&P 500 364종목·10년 자료로 표본 공분산의 잡음이 최적화에 미치는 영향을 검증한다

364종목 · 10년

신호 고유값 24개

변동성 20.9→14.6%

회전율 396→48%

개요

잡음 이론

RMT 필터

투자선

OOS 검증

시사점

EXECUTIVE SUMMARY

표본 공분산의 잡음을 걷어내면 위험 예측이 정직해진다

공매도 허용 최소분산 포트폴리오, 2018–2025 out-of-sample 기준이다.

입력

S&P 500 일별 수정종가(2016–2025) · 결측 2% 초과 제외 후 364종목 · GICS 섹터

처리

상관행렬 고유분해 → MP 상한 λ_+ 로 신호·잡음 구분 → 잡음 고유값 평탄화 → 공분산 복원 → 최적화

출력

고유값 진단 · 필터 전후 상관 차이 · in-sample 투자선 · 롤링 최소분산 백테스트 성과표

의미

실현 변동성 20.9% → 14.6%, 편향비 4.6 → 1.8. 롱온리에서는 세 추정량 차이가 사라진다

공분산 필터링의 가치는 in-sample 투자선이 아니라 out-of-sample 위험 예측에서 드러난다

개요

잡음 이론

RMT 필터

투자선

OOS 검증

시사점

CONTENTS

여섯 개의 질문으로 설명한다

01

무엇이 문제인가

역행렬과 오차 극대화기

02

잡음은 어떻게 알아보나

Marchenko–Pastur 법칙 · 신호 24개

03

잡음을 어떻게 걷어내나

고유값 평탄화 · 조건수 1/58

04

in-sample에서는 왜 같아 보이나

L1 규제가 해를 좁힌다

05

실제 성과는 어떻게 다른가

롤링 최소분산 · 편향비 · 회전을

06

실무에서 언제 쓰나

운용 상황별 가치 · 한계와 과제

01

개요

무엇이 문제인가

최적화기는 공분산의 역행렬을 쓰고, 역행렬은 잡음을 증폭한다

01. 무엇이 문제인가

최소분산 가중치는 공분산 역행렬로 결정된다

기본 지식: 전역 최소분산(GMV) 포트폴리오와 역행렬의 스펙트럼 분해.

$$w_{\text{GMV}} = \frac{\Sigma^{-1} \mathbf{1}}{\mathbf{1}^\top \Sigma^{-1} \mathbf{1}}, \quad \Sigma^{-1} = \sum_{i=1}^N \frac{1}{\lambda_i} e_i e_i^\top$$

- **GMV** 기대수익 추정 없이 공분산만으로 정해지는 최소분산 포트폴리오. 공분산 추정의 질을 재는 기준으로 쓴다
- **고유값 λ_i** 고유벡터 방향 포트폴리오의 분산. 작을수록 '안전해 보이는' 방향이다
- **$1/\lambda_i$** λ_i 가 0에 가까우면 역행렬에서 폭발한다 — 가장 작은 고유값이 가중치를 좌우한다

가장 작은 고유값이 잡음이라면, 최적화는 잡음에 가장 큰 비중을 실는다

개요

잡음 이론

RMT 필터

투자선

OOS 검증

시사점

01. 무엇이 문제인가

| 표본 공분산 최적화는 위험을 5분의 1로 과소평가했다

공매도 허용 GMV, 추정 창 504일·21일마다 재조정, 2018-2025 연율 기준이다.

82,916

조건수
최대/최소 고유값

4.64

편향비
 $\text{실현} \div \text{예상 변동성}$

15.4배

총 노출
 $\sum |w|$ 평균

396%

월 회전율
 $\frac{1}{2} \sum |\Delta w|$ 평균

오차 극대화기

예상 변동성은 4.2%였지만 실현 변동성은 20.9%로, 동일가중(20.8%)과 같았다. 레버리지와 거래비용만 늘고 얻은 것이 없다 (Michaud, 1989).

02

잡음 이론

잡음은 어떻게 알아보나

상관이 전혀 없어도 표본 고유값은 일정 구간에 퍼진다

개요

잡음 이론

RMT 필터

투자선

OOS 검증

시사점

02. 잡음은 어떻게 알아보다

상관행렬의 고유분해는 위험을 독립 방향으로 나눈다

기본 지식: $C = EAE'$. 표준화 수익률의 상관행렬이면 고유값의 합은 N 이다.

고유벡터 e	고유값 λ	$q = T/N$
방향 서로 직교하는 포트폴리오. 1번은 모든 종목이 같은 부호인 시장 방향	크기 그 방향의 분산. 전체 분산 N 가운데 몇 %를 설명하는지	표본 비율 관측 일수 ÷ 종목 수. 작을수록 고유값이 잡음으로 더 넓게 퍼진다

문제는 어느 고유값이 진짜 구조이고 어느 것이 표본 잡음인지 구별하는 것이다

02. 잡음은 어떻게 알아보나

MP 상한 λ_+ 를 넘는 고유값만 신호로 본다

Marchenko–Pastur(1967): 독립·등분산 자료의 표본 상관행렬 고유값 밀도.

$$f(\lambda) = \frac{q}{2\pi\sigma^2\lambda} \sqrt{(\lambda_+ - \lambda)(\lambda - \lambda_-)}, \quad \lambda \in [\lambda_-, \lambda_+], \quad q = \frac{T}{N}$$

$$\lambda_{\pm} = \sigma^2 \left(1 \pm \sqrt{1/q}\right)^2, \quad \sigma^2 = 1 - \frac{\lambda_1}{N}$$

- λ_+ 안쪽 고유값은 상관이 전혀 없는 자료에서도 나오는 크기 — 잡음과 구별되지 않는다
- 시장 팩터 λ_1 이 분산을 가져가므로 잡음 분산 σ^2 를 $1 - \lambda_1/N$ 으로 줄인다 (Laloux et al., 2000)

q가 클수록(관측이 길수록) 구간이 좁아져 신호를 더 많이 가려낼 수 있다

개요

잡음 이론

RMT 필터

투자선



OOS 검증

시사점

02. 잡음은 어떻게 알아보나

꼬리가 두꺼운 수익률에서도 MP 법칙은 맞는다

독립 $t(5)$ 분포 500개 $\times$ 2,000일($q = 4$)을 시뮬레이션했다.



이론 구간 $[0.25, 2.25]$ 대비 표본 고유값 $[0.257, 2.235]$ — 분산이 유한하면 법칙이 성립한다

개요

잡음 이론

RMT 필터



투자선

OOS 검증

시사점

02. 잡음은 어떻게 알아보나

| S&P 500 고유값 364개 중 신호는 24개였다

2016-2020($T = 1,258$, $N = 364$, $q = 3.46$), 보정 $\sigma^2 = 0.581$, $\lambda_+ = 1.373$.시장 팩터 $\lambda_1 = 152.6$ 이 분산의 41.9%, 신호 24개가 67.7%를 설명한다

개요

잡음 이론

RMT 필터

투자선


OOS 검증

시사점

02. 잡음은 어떻게 알아보나

신호 고유벡터는 시장과 섹터 구조를 담고 있다

상위 네 고유벡터의 성분을 GICS 섹터별로 평균했다.



읽는 법

- PC1: 전 섹터 같은 부호 — 시장 팩터
- PC2: 유틸리티·필수소비재(+) 대 에너지(-)
- PC3: 기술(+) 대 유틸리티(-)
- PC4: 통신(+) 대 기술(-)

 λ_+ 를 넘는 고유값은 통계적 신호이면서 경제적으로 해석되는 팩터다

03

RMT 필터

잡음을 어떻게 걷어내나

신호는 그대로 두고, 잡음 고유값은 평균 하나로 바꾼다

03. 잡음을 어떻게 걷어내나

고유값 평탄화는 세 단계로 끝난다

Laloux–Bouchaud–Potters 방식의 eigenvalue clipping.

STEP 1**분해·판정**

- 상관행렬 고유분해
- 내림차순 정렬
- σ^2 보정 후 λ_+ 계산
- λ_+ 초과 = 신호

STEP 2**평탄화**

- 잡음 고유값을 평균 λ 로
- 대각합 N 보존
- $\lambda > 0 \rightarrow$ 양정치 보장

STEP 3**재구성·복원**

- $\tilde{C} = E \Lambda E'$
- 대각을 1로 정규화
- 변동성을 곱해 Σ 복원

원본의 nearest correlation 최적화는 필요 없다 — 대각 정규화로 충분하다

개요

잡음 이론

RMT 필터

투자선

OOS 검증

시사점

03. 잡음을 어떻게 걷어내나

| 평탄화는 대각합을 지키며 작은 고유값만 끌어올린다

k 는 λ_+ 를 넘는 신호 고유값의 개수다.

$$\tilde{\lambda}_i = \begin{cases} \lambda_i, & \lambda_i > \lambda_+ \\ \bar{\lambda} = \frac{1}{N-k} \sum_{j>k} \lambda_j, & \lambda_i \leq \lambda_+ \end{cases} \quad \sum_i \tilde{\lambda}_i = \sum_i \lambda_i = N$$

$$\tilde{C} = E \tilde{\Lambda} E^\top, \quad \hat{C} = D^{-1/2} \tilde{C} D^{-1/2}, \quad D = \text{diag}(\tilde{C})$$

$$\hat{\Sigma} = \text{diag}(\sigma) \hat{C} \text{diag}(\sigma)$$

0에 가깝던 잡음 고유값이 평균 λ 로 올라가 역행렬이 안정된다

개요

잡음 이론

RMT 필터

투자선

OOS 검증

시사점

03. 잡음을 어떻게 걷어내나

필터링 후 조건수는 58분의 1로 줄었다

2016-2020 in-sample 공분산, 조건수 = 최대 고유값 ÷ 최소 고유값.

공분산 추정량	조건수	방식
Sample	82,916	표본 공분산 그대로
Ledoit-Wolf	4,304	스케일된 항등행렬 쪽으로 선형 수축
RMT	1,435	잡음 고유값 평탄화, 신호 고유값 보존

왜 중요한가

조건수가 크면 입력의 작은 오차가 역행렬에서 크게 부풀려진다. 최적 가중치가 추정 오차에 민감해지는 정도를 보여 준다.

개요

잡음 이론

RMT 필터

투자선



OOS 검증

시사점

03. 잡음을 어떻게 걷어내나

| 개별 상관계수는 거의 바뀌지 않았다

필터 후 - 원본 상관행렬. 비대각 원소의 차이 분포를 함께 본다.



상관 하나하나는 그대로인데 최적화 결과가 달라지는 이유는 작은 고유값에 있다

04

투자선

in-sample에서는 왜 같아 보이나

원본 노트북의 결론을 같은 조건으로 재현한다

개요

잡음 이론

RMT 필터

투자선

OOS 검증

시사점

04. in-sample에서는 왜 같아 보이나

원본은 L1 규제를 건 평균-분산 문제를 풀었다

CVXPY로 λ 를 -2부터 2까지 41개 값으로 바꿔 푼다.

$$\hat{w}(\lambda) = \arg \min_w w^\top \Sigma w - \lambda \hat{\mu}^\top w + \gamma \|w\|_1 \quad \text{s.t.} \quad \sum_i w_i = 1$$

- λ 수익 선호 강도. 바꿔 가며 풀면 효율적 투자선을 따라 이동한다
- $\gamma = 0.003$ L1 페널티. 공매도를 허용하되 총 노출과 종목 수를 억제한다
- 원본 오기 " $\mu = 0.003$ 고정"은 γ 를 잘못 적은 것이다

γ 향이 일간 분산(약 10^{-4})보다 훨씬 커서 공분산의 영향이 작아진다

개요

잡음 이론

RMT 필터

투자선


OOS 검증

시사점

04. in-sample에서는 왜 같아 보이나

L1 규제 아래에서 두 투자선은 거의 겹친다

2016-2020, 각 해의 위험을 두 공분산 모두로 평가했다(원본 버그 수정).



관찰

- 두 해 모두 평균 6.5종목
- 총 노출 $\sum |w| = 1.0$ — 사실상 롱온리
- Sample은 자기 데이터에 맞춰져 있어
- in-sample에서 늘 가장 좋아 보인다
- → 필터의 가치는 OOS로 판정한다

"필터링해도 결과가 별로 안 바뀐다"는 규제가 해를 줬기 때문이다

05

OOS 검증

실제 성과는 어떻게 다른가

다음 달에 실현된 위험으로 네 추정량을 비교한다

개요

잡음 이론

RMT 필터

투자선

OOS 검증

시사점

05. 실제 성과는 어떻게 다른가

롤링 최소분산 백테스트로 공분산의 질만 비교한다

기대수익 추정 오차를 배제하려고 GMV 포트폴리오를 쓴다.

추정 창	재조정	비교 대상	제약
504일 2년. $q = L/N \approx 1.4$ 로 표본 공분산이 특이에 가깝다	21일 매월 재추정 후 다음 21일 보유. 총 95회	4개 Sample · RMT · Ledoit- Wolf · 1/N	2종 공매도 허용(단한 해) · 롱온리(CVXPY)

실무에서 흔한 'N과 T가 비슷한' 상황을 일부러 재현했다

개요

잡음 이론

RMT 필터

투자선

OOS 검증

시사점

05. 실제 성과는 어떻게 다른가

| 편향비는 위험 예측이 얼마나 정직한지 잰다

롱온리 문제와 평가 지표의 정의.

$$\min_w w^\top \Sigma w \quad \text{s.t.} \quad \sum_i w_i = 1, w \geq 0$$

$$\text{Bias ratio} = \frac{\sigma_{\text{realized}}}{\sqrt{w^\top \hat{\Sigma} w}}, \quad \text{Turnover} = \frac{1}{2} \sum_i |w_{i,t} - w_{i,t-1}|$$

- 편향비 = 1 예상한 만큼 실제로 움직였다
- 편향비 > 1 위험을 과소평가했다 — 최적화가 잡음에 속았다

GMV의 목표는 수익이 아니라 실현 변동성 최소화다

개요

잡음 이론

RMT 필터

투자선

OOS 검증

시사점

05. 실제 성과는 어떻게 다른가

공매도 허용 시 RMT가 변동성과 회전율을 크게 낮췄다

공매도 허용 GMV, 2018-2025 연율. 회전율은 월 평균.

추정량	실현 변동성	예상 변동성	편향비	월 회전율	총 노출
Sample	20.9%	4.2%	4.64	396%	15.4배
RMT	14.6%	6.8%	1.79	48%	4.8배
Ledoit-Wolf	14.6%	6.1%	2.16	114%	7.2배
1/N	20.8%	19.1%	0.98	0%	1.0배

RMT: 실현 변동성 -6.3%p, 편향비 4.6→1.8, 회전율 1/8, 레버리지 1/3

※ 364종목, 추정 창 504일. 종목 수가 달라지면 수치도 달라진다

개요

잡음 이론

RMT 필터

투자선

OOS 검증

시사점

05. 실제 성과는 어떻게 다른가

| 롱온리에서는 세 추정량의 차이가 사라졌다

롱온리 GMV, 2018-2025 연율. 보유 종목은 비중 0.1% 초과 기준.

추정량	실현 변동성	예상 변동성	편향비	월 회전율	보유 종목
Sample	15.3%	11.1%	1.17	14%	35
RMT	15.4%	11.4%	1.14	13%	34
Ledoit-Wolf	15.2%	11.0%	1.17	13%	40
1/N	20.8%	19.1%	0.98	0%	364

공매도 금지 제약 자체가 공분산 수축과 같은 역할을 한다 (Jagannathan & Ma, 2003)

개요

잡음 이론

RMT 필터

투자선




OOS 검증

시사점

05. 실제 성과는 어떻게 다른가

Sample의 초과 변동성은 기간 전체에 걸쳐 나타났다

좌: 공매도 허용 실현 변동성(6개월 이동평균) · 중: 편향비 · 우: 롱온리 누적 가치.



1/N의 높은 누적 수익은 생존 편향 탓이 커서 비교 대상이 아니다

06

시사점

실무에서 언제 쓰나

다섯 가지 결론과 운용 상황별 판단

개요

잡음 이론

RMT 필터

투자선

OOS 검증

시사점

06. 실무에서 언제 쓰나

다섯 가지 결론

- | | | |
|---|---------------------------|-----------------------------------|
| 1 | 정보는 소수 팩터에 | 364개 중 신호 24개, 시장 팩터 하나가 분산의 42% |
| 2 | 표본은 과소평가 | 편향비 4.6 — 레버리지 15배로도 동일가중과 같은 변동성 |
| 3 | RMT $\approx$ Ledoit-Wolf | 실현 변동성은 같고, 편향비·회전율·레버리지는 RMT 우위 |
| 4 | 평탄화의 한계 | RMT 편향비도 1.8 — 비선형 수축·팩터모형 검토 필요 |
| 5 | 제약이 수축을 대신 | 롱온리에서는 추정량 간 실현 변동성 차이 0.2%p 이내 |

개요

잡음 이론

RMT 필터

투자선

OOS 검증

시사점

06. 실무에서 언제 쓰나

공매도를 허용할수록 공분산 필터링의 가치가 크다

이번 실증(롱숏·롱온리 GMV)에서 확인한 범위와 그로부터의 판단이다.

필터링 효과가 작은 경우

필터링 효과가 큰 경우

✗ 롱온리 · 비중 상한이 있는 운용



✓ 롱숏 · 팩터 중립 · 리스크 패리티

✗ 강한 L1 · 회전율 규제



✓ 리스크 모델링 · 위험예산 배분

✗ $N \ll T$ (종목 수가 적고 관측이 김)✓ $N \approx T$ (다종목 · 짧은 추정 창)

위험예산처럼 예측 위험 자체를 쓰는 곳이면 롱온리라도 편향비를 점검한다

06. 실무에서 언제 쓰나

원본 노트북의 오류 네 가지를 고쳤다

그 밖에 폐기된 API 교체와 out-of-sample 백테스트를 추가했다.

원본	문제	수정
la.eig 후 정렬 없이 자름	엉뚱한 고유값을 평탄화	la.eigh + 내림차순 정렬
재구성 행렬에 abs()	음의 상관이 양수로 뒤집힘	제거
투자선 위험을 모두 ocov로	필터 해도 원본 공분산으로 평가	두 공분산 모두로 평가
MP 상한에 $\sigma^2 = 1$	시장 팩터 분산을 잡음에 포함	$\sigma^2 = 1 - \lambda_1/N$

개요

잡음 이론

RMT 필터

투자선

OOS 검증

시사점

06. 실무에서 언제 쓰나

한계와 다음 단계

한계

- 현행 구성종목 사용 — 생존 편향
- 다운로드 제약으로 364종목만 사용
- 추정 창 504일 한 가지만 검증
- 거래비용 미반영

다음 단계

- 추정 창 252·1,008일로 q 민감도
- σ^2 보정 유무(원본 방식) 비교
- $\gamma = 0.0003 \cdot 0.03$ 으로 투자선 재비교
- 비선형 수축·팩터모형 공분산 추가

실습 노트북: [rmt_covariance_filter_lab.ipynb](#) — Colab에서 그대로 실행된다

CONCLUSION

표본 공분산의 잡음을 걷어내면 최적화가 위험을 정직하게 예측한다

효과는 in-sample 투자선이 아니라 out-of-sample 편향비·회전율·레버리지에서 드러나며, 공매도 금지 같은 제약이 있으면 그 차이는 줄어든다.

참고: Marchenko & Pastur (1967) · Laloux et al. (2000) · Bouchaud & Potters (2009) · Ledoit & Wolf (2004)