사전학습 · 비전공자용

팩터 모델 입문

수익률과 위험에서 팩터와 알파의 판정까지

「팩터 오디션」 강의와 실습을 듣기 전에 보는 자료

금융을 처음 배우는 수강생을 위해 팩터 모델의 기본 개념만 골라 담았다.
수식은 결과만 보이고, 숫자 예시와 에피소드로 직관을 먼저 잡는다.

이 자료는 세 문장으로 요약된다

끝까지 읽은 뒤 이 세 문장을 자기 말로 설명할 수 있으면 된다

1

분산투자로도 사라지지 않는 공통위험이 있다

그 공통위험의 원천을 팩터라 부르고, 팩터에 대한 노출을 베타라 부른다.

2

펀드 수익의 상당 부분은 팩터로 설명된다

팩터로 설명되지 않고 남는 부분만이 운용역의 실력, 즉 알파다.

3

알파는 우연과 구별하기 어렵다

그래서 t 통계량, 다중검정, 수축이라는 도구로 알파를 의심하며 판정한다.

이 세 문장이 본 강의 「팩터 오디션」의 출발점이다

이 자료의 위치

사전학습, 본 강의, 실습 순서로 진행한다

이 자료는 본 강의에서 설명 없이 쓰는 기본 개념을 미리 채운다

① 사전학습

이 자료

수익률과 위험, 베타와 알파, 팩터의 정의, 알파를 의심하는 법

② 본 강의

팩터 오디션

팩터 동물원, 계층적 베이지안 검정, 사전 등록, 드로다운 대응

③ QDL 가이드

실행 준비

Claude Code로 QDL을 설치하고 데이터를 불러와 본다

④ 실습

팩터 오디션 과제

리서치 에이전트가 편입과 퇴출을 판정하고 IC 안건서를 쓴다

01

1부 · 수익률과 위험

수익률과 위험

팩터를 말하기 전에 수익과 위험을 재는 법부터 정리한다

투자 성과는 위험 하나당 초과수익으로 비교한다

초과수익률(excess return) · 샤프 비율(Sharpe ratio)

$$\underbrace{r^e}_{\text{초과수익률}} = \underbrace{r}_{\text{수익률}} - \underbrace{r_f}_{\text{무위험수익률}}, \qquad \underbrace{SR}_{\text{샤프 비율}} = \frac{\overbrace{\bar{r}^e}^{\text{평균 초과수익률}}}{\underbrace{\sigma}_{\text{변동성}}}$$

6%

주식 펀드 A의 연 평균 초과수익률

15%

펀드 A의 연 변동성

0.40

펀드 A의 샤프 비율 = 6 ÷ 15

무위험수익률은 국채처럼 손실 위험이 거의 없는 자산의 수익률이다 — 그 위로 더 번 몫만 위험의 대가다

분산투자는 개별위험만 없애고 공통위험은 남긴다

diversification — 종목을 많이 담을수록 개별 충격은 서로 상쇄된다

$$\underbrace{\sigma_p^2}_{\text{포트폴리오 분산}} = \underbrace{\rho\,\sigma^2}_{\text{공통위험 — 남는다}} + \underbrace{\frac{(1-\rho)\,\sigma^2}{N}}_{\text{개별위험 — 종목 수 } N\text{으로 줄어든다}}$$

개별위험

- 한 회사에만 일어나는 일이다
- 신제품 실패, 경영진 교체 같은 사건이다
- 여러 종목을 담으면 거의 사라진다

공통위험

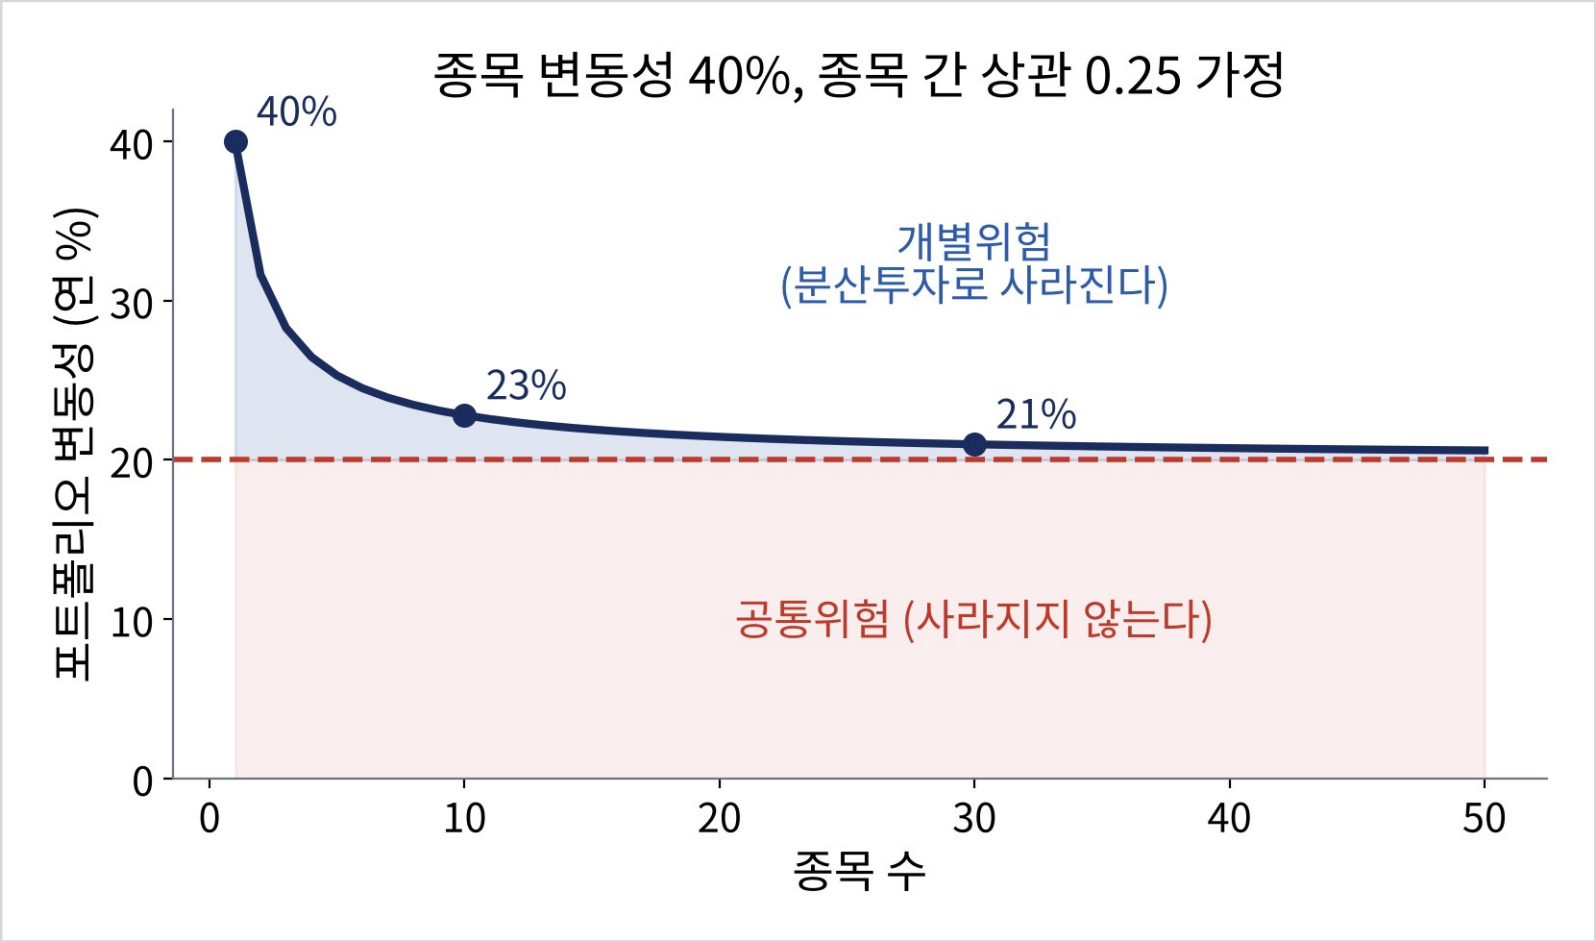
- 모든 회사에 함께 미치는 일이다
- 경기, 금리, 위기 같은 사건이다
- 아무리 많이 담아도 남는다

종목을 30개쯤 담으면 남는 위험은 거의 공통위험이다

가정 — 종목 변동성 연 40%, 종목 간 상관 0.25

읽는 법

- 1종목: 40%
- 10종목: 23%
- 30종목: 21%
- 바닥 20%는 못 없앤다



핵심 질문

시장은 없앨 수 있는 위험에는 보상하지 않는다

이 자료 전체를 이끄는 질문이다

누구나 공짜로 없앨 수 있는 위험을 졌다고 해서 대가를 받을 수는 없다

그래서 보상은 공통위험에만 붙는다

- 개별위험은 분산투자로 공짜로 없앨 수 있다
- 공통위험은 누군가는 져야 한다
- 그 공통위험에 대한 대가가 위험 프리미엄이다

다음 질문

- 공통위험은 몇 종류인가
- 시장 하나뿐이면 CAPM이다
- 여러 종류라면 다요인 모형, 즉 팩터 모델이다

02

2부 · 시장 하나로 설명하기

CAPM과 베타, 그리고 알파

공통위험이 시장 하나뿐이라고 보는 가장 단순한 모형부터 시작한다

베타는 시장이 1% 움직일 때 종목이 움직이는 정도다

CAPM — 자본자산가격결정모형(Capital Asset Pricing Model), Sharpe(1964)

$$\underbrace{r^e_{i,t}}_{\text{종목 초과수익률}} = \underbrace{\alpha_i}_{\text{알파}} + \underbrace{\beta_i}_{\text{베타}} \underbrace{r^e_{m,t}}_{\text{시장 초과수익률}} + \underbrace{\varepsilon_{i,t}}_{\text{개별 충격}}, \qquad \beta_i = \frac{\mathrm{Cov}(r^e_i,\ r^e_m)}{\mathrm{Var}(r^e_m)}$$

β = 1.3

시장보다 30% 더 크게 움직이는 종목

+13%

시장이 10% 오른 해에 기대되는 초과수익

−13%

시장이 10% 내린 해에 기대되는 초과수익

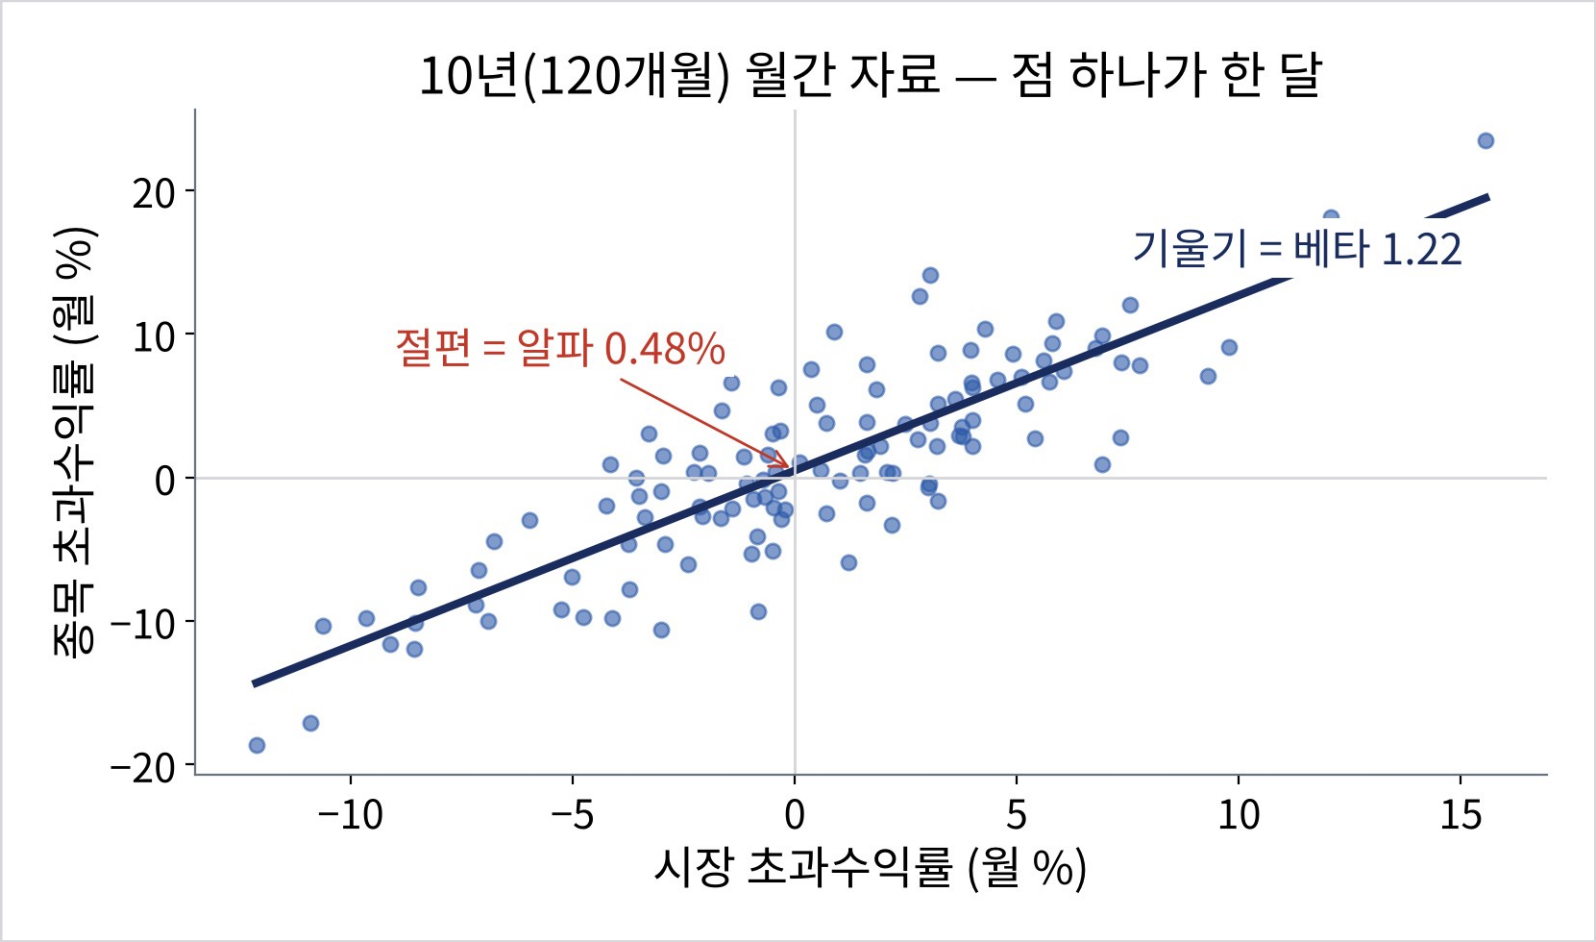
CAPM이 맞다면 알파는 0이다 — 기대수익률은 베타 하나로 정해진다

베타는 기울기이고 알파는 절편이다

시뮬레이션 예시 — 한 종목의 10년 월간 수익률을 시장 수익률에 회귀했다

무엇을 보나

- 점은 한 달
- 직선의 기울기가 베타
- 시장 0%일 때 높이가 알파
- 직선 밖 흩어짐은 개별위험



알파는 위험 노출로 설명되지 않고 남은 수익이다

alpha — 운용역이 수수료를 받을 근거가 되는 부분이다

베타는 지수 펀드로 거의 공짜에 살 수 있고, 알파는 그렇지 않다

베타의 가격

- 시장 지수 ETF는 보수가 연 0.1% 안팎이다
- 시장 위험은 누구나 싸게 살 수 있다

알파의 가격

- 액티브 펀드는 보수가 연 1% 안팎이다
- 그 보수는 알파가 있을 때만 정당하다
- 그래서 알파가 진짜인지 따지는 일이 중요하다

1992년, 베타만으로는 수익률 차이가 설명되지 않았다

Fama·French(1992) — The Cross-Section of Expected Stock Returns

무엇을 발견했나

- 베타가 큰 종목이 더 높은 수익을 내지 않았다
- 대신 작은 기업과 장부가 대비 싼 기업이 더 높은 수익을 냈다

무엇이 바뀌었나

- 시장 하나로는 공통위험을 다 설명할 수 없다는 생각이 퍼졌다
- 1993년 시장·규모·가치 3요인 모형이 나왔다

팩터 모델은 'CAPM이 설명하지 못한 수익'을 설명하려는 시도에서 나왔다

03

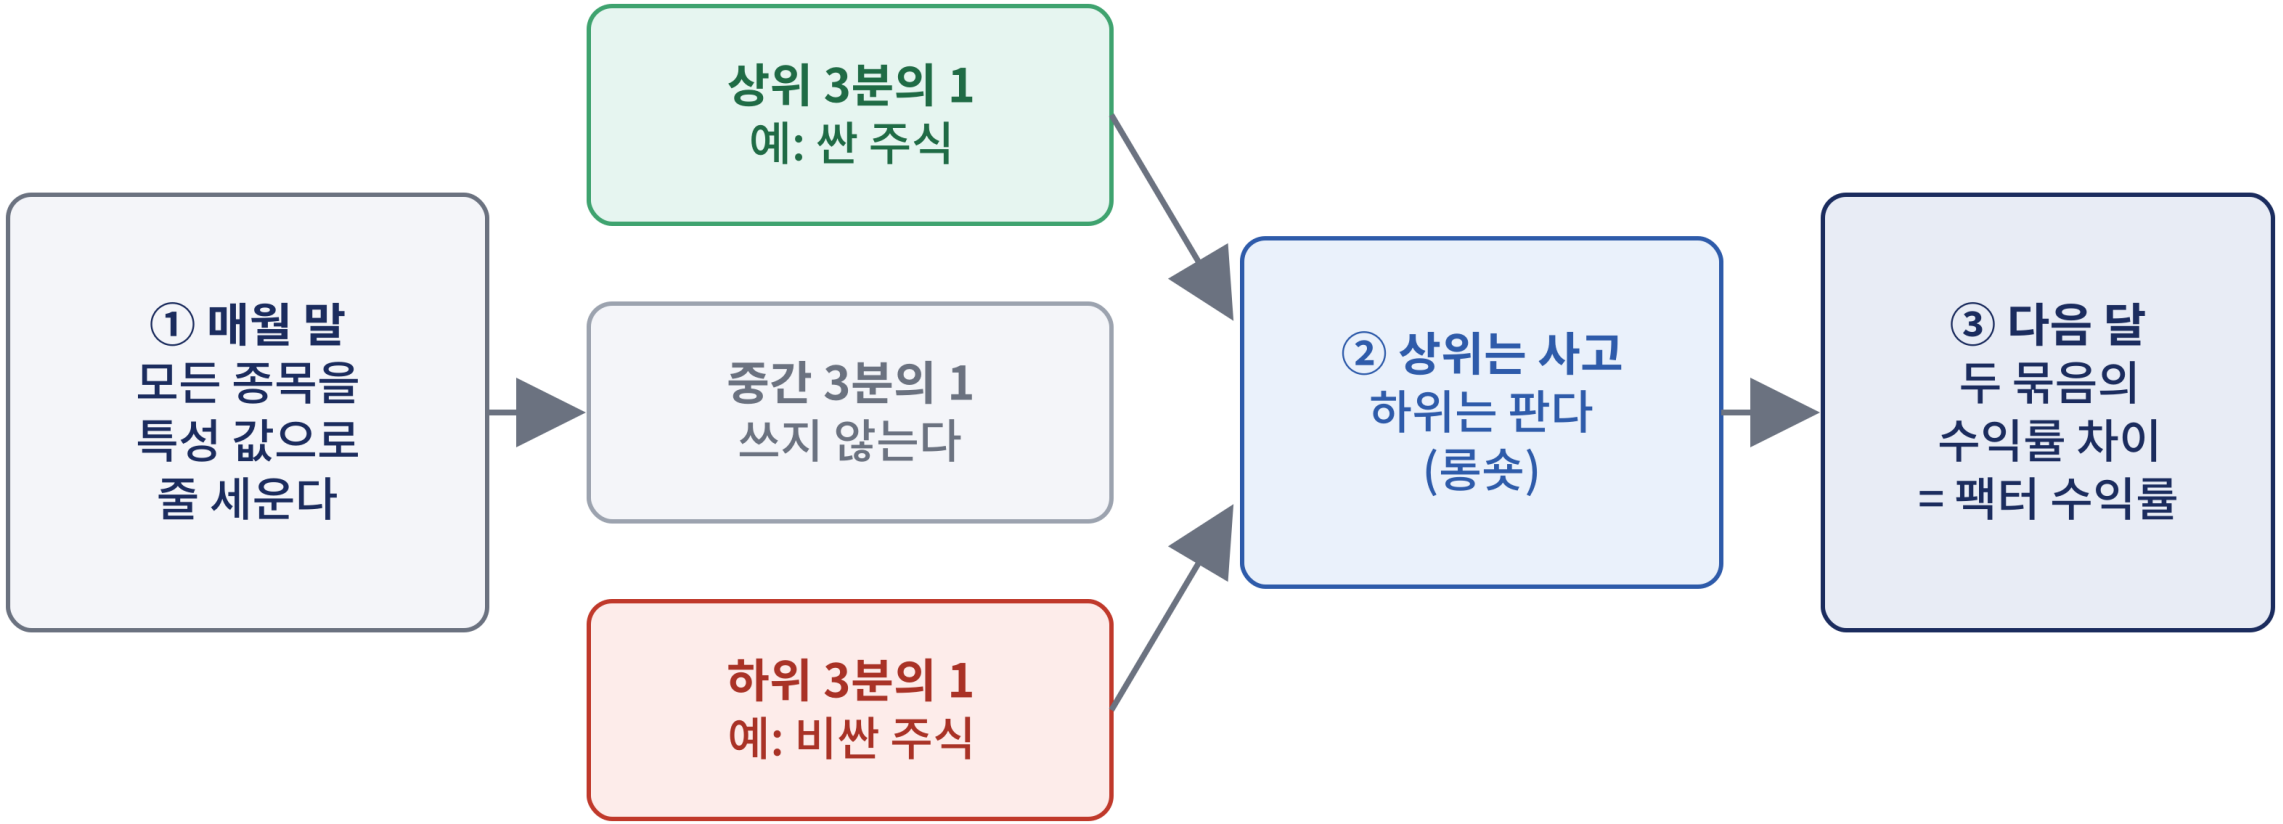
3부 · 팩터란 무엇인가

팩터와 다요인 모형

공통위험의 원천을 여러 개로 늘린다

팩터는 특성으로 줄 세운 뒤 위를 사고 아래를 판 포트폴리오다

factor — 매월 다시 줄 세우고 다음 달 수익률로 잰다



핵심 수식

팩터 수익률은 두 묶음의 수익률 차이다

롱숏(long-short) 포트폴리오 — 산 금액과 판 금액이 같다

$$\underbrace{F_t}_{\text{팩터 수익률}} = \underbrace{R_t^{\text{상위}}}_{\text{특성 상위 묶음 수익률}} - \underbrace{R_t^{\text{하위}}}_{\text{특성 하위 묶음 수익률}}$$

왜 사고파는가

- 두 묶음 모두 시장 위험을 비슷하게 갖는다
- 차이를 내면 시장 위험이 대부분 상쇄된다
- 그래서 그 특성의 효과만 남는다

예: 가치 팩터

- 장부가 대비 시가가 높은 싼 주식을 산다
- 비싼 주식을 판다
- 한 달 뒤 싼 묶음이 2%, 비싼 묶음이 1.5% 면 팩터 수익은 0.5%다

학계와 실무가 가장 많이 쓰는 팩터는 여섯 가지다

본 실습의 JKP 데이터에는 이를 포함해 153개 팩터가 들어 있다

팩터	무엇을 사는가	처음 보고한 연구
규모 (size)	시가총액이 작은 기업	Banz(1981)
가치 (value)	장부가에 비해 주가가 싼 기업	Fama·French(1992)
모멘텀 (momentum)	지난 1년 동안 많이 오른 종목	Jegadeesh·Titman(1993)
수익성 (profitability)	이익률이 높은 기업	Novy-Marx(2013)
투자 (investment)	자산을 적게 늘린 기업	Fama·French(2015)
저위험 (low risk)	베타나 변동성이 낮은 종목	Frazzini·Pedersen(2014)

팩터 수익에는 위험 설명과 행동 설명이 함께 있다

어느 설명이 맞는지에 따라 앞으로도 수익이 이어질지 판단이 달라진다

위험 설명

- 싼 기업은 불황에 더 크게 무너진다
- 나쁜 때 손실을 감수한 대가로 수익을 받는다
- 그렇다면 수익은 앞으로도 이어진다

행동 설명

- 투자자가 나쁜 소식에 지나치게 비관한다
- 가격이 바로잡히는 과정에서 수익이 난다
- 그렇다면 알려질수록 수익이 줄어든다

본 강의의 McLean·Pontiff 에피소드가 이 논쟁과 이어진다

다요인 모형은 수익을 여러 팩터 노출의 합으로 나눈다

Fama·French 5요인 모형(2015) — 시장·규모·가치·수익성·투자

$$\underbrace{r^e_{i,t}}_{\text{초과수익률}} = \underbrace{\alpha_i}_{\text{알파}} + \beta_i \underbrace{MKT_t}_{\text{시장}} + s_i \underbrace{SMB_t}_{\text{규모}} + h_i \underbrace{HML_t}_{\text{가치}} + r_i \underbrace{RMW_t}_{\text{수익성}} + c_i \underbrace{CMA_t}_{\text{투자}} + \varepsilon_{i,t}$$

계수는 노출이다

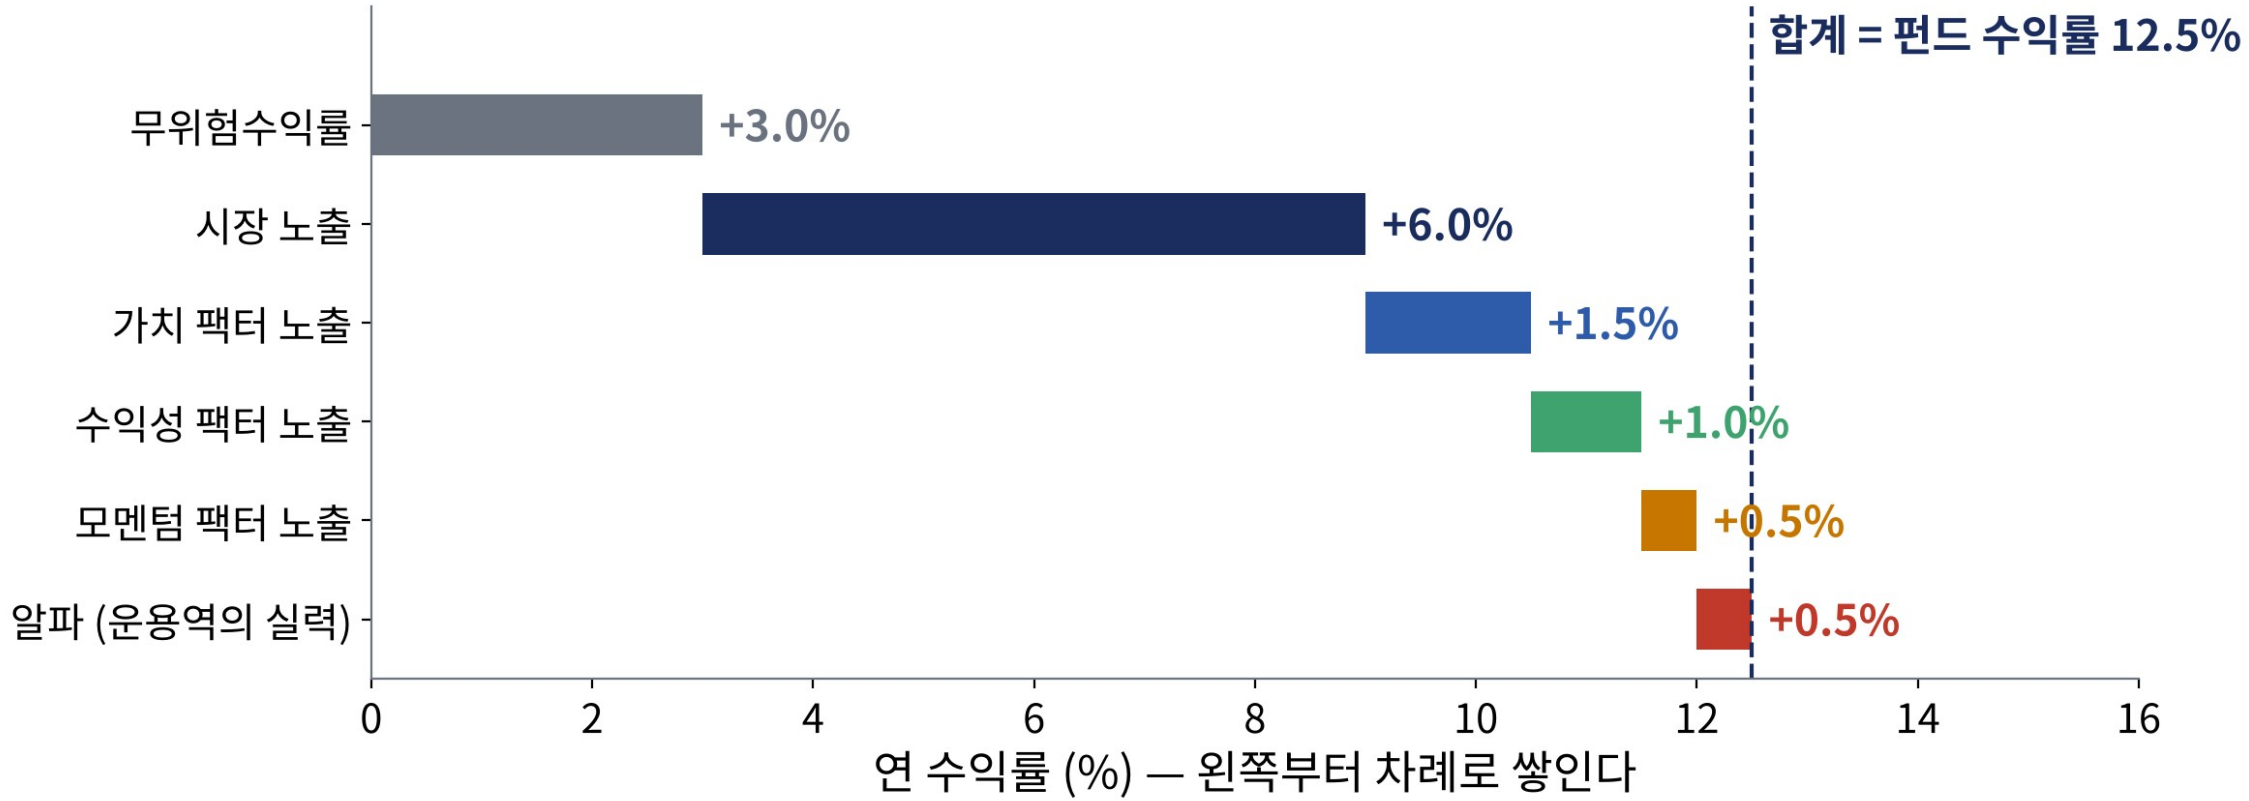
- h가 크면 가치 팩터에 많이 노출된 펀드다
- 노출은 시계열 회귀로 추정한다

알파의 뜻이 바뀐다

- CAPM 알파는 시장만 빼고 남은 수익이다
- 5요인 알파는 다섯 팩터를 모두 빼고 남은 수익이다
- 팩터를 늘릴수록 알파는 대개 줄어든다

펀드 수익의 대부분은 팩터 노출에서 나온다

교육용 예시 — 숫자는 설명을 위해 만든 것이다



에피소드

버핏의 수익도 대부분 팩터로 설명된다

Frazzini·Kabiller·Pedersen(2018), Buffett's Alpha, Financial Analysts Journal

0.79

버크셔 해서웨이의 샤프 비율

약 1.7배

추정한 평균 레버리지

유의하지 않음

저위험·우량 팩터를 통제한 뒤의 알파

무엇을 했나

- 싸고, 안전하고, 우량한 주식을 골랐다
- 보험 준비금을 싸게 빌려 레버리지를 썼다

무엇을 배우나

- 위대한 투자도 팩터 언어로 설명할 수 있다
- 버핏의 실력은 이 팩터를 일찍, 꾸준히 지킨 데 있다

에피소드

노르웨이 국부펀드는 액티브 수익의 대부분이 팩터였다

Ang·Goetzmann·Schaefer(2009) — 노르웨이 재무부에 낸 보고서

99%

기금 수익 변동 가운데 벤치마크로 설명되는 몫

약 70%

액티브 수익 가운데 팩터로 설명되는 몫

보고서의 권고

- 팩터 노출을 숨기지 말고 드러내 관리하라
- 장기 투자자의 이점을 살려 팩터를 의도적으로 가져가라

본 강의와의 연결

- 이 생각이 팩터 슬리브로 이어진다
- 남은 질문은 어떤 팩터를 담느냐다

04

4부 · 알파를 의심하는 법

우연과 실력을 구별하기

좋아 보이는 알파가 진짜인지 판정하는 세 가지 도구

핵심 수식

알파를 확신하려면 생각보다 훨씬 긴 기록이 필요하다

t 통계량 — 추정값이 추정오차의 몇 배인지 잰다. 2를 넘으면 흔히 유의하다고 본다

$$\underbrace{t}_{t\text{ 통계량}} = \frac{\overbrace{\hat{\alpha}}^{\text{추정 알파}}}{\underbrace{se(\hat{\alpha})}_{\text{추정오차}}}, \qquad se(\hat{\alpha}) = \frac{\overbrace{\sigma_\varepsilon}^{\text{잔차 변동성}}}{\sqrt{\underbrace{T}_{\text{표본 연수}}}}$$

t = 1.12

20년 기록

t = 1.58

40년 기록

T = 64년

t = 2에 이르는 데 필요한 기록

예시 가정: 알파 연 2%, 잔차 변동성 연 8% — 다음 쪽에서 직접 계산한다

20년 동안 연 2%의 알파를 낸 펀드도 t는 1.12에 그친다

가정 — 추정 알파 연 2%, 잔차 변동성 연 8%, 기록 20년

① 추정오차 $se(\hat{\alpha}) = \dfrac{\text{잔차 변동성}}{\sqrt{\text{표본 연수}}} = \dfrac{8\%}{\sqrt{20}} = \dfrac{8\%}{4.47} = 1.79\%$

② t 통계량 $t = \dfrac{\text{추정 알파}}{\text{추정오차}} = \dfrac{2\%}{1.79\%} = 1.12$

③ 판정 $t = 1.12 < 2 \Rightarrow$ 20년 기록으로는 알파가 있다고 말할 수 없다

$$t = 2 \Rightarrow \frac{2\%}{8\%/\sqrt{T}} = 2 \Rightarrow \sqrt{T} = \frac{2 \times 8\%}{2\%} = 8 \Rightarrow T = 8^2 = 64\text{년}$$

t가 2를 넘으려면 추정오차가 1%로 줄어야 하고, 그러려면 표본 연수의 제곱근이 8, 곧 64년 기록이 필요하다

여러 번 시도하면 우연히 통과하는 것이 반드시 나온다

multiple testing — 본 강의 1부의 핵심 주제다

100명이 동전을 다섯 번 던지면 평균 3명은 다섯 번 모두 앞면이 나온다

그 3명은 실력자인가

- 아니다. 100 ÷ 32 ≈ 3명은 운만으로 나온다
- 결과만 보면 실력자처럼 보인다

팩터에서도 같다

- 팩터 153개를 시험하면 효과가 없어도 7~8개는 유의하게 나온다
- 그래서 판정 기준을 올리거나 다른 정보를 함께 쓴다

p값은 효과가 없을 때 이런 결과가 우연히 나올 확률이다

p-value — 작을수록 우연으로 보기 어렵다. 보통 5%를 기준으로 삼는다

$$\underbrace{p\text{값}}_{p\text{-value}} = \Pr\left(|\text{우연히 나올 } t| \geq |\text{관측한 } t| \;\middle|\; \text{진짜 알파} = 0\right), \qquad |t| = 1.96 \;\Leftrightarrow\; p = 5\%$$

읽는 법

- p값 3%는 알파가 0이어도 이만한 t가 100번 중 3번은 나온다는 뜻이다
- 유의수준 a = 5%보다 작으면 발견으로 본다

한 번이면 괜찮다

- 검정을 한 번만 하면 가짜 발견 확률은 5%다
- 문제는 여러 번 할 때 생긴다 — 다음 쪽

검정을 100번 하면 가짜 발견이 하나라도 나올 확률은 99%다

효과가 없는 팩터 K개를 서로 독립으로 각각 5% 기준으로 검정한다고 가정한다

$$\Pr(\text{가짜 발견이 1개 이상}) = 1 - (1 - \underbrace{a}_{\text{유의수준}})^K$$

K = 검정 수

검정 수 K	보정 없음	기준을 a/K로
1	5.0%	5.0%
3	14.3%	4.9%
10	40.1%	4.9%
100	99.4%	4.9%

보정 방법은 두 갈래다

- 가짜 발견을 하나도 안 내려는 방법
- 가짜 발견의 비율을 낮게 묶는 방법

자료: Pedersen, Big Data Asset Pricing 4강 — 이어지는 네 쪽이 고전적(빈도주의) 보정 방법이다

보정의 목표는 가짜 발견 0개이거나 가짜 발견 비율 5%다

FWER(family-wise error rate) · FDR(false discovery rate)

$$\underbrace{FWER}_{\text{가족별 오류율}} = \Pr\left(\text{가짜 발견 수} \geq 1\right), \qquad \underbrace{FDR}_{\text{거짓 발견율}} = \mathbb{E}\left[\frac{\text{가짜 발견 수}}{\text{발견 수}}\right]$$

FWER — 가짜가 하나라도 나올 확률

- "한 건도 틀리면 안 된다"는 기준이다
- 신약 승인처럼 실수 하나가 치명적일 때 쓴다
- 대신 진짜 발견도 많이 놓친다

FDR — 발견 가운데 가짜의 비율

- "발견 20개 중 1개 정도는 틀려도 된다"는 기준이다
- 후보가 수백 개인 팩터 연구에 더 맞는다
- 같은 자료에서 발견이 더 많이 남는다

본페로니는 유의수준을 검정 수로 나눈다

Bonferroni(1936) — FWER를 통제하는 가장 단순한 방법

$$\text{기각(발견)} \iff \underbrace{p_i}_{\text{팩터 } i\text{의 } p\text{값}} < \frac{\overbrace{a}^{\text{유의수준}}}{\underbrace{K}_{\text{검정 수}}} \qquad \text{예: } \frac{5\%}{100} = 0.05\% \iff |t| > 3.48$$

장점

- 검정 수만 알면 바로 쓸 수 있다
- 검정끼리 상관이 있어도 FWER를 지킨다

약점

- 팩터 100개면 t가 3.48을 넘어야 한다
- 지나치게 엄격해 진짜 팩터도 대부분 떨어진다

홀름은 작은 p값부터 차례로 기준을 조금씩 풀어 준다

Holm(1979) — FWER를 지키면서 본페로니보다 발견이 늘 같거나 많다

$$\underbrace{p_{(1)} \le p_{(2)} \le \cdots \le p_{(K)}}_{\text{작은 순서로 정렬}}, \qquad p_{(i)} \le \frac{a}{K-i+1}$$ 이면 발견, 처음 실패하면 멈춘다

1번째

기준 a/K

가장 작은 p값은 본페로니와 같은 기준으로 본다

2번째

기준 a/(K−1)

하나를 통과시켰으니 남은 검정 수로 나눈다

3번째 이후

기준이 점점 커진다

하나라도 기준에 못 미치면 그 뒤는 모두 멈춘다

한 번 실패하면 멈추는 단계적 감소 방식(step-down)이다

BH는 순위에 비례해 기준을 넓혀 발견 비율을 통제한다

Benjamini·Hochberg(1995) — FDR을 통제하는 가장 널리 쓰이는 방법

$p_{(i)} \le \overbrace{i}^{\text{순위}} / K \, a$ 를 만족하는 가장 큰 순위를 k라 하면, 순위 $1 \sim k$를 모두 발견으로 본다

어떻게 다른가

- 순위가 i인 p값의 기준은 a/K의 i배다
- 10번째 p값은 첫 번째보다 기준이 10배 넓다
- 그래서 FWER 방법보다 발견이 훨씬 많다

언제 믿을 수 있나

- 효과 없는 검정끼리 독립이면 FDR ≤ a가 보장된다
- 양의 상관에서도 대체로 잘 작동한다

BY는 상관 구조와 무관하게 FDR을 지킨다

Benjamini·Yekutieli(2001) — JKP가 비교 기준으로 쓴 방법이다

$$p_{(i)} \le \frac{i}{K \underbrace{c(K)}_{\text{보정 계수}}} a, \qquad c(K) = \sum_{j=1}^{K} \frac{1}{j} = 1 + \frac{1}{2} + \cdots + \frac{1}{K}$$

검정 수 K	보정 계수 c(K)
1	1.0
10	2.9
100	5.2
1000	7.5

왜 필요한가

- 팩터들은 서로 강하게 상관되어 있다
- 상관 구조를 몰라도 FDR ≤ a를 보장한다

대가

- BH의 기준을 c(K)로 나누므로 엄격하다
- K = 100이면 기준이 BH의 약 5분의 1이다

같은 p값 10개도 방법에 따라 발견 수가 1~7개로 갈린다

가정 — 팩터 10개(K = 10), 유의수준 a = 5%. 칸의 숫자는 각 방법의 기준이고 ○는 발견이다

순위	p값	보정 없음 0.05	본페로니 0.005	홀름 a/(K−i+1)	BH i×0.005	BY i×0.0017
1	0.001	○	○	0.0050 ○	0.005 ○	0.0017 ○
2	0.004	○	○	0.0056 ○	0.010 ○	0.0034 ×
3	0.006	○	×	0.0063 ○	0.015 ○	0.0051 ×
4	0.009	○	×	0.0071 × 멈춤	0.020 ○	0.0068 ×
5	0.012	○	×	—	0.025 ○	0.0085 ×
6	0.030	○	×	—	0.030 ○	0.0102 ×
7	0.045	○	×	—	0.035 ×	0.0119 ×
8~10	0.20 이상	×	×	—	×	×
발견 수		7개	2개	3개	6개	1개

BH는 기준을 넘는 가장 큰 순위(6위)까지 모두 발견으로 본다 — BY의 c(10) = 2.93

고전적 보정은 가짜 발견을 줄이는 대신 진짜 발견도 함께 잃는다

JKP 미국 팩터 재현율: 보정 없는 OLS 82.4%, BY 75.6%, 계층적 베이지안 82.4%

방법	무엇을 통제하나	상관이 있어도 되나	엄격한 정도
본페로니	FWER	된다	가장 엄격하다
홀름	FWER	된다	본페로니보다 조금 너그럽다
BH	FDR	독립 또는 양의 상관	가장 너그럽다
BY	FDR	어떤 상관이든 된다	BH보다 엄격하다

본 강의로 가는 다리

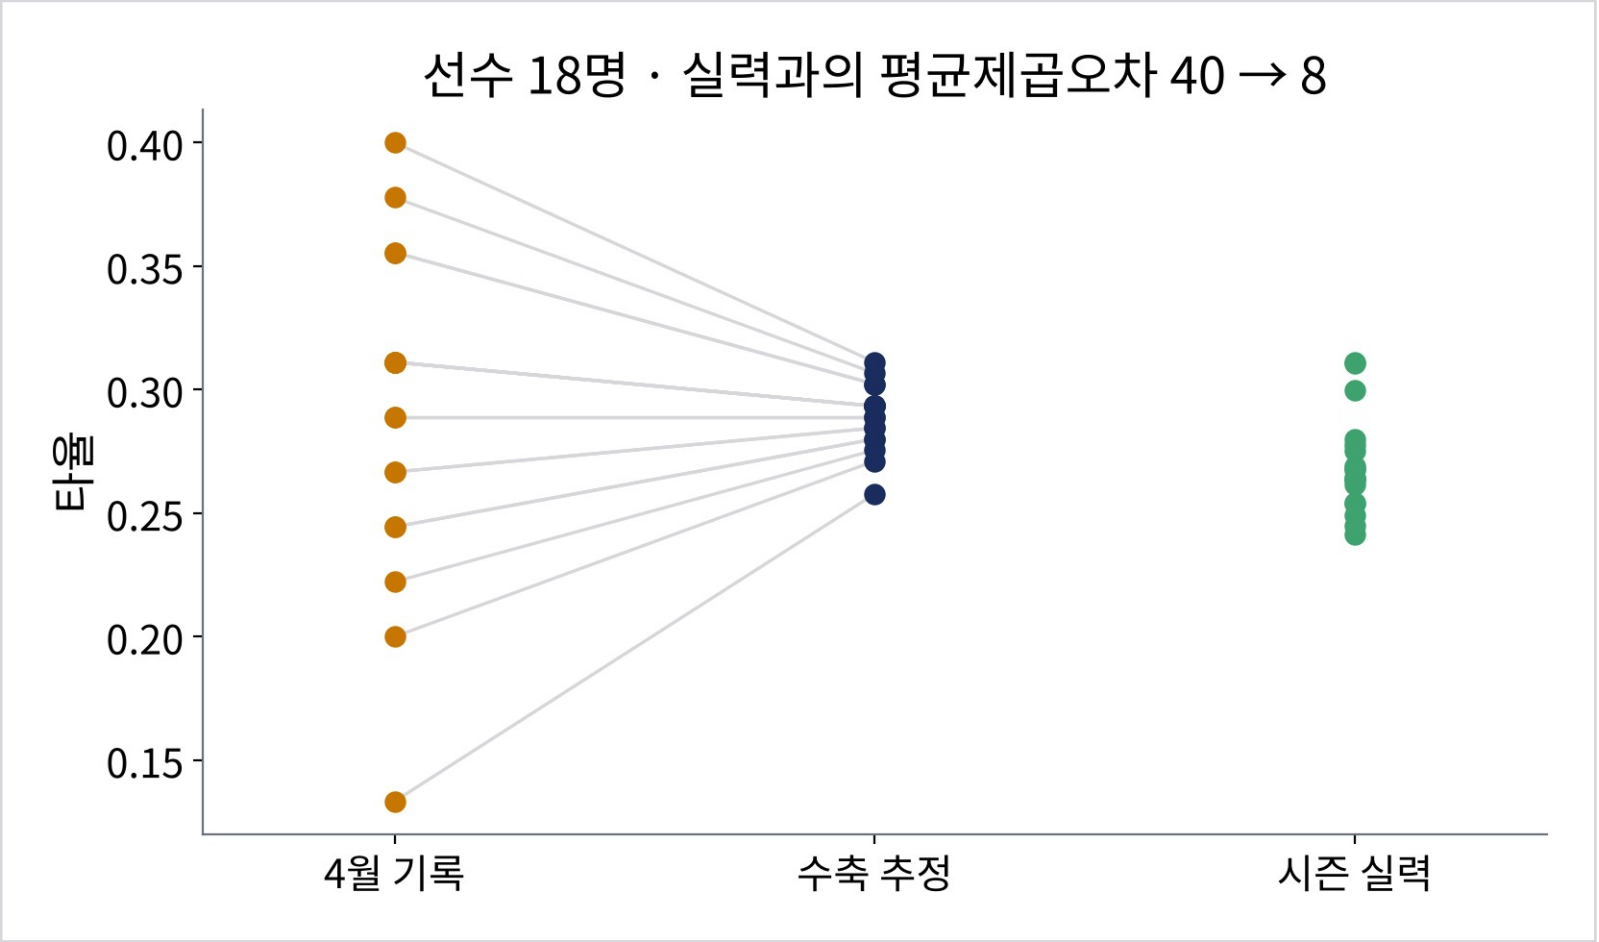
- 계층적 베이지안은 비슷한 팩터의 증거를 빌려, 가짜 발견을 통제하면서도 발견을 잃지 않는다

시즌 초 타율은 평균 쪽으로 당겨야 더 잘 맞는다

Efron·Morris(1975)의 야구 타율 예제를 시뮬레이션으로 재현했다

읽는 법

- 주황: 4월 기록
- 파랑: 평균 쪽으로 당긴 값
- 초록: 실제 실력
- 당긴 값이 더 가깝다



핵심 수식

수축은 개인 기록과 집단 평균을 섞는 일이다

shrinkage — 기록이 짧고 잡음이 클수록 집단 평균을 더 믿는다

$$\underbrace{\text{믿을 만한 추정}}_{\text{수축 추정}} = \underbrace{\kappa}_{\text{신뢰 비중}} \times \underbrace{\text{관측값}}_{\text{이 선수의 기록}} + (1-\kappa) \times \underbrace{\text{집단 평균}}_{\text{비슷한 선수들의 평균}}$$

야구에서

- 4월 45타석의 4할 타율은 운이 많이 섞였다
- 리그 평균 쪽으로 당기면 시즌 성적을 더 잘 맞힌다

팩터에서

- 팩터의 추정 알파도 운이 섞인 기록이다
- 비슷한 팩터들, 즉 같은 군집의 평균 쪽으로 당긴다
- 이것이 본 강의 2부의 계층적 베이지안 검정이다

베이지안은 다중검정을 따로 보정하지 않아도 된다

Gelman·Hill·Yajima(2012), Why We (Usually) Don't Have to Worry about Multiple Comparisons

고전적 검정

- 검정 하나는 모수 하나를 위해 설계되었다
- 그래서 여러 개를 검정하면 사후에 기준을 고쳐야 한다
- 보정할수록 기준이 엄격해져 진짜 발견도 잃는다

베이지안

- 모든 팩터의 알파를 한 모형에서 함께 추정한다
- 여러 개라는 사실이 사후분포에 이미 들어간다
- 따로 기준을 고치지 않아도 가짜 발견이 줄어든다

핵심은 수축이다 — 운 좋게 크게 나온 알파를 미리 깎아 둔다

이하 8쪽은 Pedersen, Big Data Asset Pricing 4강의 베이지안 부분을 정리한 것이다

선택 편향

가장 좋아 보이는 팩터를 고르면 그 알파는 과대평가된다

selection bias — 사전분포가 맞다면 베이지안 추정은 이 편향을 없앤다

$$\underbrace{\hat{\alpha}_i}_{\text{추정 알파}} = \underbrace{\alpha_i}_{\text{진짜 알파}} + \underbrace{\varepsilon_i}_{\text{잡음}}, \quad \alpha_i \sim N(0,\, 0.1^2), \quad \varepsilon_i \sim N(0,\, 0.1^2) \implies \underbrace{\mathbb{E}[\alpha_i \mid \hat{\alpha}_i]}_{\text{베이지안 추정}} = \tfrac{1}{2}\,\hat{\alpha}_i$$

실험

- 팩터 100개를 만들고 추정 알파가 가장 큰 하나를 고른다
- 이를 10,000번 되풀이한다

왜 ½인가

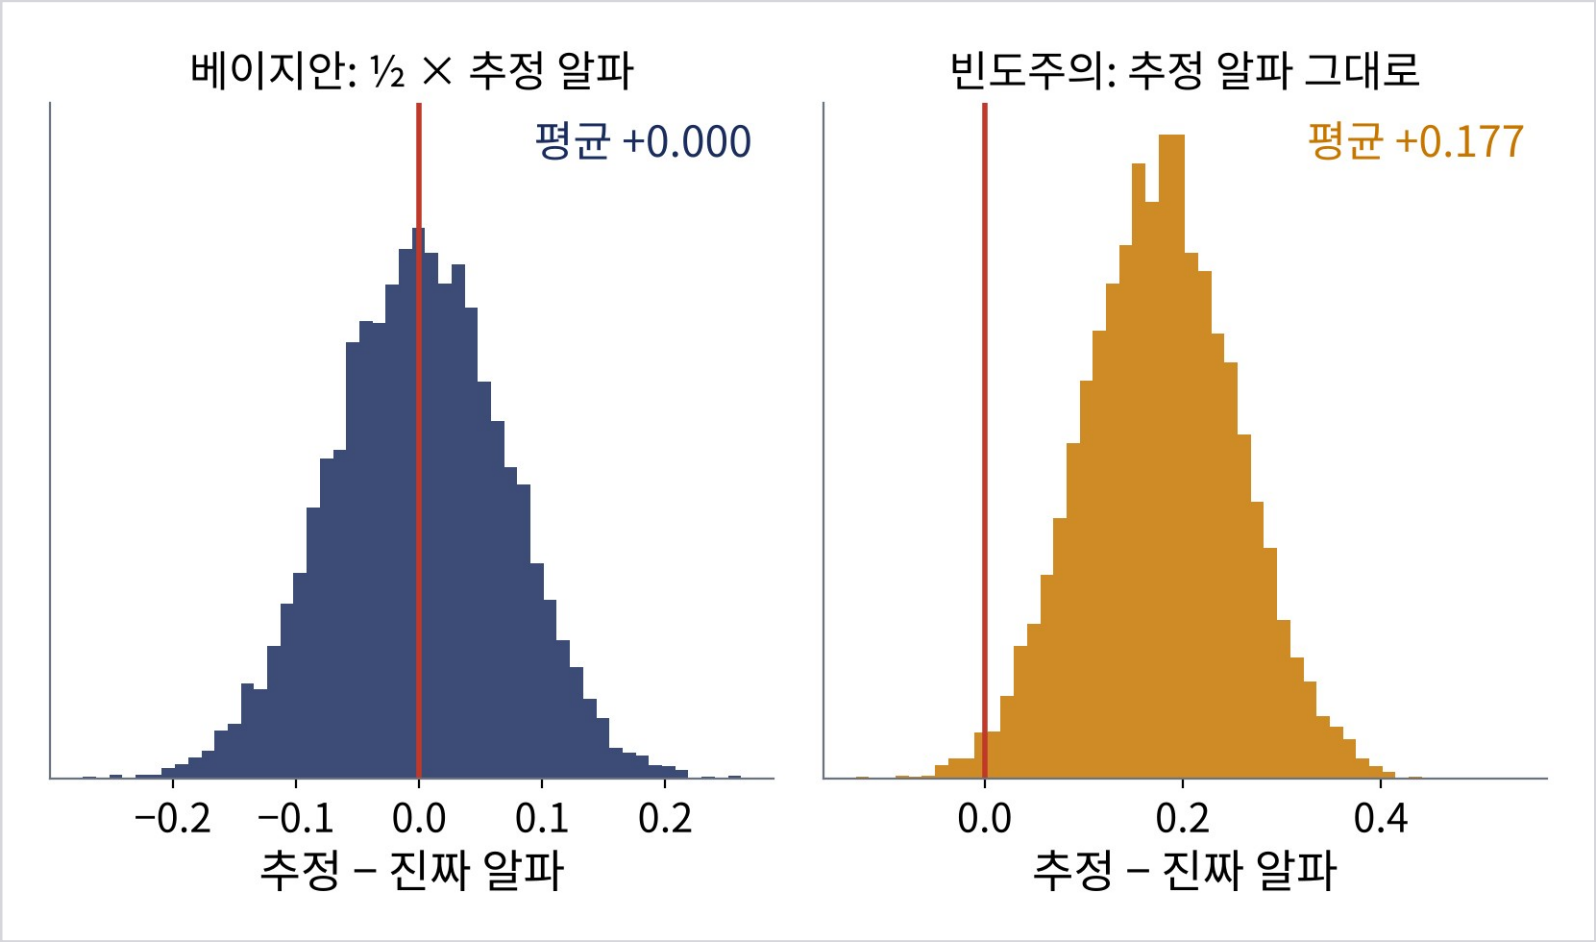
- 진짜 알파와 잡음의 분산이 같다
- 그러니 관측값의 절반만 실력으로 믿는다
- 이것이 수축 계수 κ = 0.5다

고른 팩터의 알파를 그대로 믿으면 체계적으로 부풀려진다

Pedersen의 시뮬레이션을 같은 설정으로 재현했다 — 100개 중 최고 팩터, 10,000회

읽는 법

- 빨간 선: 오차 0
- 왼쪽: 평균 0
- 오른쪽: 평균 +0.18
- 고르는 순간 부풀린다



표본 밖에서 알파가 줄어드는 것은 실패가 아니라 예상된 결과다

가정 — 잔차 변동성 σ 연 10%, 진짜 알파의 퍼짐 τ 연 2%, 표본 T 20년

$$\underbrace{\mathbb{E}(\alpha \mid \hat{\alpha})}_{\text{사후 평균}} = \underbrace{\kappa}_{\text{수축 계수}}\,\hat{\alpha}, \qquad \kappa = \frac{1}{1 + \frac{\overbrace{\sigma^2}^{\text{잔차 분산}}}{\underbrace{\tau^2}_{\text{진짜 알파의 분산}} \cdot \underbrace{T}_{\text{표본 길이}}}} \in (0,1)$$

1.25

σ² ÷ (τ² × T) = 0.01 ÷ 0.008

κ = 0.44

1 ÷ (1 + 1.25)

4% → 1.8%

추정 알파 4%의 사후 평균

표본 밖 알파가 표본 안의 절반 정도로 나오면 '재현 실패'가 아니라 수축이 맞았다는 뜻이다

알파를 부풀렸을 가능성이 있으면 더 세게 수축한다

alpha hacking — 연구자가 좋은 결과가 나올 때까지 설정을 바꿔 보는 행위

$$\mathbb{E}(\alpha \mid \hat{\alpha}) = -\underbrace{\kappa_0}_{\text{부풀린 몫 차감}} + \underbrace{\kappa_{\text{해킹}}}_{\text{더 강한 수축}} \hat{\alpha}, \qquad \kappa_{\text{해킹}} = \frac{1}{1 + \frac{\overbrace{\bar{\sigma}^2}^{\text{해킹으로 커진 분산}}}{\tau^2 T}} \leq \kappa$$

무엇이 바뀌나

- 부풀린 몫 κ_0를 먼저 빼고 남은 것도 더 세게 수축한다
- 해킹이 심하면 $\kappa_{\text{해킹}}$은 0에 가까워진다

표본 밖 자료의 가치

- 표본 안과 밖의 길이가 같아도 표본 밖 자료에 더 큰 비중을 준다
- 논문 발표 뒤의 성과가 중요한 이유다

관련된 증거가 하나 더 있으면 수축이 줄고 확신이 커진다

예 — 같은 팩터의 국내 자료와 해외 자료, 또는 BAB를 만드는 두 가지 방식

$$\mathbb{E}(\alpha \mid \hat{\alpha}, \hat{\alpha}^g) = \kappa_g \left(\tfrac{1}{2} \underbrace{\hat{\alpha}}_{\text{국내 증거}} + \tfrac{1}{2} \underbrace{\hat{\alpha}^g}_{\text{해외 증거}} \right), \qquad \kappa_g = \frac{1}{1 + \frac{\sigma^2}{\tau^2 T} \cdot \frac{1 + \overbrace{\rho}^{\text{두 증거의 상관}}}{2}} \in [\kappa,\, 1]$$

κ = 0.44

국내 자료만 쓸 때

κg = 0.52

해외 자료를 더할 때 (상관 ρ = 0.5)

1.8% → 2.1%

두 자료 모두 알파 4%일 때의 사후 평균

사후 분산도 줄어든다 — 이것이 본 과제가 한국 자료를 함께 보는 이유다

경험적 베이지안은 사전분포를 자료에서 추정한다

empirical Bayes — 추정 알파들이 퍼진 정도가 사전분포를 알려 준다

$$\underbrace{\hat{\alpha}}_{\text{추정 알파 묶음}} \sim N\Big(0,\ \underbrace{\Omega}_{\text{진짜 알파의 퍼짐}} + \underbrace{\Sigma/T}_{\text{잡음의 퍼짐}}\Big), \qquad \Omega_{ik} = \begin{cases} \tau_c^2 + \tau_w^2 & i = k \\ \tau_c^2 & \text{같은 군집} \\ 0 & \text{다른 군집} \end{cases}$$

① OLS 추정

팩터마다 알파와 잡음의 공분산을 구한다

② 퍼짐 추정

추정 알파들이 퍼진 정도에서 τc와 τw를 최대우도로 고른다

③ 사후분포

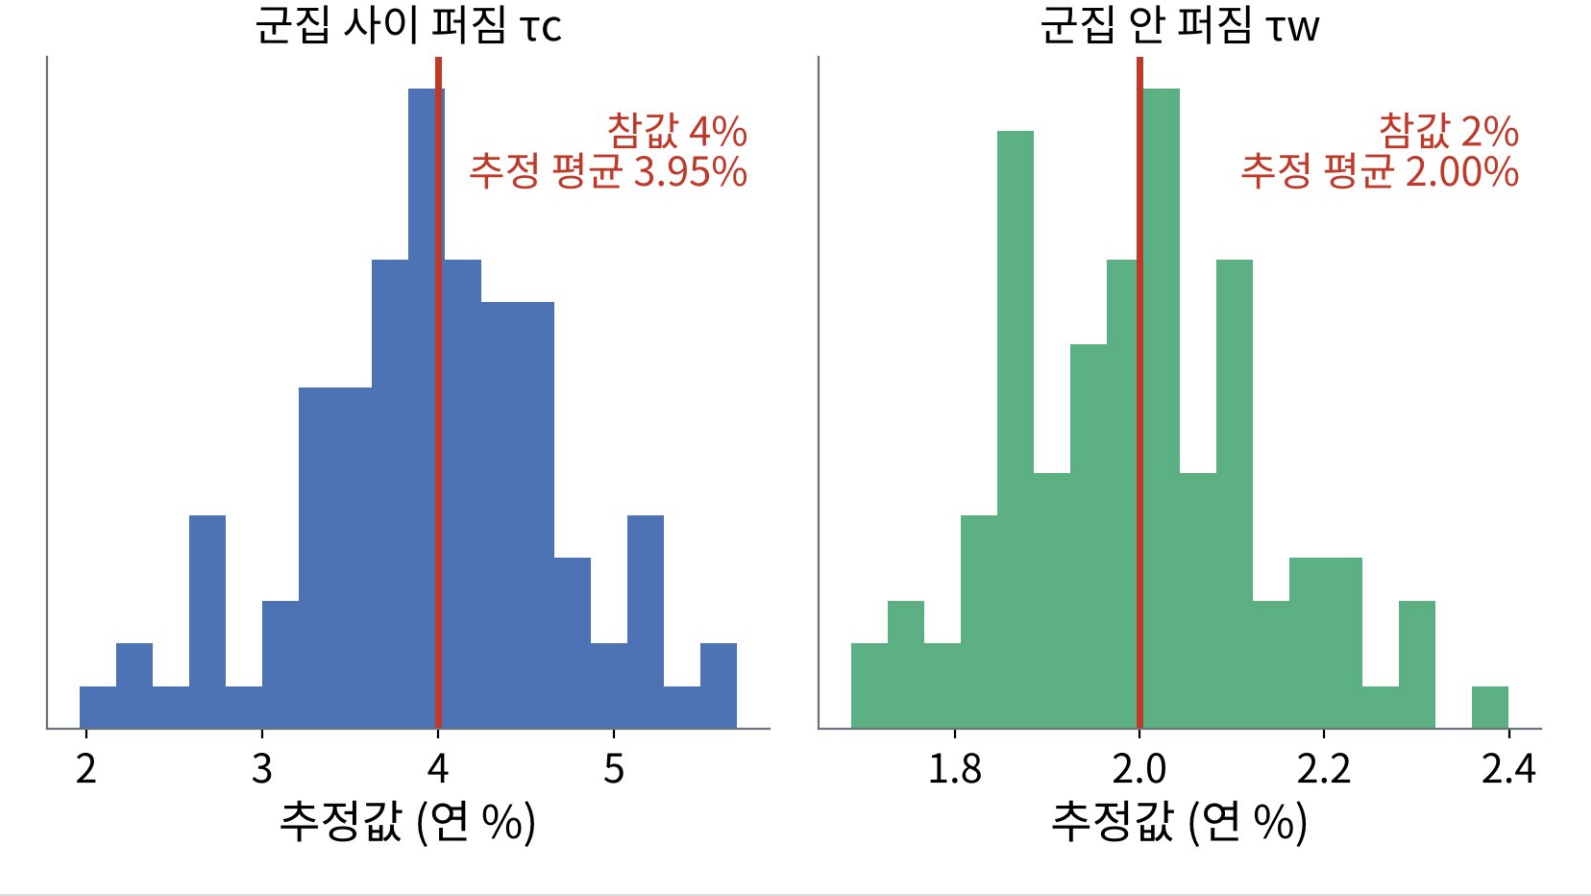
고른 사전분포로 모든 팩터의 사후 평균과 분산을 계산한다

자료만으로도 사전분포의 참값을 잘 찾아낸다

Pedersen의 예제 설정 — 팩터 150개, 군집 15개, 70년, 참값 τc 4%·τw 2%, 100회 재현

읽는 법

- 빨간 선: 참값
- 막대: 100회 추정값
- 추정이 참값 주위에 모인다
- 사전분포를 지어내지 않는다



베이지안의 거짓 발견율은 자료에서 직접 계산된다

발견 기준은 같은 1.96이다 — p-null은 자료를 다 본 뒤 진짜 알파가 0보다 작을 확률

$$\text{발견} \iff \frac{\mathbb{E}(\alpha_i \mid \text{모든 자료})}{\sqrt{\text{Var}(\alpha_i \mid \text{모든 자료})}} > 1.96 \iff \underbrace{p\text{-null}_i}_{\Pr(\alpha_i<0 \mid \text{자료})} < 2.5\%, \qquad FDR^{\text{Bayes}} = \frac{1}{\#\text{발견}} \sum_{i \in \text{발견}} p\text{-null}_i \le 2.5\%$$

0.1%

JKP 자료의 베이지안 거짓 발견율(FDR)

5.5%

가짜 발견이 하나라도 있을 확률(FWER)

사전분포를 안다는 가정 아래의 결과다 — 사후분포에서 p값, FDR, FWER를 모두 계산할 수 있다

계층적 베이지안은 가짜 발견을 통제하면서 검정력을 잃지 않는다

Pedersen 4강의 비교표와 시뮬레이션 결과를 옮겼다

	고전적 보정 (OLS + 다중검정 보정)	계층적 베이지안
추정을 함께 하는가	팩터마다 따로 한다	모든 팩터를 함께 한다
알파 추정값	OLS 그대로 둔다	군집 평균 쪽으로 수축한다
신뢰구간	넓어진다	좁아진다
가짜 발견	통제된다	통제된다
발견 수 (OLS 대비)	줄어든다	자료에 따라 늘거나 줄어든다
검정력	희생된다	유지된다

시뮬레이션에서 BY와 경험적 베이지안은 모두 FDR을 낮게 지켰고, 진짜 발견률은 경험적 베이지안이 더 높았다

본 강의와 실습에서 설명 없이 쓰는 용어를 모았다

영어 원어를 함께 적었다

용어	뜻
초과수익률 (excess return)	수익률에서 무위험수익률을 뺀 값
샤프 비율 (Sharpe ratio)	평균 초과수익률을 변동성으로 나눈 값
베타 (beta)	팩터가 1% 움직일 때 자산이 움직이는 정도
알파 (alpha)	팩터 노출로 설명되지 않고 남은 평균 수익
팩터 (factor)	특성 상위를 사고 하위를 판 롱숏 포트폴리오의 수익률
t 통계량 (t-statistic)	추정값을 추정오차로 나눈 값
다중검정 (multiple testing)	여러 번 검정해 우연히 통과하는 것이 생기는 문제
수축 (shrinkage)	개별 추정값을 집단 평균 쪽으로 당기는 추정

자기 점검

본 강의 전에 다음 네 질문에 답해 본다

정답보다 이유를 말할 수 있는지가 중요하다

Q1	종목을 100개 담은 펀드도 2008년에 크게 손실을 본 이유는 무엇인가?	**1부 · 공통위험**
Q2	베타 1.3인 펀드가 시장보다 높은 수익을 냈다면, 그것만으로 실력이라 할 수 있는가?	**2부 · 베타와 알파**
Q3	가치 팩터 노출이 큰 펀드의 높은 수수료는 정당한가?	**3부 · 수익 분해**
Q4	5년 동안 t = 2.5를 기록한 새 팩터를 바로 슬리브에 넣어도 되는가?	**4부 · 알파 의심**

공통위험을 팩터로 나누고, 남은 알파는 의심한다

다음 단계: 본 강의 「팩터 오디션」

1

분산투자로 남는 공통위험에만 보상이 붙는다

공통위험의 원천이 팩터이고, 그 노출이 베타다.

2

펀드 수익은 팩터 노출과 알파로 나뉜다

버핏과 노르웨이 국부펀드의 수익도 대부분 팩터로 설명되었다.

3

알파는 긴 기록, 다중검정, 수축으로 판정한다

본 강의는 이 세 도구로 팩터의 편입과 퇴출을 정한다.

이제 본 강의에서 어떤 팩터를 슬리브에 담을지 판정해 본다

A

부록 · 2천조 개의 모형

베이지안으로 푼 팩터 동물원

Bryzgalova·Huang·Julliard(2023), Journal of Finance 78(1)

한 장 요약

팩터 51개로 만들 수 있는 모든 모형을 한꺼번에 평가했다

Bayesian Solutions for the Factor Zoo: We Just Ran Two Quadrillion Models

51개

후보 팩터 (거래 가능한 것과 불가능한 것 모두)

2.25×10^{15}

가능한 모형의 수

60개

특성으로 정렬한 테스트 포트폴리오

약 4시간

10코어 워크스테이션 계산 시간

JKP와 무엇이 다른가

- JKP는 팩터의 알파가 재현되는지 묻는다
- 이 논문은 어떤 팩터에 위험의 가격이 붙는지 묻는다

세 가지 결론

- 확실한 팩터는 몇 개뿐이다
- 단 하나의 최선 모형은 없다
- 그래서 모형을 평균한 SDF가 가장 잘 맞는다

확률적 할인계수는 나쁜 때의 돈을 더 비싸게 쳐 주는 할인율이다

SDF(stochastic discount factor) — 팩터가 SDF에 들어가면 그 위험에 가격이 붙는다

$$\underbrace{M_t}_{\text{확률적 할인계수 (SDF)}} = 1 - \Big(\underbrace{f_t}_{\text{팩터}} - \mathbb{E}[f_t]\Big)^{\top} \underbrace{\lambda}_{\text{위험의 가격}}, \qquad \underbrace{\mathbb{E}[R]}_{\text{기대수익률}} = \underbrace{C}_{\text{수익률과 팩터의 공분산}} \lambda$$

읽는 법

- 팩터가 나쁜 쪽으로 움직일 때 M이 커진다
- 그때 돈을 주는 자산은 비싸고 기대수익률이 낮다
- λ가 0이 아니면 그 팩터는 위험의 가격을 가진다

이 논문의 질문

- 51개 팩터 가운데 어떤 것의 λ가 0이 아닌가
- 어떤 팩터 조합이 SDF를 가장 잘 만드는가

팩터마다 넣거나 빼면 모형 수는 2의 거듭제곱으로 늘어난다

model uncertainty — 어떤 모형이 맞는지 모른다는 것도 불확실성이다

$$\underbrace{2^{51}}_{\text{팩터마다 넣거나 빼거나}} = 2{,}251{,}799{,}813{,}685{,}248 \approx 2.25 \times 10^{15} \ \text{(약 2천조 개)}$$

팩터 수	가능한 모형 수	하나씩 검정하면
3	8	손으로 비교할 수 있다
10	1,024	컴퓨터로 비교할 수 있다
51	약 2.25×10^{15}	모두 돌릴 수 없다 — 표본추출(MCMC)로 탐색한다

하나의 모형을 골라 확정하면, 그 선택 자체에서 오는 불확실성을 무시하게 된다

수익률과 거의 관계없는 팩터가 오히려 유의하게 나올 수 있다

weak/useless factor — Kan·Zhang(1999)이 처음 경고한 문제다

$$\underbrace{\mathrm{Cov}(f_j,\, R)}_{\text{약한 팩터와 수익률의 공분산}} \sim \frac{1}{\sqrt{T}} \Longrightarrow \underbrace{\hat{\lambda}_j}_{\text{추정한 위험 가격}}$$

은 표본이 길어질수록 오히려 발산한다

고전적 추정에서

- 약한 팩터의 위험 가격은 식별되지 않는다
- 강한 팩터의 추정까지 함께 틀어진다
- 설명력(R^2)이 부풀려 보인다

평평한 사전분포에서도

- 아무 정보 없는 사전분포를 쓰면
- 가격이 0인 약한 팩터를 확률 1에 가깝게 고른다

그래서 약한 팩터를 미리 알아보고 0 쪽으로 수축하는 사전분포가 필요하다

스파이크-앤-슬랩은 팩터의 포함 여부를 함께 추정한다

spike-and-slab prior — 포함되면 넓은 분포, 제외되면 0에 몰린 분포

$$\underbrace{\lambda_j \mid \gamma_j}_{\text{위험 가격}} \sim N\Big(0,\ r(\gamma_j)\,\psi \underbrace{\rho_j^{\top}\rho_j}_{\text{팩터와 자산의 상관 크기}}\Big), \qquad r(\gamma_j) = \begin{cases} 1 & \text{포함 (슬랩)} \\ 0.001 & \text{제외 (스파이크)} \end{cases}$$

$$\underbrace{\gamma_j}_{\text{포함 여부}} \sim \text{Bernoulli}(\omega_j), \qquad \omega_j \sim \text{Beta}(1,1) \ \Rightarrow\ \text{사전 포함 확률 50\%}$$

두 가지 장치

- 포함 여부 γ를 모형 안에서 확률로 추정한다
- 사전 분산을 상관 크기 ρ'ρ에 비례하게 둔다

사전 정보는 하나뿐

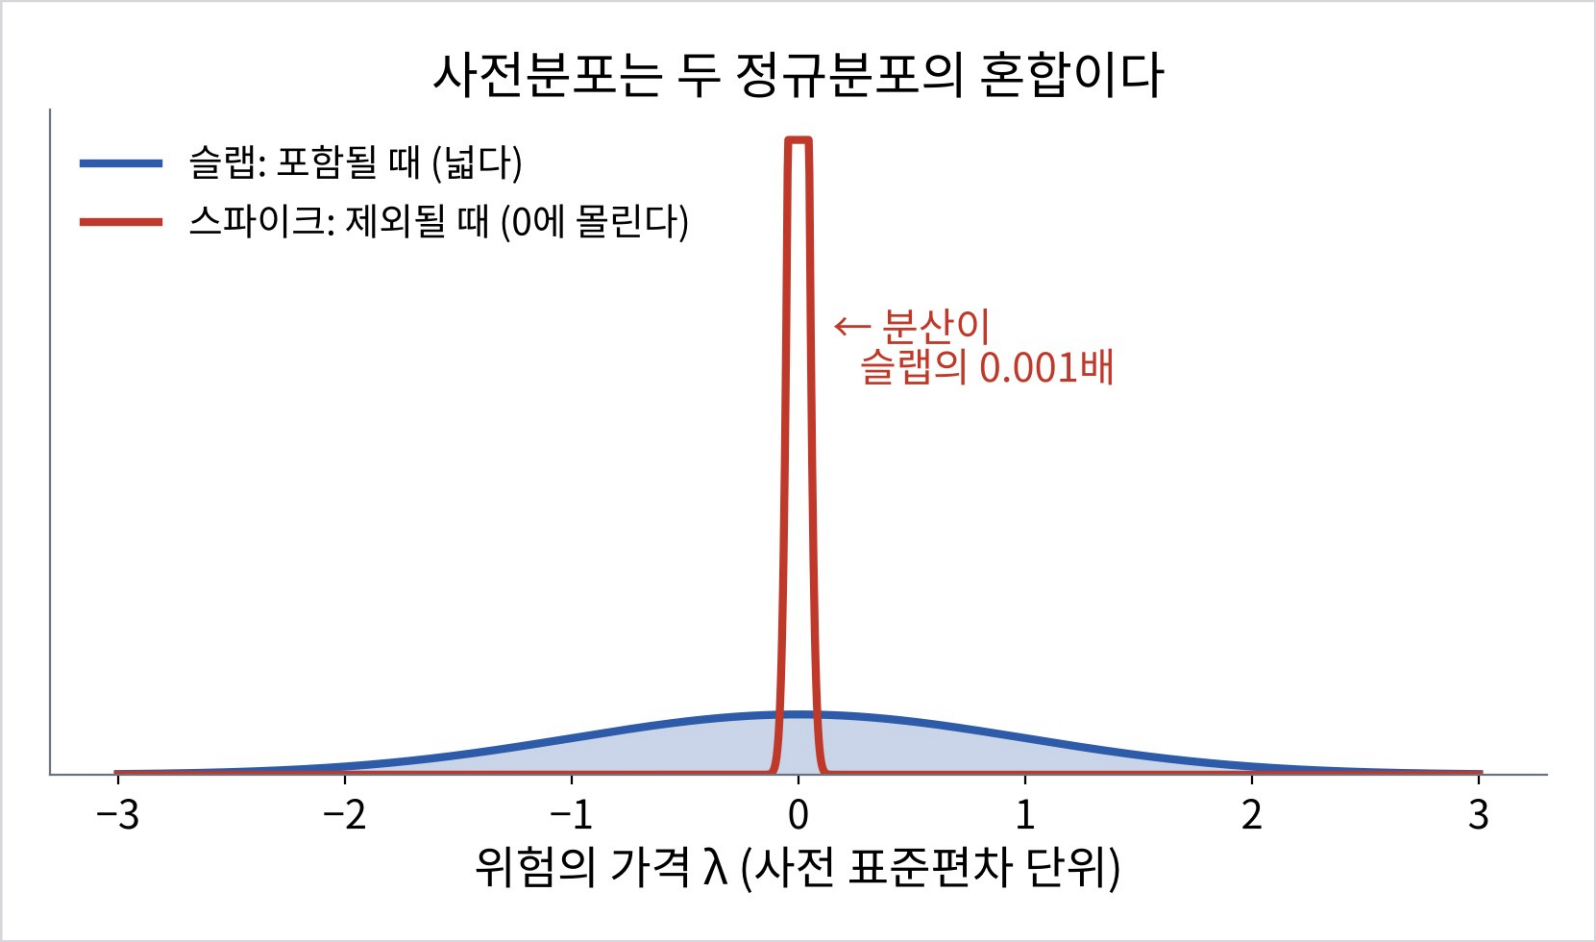
- ψ는 달성 가능한 샤프 비율에 대한 믿음으로 정한다
- 자료를 보고 조정하는 값이 아니다

포함되면 넓게, 제외되면 0에 몰리게 둔다

슬랩의 분산을 1로 두고 그린 그림 — 스파이크의 분산은 그 0.001배다

읽는 법

- 파랑: 포함될 때
- 빨강: 빨강: 제외될 때
- 자료가 둘 중
- 어느 쪽인지 정한다

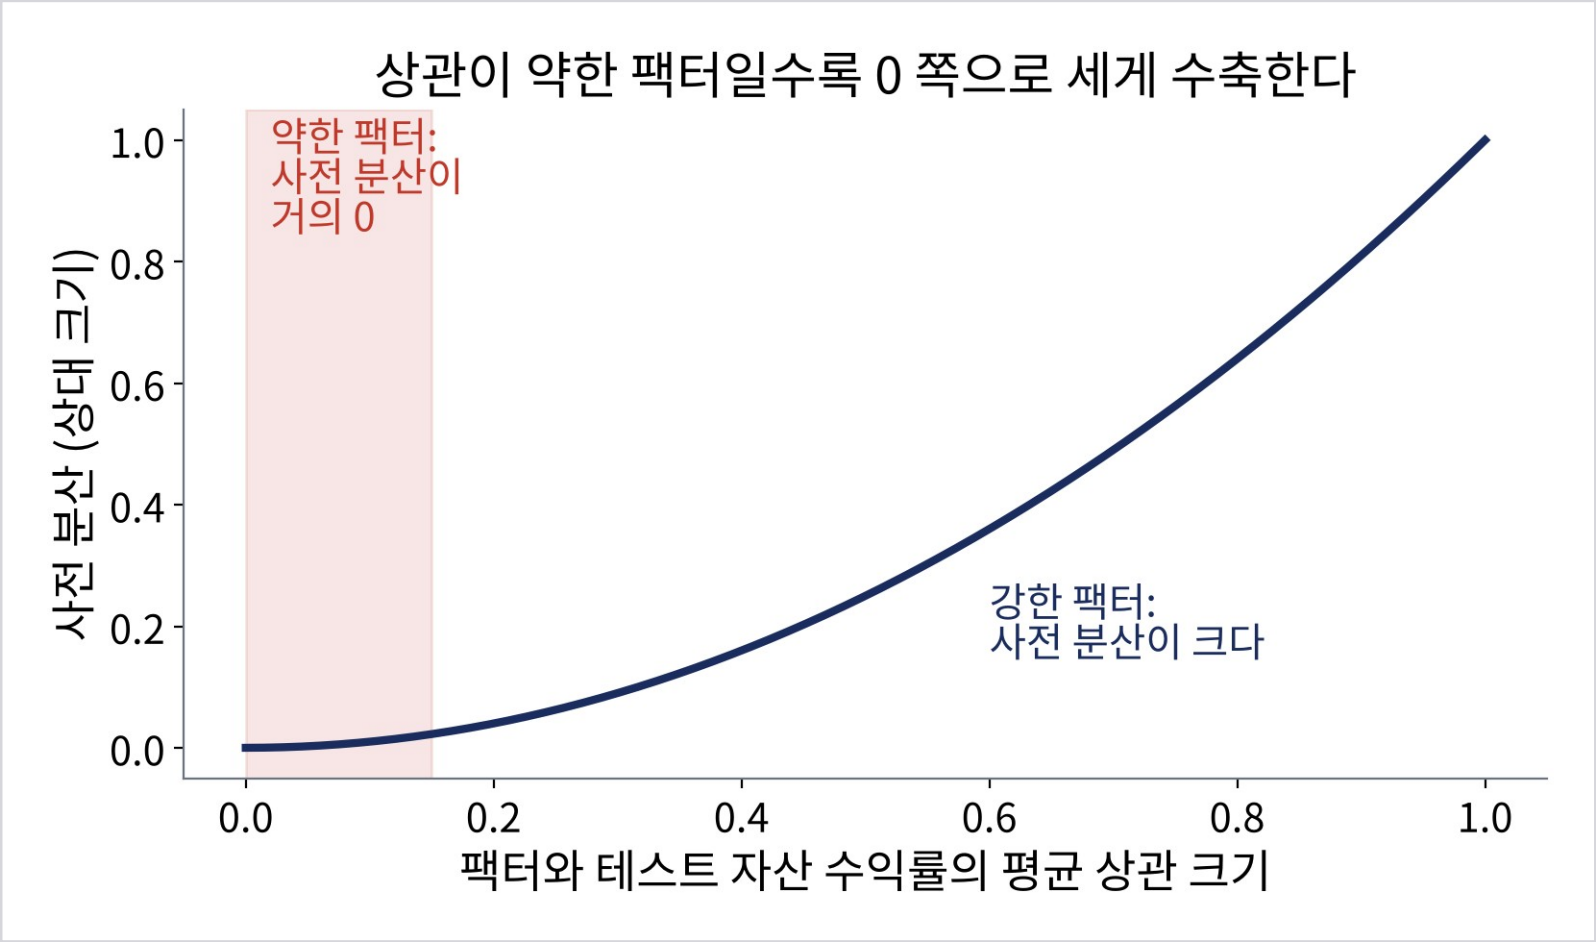


테스트 자산과 상관이 약한 팩터는 처음부터 세게 수축한다

사전 분산이 상관 크기의 제곱에 비례한다는 구조를 그렸다 (개념도)

무엇을 보나

- 왼쪽 빨간 띠: 약한 팩터
- 사전 분산이 거의 0
- 가짜 유의성을 막는다
- 본문 2부의 수축과 같은 생각



모형 하나를 고르지 않고 사후 확률로 가중해 평균한다

BMA(Bayesian model averaging) — 한 모형이 압도하면 그 모형만 남는다

$$\underbrace{\Pr(\gamma_j = 1 \mid \text{자료})}_{\text{팩터 } j\text{의 사후 포함 확률}} = \sum_{m \ni j} \Pr(m \mid \text{자료}),$$

$$\underbrace{M^{\text{BMA}}}_{\text{모형 평균 SDF}} = \sum_{m} \underbrace{\Pr(m \mid \text{자료})}_{\text{모형 } m\text{의 사후 확률}} M_m$$

사후 포함 확률

- 팩터 j가 들어간 모든 모형의 사후 확률을 더한 값이다
- 사전 포함 확률 50%에서 자료가 얼마나 움직였는지 본다

왜 평균하나

- 비슷하게 그럴듯한 모형이 수백 개다
- 하나만 고르면 그 선택이 틀릴 위험을 모두 떠안는다
- 평균은 분산투자와 같은 역할을 한다

결과 ①

확실한 팩터는 몇 개뿐이고, 최선의 모형 하나는 없다

저자들의 보고 — 수백 개 모형이 거의 같은 정도로 그럴듯하다

사후 확률이 가장 높은 3개(많아야 6개) 팩터 모형이 기존 대표 모형들을 쉽게 이긴다

포함 확률이 높은 팩터

- 실적 발표 뒤 가격 표류(PEAD) 팩터
- 시장 지수
- 대부분의 팩터는 포함 확률이 낮다

그래도 남는 것

- 가장 그럴듯한 소형 모형도 자료에 의해 강하게 기각된다
- 그래서 한 모형에 기대지 말고 평균해야 한다

PEAD·시장 지수의 높은 포함 확률은 같은 저자들의 후속 연구(Dickerson·Julliard 외)의 요약을 따랐다

결과 ②

진짜 SDF는 소수 팩터가 아니라 많은 팩터에 퍼져 있다

dense SDF — 주성분 5개를 더해도 결론이 같았다

희소하지 않다

- SDF를 잘 근사하려면 많은 팩터가 필요하다
- 3~5개 팩터 모형으로 시장을 설명한다는 관행과 다르다

표본 밖에서도 강하다

- 모형 평균 SDF는 표본 안과 밖 모두에서 기존 모형보다 낫다
- 만들 때 쓰지 않은 산업 포트폴리오 49개도 잘 가격 매긴다
- 내포된 최대 샤프 비율이 비현실적으로 크지 않다

본 과제의 슬리브 규칙도 소수 팩터에 몰지 않으려는 장치다

질문은 달라도 두 베이지안 접근은 약한 증거를 수축한다

본문 2부의 JKP와 부록의 BHJ를 나란히 놓았다

	Jensen·Kelly·Pedersen(2023)	Bryzgalova·Huang·Julliard(2023)
묻는 질문	팩터의 알파가 재현되는가	어떤 팩터에 위험의 가격이 붙는가
추정 대상	팩터 알파 α	위험의 가격 λ와 포함 여부 γ
사전분포	군집 계층 (τc, τw)	스파이크-앤-슬랩, 상관 크기로 조정
다중검정	사후 t와 베이지안 FDR	사후 포함 확률과 모형 평균
실무 함의	재현된 팩터를 군집별로 고른다	여러 팩터에 나눠 담는다

R 패키지 BayesianFactorZoo(CRAN)로 이 논문의 방법을 직접 돌려 볼 수 있다