실습 연계 강의 · 팩터 오디션

팩터 오디션 — 슬리브 편입과 퇴출의 규칙

팩터 동물원에서 계층적 베이지안 검정과 드로다운 대응까지

Jensen·Kelly·Pedersen(2023) · 자율주행 자산운용(SDAM)의 리서치 에이전트

실습과제 「팩터 오디션」을 수행하기 전에 듣는 강의다. 과제의 각 단계가 왜 그렇게 설계되었는지를 기본 지식, 핵심 수식, 사례 순서로 설명한다.

이 강의는 세 가지 주장으로 요약된다

실습 과제 0~6단계가 모두 이 세 주장에서 나온다

1

팩터는 고르는 순간 과대평가된다

후보가 많을수록 가장 좋아 보이는 팩터는 운의 덕을 본 팩터일 가능성이 크다.

2

같은 군집의 증거를 빌려 알파를 수축한다

계층적 경험적 베이지안 검정은 비슷한 팩터들의 성과로 개별 팩터의 알파를 다시 추정한다.

3

규칙을 먼저 잠가야 에이전트에게 맡길 수 있다

편입·퇴출 기준과 손실 대응을 사전에 등록해 두면 사람도 에이전트도 결과를 보고 규칙을 바꾸지 못한다.

목표: 과제의 숫자를 계산하는 법이 아니라, 그 숫자로 판단하는 법을 익힌다

강의는 다섯 부로 나뉘고 각 부는 과제 단계와 이어진다

왼쪽 질문에 답하면 오른쪽 과제 단계를 풀 수 있다

부	이 부가 답하는 질문	관련 과제 단계
1부 · 슬리브와 팩터 동물원	무엇을 고르며, 고르는 일은 왜 어려운가	부록 A, 0단계
2부 · 계층적 베이지안 검정	어떤 팩터의 알파를 믿을 수 있는가	2단계, 3단계
3부 · 사전 등록과 시점 규칙	판정 규칙을 어떻게 지키는가	1단계, 4단계
4부 · 드로다운 대응 규칙	손실이 오면 무엇을 하는가	6단계
5부 · SDAM 리서치 에이전트	에이전트와 사람은 각각 무엇을 하는가	5단계, 가산 단계

01

1부 · 슬리브와 팩터 동물원

팩터 슬리브와 팩터 동물원

무엇을 고르는지, 그리고 고르는 일이 왜 어려운지 먼저 정리한다

슬리브는 기금 안에서 따로 떼어 운용하는 자금 덩어리다

sleeve — 운용 방식·벤치마크·위험 한도를 따로 갖는다

팩터 슬리브는 가치·모멘텀·수익성 같은 팩터 전략에 맡긴 슬리브다

예시 · 해외주식 350조 원	규모	운용 방식
패시브 인덱스 슬리브	300조 원	MSCI 지수를 그대로 따라간다
액티브 위탁 슬리브	40조 원	외부 운용사 여러 곳에 나눠 맡긴다
팩터 슬리브 (이 강의의 대상)	10조 원	어떤 팩터를 담을지를 정한다

교육용 가정(기금 1,000조 원)이다. 맨데이트(mandate)는 위탁 계약 단위를 뜻한다

팩터는 특성 상위 3분의 1에서 하위 3분의 1을 뺀 수익률이다

Jensen·Kelly·Pedersen(2023)이 153개 팩터에 똑같이 적용한 규칙이다

$$\underbrace{F_{t+1}}_{\text{팩터 수익률}} = \underbrace{d}_{\text{방향 } (\pm 1)} \times \left(\underbrace{\sum_{i \in \text{상위}} w_{i,t}\, r_{i,t+1}}_{\text{상위 3분의 1}} - \underbrace{\sum_{i \in \text{하위}} w_{i,t}\, r_{i,t+1}}_{\text{하위 3분의 1}} \right)$$

경계는 초소형주를 빼고 정한다

- NYSE 시가총액 20분위 미만을 뺀 종목으로 3분위 경계를 정한다
- 초소형주가 경계를 흔들지 않게 하려는 것이다

방향과 시점이 정해져 있다

- 방향 d는 원논문이 보고한 쪽으로 맞춘다
- t월 말에 정렬하고 t+1월 수익률로 잰다

상한 시가총액가중은 대형주의 지배를 막는다

vw_cap — 시가총액을 NYSE 80분위 값에서 자른 뒤 가중한다

$$\underbrace{w_{i,t}}_{\text{vw_cap 비중}} = \frac{\min(me_{i,t},\ \underbrace{\bar{m}_t}_{\text{NYSE 시가총액 80분위}})}{\sum_j \min(me_{j,t},\ \bar{m}_t)},$$

세 가중 방식은 서로 다른 질문에 답한다

- 동일가중은 소형주 효과까지 담는다
- 시가총액가중은 실제로 살 수 있는 규모를 반영한다
- 상한 가중은 그 중간이다

슬리브 규모에 맞는 결과를 기대수익으로 삼는다

- 10조 원 슬리브는 동일가중 성과를 그대로 얻을 수 없다
- 그래서 과제는 vw_cap 팩터로 판정한다

보고된 팩터는 수백 개이고 우리는 그중 몇 개만 고른다

factor zoo — Cochrane(2011)이 붙인 이름이다

316개

Harvey·Liu·Zhu(2016)가 집계한 학술 팩터 수

153개

JKP가 같은 규칙으로 다시 만든 팩터 수

13개

JKP가 상관으로 묶은 군집(테마) 수

93개국

JKP 데이터가 다루는 나라 수

고를 후보가 많을수록, 가장 좋아 보이는 후보가 운의 덕을 봤을 가능성도 커진다

진짜 효과가 없어도 153개 중 평균 7~8개는 유의하게 나온다

다중검정(multiple testing) — 여러 번 검정하면 우연히 통과하는 것이 생긴다

$$\underbrace{\mathbb{E}[\text{우연히 유의한 팩터 수}]}_{\text{진짜 효과가 하나도 없어도}} = \underbrace{N}_{\text{검정한 팩터 수}} \times \underbrace{0.05}_{\text{유의수준}} = 153 \times 0.05 \approx 7.7$$

기준을 올리는 처방

- Harvey·Liu·Zhu(2016)는 t ≥ 3을 새 기준으로 제안했다
- 우연 통과는 줄지만 진짜 팩터도 많이 떨어뜨린다

정보를 더 쓰는 처방

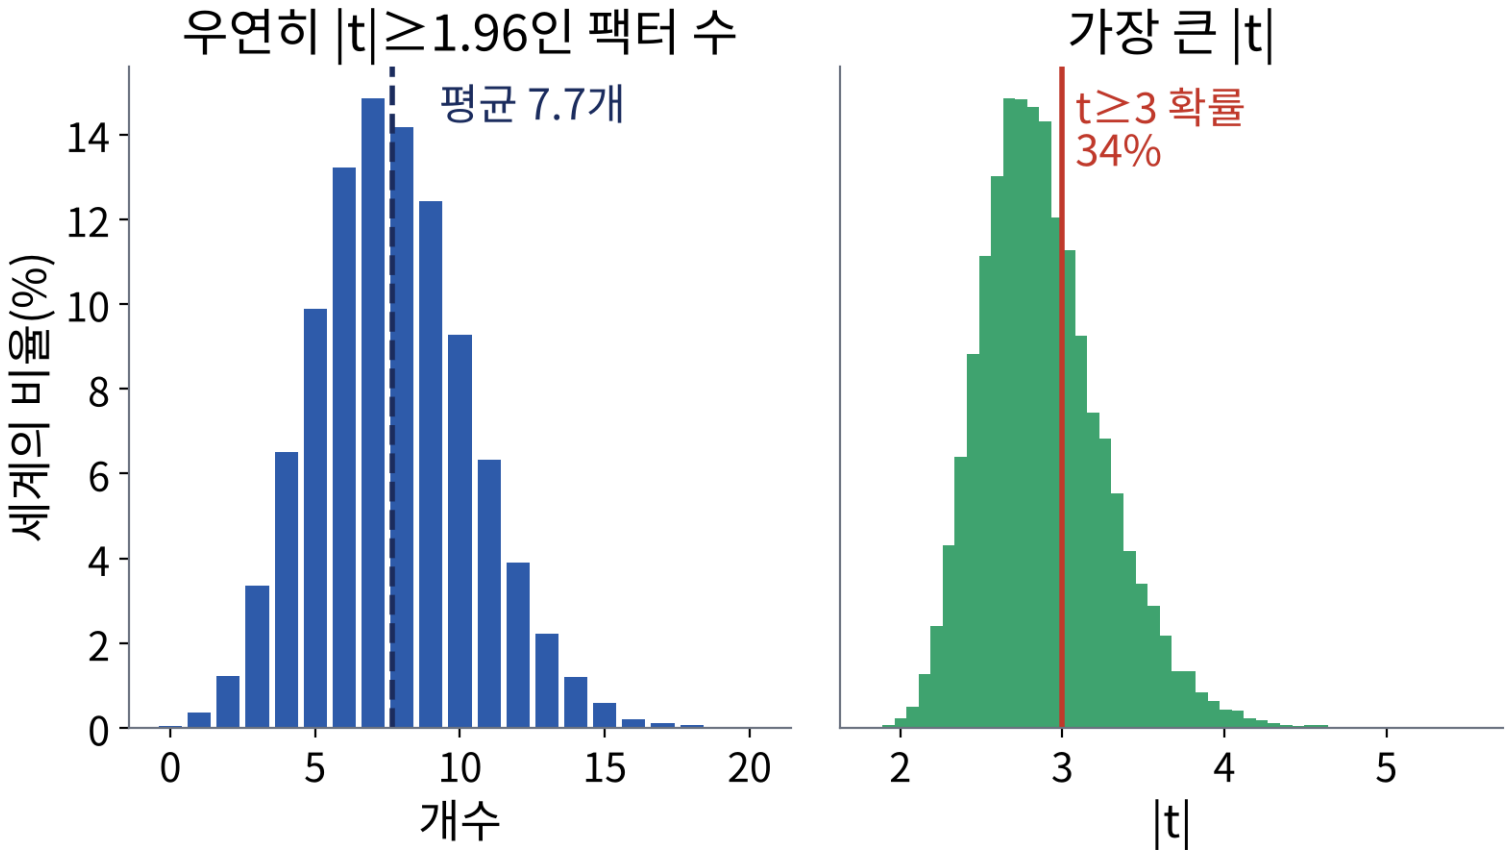
- JKP(2023)는 기준을 올리는 대신 팩터끼리 닮았다는 정보를 쓴다
- 같은 군집의 팩터들이 서로의 증거가 된다

효과가 0인 세계에서도 가장 큰 t는 3에 가깝다

시뮬레이션 예시 — 서로 독립인 팩터 153개, 진짜 알파는 모두 0

읽는 법

- 왼쪽: 우연히 통과한 팩터 수
- 평균 약 7.7개
- 오른쪽: 가장 큰 |t|
- t ≥ 3도 세 번에 한 번



논문이 나온 뒤 팩터 수익은 절반 넘게 줄었다

McLean·Pontiff(2016) — 미국 주식 수익률 예측변수 97개를 추적했다

97개

추적한 수익률 예측변수

−26%

표본 밖(논문 표본 이후, 발표 전) 수익 감소

−58%

논문 발표 이후 수익 감소

감소의 두 원인

- 표본 안의 운이 빠지면서 줄어든 부분이 있다
- 발표 뒤 투자자가 몰려 줄어든 부분이 있다

슬리브에 주는 함의

- 논문에 나온 알파를 그대로 기대수익으로 쓰면 안 된다
- 수축한 알파로 판단해야 한다

과제는 세 판정 규칙을 같은 슬리브 제약 아래에서 비교한다

4단계에서 2000~2020년 다섯 시점의 오디션으로 채점한다

규칙	편입 기준	장점	약점
가. 단순 기준	OLS t ≥ 1.96	단순하고 설명하기 쉽다	우연히 통과한 팩터가 많이 들어온다
나. 상향 기준	OLS t ≥ 3.0	우연 통과가 크게 줄어든다	표본이 짧은 진짜 팩터가 떨어진다
다. 계층 베이지안	사후 t ≥ 1.96	군집 정보를 빌려 짧은 표본도 판단한다	모형 가정과 계산이 복잡하다

세 규칙 모두 퇴출 기준은 t < 1.00이고, 최대 10개·군집당 2개·상관 0.7 이하 제약을 똑같이 적용한다

02

2부 · 계층적 베이지안 검정

경험적 베이지안과 군집 계층

추정한 알파를 얼마나 믿을지, 비슷한 팩터의 증거로 정한다

사후 평균은 추정 알파와 사전 평균의 가중평균이다

수축(shrinkage) — 추정오차가 클수록 사전 평균 쪽으로 더 끌려간다

$$\underbrace{\tilde{\alpha}}_{\text{사후 평균}} = \underbrace{\kappa}_{\text{신뢰 비중}} \underbrace{\hat{\alpha}}_{\text{추정 알파}} + (1-\kappa) \underbrace{\alpha_0}_{\text{사전 평균}}, \qquad \kappa = \frac{\overbrace{\tau^2}^{\text{진짜 알파의 분산}}}{\tau^2 + \underbrace{se^2}_{\text{추정오차 분산}}}$$

신뢰 비중 κ가 정해지는 방식

- 추정오차가 작으면 κ가 1에 가까워 추정값을 믿는다
- 추정오차가 크면 κ가 작아져 사전 평균을 믿는다

왜 '경험적' 베이지안인가

- 진짜 알파의 분산 τ^2를 연구자가 정하지 않는다
- 153개 팩터의 데이터에서 추정한다

t 2.0으로 보이던 팩터의 사후 t는 1.41로 떨어진다

가정: 추정 알파 연 4%, 추정오차 2%, τ 2%, 사전 평균 0

t 2.0

추정 알파 4.0% — 단순 기준으로는 편입

κ = 0.5

추정오차 분산과 진짜 알파 분산이 같다

t 1.41

사후 평균 2.0% — 편입 기준 1.96에 못 미친다

0.92

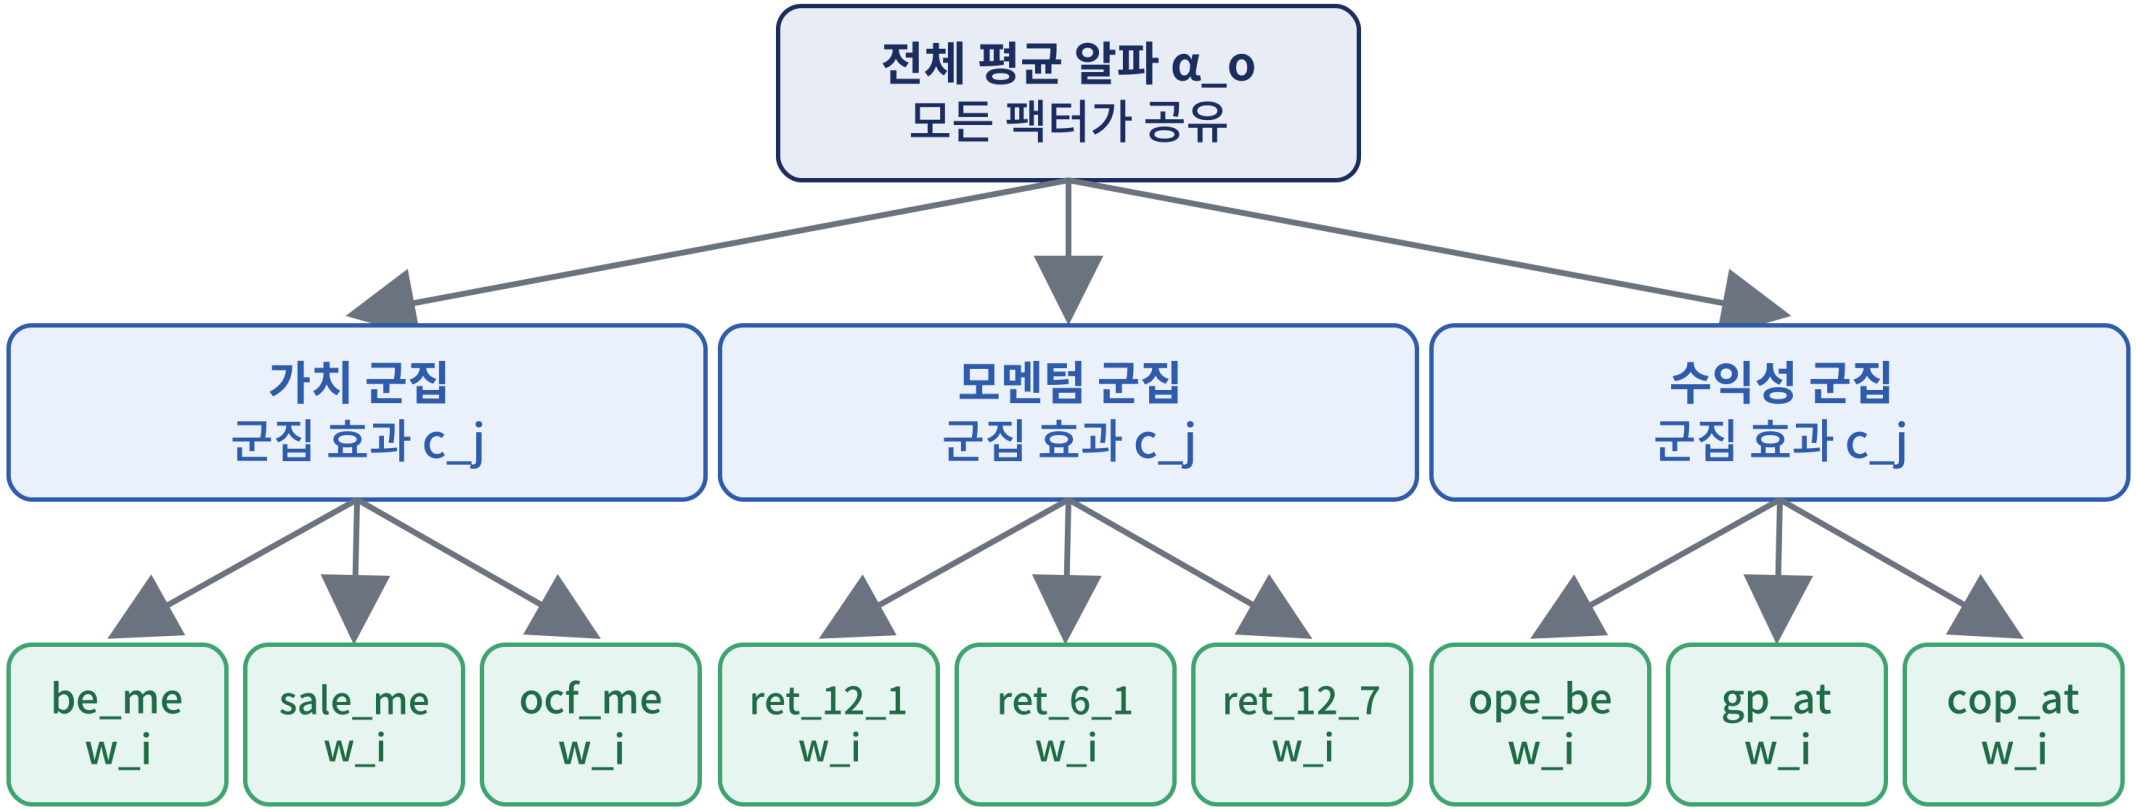
P(α > 0) — 알파가 양일 확률

알파가 있을 가능성은 높지만, 편입할 만큼 확실하지는 않다

단계별 손계산은 워크북에서 다룬다

알파는 전체·군집·팩터의 세 층으로 나뉜다

같은 군집의 팩터는 군집 효과를 함께 나눠 갖는다



13개 군집 · 153개 팩터 가운데 일부만 그렸다 — 같은 군집 팩터는 c_j 를 함께 나눠 가진다

군집 효과가 있으면 같은 군집 팩터의 알파는 서로 상관된다

τc는 군집 사이의 차이, τw는 군집 안 팩터 사이의 차이다

$$\underbrace{\alpha_i}_{\text{팩터 } i\text{의 진짜 알파}} = \underbrace{\alpha_o}_{\text{전체 평균}} + \underbrace{c_{j(i)}}_{\text{군집 효과}} + \underbrace{w_i}_{\text{팩터 고유 효과}}, \qquad c_j \sim N(0, \tau_c^2), \quad w_i \sim N(0, \tau_w^2)$$

$$\underbrace{\Omega}_{\text{진짜 알파의 공분산}} = \underbrace{\tau_c^2 \, MM^\top}_{\text{같은 군집이면 공유}} + \underbrace{\tau_w^2 \, I}_{\text{팩터마다 따로}}, \qquad \underbrace{\hat{\alpha}}_{\text{추정 알파}} \sim N\Big(\alpha_o \iota, \; \Omega + \underbrace{\tfrac{1}{T}\hat{\Sigma}}_{\text{추정오차}}\Big)$$

M은 군집 소속표다

- 팩터 i가 군집 j에 속하면 1, 아니면 0이다

두 τ는 우도 최대화로 정한다

- 추정 알파의 분포가 데이터를 가장 잘 설명하게 고른다

같은 숫자라도 어느 군집에 속했는지에 따라 판정이 갈린다

단순화한 예 — 두 팩터 모두 추정 알파 4%, 추정오차 2%, κ 0.5

	팩터 A	팩터 B
속한 군집의 평균 알파	연 3% (다른 팩터들도 좋다)	연 0% (다른 팩터들은 부진하다)
사후 평균 = 0.5×4% + 0.5×군집 평균	3.5%	2.0%
사후 t (사후 표준편차 1.41%)	2.47 → 편입 후보	1.41 → 탈락

판단 문제 3과 이어진다

- 새 팩터가 다르다는 주장은 군집 밖에 있다는 근거가 있어야 성립한다

편입 판정은 사후 평균을 사후 표준편차로 나눈 값으로 한다

과제 3단계 eb.py가 계산하는 식이다

$$\underbrace{\mathbb{E}[\alpha \mid \hat{\alpha}]}_{\text{사후 평균}} = \alpha_o \iota + \Omega\left(\Omega + \tfrac{1}{T}\hat{\Sigma}\right)^{-1}(\hat{\alpha} - \alpha_o \iota), \qquad \underbrace{\mathrm{Var}[\alpha \mid \hat{\alpha}]}_{\text{사후 공분산}} = \Omega - \Omega\left(\Omega + \tfrac{1}{T}\hat{\Sigma}\right)^{-1}\Omega$$

$$\underbrace{t_i^{\text{post}}}_{\text{사후 } t} = \frac{\text{사후 평균}_i}{\text{사후 표준편차}_i}, \qquad \underbrace{P(\alpha_i > 0)}_{\text{알파가 양일 확률}} = \Phi\left(t_i^{\text{post}}\right)$$

τ가 0이면

- 사후 평균은 모두 사전 평균 0이 된다

τ가 매우 크면

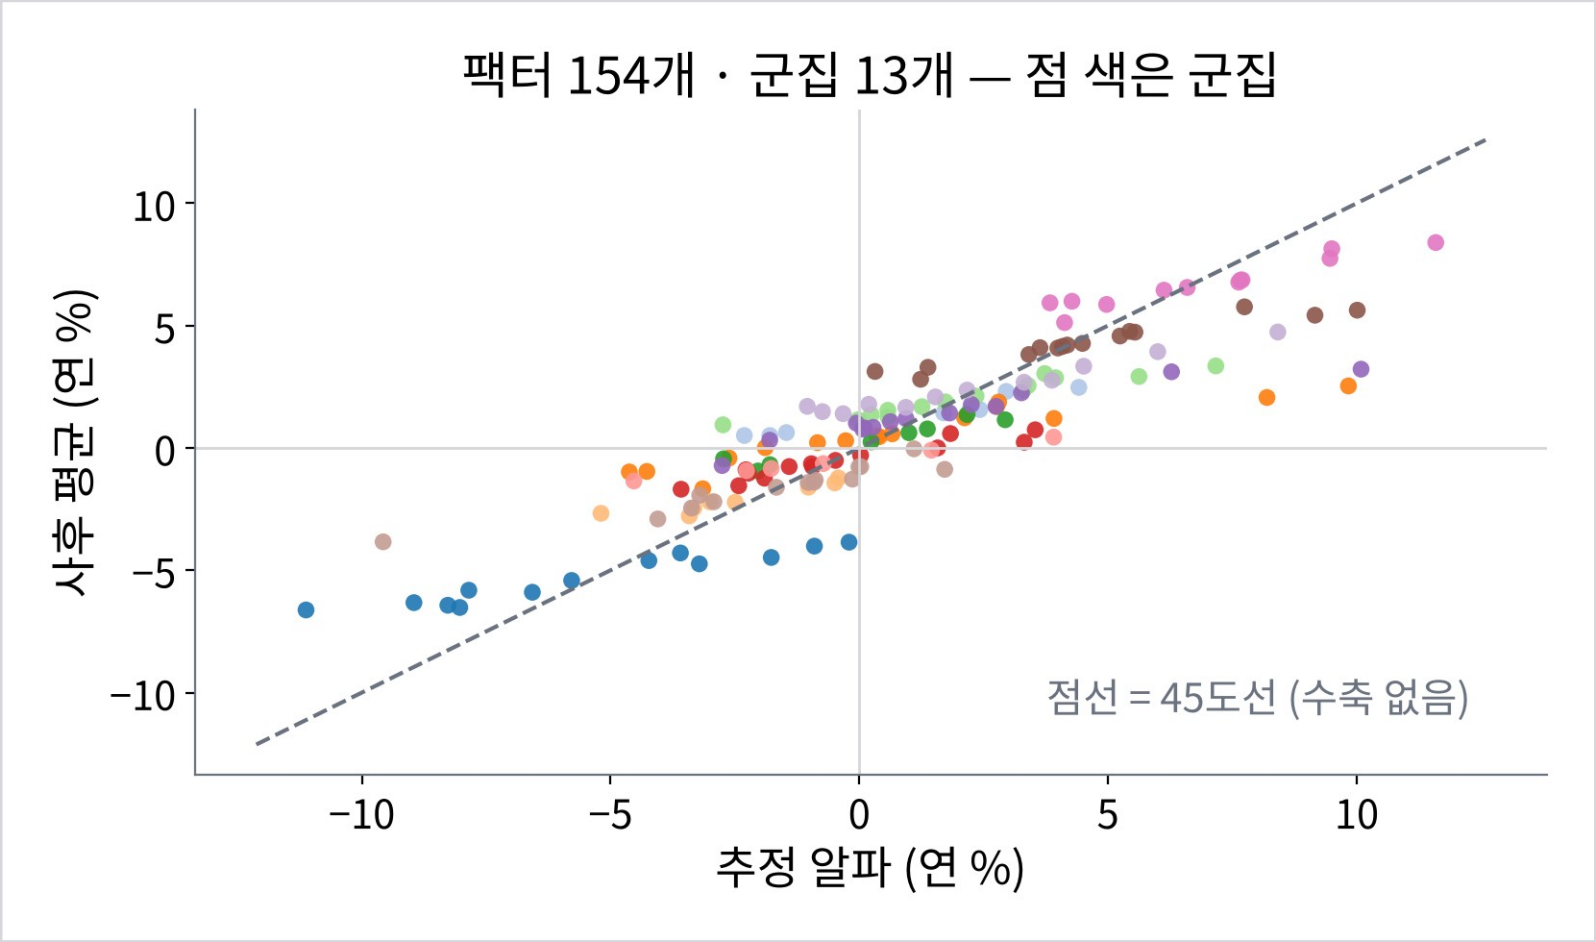
- 사후 평균은 추정 알파와 같아진다 — 3단계 검산 테스트

멀리 나간 추정 알파일수록 0 쪽으로 더 끌려온다

시뮬레이션 예시 — 군집 13개, 팩터 154개, 추정오차 연 1.2~3%

무엇을 보나

- 점선 위는 수축 없음
- 양 끝이 안쪽으로
- 군집끼리 모인다
- 부진 군집은 더 수축



계층적 검정으로 보면 미국 팩터의 대부분은 재현된다

Jensen·Kelly·Pedersen(2023), Journal of Finance — 재현 위기는 과장되었다

미국 팩터의 약 82%가 사후 기준으로 재현된다

무엇이 달라졌나

- 팩터를 하나씩 따로 보지 않고 군집 안에서 함께 본다
- 기준을 올리는 대신 추정 알파를 수축한다
- 다른 나라 자료도 같은 규칙으로 확인한다

슬리브에 주는 함의

- 재현된다는 것과 슬리브에 넣을 만하다는 것은 다르다
- 규모, 상관, 군집 분산을 함께 따져야 한다

신흥시장 팩터도 해외 증거를 빌리면 재현율이 크게 오른다

JKP는 한국을 따로 보고하지 않는다 — 한국은 신흥시장 27개국 묶음에 들어간다

지역	단순 OLS	다중검정 보정	지역 자료만 쓴 베이지안	전 세계 자료를 쓴 베이지안
미국	84.9%	77.3%	84.0%	80.7%
미국 외 선진국	63.2%	35.0%	60.7%	77.8%
신흥시장 (한국 포함)	52.9%	31.9%	56.3%	76.5%

한국만 본 연구 (2020)

- 이상현상 148개 중 t ≥ 1.96은 37.8%다
- 초소형주를 넣느냐에 따라 결과가 달라진다

과제와의 연결

- 한국 사후 평균이 양수여야 편입한다
- 한국 재현율은 3단계에서 직접 구한다

자료: JKP NBER 워킹페이퍼 w28432 Figure 5 (게재본 수치와 조금 다르다) · 한민연·이동현·강형구(2020), 선물연구 28(2)

03

3부 · 사전 등록과 시점 규칙

규칙을 먼저 잠그고 과거로 돌아간다

결과를 보고 규칙을 바꾸면 다중검정 문제가 다시 생긴다

사전 등록은 데이터를 보기 전에 판정 규칙을 잠가 두는 일이다

pre-registration — 임상시험과 실험경제학에서 쓰던 방법이다

규칙을 바꾸고 싶으면 새 버전으로 등록하고, 바꾼 이유와 날짜를 남긴다

왜 사람에게도 필요한가

- 손실이 나면 기준을 낮추자는 압력이 생긴다
- 시장 환경 변화는 규칙 개정 절차로 반영한다

왜 에이전트에게 더 필요한가

- 에이전트는 사람보다 빨리 많은 규칙을 시도할 수 있다
- 그래서 과제는 훅으로 rules.yaml 수정을 기계적으로 막는다

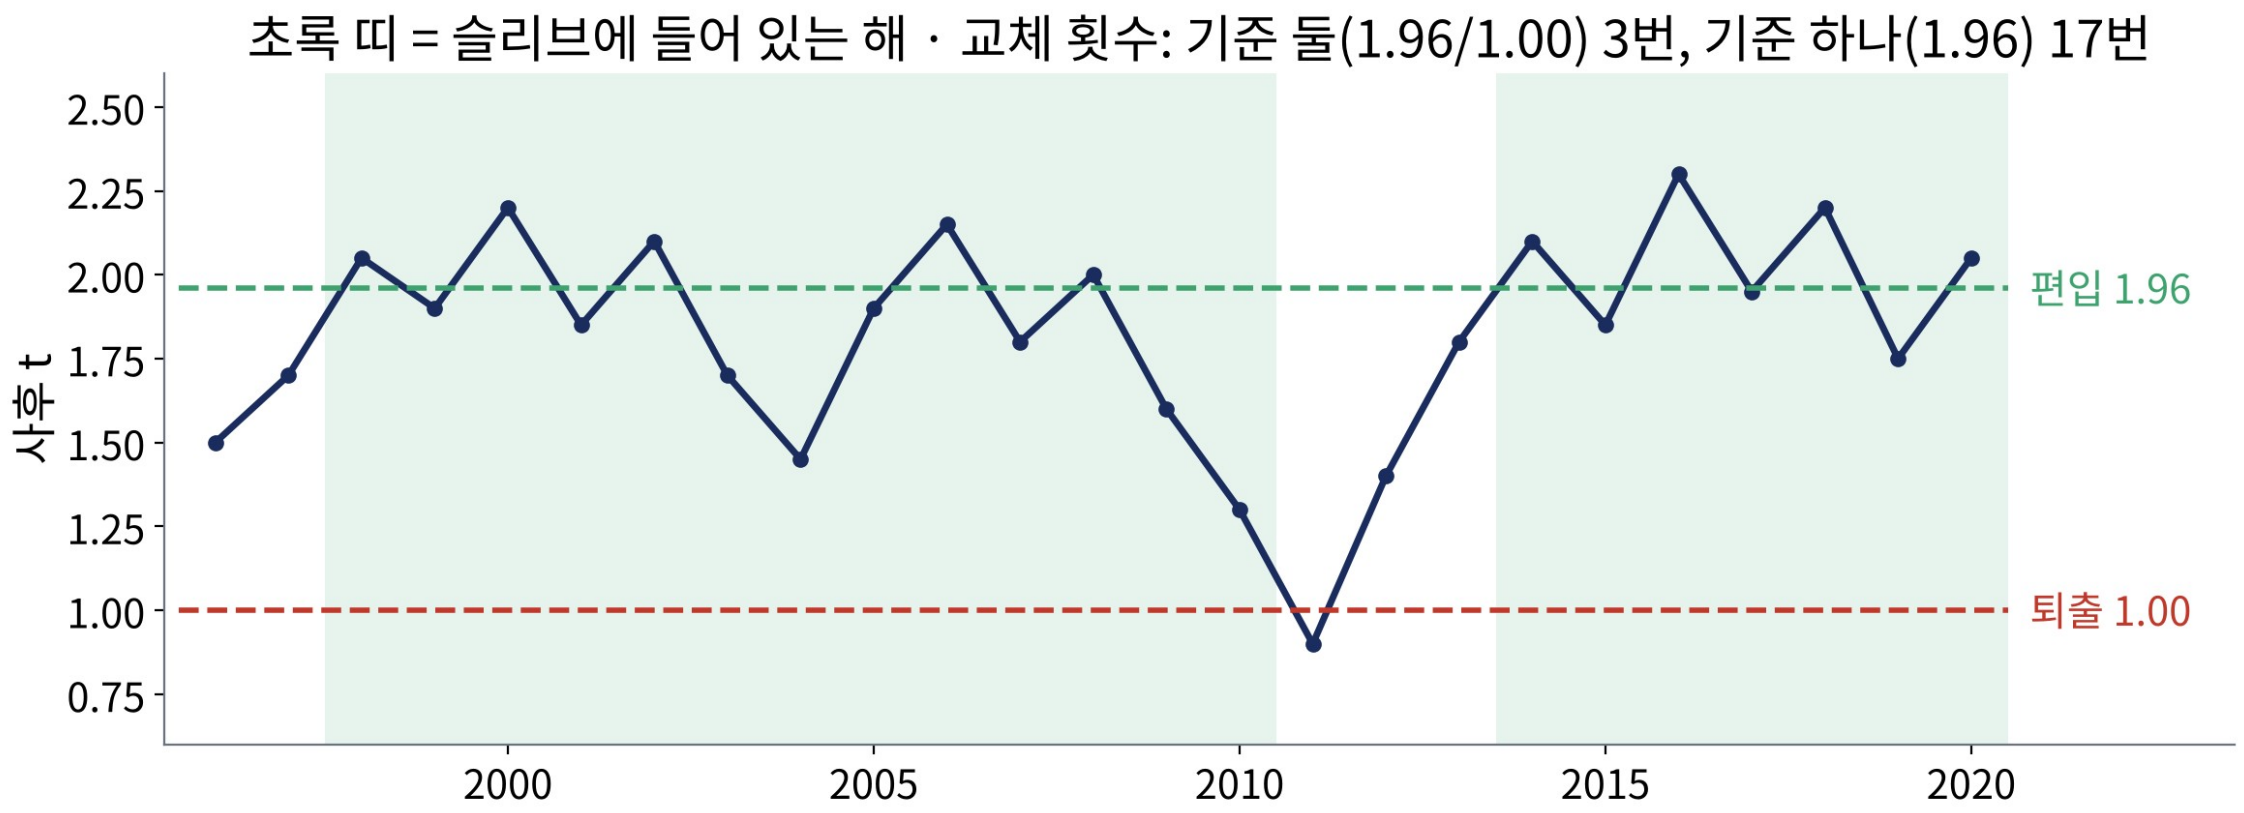
rules.yaml의 숫자 하나하나에는 이유가 있다

과제 1단계 초안이며, 숫자는 팀이 정해 등록한다

항목	값	이유
편입 기준	사후 t ≥ 1.96	재현 판정의 표준 기준이다
퇴출 기준	사후 t < 1.00	경계 근처 팩터가 매년 들락거리지 않게 한다
슬리브 크기	최대 10개, 군집당 2개	한 군집에 위험이 몰리지 않게 한다
상관 한도	기존 팩터와 0.70 이하	같은 위험을 두 번 사지 않게 한다
최소 표본	120개월	추정오차가 지나치게 큰 팩터를 거른다

편입과 퇴출 기준을 다르게 두면 교체가 크게 줄어든다

시뮬레이션 예시 — 같은 사후 t 경로에서 교체 횟수를 비교한다 (hysteresis)



2000년의 결정에는 2000년까지의 데이터만 써야 한다

point-in-time — 이것을 어기면 과거 성과가 비현실적으로 좋아진다

흔한 반칙	왜 반칙인가	과제의 처방
전체 표본으로 만든 군집 사용	미래의 상관으로 과거 군집을 정한다	리뷰 시점마다 군집을 다시 만든다
전체 표본으로 추정한 τ 사용	미래 성과가 사전분포에 들어간다	리뷰 시점까지로 τ를 다시 추정한다
전체 기간 상관으로 상관 한도 판정	나중에 드러난 상관을 미리 안다	리뷰 시점까지의 상관만 쓴다

수강생의 일은 이 반칙을 직접 피하는 것이 아니라, 에이전트가 반칙했는지 찾아내는 것이다

다섯 시점으로 돌아가 오디션을 열고 다음 5년으로 채점한다

2000·2005·2010·2015·2020년 12월 리뷰, 각 규칙의 성과를 비교한다

2000년 12월

닷컴 붕괴 직후의 판정

2005년 12월

가치 팩터가 강하던 시기

2010년 12월

모멘텀 붕괴 직후의 판정

2015년 12월

Value 겨울 직전의 판정

2020년 12월

Value 겨울 저점의 판정

채점 항목	무엇을 보는가
오탐 비율	편입한 팩터 가운데 다음 5년 알파가 음수였던 비율
회전	리뷰마다 교체한 팩터 수 — 위탁 교체 비용과 직결된다

04

4부 · 드로다운 대응 규칙

팩터 겨울을 버티는 규칙

통계 판정은 그대로 두고, 손실 구간에서 할 일을 미리 정한다

가치 팩터는 2007년 무렵부터 2020년까지 긴 손실을 겪었다

Value 겨울 — 2018~2020년에 손실이 가장 깊었다

무슨 일이 있었나

- 성장주가 크게 오르며 가치 팩터가 오래 부진했다
- 2020년 가치 팩터 운용사들은 큰 자금 유출을 겪었다

논쟁

- Asness(2020)는 가치 투자가 죽지 않았다고 반박했다
- Arnott 외(2021)는 무형자산 문제를 지적하면서도 복귀 가능성을 보았다

질문: 2019년 말에 가치 팩터를 슬리브에서 뺐어야 했는가

6단계에서 세 정책(대응 규칙, 그대로 보유, 기계적 매도)을 이 구간으로 비교한다

모멘텀은 2009년 반등장에서 몇 달 만에 크게 무너졌다

Daniel·Moskowitz(2016), Momentum Crashes

왜 무너졌나

- 하락장의 승자는 방어주, 패자는 낙폭이 큰 종목이었다
- 시장이 급반등하자 패자가 더 크게 올랐다

무엇을 배우나

- 손실이 컸다고 바로 빼면 저점에서 판다
- 붕괴가 언제 잘 일어나는지 미리 알아 둔다

손실의 크기만으로 퇴출하지 않는다 — 퇴출은 정기 리뷰의 사후 t로만 한다

긴 표본에서 몇 년의 손실은 사후분포를 조금밖에 바꾸지 못한다

추정오차는 표본 길이의 제곱근에 반비례한다

$$\underbrace{se(\hat{\alpha})}_{\text{알파 추정오차}} = \frac{\overbrace{\sigma}^{\text{잔차 변동성}}}{\sqrt{\underbrace{T}_{\text{표본 개월 수}}}}$$

$$\underbrace{DD_t}_{\text{드로다운}} = \frac{\overbrace{V_t}^{\text{현재 누적가치}}}{\max\limits_{\underbrace{s \le t}_{\text{과거 최고점}}} V_s} - 1$$

통계와 위원회의 시간은 다르다

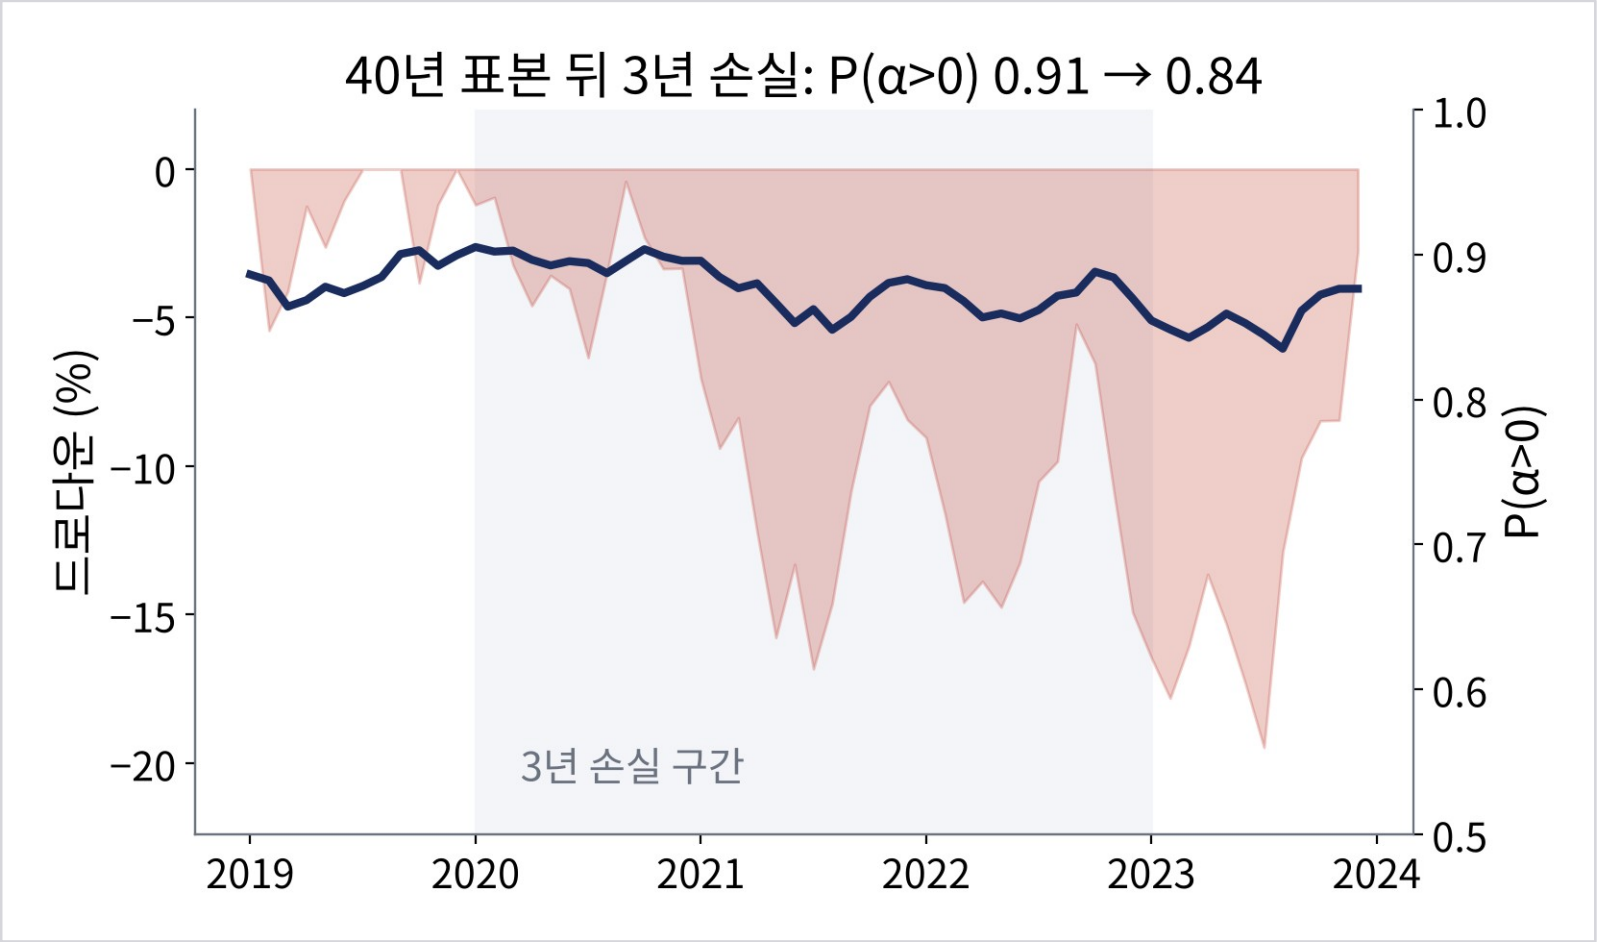
- 480개월 표본에 36개월을 더해도 추정오차는 약 4% 줄어들 뿐이다
- 통계로는 버티는 것이 옳을 때가 많지만, 위원회와 수익자는 2~3년 손실을 견디기 어렵다
- 그래서 손실 구간에서 누가 무엇을 하는지 미리 정한다

3년 손실 뒤에도 알파가 양일 확률은 크게 떨어지지 않는다

시뮬레이션 예시 — 진짜 알파 연 3%, 변동성 10%, 40년 뒤 3년 손실

읽는 법

- 빨간 면: 드로다운
- 파란 선: P(α>0)
- 손실은 깊어도
- 확률은 천천히 준다



손실 단계마다 할 일을 미리 정해 둔다

교육용 기준 — 퇴출은 하지 않고 정기 리뷰에서만 한다

1단계 −10%

보고

월간 보고서에 원인 분석을 싣고 비중은 바꾸지 않는다

2단계 −20%

재검정

그 시점까지의 데이터로 검정을 다시 돌려 P(α>0)를 보고한다

3단계 −30%

결정

P(α>0) ≥ 0.90이면 유지하고 설명서를 낸다. 미만이면 위험을 절반으로 줄인다

회복

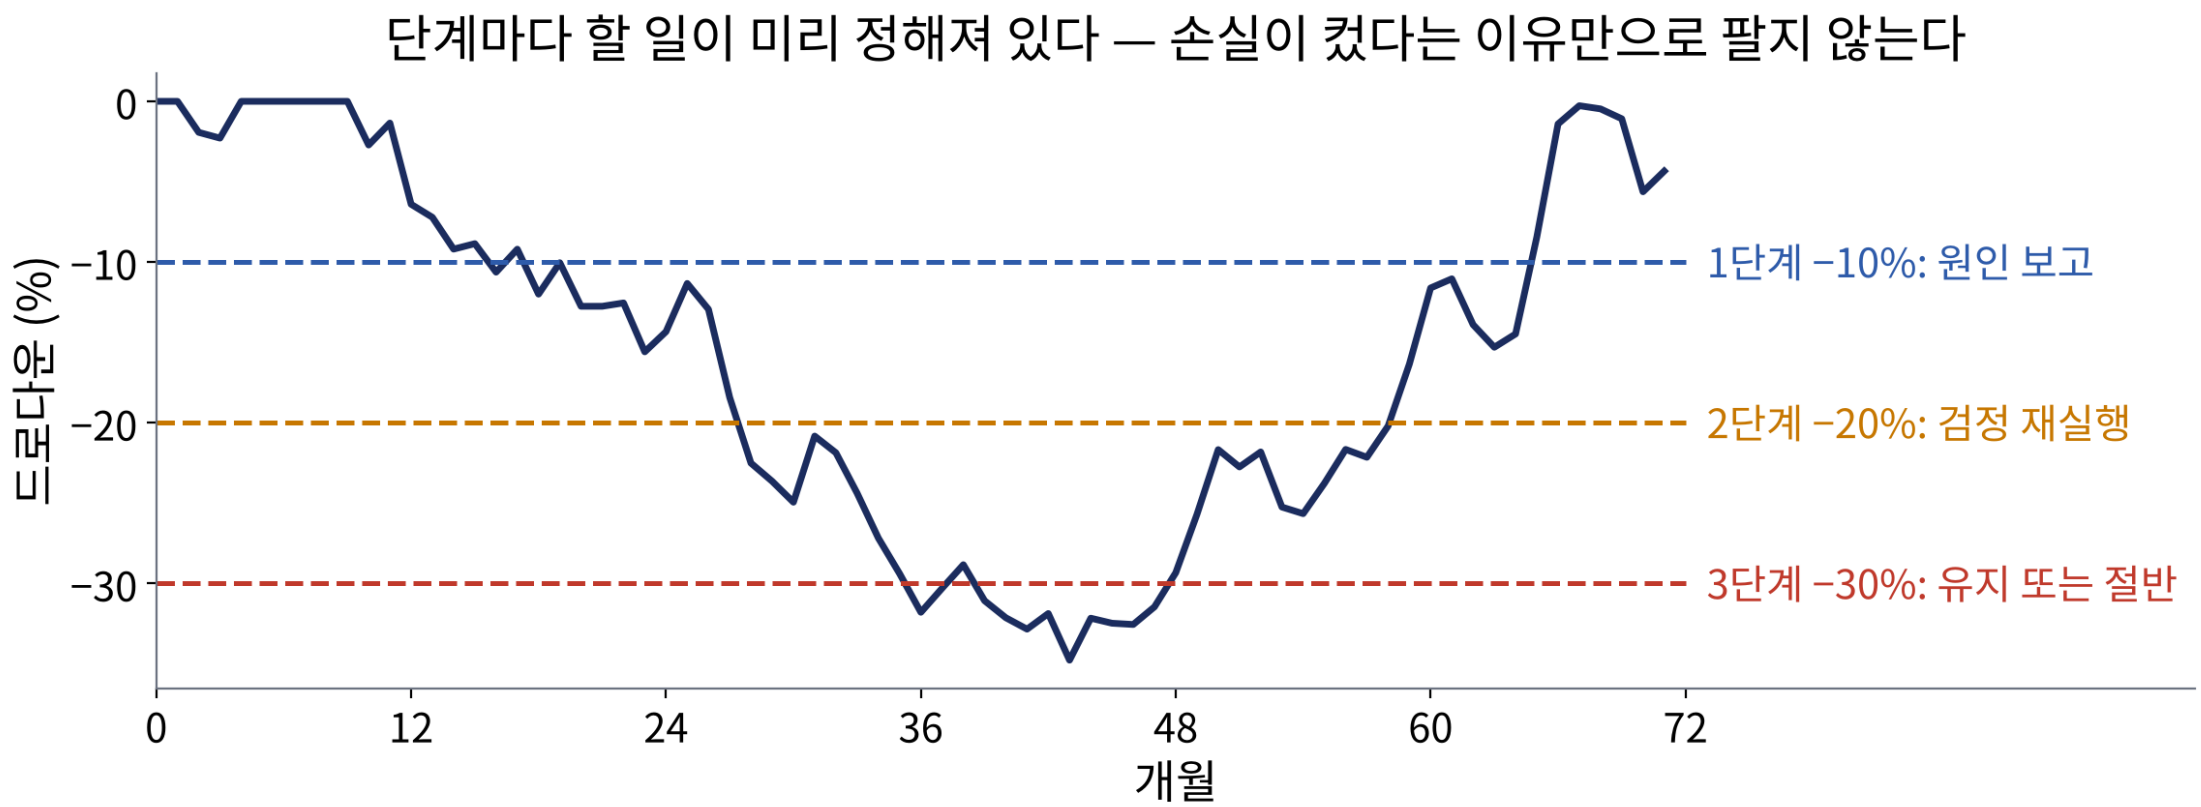
복귀

고점 대비 −10% 위로 회복하면 줄인 위험을 되돌린다

P(α>0) = Φ(사후 t) 이고 Φ는 표준정규분포의 누적분포함수다

단계에 들어선 달마다 정해진 행동을 한다

시뮬레이션 예시 — 72개월 드로다운 경로와 세 단계 기준선



과제는 대응 규칙을 두 대조군과 같은 기준으로 비교한다

같은 기간, 같은 연 변동성 10% 기준에서 비교한다

정책	손실 구간에서 하는 일	기대되는 장점	기대되는 약점
대응 규칙	단계마다 보고·재검정·조건부 축소	근거를 남기며 손실을 줄인다	규칙이 복잡하다
그대로 보유	아무것도 하지 않는다	회복을 온전히 누린다	손실이 깊고 위원회가 버티기 어렵다
기계적 매도	2단계에서 전량 매도한다	손실을 일찍 끊는다	저점에서 팔고 회복을 놓친다

어느 정책이 이기는지는 정해져 있지 않다 — 결과를 숫자로 확인하는 것이 6단계다

05

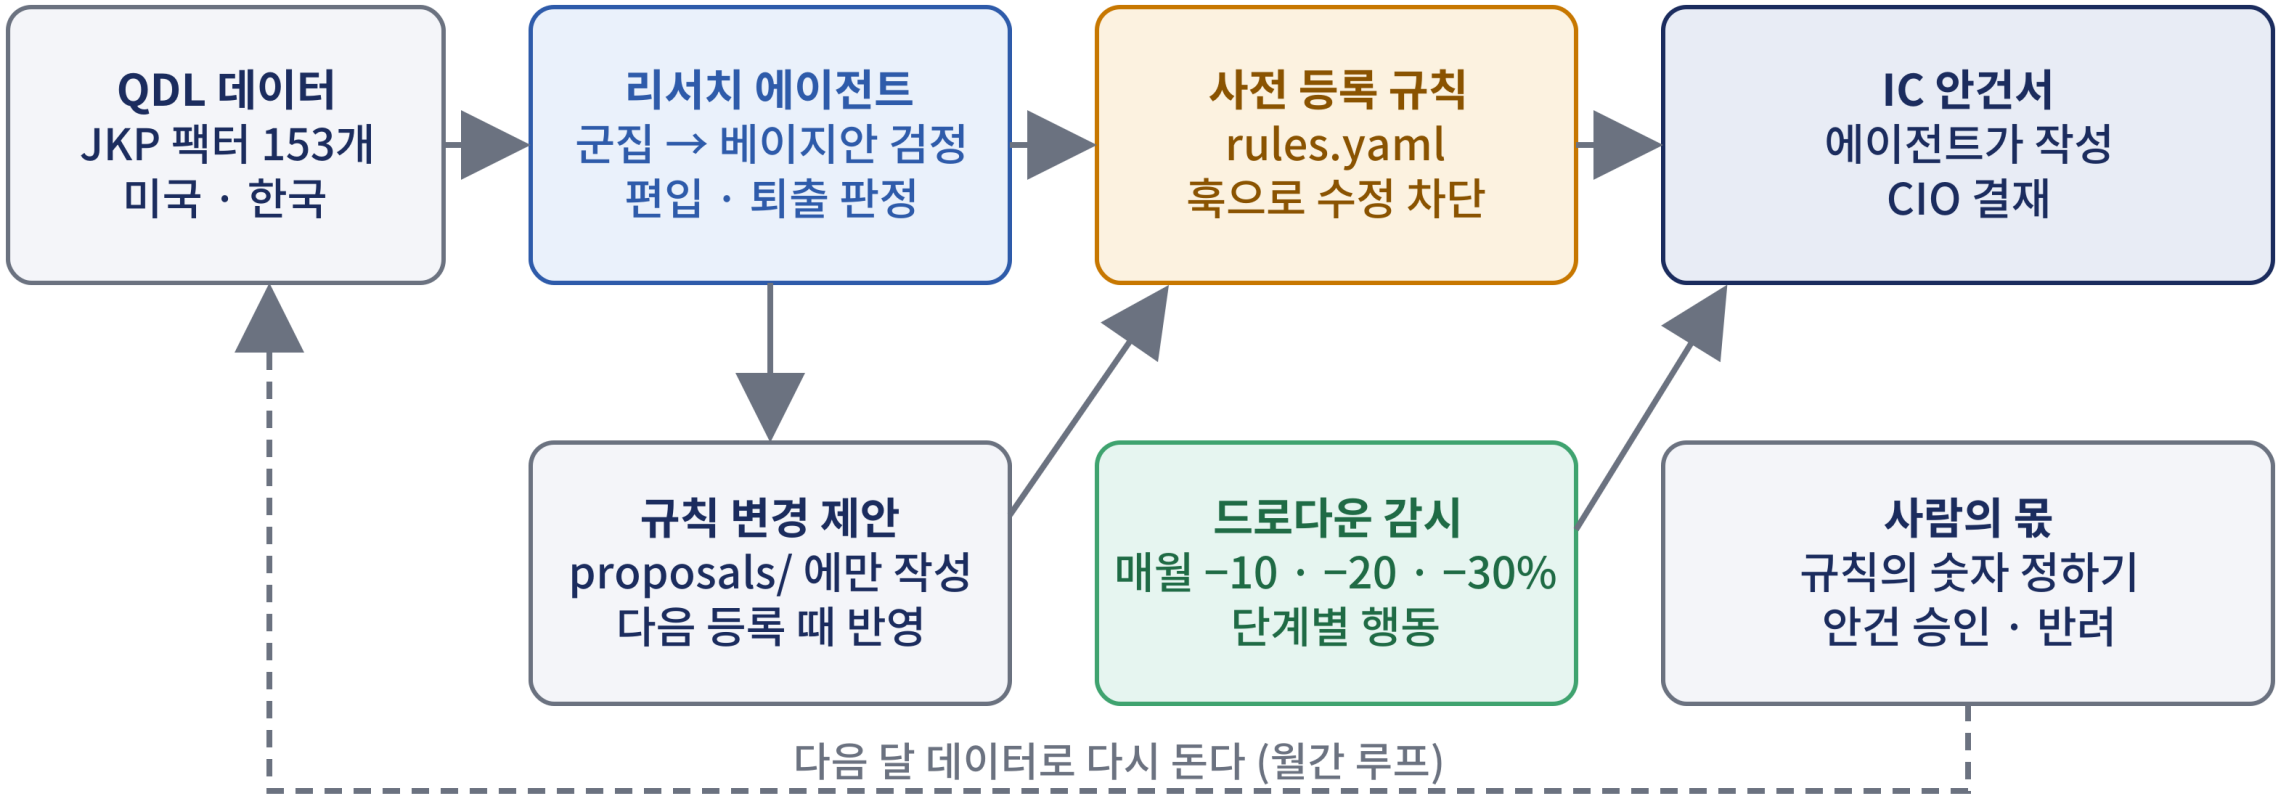
5부 · SDAM 리서치 에이전트

에이전트가 제안하고 CIO가 결재한다

자율주행 자산운용(SDAM)의 리서치 역할 하나를 작동하는 MVP로 만든다

규칙이 에이전트의 제안을 걸러 내고 사람은 결재한다

리서치 에이전트 하나를 사전 등록 규칙과 드로다운 감시로 감싼 구조다



수강생은 코드를 짜지 않고 판단과 검증을 맡는다

모든 구현은 Claude Code에게 지시문으로 시킨다

Claude Code(에이전트)가 하는 일	수강생(사람)이 하는 일
데이터를 내려받고 코드를 짜고 실행한다	지시문을 붙여넣고, 결과가 이상하면 지시문을 고친다
군집, 사후 t, 오디션 성과를 계산한다	검산 테스트 통과와 시점 규칙 위반 여부를 확인한다
IC 안건서와 드로다운 설명서를 쓴다	안건서를 CIO 입장에서 승인하거나 반려한다
규칙 변경이 필요하면 제안서만 쓴다	rules.yaml의 숫자를 팀이 정해 등록한다

좋은 지시문은 수식, 산출물, 검산 방법을 함께 적는다

과제 지시문 P3의 요약 — 원문은 실습과제 문서에 있다

[입력] 프롬프트 · Claude Code

eb.py 의 빈 부분을 위 수식대로 완성해 줘.

1. 미국 전체 표본의 τ_c, τ_w 와
   재현율(사후 t ≥ 1.96 비율)을 구하고,
   단순 t ≥ 1.96, t ≥ 3 비율과 비교한다.

2. 추정 알파 대 사후 평균 그림을
   results/fig_shrinkage.png 로 저장한다.

3. τ=0 이면 사후 평균이 0, τ가 매우 크면
   추정 알파와 같아지는지 테스트한다.

[출력] 결과 · 수강생이 확인할 파일

results/eb_full.md
  τ_c, τ_w, 세 기준의 재현율 표

results/fig_shrinkage.png
  수축 그림 (2부의 그림과 같은 모양)

tests/test_eb.py
  검산 테스트 2개 — 통과 화면 확인

확인: 재현율이 JKP의 82.4%와
크게 다르면 이유가 적혀 있는가

훅은 에이전트가 rules.yaml을 고치려 할 때 실행을 막는다

hook — Claude Code가 도구를 쓰기 직전에 자동으로 실행되는 검사다

[입력] 프롬프트 · Claude Code

rules.yaml 수정을 막는 훅을 설정해 줘.

Edit 와 Write 도구가 rules.yaml 을
고치려 하면 막고, proposals/ 에
제안서를 쓰라고 안내한다.

설정 뒤 일부러 수정을 시도해
차단되는지 확인해 줘.

[출력] 결과 · 차단 메시지

rules.yaml 은 사전 등록 파일이라
수정할 수 없다.
proposals/ 에 제안서를 써라.

(results/guard_test.md 에 기록)

왜 문서 규칙만으로는 부족한가

- CLAUDE.md의 금지 문구는 지시일 뿐이고, 훅은 실행 자체를 막는다

안건서는 CIO가 계산 없이 읽고 결재할 수 있어야 한다

과제 5단계 — 2020년 12월 리뷰 안건서를 에이전트가 쓴다

절	무엇을 담는가
한 장 요약	편입·퇴출·유지 수, 에이전트 권고, 등록 규칙의 커밋 해시
무엇을 결정하는가	팩터별 군집, 사후 알파, 사후 t, 한국 사후 알파, 결정
왜 이렇게 판정했는가	팩터마다 한 문단, 완결된 문장으로 쓴 사유
탈락한 유력 후보	단순 t로는 편입됐을 팩터가 왜 떨어졌는지
드로다운 현황과 규칙 변경 제안	대응 단계 현황과 proposals/ 링크

이 강의의 각 부가 과제 단계의 근거가 된다

QDL을 처음 쓰면 QDL 사용 가이드와 부록 A를 먼저 한다

과제 단계	할 일	근거가 되는 부분
부록 A · 0단계	팩터 복제 연습, 환경과 데이터 확인	1부 팩터 구축 규칙
1단계	판정 규칙을 사전 등록하고 잠근다	3부 사전 등록, 5부 훅
2·3단계	군집을 만들고 계층 베이지안 엔진을 만든다	2부 전체
4단계	다섯 시점 오디션으로 세 규칙을 채점한다	1부 다중검정, 3부 시점 규칙
5·6단계	안건서를 쓰고 드로다운 대응 규칙을 시험한다	4부, 5부

과제를 시작하기 전에 팀에서 먼저 답해 본다

정답보다 근거를 묻는 질문이다

Q1	t ≥ 3 기준을 쓰면 우리 슬리브에서 어떤 종류의 팩터가 먼저 빠지겠는가?	**1부 · 다중검정**
Q2	표본이 짧은 새 팩터를 편입하려면 데이터에서 무엇이 보여야 하는가?	**2부 · 정보 공유**
Q3	편입 1.96·퇴출 1.00이라는 숫자는 우리 기금의 무엇을 반영해야 하는가?	**3부 · 사전 등록**
Q4	3단계 손실에서 유지를 택했을 때 위원회에 무엇을 설명하겠는가?	**4부 · 드로다운**

고르기 전에 의심하고, 결과를 보기 전에 규칙을 잠근다

다음 단계: QDL 사용 가이드로 환경을 만들고 부록 A부터 시작한다

1

가장 좋아 보이는 팩터를 가장 먼저 의심한다

후보 153개에서는 효과가 없어도 7~8개가 유의하게 나온다.

2

알파는 군집의 증거로 수축해서 판단한다

같은 t라도 군집의 성과에 따라 사후 t가 갈린다.

3

규칙과 손실 대응을 먼저 등록한다

그래야 사람도 에이전트도 결과를 보고 기준을 바꾸지 못한다.

에이전트가 계산하고 제안한다 — 판단하고 결재하는 것은 사람이다