

강화학습을 이용한 동적 포트폴리오 운용

RL은 예측기가 아니라 제어기입니다

신호



정책



비용



순성과

다섯 부분으로 문제 설정에서 검증까지 이어갑니다

01	기본 개념과 연구 지형	순차적 의사결정 MDP · 외생 MDP · 원문 평가 · 최신 연구
02	문제 설정과 기준선	RL이 넘어야 할 벽 MVO · Merton · 무거래 구간 · GP
03	환경 · 보상 · 알고리즘	회계가 먼저 거래 시점 · 비용 · 보상 · 알고리즘 선택
04	검증	정답이 알려진 테스트 합성시장 · walk-forward · DSR · 시드
05	기관 적용과 다른 의견	예측이 아니라 제어 결합 구조 · 신호 대 거래 · 점검표

세 가지 주장이 이 강의 전체를 관통합니다

원본 강의노트의 신중한 결론을 운용 실무 관점에서 한 걸음 더 밀었다

CLAIM 1

예측이 아니라 제어

- 신호 없으면 초과수익 없음
- 가치는 언제·얼마나 거래

CLAIM 2

환경의 절반은 안다

- 회계·비용은 알려진 식
- 모르는 것은 시장 경로

CLAIM 3

기준선이 먼저

- 단순 MVO는 약한 상대
- 비용 인지형 전략을 이겨야

좋은 환경과 강한 기준선이 좋은 알고리즘보다 먼저입니다

01

기본 개념과 연구 지형

포트폴리오를 순차적 의사결정 문제로 보고, 원문과 최신 연구의 범위를 확인한다

포트폴리오 운용은 순차적 의사결정 문제입니다

MDP = 상태 · 행동 · 전이 확률 · 보상으로 정의한 문제

STATE

상태 s

- 시장 특성
- 보유 비중 · 낙폭

ACTION

행동 a

- 목표 비중
- 또는 거래량

REWARD

보상 ρ

- 순수익의 로그
- 위험 · 회전율 벌점

POLICY

정책 π

- 상태 $\rightarrow$ 행동 규칙
- 학습의 결과물

비용이 없고 행동이 시장을 바꾸지 않으면 매 기간 문제는 분리됩니다
비용 · 한도 · 낙폭 제약이 오늘의 보유를 내일의 선택지로 연결합니다

가격수용자의 상태는 시장과 계좌로 나뉩니다

외생 MDP(exogenous MDP) — 시장은 행동과 무관하고 계좌는 알려진 회계식으로 움직인다

상태의 분해

$$s_t = (m_t, \tilde{w}_t, V_t, H_t)$$

MARKET · 모르는 부분

시장 상태 m

행동과 무관, 과거 경로는 하나

ACCOUNT · 아는 부분

계좌 상태 $\tilde{w}, V, H$

알려진 회계식으로 전이

과거 경로 하나로 모든 행동의 결과를 반사실적으로 계산할 수 있습니다

원문의 20% 대 -1%는 RL의 우월성을 입증하지 않습니다

Samsudin(2021): 주식 3개+현금, Actor-Critic, 무작위 500시점, 30시점 마코위츠와 비교

원문의 설계

한계

II판의 개선

무작위 구간 평가

학습·평가 구간 중첩

시간순 walk-forward

비용·지연 생략

실현 불가능한 성과

수수료·스프레드·충격

30시점 MVO

약한 비교 상대

수축 MVO·GP·MPO

단일 실행

운과 실력 구분 불가

시드 분포·DSR

평균 수익률 두 숫자는 연율도, 위험조정 성과도 아닙니다

최신 연구는 보편적 우월성보다 조건부 유용성을 가리킵니다


2017~2026 주요 연구 — 검색으로 확인한 초록·서지 기준

연구	핵심 결과	시사점
Jiang 외 2017	암호자산, 과거 비중 저장	비중이 상태에 있어야
Li 2024	주식에선 성과 부진	시장 간 이전은 별개
Lu 2023	PPO 근사 최적, SAC 실패	합성시장 테스트의 모범
Kashif 외 2026	16구간 유의한 초과 없음	조건부 유용성 검증
Huh 외 2025	PG-DPO 50자산 확장	직접 정책 최적화

※ Kashif·Skepaczuk(2026)는 동료심사 전 프리프린트다

모형 없는 RL은 실제 시장보다 훨씬 많은 표본을 요구합니다

Lu(2023): 가장 단순한 합성시장에서도 PPO가 약 200만 스텝을 필요로 했다



※ 에피소드를 반복해도 독립된 시장 표본은 늘지 않는다

02

문제 설정과 기준선

1기간 MVO에서 해석해가 있는 동적 전략까지, RL이 넘어야 할 기준을 세운다

MVO는 한 기간을, RL은 누적 보상을 최적화합니다

1기간 평균-분산 최적화

$$\max_{w \in \mathcal{W}} w^\top \hat{\mu}_t - \frac{\lambda}{2} w^\top \hat{\Sigma}_t w - \kappa \|w - \tilde{w}_t\|_1$$

강화학습의 목적함수

$$J(\theta) = \mathbb{E}_{\pi_\theta} \left[\sum_{t=0}^{T-1} \gamma^t \rho_{t+1} \right]$$

1기간 MVO는 비용 항이 있어도 내일 다시 거래할 가능성을 보지 않습니다
동적 운용은 RL만의 영역이 아닙니다

비례 거래비용이 있으면 최적 정책은 무거래 구간을 가집니다

CRRA 투자자, 위험자산 1개(GBM) — Merton(1969), Davis-Norman(1990)

비용 없는 최적 비중

$$\pi^* = \frac{\mu - r}{\gamma_R \sigma^2}$$

무거래 구간 반폭 (점근 근사)

$$h \approx \left(\frac{3}{2\gamma_R} c \pi^{*2} (1 - \pi^*)^2 \right)^{1/3}$$

성질 1

구간 안: 무거래

성질 2

밖: 경계까지만

성질 3

반폭 $\propto$ 비용^(1/3)

비용이 작아도 구간은 상대적으로 넓습니다

Gârleanu-Pedersen 정책은 조준 포트폴리오로 부분 이동합니다

예측 신호가 소멸하고 비용이 거래량의 제공에 비례할 때의 해석해 (JF 2013)

부분 조정과 조준 포트폴리오

$$x_t = x_{t-1} + \tau (\text{aim}_t - x_{t-1})$$
$$\text{aim}_t = z \text{Markowitz}_t + (1 - z) \mathbb{E}_t[\text{aim}_{t+1}]$$

원칙 1

일부(τ)만 이동

한 번에 가지 않는다

원칙 2

조준 포트폴리오

미래 목표의 가중평균


비용 효과

비용 $\uparrow \rightarrow \tau, z \downarrow$

느린 신호일수록 비중 증가

비용이 있으면 목표를 그대로 좇지 않고 부분만 이동합니다


회색: 1기간 Markowitz 목표 · 파랑 점선: 조준 포트폴리오 · 티일: GP 보유



※ 가상 신호로 만든 개념도

RL 결과는 여섯 단계 기준선과 같은 조건에서 비교합니다

각 단계는 앞 단계가 설명하지 못하는 효과 하나를 통제한다



4단계를 못 이긴 RL은 단순 규칙을 복잡하게 다시 배운 것입니다

03


환경 · 보상 · 알고리즘

거래 시점과 회계를 먼저 고정하고, 보상과 학습 방법을 고른다

정보 마감·체결·보유 구간을 분리해야 미래정보가 섞이지 않습니다

전일 종가 정보 → 오늘 시가 체결 → 시가부터 다음 시가까지의 총수익률 적용

정책 계산 (미래 정보 없음) 보유 구간: 시가→시가 총수익률 r_{t+1} 적용



※ 종가를 보고 같은 종가에 무비용 거래하는 설정은 존재할 수 없는 이익을 만든다

비용은 표류한 비중과 목표 비중의 차이로 계산합니다

회전율과 거래비용

$$\text{TO}_t = \frac{1}{2} \sum_{i=0}^N |w_{i,t} - \tilde{w}_{i,t}|, \quad C_t = \sum_{i=1}^N c_i |w_{i,t} - \tilde{w}_{i,t}|$$

순수익과 가격 변화 후 비중

$$R_{t+1}^{\text{net}} = (1 - C_t)(1 + w_t^\top r_{t+1}) - 1, \quad \tilde{w}_{i,t+1} = \frac{w_{i,t}(1 + r_{i,t+1})}{1 + g_{t+1}}$$

예제(40/30/30 → 50/20/30, 편도 10bp): 비용 2bp, 순수익 0.7828%

※ 현금 변화에는 직접 비용을 부과하지 않는다(c_i 는 편도 비용률). 단계별 손계산은 워크북 데크에 있다

학습 보상과 실제 순수익은 서로 다른 값입니다

비용은 자산가치에서 차감되고, 회전율 벌점은 학습 목표에만 추가되는 선호다

벌점을 더한 학습 보상

$$\rho_{t+1} = \log(1 + R_{t+1}^{net}) - \lambda_v w_t^\top \hat{\Sigma}_t w_t - \lambda_{to} TO_t - \lambda_d \max(0, DD_{t+1} - DD_t)$$

실제 순수익

0.7828%

로그 순수익

0.7798%

위험 벌점

-0.05%

회전율 벌점

-0.01%

학습 보상 0.7198%와 실제 순수익 0.7828%를 따로 저장해야 합니다

샤프는 미분 샤프로 학습하고, 성과는 확실성등가로 평가합니다

Moody · Saffell(2001)의 Differential Sharpe Ratio — A, B는 지수이동 1·2차 적률

미분 샤프 보상

$$D_t = \frac{B_{t-1}\Delta A_t - \frac{1}{2}A_{t-1}\Delta B_t}{(B_{t-1} - A_{t-1}^2)^{3/2}}$$

연율 확실성등가 (CRRA)

$$\text{CE} = \left(\mathbb{E} \left[W_T^{1-\gamma_R} \right] \right)^{\frac{1}{(1-\gamma_R)T}} - 1$$

초기 구간은 분모가 작아 워밍업 기간과 분모 하한이 필요합니다

현금 편향 정책은 샤프가 불안정하므로 효용으로 비교합니다

알고리즘은 표본 효율과 구조 활용으로 고릅니다

Lu(2023) 합성시장: on-policy는 근사 최적, off-policy는 잡음 보상에 취약

방법	성격	이 강의의 용도
직접 정책 탐색	규칙 매개변수를 직접 최적화	첫 기준 학습법
미분 가능 시뮬레이터	회계식으로 시간 역전파	가격수용자 권장
PPO	클리핑 on-policy	첫 RL 실험
SAC	경험 재사용·엔트로피	비교 실험
DQN	이산 행동 가치	방어·중립·공격

※ 어느 알고리즘이 최선인지는 사전에 단정하지 않는다

가격수용자는 자산가치를 정책 파라미터로 직접 미분할 수 있습니다

시장 경로가 주어지면 로그 자산가치는 θ 의 미분 가능한 함수 — 딥헤징·PG-DPO의 원리

직접 정책 최적화의 목적함수

$$\log \frac{V_T}{V_0} = \sum_{t=0}^{T-1} \left[\log \left(1 - C_t(\theta) \right) + \log \left(1 + w_t(\theta)^\top r_{t+1} \right) \right]$$

장점 · 분산 작은 경사

정확한 경사

처리 · $\sqrt{(x^2 + \epsilon)}$

절댓값 평활화

주의 · 부트스트랩 경로

과적합 방지



04

검증

정답이 알려진 합성시장에서 먼저 확인하고, 시도 횟수의 대가를 보정한다

무거래 구간은 비용 손실을 연 14.7bp에서 1.1bp로 줄입니다

합성 GBM(μ 7%, σ 18%, γ 3), 편도 25bp, 10년·20,000경로 시뮬레이션



※ 시뮬레이션 최적 반폭 3~5%p는 점근 공식(4.3%p)과 가깝다

RL 정책은 먼저 밴드 정책을 재현해야 합니다

편도 25bp 기준 연율 확실성등가(bp) — 합성 GBM 시뮬레이션

정책	확실성등가	연간 거래량		
비용 없는 Merton 상한	329.8	—		
매일 Merton 리밸런싱	315.1	57%		
무거래 구간 (반폭 3%p)	328.7	3%		
합격 기준	평균 비중 $\approx \pi^*$	구간 안 무거래	비용 ↑ 구간 ↑	CE 90% 회복

곡선이 평평해 좋은 정책과 조금 나쁜 정책을 데이터로 구별하기 어렵습니다

테스트 구간을 이어 붙여 하나의 외표본 성과 경로를 만듭니다

전처리·하이퍼파라미터는 학습·검증 구간에서만 정한다

회색: purge·embargo 간격



※ purge·embargo 폭은 레이블과 보유기간의 중첩에 맞춘다

20번 시도한 샤프 0.80은 운으로 설명될 확률이 절반입니다

운으로 기대되는 최대 샤프

$$SR_0 = \sqrt{\mathbb{V}[\hat{SR}_n]} \left[(1 - \gamma_e) \Phi^{-1}\left(1 - \frac{1}{N}\right) + \gamma_e \Phi^{-1}\left(1 - \frac{1}{Ne}\right) \right]$$

Deflated Sharpe

$$DSR = \Phi \left(\frac{(\hat{SR} - SR_0) \sqrt{T-1}}{\sqrt{1 - \hat{\gamma}_3 \hat{SR} + \frac{\hat{\gamma}_4 - 1}{4} \hat{SR}^2}} \right)$$

설정 20개, 시도 간 표준편차 0.40, 테스트 3년 → DSR ≈ 0.52

※ Bailey · López de Prado(2014): 시도 N번에서 운만으로 기대되는 최대 샤프를 기준으로 삼는다

시드와 절제 실험으로 성과의 출처를 밝힙니다

Henderson 외(2018), Agarwal 외(2021)의 보고 권고

SEEDS

10개 이상

- 중앙값·IQM
- 최악 시드 보고

COSTS

5·10·25bp

- 비용 민감도
- 이기지 못한 구간

ABLATION

하나씩 제거

- 보유 비중 제거
- 현금·벌점 제거

가장 좋은 시드만 고르는 순간 DSR 계산의 전제가 무너집니다

05


기관 적용과 다른 의견

RL이 비중이 아니라 운용 강도를 고르게 하고, RL의 역할을 제어로 재정의한다

RL은 언제 · 얼마나 세계를, 최적화기는 무엇을 담당합니다

본 강의의 제안 구조 — 특정 기관의 실제 운용 방식이 아니다

순차 판단 (언제, 얼마나 세계) 자산 간 배분과 제약 (무엇을)



※ 위험 · 종목 한도는 최적화기가 항상 지키므로 RL 오작동의 피해 범위가 제한된다

성과를 신호의 가치와 거래의 가치로 분해해야 합니다


다른 의견 1 — 신호를 고정하고 정책만, 정책을 고정하고 신호만 바꿔 비교한다

SIGNAL

신호의 가치

- 수익률 예측
- 지도학습 문제

RL이 특별히 잘할 이유 없음



POLICY

거래의 가치

- 비용·제약 아래 거래
- 제어 문제

RL의 본래 영역

두 효과가 섞인 백테스트로는 RL의 기여를 말할 수 없습니다

RL의 비교우위는 예측보다 제어가 어려운 문제에 있습니다

다른 의견 2~5

의견 2

구조를 버리지 말 것

- 회계식은 이미 얹
- 직접 최적화 우선

의견 4

RL이 빛나는 곳

- 대규모 주문 실행
- 옵션 헤지·연기금

의견 5

LLM 신호 주의

- 학습 시점 정보 유입
- 테스트는 마감 이후

실데이터 심층 RL의 좋은 백테스트는 먼저 과적합을 의심합니다

좋은 결과일수록 일곱 항목을 먼저 점검합니다

다른 의견 6 — 위에서 아래로 순서대로 확인한다

점검 항목

1 체결 시점·정보집합 동일

2 현금·공매도·레버리지 동일

3 변동성 조정 후에도 차이

4 비용 25bp에서도 차이

점검 항목

5 무거래·GP·MPO를 이김

6 DSR 보정 후에도 유의

7 여러 시장·국면에서 동일

5번, 비용 인지형 동적 기준선을 이겼는지가 핵심입니다

실습은 회계 재현에서 시작해 시드 분포 보고로 끝납니다

학습 정책을 만들기 전에 비교 전략과 회계가 정상 작동해야 한다

과제	내용	산출물
1 회계	표류 비중에서 비용 재계산	손계산 일치
2 합성시장	Merton·밴드 재현, 직접 탐색 vs PPO	CE 회복률
3 기준선	동일가중·비용 MVO·GP	공정 비교 표
4 이산 정책	방어·중립·공격, 일별 vs 주별	거래 빈도
5 연속 정책	PPO vs SAC, 10시드	IQM·DSR

RL은 예측기가 아니라 제어기입니다

환경의 절반은 이미 알려져 있습니다

강한 기준선을 같은 조건에서 이겨야 합니다

**손계산은 워크북,
기초 개념은 부록 덱으로**

수치 예제는 교육용 가상 값이며, 시뮬레이션 결과는 합성 시장에서 계산한 값이다.