

처음 배우는 강화학습 기초 부록

행동하고, 보상받고, 규칙을 고칩니다

행동



보상



가치



정책

네 부분으로 강화학습의 기초를 정리합니다

필요한 수학은 덧셈·곱셈과 평균(기댓값) 정도다

01 ————— 개념과 구성요소

무엇이 다른가

지도·비지도와의 차이 · 에이전트와 환경

02 ————— 보상과 가치

당장보다 앞으로

누적 보상 · 할인 · 정책 · 가치 · 벨만

03 ————— 학습 알고리즘

경험으로 고치기

탐색과 활용 · Q-러닝 · 심층 RL

04 ————— 금융에 적용할 때

다섯 가지 함정

데이터 · 비정상성 · 잡음 · 미래정보 · 다중 시도

01

개념과 구성요소

정답 없이 보상으로 배우는 방법과 그 다섯 가지 구성요소

강화학습은 정답 없이 보상으로 행동 규칙을 배웁니다

세 가지 머신러닝을 투자 예시 하나로 비교한다

SUPERVISED

지도학습

배움	입력 → 정답
자료	정답 붙은 데이터
예시	내일 오를지 예측

UNSUPERVISED

비지도학습

배움	숨은 구조
자료	정답 없는 데이터
예시	비슷한 종목 묶기

REINFORCEMENT

강화학습

배움	상황 → 행동 규칙
자료	행동과 보상
예시	매일 비중 결정

강화학습에는 '이 상황의 정답 행동'이 주어지지 않습니다

오늘의 행동이 내일의 상황을 바꾸는 문제입니다

순차적 의사결정(sequential decision-making) — 선택이 줄줄이 이어진다

ONE-SHOT

한 번의 예측

- 맞으면 끝
- 다음 문제와 무관

지도학습의 세계



SEQUENTIAL

이어지는 선택

- 오늘 산 주식이 남음
- 바꾸려면 비용

강화학습의 세계

좋은 결과를 낸 행동은 더 자주, 나쁜 행동은 덜 하게 됩니다

에이전트와 환경은 행동과 보상을 주고받습니다

에이전트가 행동하면 환경이 다음 상태와 보상을 돌려준다 — 매 기간 반복

행동 a_t : 주식 비중을 정한다



다음 상태 s_{t+1} 와 보상 r_{t+1} : 가격 변화, 수익

※ 보상에 t+1을 붙이는 이유: 오늘 행동한 결과가 내일 확인되기 때문이다

다섯 가지 구성요소를 포트폴리오 언어로 옮깁니다

구성요소	뜻	포트폴리오 예시
에이전트 (agent)	결정을 내리는 주체	운용 프로그램
환경 (environment)	바깥 세계 전부	시장 + 계좌 회계
상태 (state)	결정할 때 보는 정보	수익률·변동성·보유 비중
행동 (action)	고르는 것	주식 20% 또는 80%
보상 (reward)	행동 직후의 점수	비용 뺀 그날 수익률

※ 보유 비중을 상태에서 빼면 에이전트는 거래비용을 알 수 없다

02

보상과 가치

당장의 점수가 아니라 앞으로 받을 보상의 합을 본다

강화학습은 할인된 누적 보상을 최대화합니다

할인계수 $\gamma(0\sim1)$ 는 미래 보상을 오늘 가치로 바꾼다 — 현재가치 계산과 같은 생각

할인된 누적 보상 (return)

$$G_t = r_{t+1} + \gamma r_{t+2} + \gamma^2 r_{t+3} + \dots = \sum_{k=0}^{\infty} \gamma^k r_{t+k+1}$$

$\gamma = 0$ · 근시안

바로 다음 보상만

$\gamma = 0.9$ · 적당히


10기간 뒤 0.35

$\gamma = 0.99$ · 멀리

10기간 뒤 0.90

할인계수가 작을수록 먼 미래의 보상을 가볍게 봅니다

몇 기간 뒤의 보상인가(k)에 따른 가중치 γ^k



※ 손계산: 보상 1, 0, 2, $\gamma=0.9 \rightarrow G = 2.62$ (워크북 W1)

정책은 상태에서 행동을 고르는 규칙입니다

policy π — 강화학습이 최종적으로 찾으려는 것

DETERMINISTIC

결정적 정책

- 상태 $\rightarrow$ 행동 하나
- 강세면 주식 80%

$$a = \pi(s)$$



STOCHASTIC

확률적 정책

- 행동을 확률로 선택
- 강세면 80%로 공격형

$$\pi(a | s)$$

확률적 정책은 학습 초기에 여러 행동을 골고루 시도하게 합니다

가치는 지금 상황이 앞으로 얼마나 유리한지를 잽니다

$\mathbb{E}$ 는 기댓값(여러 번 반복했을 때의 평균), 세로선은 '~라는 조건에서'로 읽는다

상태가치 V

$$V^{\pi}(s) = \mathbb{E}_{\pi} [G_t \mid s_t = s]$$

행동가치 Q

$$Q^{\pi}(s, a) = \mathbb{E}_{\pi} [G_t \mid s_t = s, a_t = a]$$

보상 r

오늘 하루 수익

가치 $V(s)$

현재 포지션의 미래

Q값 $Q(s,a)$

지금 매수하면의 미래

오늘 손실이 나도 앞으로의 가치는 높을 수 있습니다

강세·약세 두 국면의 예제 시장으로 설명합니다


상태 = (현재 국면, 현재 자세) 4개 · 행동 = 방어형 20% 또는 공격형 80%

SETTING

국면은 지속된다

- 유지 확률 0.8
- 강세 +1%, 약세 -1%
- 자세 변경 시 비용

신호와 순차성이 모두 있음



보상은 주식 비중 × 수익률에서 비용을 뺀 값입니다

자세를 바꾸면 비중이 0.6만큼 움직이므로 비용은 $0.6c$

예제 시장의 보상 (단위 %)

$$r = w_a \times r_{t+1}^{\text{stock}} - c |w_a - w_{\text{now}}|$$

w_a

새로 고른 주식 비중

r^{stock}

다음 기간 주식 수익률

c

거래금액 대비 비용을

벨만 방정식은 가치를 한 단계씩 쪼갭니다

지금 행동의 가치 = 당장 보상의 평균 + 할인된 다음 상태에서 최선을 다한 가치

최적 행동가치의 벨만 방정식

$$Q^*(s, a) = \mathbb{E} \left[r + \gamma \max_{a'} Q^*(s', a') \mid s, a \right]$$

상태 (국면, 자세)	Q(방어 D)	Q(공격 A)	최적 행동
(B, D) 강세·방어	1.811	2.116	A로 전환
(R, A) 약세·공격	0.812	0.507	D로 전환

※ 비용 0.2%, $\gamma=0.9$ 가치 반복 결과 — 나머지 두 상태와 한 칸 손계산은 워크북 W2

비용이 크면 지금 자세를 유지하는 것이 최적입니다

같은 시장, 비용만 0.2%에서 2%로 올렸을 때의 최적 정책

상태	비용 0.2%	비용 2%
(B, D) 강세·방어	공격형으로 전환	방어형 유지
(B, A) 강세·공격	공격형 유지	공격형 유지
(R, D) 약세·방어	방어형 유지	방어형 유지
(R, A) 약세·공격	방어형으로 전환	공격형 유지

자세 변경 비용 1.2%가 국면 신호의 이득보다 큼니다
이것이 본편 '무거래 구간'의 출발점입니다


03

학습 알고리즘

확률을 모르는 채로 경험에서 배우는 방법

탐색이 없으면 초반의 우연한 결과에 갇힙니다

평균 0.2·0.5·0.8인 세 선택지를 1,000번 고르는 ϵ -greedy 실험 (시뮬레이션)



※ 마지막 200회 평균: $\epsilon=0 \rightarrow 0.60$, $\epsilon=0.1 \rightarrow 0.77$, $\epsilon=0.3 \rightarrow 0.71$

금융 RL은 시뮬레이터 안에서만 탐색합니다

탐색(exploration)과 활용(exploitation)의 균형

EXPLOITATION

활용

- 아는 최선 반복
- 더 좋은 것을 놓침

단골 식당만 가기



EXPLORATION

탐색

- 새 행동 시도
- 실제 계좌면 손실

과거 데이터 시뮬레이터에서만

가격수용자는 과거 경로 하나로 모든 행동의 결과를 계산할 수 있습니다

Q-러닝은 경험 한 번마다 Q표를 조금씩 고칩니다

전이 확률을 몰라도 된다 — 벨만 방정식의 오른쪽을 경험 한 번으로 대신한다

Q-러닝 업데이트

$$Q(s, a) \leftarrow Q(s, a) + \alpha \left[\underbrace{r + \gamma \max_{a'} Q(s', a')}_{\text{target}} - Q(s, a) \right]$$

TARGET

보상 + 다음 최선

TD ERROR

목표 - 현재 추정


LEARNING RATE α

오차의 α 만 반영

※ 손계산 두 개($0 \rightarrow 0.068$, $1.5 \rightarrow 1.598$)는 워크북 W3

상태 4개짜리 문제에도 수천 번의 경험이 필요합니다

예제 시장, $\alpha=0.05 \cdot \epsilon=0.1$ 로 20번 반복 실행 — 음영은 10~90% 범위 (시뮬레이션)



※ 약 1,100스텝(일별이면 4년 이상)에 최적 행동 90% 도달 — 정책은 Q값보다 먼저 맞춰진다

상태가 많으면 표 대신 신경망으로 근사합니다

심층 강화학습(deep RL) — 본편에서 비교하는 방법들

방법	무엇을 배우나	한 줄 설명
DQN	Q값	Q표를 신경망으로, 이산 행동
정책경사	정책	좋았던 행동의 확률을 높임
Actor-Critic	정책 + 가치	운용역과 리스크 담당자
PPO	정책 + 가치	한 번에 크게 바꾸지 않음
SAC	정책 + 가치	경험 재사용 · 다양성 보너스

※ 파라미터가 많을수록 데이터가 적을 때 과거만 외우기 쉽다(과적합)

04

금융에 적용할 때

게임에서 통한 방법이 시장에서 그대로 통하지 않는 이유

금융 RL의 함정은 다섯 가지로 정리됩니다

오른쪽 열은 본편에서 다루는 곳

함정	이유	본편
데이터가 적다	시장의 과거는 한 번뿐	13절
규칙이 변한다	금리·규제·참여자 변화	11절
보상 잡음이 크다	하루 수익률은 대부분 운	10절
미래정보 유입	종가 보고 종가 체결	7절
여러 번 시도	하나쯤은 우연히 좋아 보임	11.3절

같은 과거를 반복 학습해도 새로운 정보는 늘지 않습니다

셀프 체크 — 10년 데이터로 에피소드를 10,000번 돌리면 10만 년치 경험인가

GAME

바둑·게임

- 수백만 판 가능
- 규칙은 고정

반복 = 새 경험



MARKET

시장

- 과거는 한 번
- 성질이 변함

반복 = 같은 10년

반복 학습은 오히려 그 10년에만 맞는 규칙을 외우게 할 수 있습니다

행동하고, 보상받고, 규칙을 고칩니다

당장의 보상보다 앞으로의 가치를 봅니다

금융에서는 데이터와 비용이 학습을 제약합니다

손계산은 워크북,
본편은 강의노트 II 덱으로

수치 예제는 교육용 가상 값이며, 시뮬레이션 결과는 컴퓨터로 만든 가상 실험이다.