

적극적 운용의 기본법칙(FLAM) — 일반화 식과 증명

Sep 30, 2026 · @Keehong Rhee

요약

- 일반화 기본법칙은 $IR = TC \cdot IC \cdot \sqrt{BR}$ 이다. 원래 식 $IR = IC\sqrt{BR}$ 는 제약이 없는 $TC = 1$ 의 특수형이다.
- 법칙의 출발점은 Grinold의 예측 규칙 "알파 = 변동성 $\times$ IC $\times$ 점수"다.
- 예측 규칙은 기본 예측 공식(최적 선형 예측, 정규분포에서는 조건부 기대값)에서 나온다.

증명은 역순으로 쌓인다. 3절(기본 예측 공식) $\rightarrow$ 2절(예측 규칙) $\rightarrow$ 1절(일반화 법칙).

1. 일반화 기본법칙

Clarke-de Silva-Thorley(2002)의 식이다. 전이계수(transfer coefficient) TC는 알파 신호가 실제 액티브 비중으로 옮겨진 정도를 나타낸다.

$$IR = TC \cdot IC \cdot \sqrt{BR}$$

설정

- 종목 $i = 1, \dots, N$. 잔차수익률 변동성은 σ_i 이고 종목 간 잔차는 무상관이다.
- 표준화 점수 z_i 는 횡단면 평균 0, 분산 1이다.
- 정보계수는 $IC = \text{corr}(r_i/\sigma_i, z_i)$ 이다.
- 실제 액티브 비중은 Δw_i 이며 long-only, 한도 등 제약이 걸릴 수 있다.
- 전이계수는 다음과 같다.

$$TC = \text{corr}\left(\Delta w_i \sigma_i, \frac{\alpha_i}{\sigma_i}\right)$$

증명

1단계, 예측 규칙(2절에서 증명). 위험조정 알파의 횡단면 표준편차가 IC다.

$$\frac{\alpha_i}{\sigma_i} = IC \cdot z_i, \quad \text{sd}\left(\frac{\alpha_i}{\sigma_i}\right) = IC$$

2단계, 기대 액티브 수익률. α_i/σ_i 의 횡단면 평균이 0이므로 곱의 합은 $N \times$ 공분산이다.

$$E[R_A] = \sum_i (\Delta w_i \sigma_i) \left(\frac{\alpha_i}{\sigma_i}\right) = N \text{cov}\left(\Delta w_i \sigma_i, \frac{\alpha_i}{\sigma_i}\right) = N \cdot TC \cdot \text{sd}(\Delta w_i \sigma_i) \cdot IC$$

3단계, 액티브 리스크. 잔차가 무상관이고 $\Delta w_i \sigma_i$ 의 평균이 약 0이라고 둔다.

$$\sigma_A^2 = \sum_i \Delta w_i^2 \sigma_i^2 = N \text{var}(\Delta w_i \sigma_i) \Rightarrow \sigma_A = \sqrt{N} \text{sd}(\Delta w_i \sigma_i)$$

4단계, 비율. 비중 규모 $\text{sd}(\Delta w_i \sigma_i)$ 가 약분된다. 독립 베팅 수 $BR = N$ 을 넣으면 증명이 끝난다.

$$IR = \frac{E[R_A]}{\sigma_A} = \frac{N \cdot TC \cdot \text{sd}(\Delta w \sigma) \cdot IC}{\sqrt{N} \text{sd}(\Delta w \sigma)} = TC \cdot IC \cdot \sqrt{N}$$

2. 예측 규칙: 알파 = 변동성 × IC × 점수

Grinold의 예측 규칙이다. 3절의 기본 예측 공식에 네 가지 가정을 넣으면 바로 나온다.

$$\alpha_i = E[r_i | z_i] = \sigma_i \cdot IC \cdot z_i$$

가정

- 잔차수익률의 사전 평균은 $E[r_i] = 0$ (컨센서스 기대값이 0), 변동성은 $\text{sd}(r_i) = \sigma_i$ 이다.
- 점수는 $E[z_i] = 0$, $\text{Var}(z_i) = 1$ 로 표준화되어 있다.
- 상관은 종목에 관계없이 $\text{corr}(r_i, z_i) = IC$ 로 같다.
- (r_i, z_i) 는 결합정규분포를 따른다. 정규가 아니면 결과는 최적 선형 예측으로 해석한다.

증명

1단계, 기본 예측 공식(3절)에서 출발한다.

$$E[r_i | z_i] = E[r_i] + \frac{\text{Cov}(r_i, z_i)}{\text{Var}(z_i)}(z_i - E[z_i])$$

2단계, 공분산을 IC로 쓴다.

$$\text{Cov}(r_i, z_i) = \text{corr}(r_i, z_i) \cdot \text{sd}(r_i) \cdot \text{sd}(z_i) = IC \cdot \sigma_i$$

3단계, 대입하면 예측 규칙을 얻는다.

$$\alpha_i = 0 + \frac{IC \sigma_i}{1}(z_i - 0) = \sigma_i \cdot IC \cdot z_i$$

4단계, 양변을 σ_i 로 나누고 횡단면 표준편차를 취한다. $\text{sd}(z_i) = 1$ 이고 IC는 상수다.

$$\frac{\alpha_i}{\sigma_i} = IC \cdot z_i \Rightarrow \text{sd}\left(\frac{\alpha_i}{\sigma_i}\right) = IC \quad (IC > 0)$$

해석

IC가 0.05 수준으로 작으면 점수는 크게 줄어 알파에 반영된다. 이것이 과신을 막는 수축(shrinkage) 역할을 한다. 예측 오차 분산은 $\sigma_i^2(1 - IC^2)$ 로 사전 분산보다 아주 조금 줄어들 뿐이다.

3. 기본 예측 공식의 도출

기본 예측 공식은 두 경로로 나온다. 어떤 분포든 MSE를 최소화하는 최적 선형 예측이고, 결합정규분포에서는 조건부 기대값 그 자체다. 표기는 $\mu_r = E[r]$, $\mu_z = E[z]$ 로 둔다.

경로 ① 최적 선형 예측 (분포 가정 없음)

예측식을 $\hat{r} = a + bz$ 로 두고 평균제곱오차를 최소화한다.

$$\min_{a,b} E[(r - a - bz)^2]$$

a에 대한 1계 조건에서 절편이 정해진다.

$$-2E[r - a - bz] = 0 \Rightarrow a = \mu_r - b\mu_z$$

a를 대입하고 b에 대한 1계 조건을 풀면 기울기가 정해진다.

$$-2E[(z - \mu_z)\{(r - \mu_r) - b(z - \mu_z)\}] = 0 \Rightarrow b = \frac{\text{Cov}(r, z)}{\text{Var}(z)}$$

둘을 합치면 공식이 된다. OLS 회귀의 모집단 버전이다.

$$\hat{r} = \mu_r + \frac{\text{Cov}(r, z)}{\text{Var}(z)}(z - \mu_z)$$

경로 ② 결합정규분포의 조건부 기대값

(r, z) 가 이변량 정규분포를 따른다고 두고, r을 두 부분으로 분해한다.

$$r = \mu_r + b(z - \mu_z) + \varepsilon, \quad b = \frac{\text{Cov}(r, z)}{\text{Var}(z)}$$

오차는 점수와 무상관이다.

$$\text{Cov}(\varepsilon, z) = \text{Cov}(r, z) - b \text{Var}(z) = 0$$

ε 은 (r, z) 의 선형결합이므로 (ε, z) 도 결합정규다. 정규분포에서는 무상관이 곧 독립이므로 조건부 기대값이 선형이 된다.

$$E[r | z] = \mu_r + b(z - \mu_z) + E[\varepsilon | z] = \mu_r + \frac{\text{Cov}(r, z)}{\text{Var}(z)} (z - \mu_z)$$

두 경로의 차이

- 정규분포일 때: 조건부 기대값이 정확히 선형이므로 최적 선형 예측이 모든 예측 중 최적이다.
- 정규가 아닐 때: $E[r | z]$ 는 비선형일 수 있고, 공식은 선형 예측 가운데 최선일 뿐이다.

Grinold가 이 공식을 쓰는 근거는 경로 ①이다. 정규성은 "조건부 기대값"이라는 해석을 덧붙인다.

4. 특수형과 실무 함의

제약이 없으면 평균-분산 최적 비중은 $\Delta w_i \propto \alpha_i / \sigma_i^2$ 이다. 이때 $\Delta w_i \sigma_i \propto \alpha_i / \sigma_i$ 이므로 $TC = 1$ 이 되고 원래 식 $IR = IC\sqrt{BR}$ 로 돌아간다.

같은 경우를 제곱 형태로 쓰면 가법성이 드러난다. 독립 신호의 IR^2 는 더해지며, 여러 전략을 결합할 때 $IR^2(\text{total}) = \sum IR^2(k)$ 를 쓰는 근거가 된다.

$$IR^2 = IC^2 \cdot BR, \quad IR_{\text{total}}^2 = \sum_k IR_k^2$$

실증 연구에서 long-only 제약하의 TC는 대체로 0.3~0.6 수준으로 보고된다. 따라서 IC나 breadth를 높이는 것만큼, 제약을 완화해(예: 130/30) TC를 끌어올리는 것도 IR 개선에 효과적이다.