

주식 데이터 아키텍처 검토와 제안

2026-09-20 · @Someone

원자료: 내부 이슈 「국내·해외 주식 데이터 아키텍처」 (2026.09.17)

요약

보고서가 "미확인" 또는 "구조적 한계"로 남긴 네 항목 중 셋은 원인이 확정되어 있고 해법도 WRDS 안에 있다. 실질 병목은 데이터가 아니라 구독 범위와 라이선스다.

항목	보고서의 서술	실제
해외 시세 2024년 단절	원인 미확인	CRSP 포맷 세대교체(SIZ→CIZ). 지금 구독으로 코드만 바꾸면 해결, 비용 0
회사-종목 연결 43~48%	원인 미확정	원인 확정(Compustat 최신 CUSIP vs CRSP 역사적 CUSIP). WRDS sec_idhist 로 개선 가능. 분모 자체도 재측정 필요
미국 재무 PIT	가장 큰 문제, 불가능	불가능이 아니라 미구독. Compustat Snapshot(1986~) 존재. 무료 대안(SEC EDGAR XBRL, 2009~)도 있음
해외 분봉	소스 없음	미구독. WRDS TAQ 존재(Monthly 1993-2014, Daily 2003~)

네 항목 중 실제로 설계 판단이 필요한 것은 S48 4번(상장폐지 처리)뿐이다. 나머지는 구독·구현 선택이다.

우선순위는 셋이다. ① CIZ 전환을 재무제표 EAV 수집 착수 **전에** 끝낸다. ② SEC EDGAR XBRL로 PIT을 자체 확보한다 — 국내 DART XBRL 파이프라인과 구조가 같아 재사용된다. ③ 이 DB의 용도(학술 공동연구 vs 상업 운용)를 확정한다. 세 번째가 나머지 모든 판단의 전제다.

원 보고서 상세 정리

55장 구성이다. 백테스트와 라이브트레이딩을 위한 주가·재무 DB를 어떻게 만들었고 무엇을 아직 풀지 못했는지 정리한 자료다. 국내 28장, 해외 9장, 국내·해외 비교 7장, 정기미팅 회고 3장, 미결정 사안 3장으로 나뉜다.

진행 우선순위 (S2)

260916 정기미팅에서 확정된 순서다. 과거 데이터가 항상 실시간보다 먼저라는 판단이다.

순서	항목	상태
①	국내 과거	진행 중, 9/23 목표
②	해외 과거	준비 단계, 이 자료가 시작점
③	국내 실시간	착수 전, 완료 미보장
④	해외 실시간	범위 밖

데이터 커버리지 (S3)

2026-09-18 후속 이슈에서 개별 회사 표본이 아니라 전체 대상 집계 쿼리 4건을 직접 실행해 해외 범위를 확정했다.

축	국내(KR)	해외(US) 실측
종목정보	2010~	comp.names 47,209행, 1950-2026
일별시세	2010~	crsp.dsfc 1925-12-31 ~ 2024-12-31, 1억766만행, 38,872종목
분봉	최근 1년(2025-09-04~)	TAQ 미구독, 소스 없음
재무 연간	2015~	comp.funda 1950-06-30 ~ 2026-08-31, 60만317행, 46,820사
재무 분기	2015~	comp.fundq 1961-03-31 ~ 2026-08-31, 213만2,141행, 46,589사

보고서가 스스로 붙인 주의 둘이다. 첫째, 일별시세만 2024-12-31에서 멈춰 있고 재무제표가 오히려 최신이다(원인 미확인). 둘째, "몇 년부터 있는가"와 "그 시점 값을 나중에도 믿을 수 있는가"는 별개 문제다.

국내 수집 4축 (S4~S7)

종목마스터. KRX 종목기본정보(stk_base / ksq_base)를 매일 스냅샷으로 받아 어제와 비교해 바뀐 것만 security_history 에 새 행으로 쌓는다(SCD). DART 회사등록부 corpCode.xml (118,675개사)와 연결하되 삼성전자우처럼 DART에 없는 종목은 종목코드 규칙으로 잇는다. 원문 수집은 2010-01-04 ~ 2026-09-11 완주(8,220행)했고 DB 적재는 2026-02-24 이후 중단 상태다. 2010년이 하한인 이유는 그 이전 폐지 종목을 조회할 API가 없는 물리적 한계다.

일별시세. 국내 4개 축 중 유일하게 독립된 두 파이프라인을 끝까지 돌려 대조한다. 소스가 하나면 그 소스가 틀렸을 때 알아챌 방법이 없기 때문이다.

소스	수집축	콜·시간	특성
KRX	날짜축(오늘 하루 전종목)	8,182콜, 약 34분	당일 데이터 없음(다음날 확정치), 원주가 축 고정
KIS	종목축(이 종목 전체기간)	150,511콜, 약 10.5시간	원주가+수정주가 양쪽, 보조정보 있음

대조 결과는 `price_quality` 에 영구 기록되며 6유형으로 분류한다.

유형	의미	사람 확인
B	배당락 등 기준가격 조정일·상장주식수 변동일 차이	불필요
C	단위 차이로 생기는 1000배 차이	불필요
D	거래정지일 표기 규약 차이(KRX 시고저 0, KIS 증가)	불필요
F	한쪽에만 값 있음(신규상장 첫날 등)	불필요
J	원인 불명 순수 불일치	필요
V	시고저종은 같은데 거래량·거래대금만 다름 = 소스 값 오염 추정	필요

실효 증거는 삼성전자우(005935) 2017-01-25다. 거래량 차이가 그날 시가와 같은 숫자여서 소스 값 오류로 재분류했다.

분봉. KIS 1분봉이 유일한 실사용 소스다(KRX는 분봉 자체를 제공하지 않는다). 장 마감 15:30부터 09:00까지 거슬러 한 번에 120건씩 받는다. 세션은 PRE(08:30-09:00), REG(09:00-15:30), POST(15:40-18:00) 셋이다. 전체 행의 15~21%가 체결주식수 0인데 누적거래대금만 547~551원 늘어나며, KIS 내부 계산 잔차로 보아 오류가 아니라 원문 그대로 받아들인다. 보관은 최근 1년이고, 그 이전이 필요하면 KRX 정보데이터시스템(1999-10~, 월 248,000원부터, 26년 전체 시장당 약 7,700만원) 또는 대신증권 크레온(무료·미검증, 1분봉 약 2년 추정)이 대안이다.

재무제표. DART `list.json` 을 먼저 조회해 정정 여부를 판정한다. 별도 플래그가 없어 `report_nm` 맨 앞 대괄호 접두사로 가른다([기재정정]사업보고서 = 정정, 접두사 없음 = 원본). 원본과 정정본은 DART가 서로 다른 접수번호를 발급하므로 자연히 별도 행이 되고, 여기에 `dart_filing.is_correction` 으로 명시한다. 범위는 2015 사업연도부터(DART API 공식 하한), 2025년까지 전체, 2026년은 1·2분기만이다.

국내 데이터 구조 — 18개 표 (S8~S22)

클러스터	표
종목마스터 5	company, security, security_history, delisting, trade_halt
시세 5	price_daily, price_daily_adj, price_daily_kis_supplement, price_adj_event, price_quality
분봉 1	price_intraday
재무 6	dart_filing, dart_filing_period, dart_fs_coverage, dart_fs_line, std_item, account_map
기타 1	krx_base_cache

종목마스터 설계 근거(S11). DART corp_code 는 법인 단위, KRX·KIS 종목코드는 거래종목 단위다. 우선주는 DART에 별도 법인 코드가 없어(194건 실측) 회사축과 종목축을 분리했다. 표 이름을 stock이 아니라 security로 정한 것은 ETF 1,163건(26.5%)·ETN 370건이 섞여 있기 때문이다. 가변 속성을 security_history 로 뺀 것은 036800·090150·177350 세 종목이 2026-08-18 실제로 액면분할·병합을 겪은 것처럼 시점 재현이 필요해서다. 상장주식수는 2026-09-15에 price_daily 로 옮겼다. 16년 치 backfill 실측에서 변경행의 96.8%가 상장주식수 단독 변동이었기 때문이다(카카오 145행 중 144행).

거래정지·상장폐지 판정(S12·S13). 공식 공시(KIND/DART)가 없을 때는 KRX 목록에서 종목이 사라진 것을 1차 신호로 삼고, 실제 OHLCV를 재조회해 최근 3거래일 거래량이 0인지 확인한 뒤에만 trade_halt(source='DERIVED', end_date=NULL) 을 남긴다. 상장폐지는 KRX가 폐지일 필드를 주지 않아 "그 종목코드가 마지막으로 나타난 날의 다음 관측일"을 근사값으로 채택했다.

항목	값
전체 종목	3,679
폐지 판정·적재	914
현재 상장 중	2,765
코드중복·FK 고아 행	0
914건 중 trade_halt 대응	0건 (trade_halt 자체가 0행)

실행 중 결함 2건을 발견·수정했다. ETF/ETN에서 ISU_CD 가 6자리 단축코드인데 주식에서는 12자리 표준코드라 DB가 거부한 건과, 기준일 계산이 밀려 정상 상장 3,679건 전체가 폐지로 오탐된 건이다. 후자는 즉시 롤백했다.

시세 5표 분리 원칙(S15). "이 값은 어느 소스 책임인가"를 표 자체로 구분했다. price_daily 는 KRX 정본, kis_supplement 는 KIS 전용 필드(등락부호·권리 플래그)만, price_daily_adj 는 KIS가 계산한 수정주가를 그대로 보존, price_adj_event 는 자체 판정 로직, price_quality 는 대조 결과다.

재무 표준화(S19~S21). 표준계정은 7개다.

표준계정	표	성격
매출액·영업이익·당기순이익	IS	유량
자산총계·부채총계·자본총계	BS	저량
영업활동현금흐름	CF	유량

실제 account_map 행은 6개뿐이다. 대부분 IFRS 표준코드 하나로 자동 흡수돼 계정명이 달라도 매핑이 필요 없었다. 은행·증권·보험 다수가 손익계산서를 IS가 아니라 CIS로만 제출하므로 IS·CIS 양쪽에 같은 규칙을 심었다. 업종 판정은 산업분류코드 앞자리로 한다(641 BANK, 651 INSURANCE, 661 SECURITIES). 649는 은행지주와 일반 지주회사가 같은 코드(64992)라 걸러지지 않는다. REIT만 security.product_type 으로 판정한다.

CIS-only 7개사는 KB금융(105560), 신한지주(055550), 미래에셋증권(006800), NH투자증권(005940), 삼성화재(000810), 한화생명(088350), 기업은행(024110)이다.

실측으로 발견한 문제 둘이다. 첫째, 원래 은행 정규식 $^(\text{순})?\text{영업수익}\$$ 은 sj_div 도 틀렸고 기업은행 매칭이 0건이었다. "총영업이익"과 "순영업이익"이 별개 줄로 공존해 비결정적 버그가 될 뻔했다. 둘째, 같은 업종 안에서도 계정 체계가 다르다(미래에셋증권은 ifrs-full_Revenue 를 공시하지만 NH투자증권은 그 태그 자체가 없다). 그래서 기업은행만 $^{\text{순}}\text{영업이익}\$$ 으로 근사하고 나머지 지주·증권·보험은 역시 근사 대신 정직한 결측을 택했다.

스키마 분리 근거(S22). 기간 라벨을 dart_filing_period 로 뺀 것은 분기·반기 지원 시 기간 종류가 3종에서 6종으로 늘어나야 했기 때문이다. 컬럼을 늘리는 대신 행으로 분리했다. dart_fs_coverage 는 DART 응답코드 013(정상 결측)과 "아직 조회 안 함"을 구분하기 위한 자체 체크리스트다.

XBRL 정정 원본 복구 (S23)

현재 쓰는 fnl1ttSinglAcntAll 은 접수번호를 지정할 수 없어 옛 접수번호로 물어도 최종 확정본만 돌아온다. fnl1ttXbrl.xml 이 접수번호별 원본을 보존한다는 것을 아미코젠 정정 사례로 확인했다.

항목	정정 전	정정 후
자산총계	269,016,931,029	261,371,497,913
당기순이익	31,692,976,687	39,338,409,803

검증은 4단계였다. SK리츠 651/657행 일치(99.1%, 금액 오류 0), 삼성전자 986/998행(98.8%, 금액 오류 0), 기업은행 정정보 608/1258행(48.3%, 금액 오류 8건). 마지막에서 결함을 찾았다. 분기·반기의 "그 분기만"과 "연초 누적" 문맥을 파서가 구분하지 못해 자본총계 등 4개 계정에서 틀린 금액이 나왔다(31조8,168억 vs 29조8,577억). 수정 후 기업은행 3건 재검증을 통과했고 대상 7건 전부 복구했다. MR이 2026-09-17 dev로 병합됐다.

종목 유형 판정 (S28)

KIS 상품구분코드의 SPAC 여부 → KRX 증권그룹명 1차 분기 → 종류코드 2차 분기 → 종목명의 "우선주" 포함 여부 순으로 판정한다. 실제로 헤맸던 사례는 선박투자회사와 사회간접자본투자회사들을 처음에 같은 SHIP_FUND로 묶은 것이다. 조사 결과 둘은 근거 법률이 다른 별개 투자기구였다(선박투자회사법 vs 사회기반시설 민간투자법). INFRA_FUND를 신설하고 라이브 DB의 088980 맥쿼리한국인프라투자회사, 415640 KB발해인프라투자회사 두 종목만 UPDATE한 줄로 이관했다.

수정주가 탐지와 역산 (S29~S31)

탐지는 날짜별 원주가증가 / 수정주가증가 비율의 전일 대비 변화율이 1% 이상일 때 이벤트로 본다. 005930·900140 실측에서 실제 배율이 1.28~50배로 나타나, 1%는 부동산수점 잡음보다 크면서 진짜 이벤트를 놓치지 않는 문턱이다. 005930은 1차 표본이 등성해 관측일이 2023-03-09로 잘못 찍혔다가, 분할일 전후 영업일을 채워 재계산하자 실제 액면분할일 2018-05-04(배율 50)가 잡혔다.

역산이 필요한 이유는 KIS가 분봉을 수정주가로만 주기 때문이다(원주가 축 선택 플래그가 없다). 구간 이벤트를 유리수(big.Rat)로 누적급하되 상장주식수 비율을 가격비보다 우선한다. 001080에서 가격비로 역산하면 57,004.31원(+4.7873% 부풀림)이 나오던 버그를 이 우선순위로 고쳤다.

종목·사건	오염값	역산 결과	KRX 실제 원주가
001080 만호제강, 10:1 분할	5,440	54,400	54,400
090150 아이원, 10:1 병합	4,990	499	499
177350 베셀, 5:1→2:1 누적	2,018	201.8	202
036800 나이스정보통신, 5:1 분할	5,630	28,150	28,150

보고서는 이 결과를 근거로 독립 3단계 설계(ca_event / ca_factor_range / v_price_adj)가 불필요해 보인다고 판단하고, 이슈 종결 여부는 결정이 필요하다고 남겼다.

실제 데이터 예시 (S25 계열)

국내 16개 표를 로컬 DB 실측값으로 채웠다. 보고서의 태도가 드러나는 지점은 채우지 못한 표를 그대로 밝힌 것이다. `trade_halt` 는 전체 0행이고, `price_quality` 도 0행이며 삼성전자 V유형 사례는 조사 단계에서 발견한 사실일 뿐 적재된 적이 없다고 명시했다. 분봉은 이전 회차에 개별종목 예시가 없어 이번에 `cmd/collect-intraday -code=005930` 을 직접 돌려 381행을 새로 적재했고, 해외 `us_price_daily` 도 WRDS 라이브 조회로 33행을 새로 넣었다.

`security_history` 의 `valid_to` 가 전부 NULL인 이유도 밝혀 두었다. 다른 이슈에서 "다음 `valid_from` - 1일"로 근사했다가 실제 7.9년 공백을 하루로 기록하는 결함을 발견해 정직한 결측으로 바꿨다.

해외 구조 (S32~S37)

WRDS라는 하나의 Postgres 서버에 pgx로 직접 접속해 CRSP와 Compustat을 SQL로 가져온다. REST API가 아니다.

소스	담당	테이블	식별자
CRSP	시세·종목 이력	<code>crsp.stocknames</code> , <code>crsp.dsfc</code> (20개 컬럼 전부)	<code>permno/permco</code>
Compustat	회사·재무제표	<code>comp.company</code> , <code>comp.names</code> , <code>comp.security</code> , <code>comp.funda</code> , <code>comp.fundq</code>	<code>gvkey</code>

표는 10개이고 클러스터는 2개뿐이다. WRDS 원본 컬럼을 선별 없이 보존해 표당 컬럼 수는 국내보다 많다(`us_company` 33개, `us_price_daily` 20개). 회사1:종목 N 구조는 버크셔 해서웨이(`permco` 540)가 BRK.A·BRK.B 두 `permno`를 갖는 것으로 실측 확인했다. `us_security_history` 는 CRSP가 이미 (`namedt`, `nameenddt`) 유효기간 구조로 관리하고 있어 그대로 채용했다.

CUSIP8 근사매칭은 CRSP `cusip` 앞 8자리와 Compustat `cusip` 앞 8자리를 문자열 비교한다. 정식 연결 서비스(CCM)가 한양대 구독 범위에 없어서다. 재현율은 Compustat 회사 77,578개 중 33,291개 (42.9%), 미국·활성기업만 좁히면 16,212개 중 7,839개(48.4%)다. 모호매칭·오매칭은 0건이다. 같은 조사에서 "미국 소재·상장폐지 기업"만 보면 62.9%가 나왔는데 이 값이 위 범위에 포함되지 않은 이유는 원본에 없다.

재무제표는 국내와 같은 EAV 구조다. 다만 목적이 반대다. 국내는 같은 개념을 회사마다 다른 이름으로 부르는 문제라 7개로 통일하는 것이 목적이고, 해외는 항목 개념 자체가 특정 업종에만 존재해 원본을 손실 없이 보존하는 것이 원칙이다. 예컨대 `comp.funda` 의 은행 전용 항목 11개(`dptb` 예금총계, `lcabg` 대출채권, `ibki` IB수익 등)는 제조업 회사에서는 컬럼이 있어도 항상 NULL이다.

`us_financial_item_dict` 는 표준계정 매핑 표가 아니라 항목코드의 영·한 뜻풀이 사전이다.

국내 vs 해외 비교 (S39~S43)

비교 축	국내	해외
표 개수	18개	10개
차이의 원인	직접 판정해 만든 품질관리 표 5종이 국내에만 존재	WRDS가 정제된 값을 주고, 아직 그 단계까지 구현 안 됨
회사-종목 연결	종목코드 앞 5자리 대조, 195/195건 전량	CUSIP8 문자열 비교, 42.9~48.4%
정정 이력	새 접수번호로 새 행, 원본·정정보 둘 다 보존	같은 자리를 덮어쓰, 원본 소멸
PIT 준수	가능	불가능
진행 단계	Go 전면 재작성, Phase1-4 전부 dev 병합	체크리스트 5개 중 3개
남은 것	재무제표 전종목 backfill 실행	재무제표 EAV 5개 표 수집

국내 재무제표는 "다 했다"가 아니라 "코드는 다 뒀고 실행만 남았다"이다. 수집 로직·전종목 backfill 구현·계정매핑이 전부 closed이고 실물 코드도 확인됐지만, 3,443개사 재무제표를 실제로 받아오는 약 320,133콜(약 16.8일 추정)은 실행 이력이 없다. 표본검증은 13개사 21,897행까지 마쳤다.

정기미팅 회고 (S45~S47)

정규장 외 시세. 시간외단일가(16:00-18:00)는 2026-09-07에

`price_intraday.session='POST'` 를 재사용해 체결틱 전건 보존으로 확정했다(신규 DDL 불필요). 장전(08:30-08:40)·장후(15:40-16:00) 거래량은 직접 주는 API가 없어 별도 컬럼 신설과 인트라데이 방식 관리 중 무엇을 택할지 미정이다.

미국 재무 PIT. 두 가지가 미결이다. Compustat 특정 상품의 PIT 지원 여부(회의 음성인식 한계로 명칭 재확인 필요)와, S&P Global Market Intelligence 경유 데이터가 WRDS 직접 접근과 같은 데이터인지 여부다. WRDS 레거시 데이터를 스냅샷처럼 쓸 수 있는지에 대한 논의는 결론이 나지 않았다.

우선주 vs 종류주. 260909 미팅에서 종목명에는 "우선주"가 있는데 분류 타입 코드상으로는 상위 개념인 종류주로 분류된 사례(한진칼 우선주)가 발견됐다. 2026-09-18 재확인 결과 종류주권 15건 전부 종목명에 "우선주"가 포함돼 정상적으로 PREFERRED로 분류됐고 오분류는 0건이었다. 잔여 OTHER 12건도 전부 "투자회사" 유형이다. 다만 이는 전수조사 완료가 아니라 backfill된 범위 안에서 문제 없음이라는 뜻이다.

미결정 사안 상세 (S48-A·S48-B)

거래정지와 무거래 구분. 거래정지는 거래소가 매매를 막은 사건이고 무거래는 매매는 열렸지만 체결이 0건인 날이다. 기존 로직은 "거래량 0이면 정지"로 뭉뚱그렸고, 실측으로 오판정 규모가 드러났다.

실측 항목	결과
<code>no_trade=true</code> 전체 행	282,543행(3.07%)
연속구간 24,144개 중 1~2일짜리	17,177개(71.1%), 우선주·리츠·스팩이 78.3%
KRX 정지목록에 없는데 volume=0인 137종목 중 재조회 29개	29개 전부 오탐
KRX 공식 정지 119건 대조	49건 누락
독립 2차 표본 138종목 재조회	76개(55%) 공식 정지 확인, 62개(45%) 미확인

스키마 차원의 구분은 반영됐다(`is_halted` → `no_trade` 개명, `trade_halt`·`delisting` 신설). 다만 `trade_halt`에 KRX 공식 사유를 채우는 작업은 미결이다. KRX Data Marketplace API로 종목당 정지일·재개일 컬럼까지 확인하고 4,476콜 예산까지 산정했지만, 종목명 검색 시 UI 캐시로 보이는 동작이 불안정해 신뢰도가 낮다는 이유로 260904 미팅에서 채택을 보류했다.

장 전후 거래량 분리. 일별 거래량은 정규장과 세 시간외 세션을 합산한 값이라 세션별 분해가 안 된다. KIS API 시간외 관련 7종을 전수 스캔했으나 전부 16:00-18:00 시간외단일가만 제공하고, 장전·장후 거래량을 직접 주는 API는 끝내 찾지 못했다. 유일한 대안은 뿔샘 유추이며 장전과 장후는 서로 구분되지 않는다.

2024년 시세 단절 — 원인과 해법

데이터 문제가 아니라 CRSP의 포맷 세대교체다. 지금 구독 그대로, 코드만 바꾸면 해결된다.

CRSP는 2022년 여름 Stock & Indexes Flat File Format 2.0(CIZ)을 도입했고, 2025년 1월에 배포된 2024년 12월 데이터가 레거시(FIZ)와 Format 1.0(SIZ)으로 만들어진 마지막 배포였다. SIZ는 중단되며 갱신 데이터를 받으려면 새 포맷으로 옮겨야 한다([CRSP 공지](#), [WRDS 안내](#)).

지금 쓰는 `crsp.dsf`와 `crsp.stocknames`가 그 SIZ 계열 테이블이다. WRDS가 옛 데이터를 제자리에 남겨두므로 조회는 되지만 2024년 12월 이후로 영원히 늘지 않는다. Compustat은 S&P가 제공하는 별개 데이터셋이라 정상 갱신되어 2026-08-31까지 있다. "시세만 멈추고 재무가 더 최신"인 역전은 여기서 나온다.

옮겨갈 테이블

지금(SIZ)	바꿀 곳(CIZ)	컬럼 대응
<code>crsp.dsf</code>	<code>crsp.dsf_v2</code>	<code>date</code> → <code>dlycaldt</code> , <code>prc</code> → <code>dlyprc</code> , <code>ret</code> → <code>dlyret</code> , <code>retx</code> → <code>dlyretx</code> , <code>vol</code> → <code>dlyvol</code> , <code>openprc</code> → <code>dlyopen</code> , <code>askhi/bidlo</code> → <code>dlyhigh</code> / <code>dlylow</code>

지금(SIZ)	바꿀 곳(CIZ)	컬럼 대응
<code>crsp.stocknames</code>	<code>crsp.stksecurityinfohist</code>	<code>namedt/nameenddt</code> → <code>secinfostartdt / secinfoenddt</code>
<code>crsp.dsedelist</code>	(불필요)	폐지 수익률이 <code>dlyret</code> 에 통합

단순 개명이 아닌 지점 셋

1. **폐지 수익률이 본 시계열에 들어온다.** SIZ에서 별도 표(`dsedelist`)에 있던 값이 CIZ에서는 `stkdllysecuritydata`에 통합된다. 리먼브러더스는 2008-09-18 행에 `dlydel_flg='Y'`, `dlyret=-0.6`으로 찍힌다. 해외는 생존편향 처리가 공짜로 따라온다는 뜻이다.
2. **보통주 필터가 바뀐다.** `shrcd in (10,11)`이 사라지고 `sharetype='NS'`, `securitytype='EQTY'`, `securitysubtype='COM'`, `usincflg='Y'`, `issuertype in ('ACOR','CORP')` 조합으로 대체되며, `secinfostartdt <= dlycaldt <= secinfoenddt` 시점 조인이 붙는다.
3. **스키마에 영향이 있다.** `us_security_history`를 "CRSP가 이미 (`namedt`, `nameenddt`)로 관리하니 그대로 채용"했는데 그 원본이 동결 테이블이다.

`us_price_daily`가 33행뿐인 지금이 옮기는 비용이 가장 싸다. 재무제표 EAV 수집 착수 전에 끝내는 것이 순서다.

S48 미결정 4건 — 리뷰와 제안

Q1. 미국 재무제표 PIT

질문의 전제가 틀렸다. "Compustat 표준이 덮어쓰기 구조라 PIT이 불가능하다"가 아니라 PIT 전용 상품을 구독하지 않은 것이다. WRDS에는 Compustat Snapshot이 있고, 수집 과정에서 얻은 모든 값을 예비치와 최종치까지 함께 제공하며 Point-in-Time 커버리지가 1986년부터다([WRDS DB 목록](#)). S46에서 "음성인식 한계로 명칭 재확인 필요"라던 상품이 이것으로 보인다.

다만 Snapshot 계열의 "unrestated(as first reported)"는 이름과 달리 무조정 원본이 아니다. SEC 제출 대비 Compustat 내 최초 표준화 값이며 PIT 파일 안의 첫 행에 해당한다([Lyle 외](#)). 구독한다면 unrestated가 아니라 PIT 본체를 써야 한다.

순위	방안	비용	커버
①	rdq (실적발표일) 기준 지연 적용	0, 이미 보유	발표 타이밍 록어헤드
②	SEC EDGAR XBRL로 자체 PIT 구축	0	2009~, 접수번호 단위 원본
③	분기마다 전체 스냅샷 축적	저장소만	지금부터의 미래
④	Compustat Snapshot 구독	유상	1986~

②가 핵심이다. EDGAR XBRL은 제출 건별 원본을 접수번호와 제출일로 보존하므로 국내 DART XBRL 복구와 구조가 같다. 이미 만든 파이프라인 경험이 그대로 재사용되고, 백테스트 기간이 2009년 이후라면 ④ 없이 완결된다. 표준화는 포기해야 하지만 해외는 애초에 "원본 보존이 설계 원칙"이라 방향이 어긋나지 않는다.

①은 오늘 할 수 있고 반드시 해야 한다. `datadate` 가 아니라 `rdq` 이후 데이터만 쓰게 하면 정정과 별개로 발표 시차 록어헤드가 제거된다.

Q2. 매칭률 43~48%로 백테스트에 써도 되는가

지금 숫자로는 판단할 수 없고, 원인은 이미 밝혀져 있으며, 해법도 **WRDS**에 있다. 세 층이다.

분모가 틀렸다. 42.9%는 Compustat 전체 77,578개사 기준인데 CRSP는 NYSE·AMEX·Nasdaq 상장 미국 주식만 다룬다. 애초에 CRSP에 있을 수 없는 회사가 분모에 들어 있다. "미국 소재·폐지 기업만 보면 62.9%"가 그 증거다. 교집합 유니버스(CIZ 필터 통과 + 해당 기간 거래 중인 permno)를 분모로 재측정해야 한다.

원인은 추정이 아니라 확정된 사실이다. Compustat은 최신 CUSIP만 담았고 CRSP는 거래 시점에 맞춘 역사적 CUSIP을 유지해 매칭이 실패했으며, 특히 Compustat 최신 CUSIP이 CRSP 커버리지 밖의 OTC·지역 거래소 증권을 가리킬 때 그렇다([WRDS](#)). S40의 버크셔 B주 2010년 CUSIP 변경 사례가 정확히 이 패턴이다.

해법이 이미 제공된다. Compustat이 시간에 따라 바뀌는 티커·CUSIP·거래소 이력을 `sec_history`·`sec_idhist` 두 테이블로 제공하고, WRDS가 CCM 없이 이 표들로 CRSP V2와 매칭하는 노트북을 공개해 두었다. CCM 방식과 비교해 CCM 쪽 한계까지 짚는다.

권고 순서는 이렇다.

1. 교집합 유니버스로 매칭률 재측정
2. `sec_idhist` + CRSP 역사적 CUSIP으로 시점별 매칭으로 교체
3. 잔여 실패군의 분포(연도·폐지 여부·규모) 확인

3번이 핵심이다. 실패가 "오래전 폐지된 소형주"에 몰려 있으면 매칭 문제가 아니라 생존편향이 뒷문으로 들어온 것이고 백테스트 수익률이 위로 편향된다. 이 분포 확인 전에는 "써도 되는가"에 답할 수 없다. 실무 기준선은 교집합 유니버스에서 95% 이상이다.

Q3. 1년 초과 과거 분봉이 필요한가

지금 사지 말고, 오늘부터 축적을 시작한다.

분봉이 꼭 필요한 용도는 인트라데이 알파, 집행 알고리즘, 미시구조 연구 셋뿐이다. 일간 리밸런싱 팩터 전략이면 분봉은 체결가정 검증(VWAP·슬리피지·시가 체결 가능성)에만 쓰이고 최근 1년 표본으로 충분하다. 1순위가 "국내 과거 일별"인 상황에서 26년치 7,700만원은 순서가 맞지 않는다.

KIS 1분봉을 1년 롤링이 아니라 **영구 축적**으로 오늘 전환하는 것이 제안이다. 1년만 지나도 크레온이 제공한다는 2년치와 같아지고 3년 뒤엔 유료 대안이 불필요해진다. 하루 늦출 때마다 하루치가 영구히 사라지므로 이 결정은 어떤 구매 판단보다 앞선다. 크레온은 Windows COM 의존이라 상시 운영에는 부담이지만 2년치 확보용 1회성 배치로는 합리적이다.

Q4. 상장폐지일 근사가 생존편향 방지에 적절한가

날짜 근사는 큰 문제가 아니다. 빠진 것은 폐지 수익률과 정지 구간이다.

생존편향의 본질은 "폐지 종목이 유니버스에 있는가"가 아니라 "폐지 시점의 손실을 반영하는가"다. 폐지 종목 914건을 넣어도 마지막 관측일에 조용히 사라지면 "마지막 종가에 전량 매도 성공"이라는 가정이 되어 실제보다 성과가 좋게 나온다. Shumway(1997) 이래 표준 처리는 성과부진 폐지에 -30%를 대입하는 것이다.

더 큰 왜곡은 거래정지 후 폐지다. 이 경우 마지막 관측일이 정지 개시일이라 근사 폐지일이 실제보다 수개월 이른다. 그 구간이 유니버스에서 사라지면 "정지되면 즉시 청산 가능"이라는 비현실적 가정이 되는데, 실제로는 못 팔고 폐지까지 간다. 날짜가 며칠 어긋나는 것보다 이쪽이 크다.

1. `delisting` 에 `last_trade_date` 와 `delist_date` 를 분리 보관 — 정리매매 종료일과 폐지일은 다른 날이다
2. 폐지 사유 확보를 우선순위로 올린다 — 사유가 없으면 -30% 규칙도, 합병(가치 보존)과 부실폐지(가치 0) 구분도 불가능하다. KIND API가 신뢰도 문제로 보류 중이면 DART 주요사항보고서나 KRX 정보데이터시스템 폐지종목 목록을 대안으로 검토한다
3. 백테스트 엔진에 "정지~폐지 구간은 청산 불가, 폐지 시 잔여가치는 사유별 계수" 규칙을 명시한다
4. 같은 전략을 폐지 종목 포함/제외 두 버전으로 돌려 CAGR 차이를 제시한다 — 편향의 크기를 수치로 보이는 것이 근사 방식의 적절성을 논하는 것보다 설득력 있다

해외는 이 문제가 CIZ 전환으로 상당 부분 자동 해결된다. 폐지 수익률이 `dlyret` 에 이미 들어 있기 때문이다. 국내만 직접 만들어야 하는 구조다.

정정공시 처리 규칙

완전한 정정 추적은 불가능하다. 목표는 완전성이 아니라 **일관성과 정직한 결측**이다. 못 잡는 케이스를 명시적으로 기록하면 백테스트 결과의 신뢰구간을 말할 수 있지만, 못 잡는 줄 모르면 말할 수 없다.

원칙 셋으로 출발한다. 판정이 애매하면 판정하지 말고 둘 다 보관한다. 시점은 `rcept_dt` 하나로 통일한다. 값을 고치지 말고 플래그만 남긴다.

R1. 접두사를 원문 그대로 보관한다

지금은 대괄호 유무만 보고 `is_correction` 을 세운다. DART 접두사는 [기재정정] 외에 [첨부정정] · [첨부추가] · [연장결정] 등이 있고 재무 수치가 실제로 바뀌는 것은 일부다. 첨부파일만 고친 건도 정정으로 잡히면 "정정이 몇 건인가"가 부풀려진다.

`dart_filing` 에 `correction_tag` VARCHAR 한 컬럼을 추가해 접두사 원문(기재정정, 첨부정정, NULL)을 넣는다. `is_correction` 은 `correction_tag IS NOT NULL` 로 유지해 기존 코드를 깨지 않는다. 비용은 컬럼 하나다.

R2. as-of 조회 규칙을 뷰 하나에 못 박는다

정정보를 다 보관해도 조회가 틀리면 소용없다. PIT의 실제 집행 지점은 여기서다.

기준일 d에서 회사 c.기간 p의 값은, `rcept_dt < d` 인 필링 중 `rcept_dt` 가 가장 큰 건의 값이다.

부등호가 `<=` 가 아니라 `<` 인 이유는 DART 공시가 장중에도 올라오기 때문이다. 당일 공시를 당일 종가 기준 전략에 쓰면 록어헤드가 생긴다. 하루 보수적으로 잡는 편이 안전하다.

`v_fs_std` 는 지금 최신본을 주는 뷰로 보인다. as-of 파라미터를 받는 `v_fs_std_asof(d)` 를 따로 만들고, 백테스트는 이쪽만 쓰게 한다. 최신본 뷰는 리서치·검증용으로 남긴다.

R3. 소급 정정은 짧은 창으로 회수한다

2020년 보고서가 2026년에 정정되는 경우를 잡으려면 폴링이 필요하다. 전량 재수집은 비용이 과하고, 짧은 창이면 충분하다.

```
flowchart LR
    A["A[매일 list.json<br/>최근 7일 창] --> B{새 rcept_no?}"]
    B -- "아니오" --> A
    B -- "예" --> C["C{corp+기간 조합이<br/>이미 있나}"]
    C -- "아니오" --> D["D[신규 필링으로 적재]"]
    C -- "예" --> E["E[정정으로 적재<br/>correction_tag 기록]"]
    E --> F["F[R4 수치 대조]"]
```

창 길이는 7일이면 실무상 충분하고, 주 1회 30일 창을 한 번 더 돌리면 누락 위험이 거의 사라진다. 쿨 수는 하루 수십 건 수준이다.

R4. 수치 변경 여부는 표준계정 7개로만 판정한다

정정보가 잡히면 원본과 대조해 `dart_filing.fs_changed` 를 세운다. 전 계정(수백 개)을 비교하면 비용이 크고 노이즈도 많다. `std_item` 7개만 비교한다. 이 7개가 안 바뀌었으면 백테스트 관점에서는 정정이 아니다.

비교 대상이 없을 때(원본 필링이 DB에 없음)는 `fs_changed = NULL` 로 둔다. `false`가 아니라 `NULL`이다.

R5. 비교표시 재작성은 탐지만 하고 고치지 않는다

가장 놓치기 쉬운 경로다. 전기 재무제표가 정정공시 없이 당기 보고서의 비교표시 수치로만 조용히 바뀌는 경우가 있다. 정정 플래그로는 절대 잡히지 않는다.

`dart_filing_period` 에 전기·전전기가 이미 행으로 들어 있으므로 쿼리 하나면 된다.

N년 보고서의 `relative_period='frmtrm'` 값과 N-1년 보고서의 `relative_period='thstrm'` 값을 같은 계정끼리 대조한다.

불일치는 `restatement_flag(corp_code, period_end, item_code, old_value, new_value, detected_at)` 에 기록만 한다. 어느 쪽이 옳은지 판정하지 않고 값도 건드리지 않는다. 분기 배치로 돌리면 충분하다.

이 표가 쌓이면 부수 효과가 있다. 재작성이 잦은 회사를 팩터 유니버스에서 뺄지 판단하는 근거가 된다.

R6. XBRL 복구는 전건이 아니라 조건부로 돌린다

이미 구현은 끝났지만 전건에 돌리면 콜 예산이 감당되지 않는다. 대상을 좁힌다.

조건	처리
<code>correction_tag='기재정정' AND fs_changed=true</code>	XBRL 복구 대상
<code>correction_tag='기재정정' AND fs_changed=false</code>	복구 불필요
<code>correction_tag='첨부정정'</code> 등	복구 불필요
원본 필링이 없어 <code>fs_changed=NULL</code>	큐에 넣되 후순위

이렇게 좁히면 실제 복구 대상은 전체 필링의 한 자릿수 퍼센트에 그친다.

R7. 못 잡는 것을 표로 명시한다

사각지대	이유	처리
2015년 이전	DART API 공식 하한	해당 기간 백테스트 불가로 명시
XBRL 미제출 필링	소규모·구형 공시	<code>fs_changed=NULL</code> 로 남김
감사보고서만 정정된 건	본보고서 접수번호가 안 바뀜	미탐지, 알려진 한계로 기록

사각지대	이유	처리
정정 전 원본이 DB에 없는 건	수집 시작 이전 정정	<code>fs_changed=NULL</code>

이 표 자체가 산출물이다. 백테스트 결과를 보고할 때 같이 붙인다.

사례로 보는 규칙 적용

네 가지 경로를 한 번씩 밟아 본다. 금액은 보고서가 실제로 복구한 아미코젠 수치이고, 날짜와 접수번호는 흐름을 보이기 위한 예시다.

사례 A — 기재정정, 수치가 바뀐 경우

원본 제출 뒤 다섯 달 만에 정정본이 올라온 상황이다.

시점	필링	correction_tag	자산총계	당기순이익
2024-03-15	사업보고서 (2023.12)	NULL	269,016,931,029	31,692,976,687
2024-08-20	[기재정정]사업보고서 (2023.12)	기재정정	261,371,497,913	39,338,409,803

규칙이 순서대로 걸린다. R3의 7일 창 풀링이 8월 20일에 새 `rcept_no` 를 잡고, 같은 회사·같은 `period_end` 조합이 이미 있으므로 정정으로 분류한다. R1이 `correction_tag='기재정정'` 을 기록한다. R4가 표준계정 7개를 대조해 자산총계와 당기순이익이 달라진 것을 확인하고 `fs_changed=true` 를 세운다. R6의 필터를 통과하므로 XBRL 복구가 돌아 두 값이 모두 DB에 남는다.

R2가 실제로 쓰이는 지점은 여기서다.

백테스트 기준일	<code>rcept_dt < d</code> 필링	반환되는 자산총계	ROA
2024-05-01	03-15 원본만	269,016,931,029	11.8%
2024-08-20	03-15 원본만 (당일 제외)	269,016,931,029	11.8%
2024-12-01	03-15, 08-20 중 최신	261,371,497,913	15.0%

5월 리밸런싱에서 정정 후 값을 쓰면 ROA가 3.2%p 부풀려진다. 그 시점에는 아무도 알 수 없었던 숫자이기 때문이다. 8월 20일 행이 부등호를 `<=` 가 아니라 `<` 로 둔 이유를 보여준다. DART 공시는 장중에도 올라오므로 당일 종가 전략에 당일 공시를 쓰면 록어헤드가 생긴다.

사례 B — 첨부정정, 수치는 그대로인 경우

같은 회사가 11월에 [첨부정정]분기보고서를 낸다. 지금 로직은 대괄호만 보고 정정으로 잡지만, R10이 `correction_tag='첨부정정'` 을 기록하고 R4가 표준계정 7개를 대조해 전부 동일함을 확인한다. `fs_changed=false` 가 되어 R6 필터에서 빠지고 XBRL 복구를 돌리지 않는다.

효과는 두 가지다. 콜이 절약되고, "정정 N건"이라는 품질 지표가 부풀려지지 않는다.

사례 C — 비교표시 재작성, 정정공시가 없는 경우

정정 플래그로는 절대 잡히지 않는 경로다.

출처 필링	기간 라벨	대상 연도	매출액
2023년 사업보고서 (2024-03 제출)	thstrm (당기)	2023	1,200억
2024년 사업보고서 (2025-03 제출)	frmtrm (전기)	2023	1,150억

같은 2023년 매출액인데 값이 다르다. 2024년 보고서를 쓰면서 조용히 다시 작성한 것이고, 정정공시는 없었다. R5 쿼리가 이 불일치를 잡아 `restatement_flag` 에 기록한다.

중요한 것은 그 다음이다. **값을 고치지 않는다.** as-of 조회는 2023~2024년 기준일에 대해 계속 1,200억을 돌려준다. 그때 시장이 본 숫자가 그것이기 때문이다. 1,150억은 2025-03 이후 기준일에서만 보인다. 플래그는 "이 회사는 재작성 이력이 있다"는 별도 정보로만 쓴다.

사례 D — 사각지대, 감사보고서만 정정된 경우

감사보고서가 정정되었지만 본보고서 접수번호는 그대로인 경우다. `list.json` 에 새 `rcept_no` 가 안 생기므로 R3이 잡지 못하고, R4도 R6도 돌지 않는다.

이때 하는 일은 하나다. R7 표에 "감사보고서만 정정된 건 — 미탐지"로 한 줄 남긴다. 고치지 못하는 것을 고치려 들지 않고, 모른다는 사실을 기록한다. 백테스트 결과를 보고할 때 이 표를 같이 붙이면 결과의 한계를 정직하게 말할 수 있다.

네 사례를 한 줄로

사례	탐지	fs_changed	XBRL 복구	as-of 반환값
A 기재정정·수치변경	R3	true	실행	기준일 따라 바뀜
B 첨부정정	R3	false	생략	변화 없음
C 비교표시 재작성	R5	해당 없음	해당 없음	원래 값 유지
D 감사보고서 정정	미탐지	NULL	해당 없음	원래 값 유지

해외에 같은 규칙을 적용하면

Compustat은 같은 자리를 덮어써서 R1~R6을 적용할 대상 자체가 없다. SEC EDGAR XBRL로 가면 구조가 그대로 대응된다.

국내	해외(EDGAR)
rcept_no	accn (접수번호)
rcept_dt	filed (제출일)
[기재정정] 접두사	폼 타입(10-K/A , 10-Q/A)
R2 as-of 규칙	동일하게 적용

EDGAR가 안 되는 기간(2009년 이전)은 Compustat rdq 로 발표 시차만 막고 정정은 포기한다. 이것도 R7 표에 한 줄로 적는다.

착수 순서

순위	항목	규모
1	R2 as-of 뷰	뷰 하나, 하루
2	R1 correction_tag 컬럼	컬럼 하나, 하루
3	R7 사각지대 표 작성	문서, 반나절
4	R3 일일 폴링 루프	배치 하나, 며칠
5	R4 7개 계정 대조	쿼리, 며칠
6	R5 비교표시 대조	쿼리 + 표 하나, 1주
7	R6 조건부 XBRL 복구	이미 구현, 필터만

1~3번은 합쳐 이틀이면 끝나고, 그것만으로도 PIT이 실제로 집행되기 시작한다. 지금은 데이터는 있는데 조회 규칙이 없어서 보관한 정정본이 백테스트에 반영되지 않는 상태로 보인다.

코퍼릿 액션 처리 규칙

정정공시가 재무 축의 시점 문제라면, 여기는 시세 축의 시점 문제다. 한 종목이 살아 있는 동안 겪는 사건들이 가격·주식수·존재 여부를 바꾸고, 그 처리가 틀리면 백테스트 수익률이 조용히 왜곡된다.

현 상태 점검 — 이벤트별 커버리지

보고서에 나온 범위에서 판단한 것이다. 코드를 직접 본 것은 아니므로 "부분"과 "공백"은 확인이 필요한 항목으로 읽으면 된다.

이벤트	현 처리	상태	위험
액면분할·병합	price_adj_event 탐지 + 역산, 4종목 검증	충분	—
무상증자	KIS flag_class / prtt_rate	부분	배율 출처가 KIS 단일, 자체 검증 없음
유상증자	동일	부분	주식수비와 가격비가 갈리는 구간
유상감자·자사주 소각	분류 없음	공백	주식수비 적용 시 가격 왜곡
현금배당	없음	공백	총수익률 계산 불가
거래정지	trade_halt(DERIVED) 설계만	공백(0행)	정지 구간 청산 가정 오류
거래재개	end_date=NULL 고정	공백	정지가 영구처럼 보임
상장폐지	914건 적재, 사유·수익률 없음	부분	생존편향 잔존
합병·분할	delisting.successor 컬럼 하나	부분	1:N·N:1 계보 표현 불가
신규상장	대사에서 F유형으로 제외	충분	—
시장 이전·종목명 변경	security_history	충분	—

충분 3, 부분 4, 공백 4다. 공백 넷 중 현금배당과 거래재개가 가장 크다. 배당은 팩터 수익률을 체계적으로 깎고, 거래재개는 정지 구간의 손익을 통째로 날린다.

E1. 배율의 출처를 이벤트 유형이 정하게 한다

현 규칙은 상장주식수 비율을 가격비보다 우선한다. 001080 만호제강 10:1 분할에서 가격비로 역산하면 57,004.31원(+4.7873% 부풀림)이 나오던 버그를 이 우선순위로 고쳤으니, 액면분할·병합에서는 옳다. 문제는 두 비율이 갈리는 이벤트다.

이벤트	주식수비	가격비	써야 할 배율
액면분할·병합	변동	주식수비와 일치	주식수비(정밀)

이벤트	주식수비	가격비	써야 할 배율
무상증자	변동	주식수비와 대체로 일치	주식수비
유상증자	변동	발행가 할인율에 따라 다름	가격비
유상감자(현금 환급)	감소	환급액에 따라 다름	가격비
자사주 소각	감소	조정 없음(=1)	배율 1
현금배당	불변(=1)	배당락만큼 하락	별도 축(E2)

`price_adj_event` 에 `event_type` 컬럼을 추가하고, 배율 산출 방식을 `event_type` 이 결정하게 한다. 1차 판별은 이미 수집 중인 `price_daily_kis_supplement.flag_class` (권리 구분 플래그)로 하고, 애매하면 DART 주요사항보고서로 보강한다.

`event_type` 을 모르면 가격비를 쓴다. 가격비는 어떤 이벤트든 시장이 실제로 매긴 조정을 반영하므로 틀려도 덜 틀린다. 주식수비는 맞을 때 더 정밀하지만 틀릴 때 크게 틀린다.

E2. 배당을 별도 축으로 수집한다

보고서 55장 어디에도 배당이 나오지 않는다. `price_daily_adj` 는 분할 등을 반영한 수정주가이고, 배당은 어느 표에도 없다. 총수익률을 계산할 수 없다는 뜻이다.

표 하나면 된다.

```
dividend(short_code, ex_date, record_date, pay_date, amount_per_share,
kind, source)
```

`kind` 는 현금·현물·주식을 구분한다. 소스는 DART 현금·현물배당결정 공시가 1차이고, 사업보고서 배당 항목으로 보강한다. 총수익률은 배당락일에 `주가수익률 + 주당배당금 / 전일종가` 로 더한다.

E2 확정 — 총수익 축 구축안

KIS 수정주가의 사양이 확인됐다. 액면분할·병합, 무상증자·감자, 주주배정 유상증자(권리락), 주식배당은 반영되고, **현금배당과 제3자배정·일반공모 유상증자는 반영되지 않는다**. 앞의 넷은 KRX가 기준가를 조정하는 이벤트이고 뒤의 둘은 조정하지 않기 때문이다.

백테스트 관점에서 결론은 하나다. 지금 가진 두 축만으로는 **성과를 측정할 수 없다**. 수익률을 재는 축이 없다.

세 축으로 나누고 용도를 고정한다

축	반영 범위	용도
<code>price_daily</code> 원주가	없음(실제 체결가)	주문 체결가, 호가단위, 상하한가, 유동성 판단
<code>price_daily_adj</code> 수정주가	자본 변동만	기술지표, 모멘텀, 연속 시계열
<code>price_daily_tri</code> 총수익지수	자본 변동 + 현금배당 재투자	수익률·성과 측정의 유일한 기준

원칙은 한 줄이다. 수익률은 총수익지수에서 재고, 체결은 원주가로 한다. 수정주가로 수익률을 재면 배당만큼 체계적으로 낮게 나오고, 수정주가로 체결하면 호가단위와 상하한가가 맞지 않는다.

총수익지수 계산

$$r_t \text{ \textbackslash;=\\; } \frac{P^{\text{adj}}_t + D^{\text{adj}}_t}{P^{\text{adj}}_{t-1}} - 1$$

$$\mathrm{TRI}_t \text{ \textbackslash;=\\; } \mathrm{TRI}_{t-1} \cdot (1 + r_t), \quad \mathrm{TRI}_0 = 100$$

여기서 배당 항은 배당락일에 귀속되는 주당 현금배당을 수정주가 축으로 환산한 값이다. 이 환산이 빠지기 쉽다. 10:1 액면분할 이전에 지급된 주당 500원 배당은 수정주가 축에서 50원이다. 분할 배율을 곱하지 않으면 배당이 10배로 들어간다.

소급 수정이 아니라 별도 지수여야 하는 이유

배당을 반영하는 방법은 둘이다.

방식	내용	문제
소급 수정(back-adjust)	과거 가격에 배당 계수를 누적곱. Yahoo Adj Close 방식	새 배당이 생길 때마다 과거 전체가 바뀐다
별도 지수(TRI)	과거 가격은 그대로 두고 수익률 시계열을 따로 적재	표 하나 추가

소급 수정은 PIT을 정면으로 깬다. 2026년에 배당을 한 번 더 하면 2015년 가격이 바뀌고, 어제 돌린 백테스트가 오늘 다른 결과를 낸다. 정정공시를 R2로 그렇게 조심스럽게 다루면서 가격 축에서 같은 문제를 들여올 이유가 없다. TRI를 미리 계산해 `price_daily_tri`에 적재하고, 새 배당은 그 이후 구간만 늘린다.

이중계산 차단

`dividend.kind` 를 반드시 나눈다.

kind	수정주가 반영 여부	TRI 계산
CASH 현금배당	미반영	더한다
STOCK 주식배당	이미 반영됨	더하지 않는다
IN_KIND 현물배당	사안별	평가액으로 더하되 개별 확인

주식배당을 더하면 두 번 센다. 이 한 줄이 배당 축에서 가장 흔한 버그다.

배당 데이터 소스와 날짜 문제

DART 현금·현물배당결정 공시가 1차 소스다. 다만 이 공시는 배당기준일은 주지만 **배당락일은 주지 않는다**. 배당락일은 결제주기 때문에 기준일보다 앞선다.

실용적 처리는 이렇다. 배당락일을 "배당기준일 직전 거래일"로 근사하고 `ex_date_is_approx` 플래그를 세운다. 하루 어긋나도 TRI에 미치는 영향은 작고, 필요하면 나중에 KRX 기준가 조정 흔적으로 확인한다. 금액은 사업보고서 "배당에 관한 사항"으로 교차 검증한다. 공시는 시점을, 사업보고서는 금액을 담당하는 구조다.

2023년 배당절차 개선 이후 배당액을 확정된 뒤에 기준일을 정하는 회사가 늘어 기준일이 3~4월로 이동했다. 12월 결산 일괄 처리를 가정한 로직을 쓰면 최근 연도가 틀어진다.

E7 점검 규칙 보완

제3자배정·일반공모 유상증자는 기준가 조정이 없다. 상장주식수는 변하는데 `price_adj_event` 가 없는 것이 정상이므로, E7의 세 번째 점검("상장주식수가 바뀌었는데 이벤트 없음")이 오탐을 낸다.

조정 없는 주식수 변동을 화이트리스트로 둔다. 제3자배정 유상증자, 일반공모 유상증자, 자사주 소각, 전환사채·신주인수권 행사가 여기 해당한다. 배율은 1이지만 이벤트 자체는 기록한다. 시가총액이 점프하므로 사이즈 팩터에서 정상적인 급변으로 나타나고, 그 사실을 알고 있어야 한다.

검증 방법

개별 종목 TRI를 시가총액 가중으로 합성해 KRX가 발표하는 코스피200 총수익지수와 대조한다. 추적오차가 크면 배당 데이터에 구멍이 있다는 뜻이다. 종목별로 하나씩 맞춰보는 것보다 훨씬 빠르게 누락을 찾는다.

작수 순서

순위	항목
1	<code>dividend</code> 표 신설 + DART 배당결정 공시 수집

순위	항목
2	<code>kind</code> 분리로 이중계산 차단
3	배당금의 수정주가 축 환산 로직
4	<code>price_daily_tri</code> 생성 배치
5	코스피200 TR 대조 검증
6	E7 화이트리스트 보완

백테스트 엔진 계약

용도	쓸 축
주문 체결가·슬리피지	<code>price_daily</code> 원주가
거래 가능 여부	<code>price_daily.volume</code> , <code>no_trade</code> , <code>trade_halt</code>
기술지표·모멘텀	<code>price_daily_adj</code>
수익률·성과	<code>price_daily_tri</code>
사이즈 팩터	<code>price_daily.market_cap</code>
밸류에이션	원주가 × 주식수 ÷ <code>v_fs_std_asof(d)</code>

이 표를 엔진 코드 주석이 아니라 별도 문서로 고정해 두면, 나중에 누가 어느 축을 잘못 쓰는 일이 줄어든다.

E3. 거래재개를 탐지해 `end_date` 를 채운다

지금 DERIVED 판정은 `end_date=NULL` 로만 남긴다. 재개 탐지 규칙이 없어 한 번 정지된 종목은 영구히 정지 상태로 보인다.

정지 구간 이후 첫 `volume > 0` 거래일을 재개일로 보고 `end_date` 에 채운다.
`source='DERIVED'` 를 유지하고, 공식 공시(KIND/DART)가 나중에 오면 덮어쓴다.

우선순위는 KIND·DART가 DERIVED보다 항상 높다. 백테스트 쪽 규칙은 하나 더 필요하다.

`end_date IS NULL` 이면 폐지로 승격하지 말고 **"보유 중이면 청산 불가"** 상태를 유지한다. 지금처럼 마지막 관측일에 종목이 사라지면 "정지되면 즉시 팔 수 있다"는 비현실적 가정이 된다.

E4. 상장폐지를 세 날짜와 한 수익률로 분해한다

`delisting` 이 지금 담는 것은 `delist_date` 하나다. 실제로는 구분되어야 할 사건이 셋이다.

컬럼	의미	모를 때
halt_start_date	정지 개시일(정지 후 폐지인 경우)	NULL
last_trade_date	마지막 거래 관측일	실측값
delist_date	폐지일	NULL + is_approx
delist_return	폐지 수익률	NULL

delist_return의 사유별 기본값은 이렇게 둔다. 합병은 successor 교환비로 승계, 자진상폐는 공개매수가, 부실 폐지는 관례에 따라 -30%, 사유 미상은 NULL이다. **NULL을 -100%로 볼지 유니버스에서 뺀지는 백테스트 엔진의 플래그로 선택하게 하고, 두 결과를 함께 보고한다.**

E5. 종목 계보를 표로 남긴다

delisting.successor 한 컬럼으로는 인적분할(1:N)과 합병(N:1)을 표현할 수 없다.

```
security_lineage(from_code, to_code, event_type, event_date,
exchange_ratio, source)
```

인적분할이면 from_code 하나에 to_code 여러 행, 합병이면 반대다. 지주회사 전환처럼 존속·신설이 섞인 경우도 행으로 표현된다. 이 표가 없으면 분할 전후 종목을 이어 붙인 장기 시계열을 만들 수 없다.

E6. 이벤트를 하나의 로그로 합쳐서 조회한다

지금 이벤트는 price_adj_event · delisting · trade_halt · security_history 네 곳에 흩어져 있다. 백테스트 엔진이 종목마다 네 표를 각각 조회해야 하고, 하나를 빠뜨려도 조용히 지나간다.

기존 표는 그대로 두고 UNION 뷰만 만든다.

```
v_corporate_action(short_code, event_date, event_type, payload, source,
confidence)
```

confidence는 공식 공시면 높고 DERIVED면 낮다. 엔진은 이 뷰 하나만 본다.

E7. 이벤트 전후를 자동 점검한다

이벤트일 ±5거래일 구간에 세 가지를 건다. 결과는 이미 있는 price_quality에 새 유형으로 기록한다.

점검	의심
일간 수익률 절대값 > 50%인데 대응 이벤트 없음	미탐지 이벤트

점검	의심
이벤트가 있는데 가격 점프 없음	오탐
상장주식수가 바뀌었는데 이벤트 없음	미탐지

세 번째가 가장 잘 걸린다. 상장주식수는 KRX가 매일 주으로 변동 자체는 놓칠 수 없고, 변동이 있는데 이벤트가 없으면 무언가 빠진 것이다.

E8. 사각지대를 명시한다

사각지대	이유	처리
2010년 이전 이벤트	수집 하한	해당 기간 백테스트 불가로 명시
원주가·수정주가 한쪽만 있는 구간	비율 산출 불가	<code>confidence='low'</code>
ETF·ETN 분배금	배당과 체계가 다름	별도 과제로 분리
<code>event_type</code> 판별 실패	플래그 부재	가격비 사용 + <code>confidence='low'</code>

사례로 보는 규칙 적용

숫자는 규칙의 작동을 보이기 위한 예시다.

사례 E-A — 자사주 소각, 주식수비를 쓰면 안 되는 경우

항목	이벤트 전	이벤트 후
상장주식수	100,000,000	90,000,000
종가	50,000	50,000
주식수비	—	1.111
실제 가격 조정	—	없음(배율 1)

자사주 소각은 이미 회사가 보유한 주식을 없애는 것이라 권리락이 없다. 주식수만 10% 줄고 가격은 그대로다.

현 규칙대로 주식수비를 우선 적용하면 분봉 역산에서 이벤트 이전 구간의 가격이 1.111배로 부풀려진다. 50,000원이던 봉이 55,550원으로 복원되고, 이벤트일에 -10% 수익률이 인위적으로 생긴다. E1의 `event_type='TREASURY_CANCEL'` 분류가 배율을 1로 고정해 이를 막는다.

다만 E7의 세 번째 점검("상장주식수가 바뀌었는데 이벤트 없음")에는 걸려야 한다. 배율이 1이어도 이벤트 자체는 기록한다.

사례 E-B — 유상증자, 두 비율이 갈리는 경우

항목	값
증자 전 주식수	10,000,000
증자 후 주식수	15,000,000
주식수비	1.500
권리락 기준가 조정 비율	0.900

발행가를 시가보다 할인해 발행하면 희석 효과는 주식수 증가분보다 작다. 주식수는 1.5배인데 가격 조정은 10%에 그친다.

주식수비 1.5를 쓰면 증자 이전 구간 가격이 실제보다 67% 부풀려진다. E10이 `event_type='RIGHTS_OFFERING'` 으로 분류해 KIS `prtt_rate` 기반 가격비 0.9를 쓰게 한다.

사례 E-C — 배당 누락이 누적되는 크기

배당수익률 4%인 종목을 10년 보유했다고 하자.

계산	10년 누적
주가수익률만	기준
총수익률(배당 포함)	기준 대비 약 +48%p

복리로 $1.04^{10} - 1$ 이다. 배당을 빼고 팩터를 평가하면 고배당주가 체계적으로 저평가되고, 배당 팩터 자체는 아예 검증할 수 없다. 표 하나 추가로 풀리는 문제치고는 영향이 크다.

사례 E-D — 정지 후 재개와 정지 후 폐지

두 종목이 같은 날 정지된다.

	종목 X	종목 Y
마지막 거래	2024-05-02	2024-05-02
사건	2024-08-10 재개	2024-11-15 폐지
현 규칙 처리	폐지로 오판(마지막 관측일 다음날)	폐지일이 3.5개월 이르게 기록
백테스트 결과	8월 이후 회복 구간이 통째로 사라짐	5월에 청산 성공으로 처리

두 오류의 방향이 다르다. X는 회복을 놓쳐 성과가 낮게, Y는 실제로는 못 팔았을 가격에 판 것으로 처리돼 성과가 높게 나온다. E3의 재개 탐지가 X를 살리고, E4의 날짜 분해와 `delist_return` 이 Y를 바로 잡는다.

네 사례를 한 줄로

사례	현 규칙의 결과	적용 규칙	교정 후
E-A 자사주 소각	과거 가격 +11% 부풀림	E1	배율 1, 이벤트만 기록
E-B 유상증자	과거 가격 +67% 부풀림	E1	가격비 0.9 적용
E-C 배당 누락	10년 -48%p 과소	E2	총수익률 산출
E-D 정지·재개	회복 누락 / 청산 과대	E3·E4	구간 유지, 폐지 수익률 반영

착수 순서

순위	항목	규모	이유
1	E2 배당 표	표 하나 + DART 수집	공백이 가장 크고 대안이 없음
2	E1 <code>event_type</code> 분류	컬럼 하나 + 분기 로직	이미 있는 <code>flag_class</code> 로 대부분 해결
3	E3 재개 탐지	쿼리 하나	<code>trade_halt</code> 를 실제로 돌리는 것이 선행
4	E4 폐지 3날짜 분해	컬럼 셋	Q4 답변과 직결
5	E7 자동 점검	배치	1~4의 결과를 검증
6	E5 계보 표	표 하나	장기 시계열이 필요해지면
7	E6 통합 뷰	뷰 하나	위가 다 끝난 뒤

E1과 E3은 이미 수집 중인 데이터(`flag_class` , `volume`)로 폴리므로 새 수집이 필요 없다. E2만 새 소스가 붙는다.

애널리스트 추정치(IBES) 추가안

WRDS 구독에 LSEG IBES가 포함돼 있다면 지금 없는 팩터 계열 하나가 통째로 열린다. 추가 구독 없이 붙는 데이터이므로 착수 비용은 연결과 정제뿐이다.

무엇이 열리는가

팩터 계열	필요한 IBES 항목	비고
이익 수정(revision)	컨센서스 EPS의 시계열 변화	국내외 모두 강건한 편
어닝 서프라이즈·PEAD	컨센서스 대비 실제치	발표일 정합이 관건
추정치 분산(dispersion)	애널리스트별 추정치 표준편차	불확실성 대용치
커버리지	추정 애널리스트 수	소형주 필터로도 쓰임
발표일	ANNDATS_ACT	Compustat rdq 대체·교차검증

마지막 줄이 부수 효과다. P1에서 `rdq` 로 발표 시차를 막자고 했는데, IBES 실적 발표일이 그 값을 교차 검증해 준다.

I1. 조정판이 아니라 미조정판을 쓴다

이 문서에서 이미 두 번 나온 문제가 세 번째로 나온다. IBES 요약·상세 파일의 추정치는 최신 분할 기준으로 소급 조정돼 있고 센트 단위로 반올림된다. 분할 배수가 크거나 주가가 낮은 종목에서는 조정된 EPS가 0으로 반올림되거나 부호가 뒤집힌다.

처리는 정해져 있다. **미조정 파일(`detu`·`actu`)을 쓰고 CRSP 조정계수(`cfacshr`)로 직접 환산한다.** IBES가 미조정 데이터를 주는 항목은 EPS뿐이므로, 다른 측정치를 쓸 때는 이 한계를 안고 간다.

앞서 정한 원칙과 같은 모양이다. 원자료를 받아 우리가 조정하고, 벤더가 미리 조정해 준 값은 검증용으로만 쓴다.

I2. 추정치와 실적을 같은 주식 기준에 올린다

추정일과 실적 발표일 사이에 분할이 있으면 두 값의 주식수 기준이 다르다. WRDS 문서가 드는 예가 아 마존이다. 1998-06-02에 2:1, 1999-01-26 실적 발표 전에 3:1 분할이 있어 추정치와 실적의 누적조정계 수 비율이 6배가 된다. 티커와 기간만 맞춰 단순 병합하면 서프라이즈가 6배로 계산된다.

미조정 추정치에 `CumAdj_est` / `CumAdj_rep` 비율을 곱해 같은 주당 기준으로 올린 뒤 비교한다.

E1에서 배율의 출처를 이벤트가 정하게 한 것과 같은 논리다. 여기서는 CRSP 조정계수가 그 역할을 한다.

I3. 시점은 수록일 기준으로 자른다

날짜 필드가 둘이다.

필드	의미	PIT 용도
ANNDATS	애널리스트가 추정치를 낸 날	참고
ACTDATS	IBES가 그 추정치를 수록한 날	기준일 비교에 사용
STATPERS	요약 파일의 월별 집계 시점	요약 파일의 as-of

기준일 d에서 쓸 수 있는 추정치는 `ACTDATS < d` 인 것뿐이다. R2의 부등호 규칙을 그대로 적용한다. 애널리스트가 냈지만 아직 DB에 들어오지 않은 값을 쓰면 록어헤드다.

I4. 연결은 ICLINK으로 한다

IBES는 자체 `TICKER` 로 키를 잡는데 이것은 거래소 티커가 아니다. WRDS가 제공하는 ICLINK 매크로가 IBES TICKER와 CRSP PERMNO를 이어 주고, 15,187개 고유 링크를 만든다. 점수는 0(최상)부터 6까지이며 CUSIP 일치가 티커 일치보다 높게 평가되고 회사명 철자 거리로 감점한다.

실무 기준은 **score 0~2만 채택**하고 한 티커가 여러 permno에 붙는 경우는 제외하는 것이다.

여기서 중요한 점이 하나 있다. **ICLINK은 CCM과 별개 경로다**. CCM 미구독 때문에 막혀 있던 D3과 달리, IBES-CRSP 연결은 지금 구독으로 바로 된다.

I5. 미국판과 국제판을 섞지 않는다

`epsus` 와 `epsint` 는 통화와 측정치 정의가 다르므로 정렬 없이 합치면 안 된다.

다만 국제판이 국내 측에 열어 주는 가능성이 있다. 국내 컨센서스는 지금 어느 측에도 없고, DART로는 만들 수 없다. IBES 국제판의 한국 종목 커버리지를 확인해 볼 값어치가 있다. 커버리지가 쓸 만하면 국내 팩터에도 추정치 계열이 생기고, 부족하면 FnGuide·연합인포맥스 같은 국내 벤더가 대안이다.

국제판(epsint) — 한국 커버리지 확인과 연결 설계

IBES 국제판은 미국 외 상장기업을 담고 한국도 대상에 들어간다. 다만 **커버리지 깊이는 계정마다 다르므로 직접 재야 한다**. 여기서 원격으로 확인할 수 없으니 확인 절차와 그 결과에 따른 설계를 함께 둔다.

1단계 — 커버리지 측정

`ibes.idsum` 에는 두 자리 국가코드가 `COUNTRY` 컬럼으로 들어 있다. 세 가지를 순서대로 켜다.

질문	확인 방법
한국 기업이 몇 개인가	<code>ibes.idsum</code> 에서 <code>COUNTRY</code> 한국 코드로 집계
언제부터 있는가	<code>ibes.statsum_epsint</code> 에서 그 티커들의 <code>STATPERS</code> 최소·최대

질문	확인 방법
얼마나 깊은가	연도별 커버 종목 수와 종목당 애널리스트 수 중앙값

세 번째가 판단 기준이다. 대형주 200종목만 커버하면 KOSPI200 안에서만 쓸 수 있고, 코스닥까지 내려가면 전종목 팩터가 된다.

2단계 — 연결. ICLINK은 못 쓴다

ICLINK은 IBES TICKER를 CRSP PERMNO에 있는 매크로이고 한국 종목에는 permno가 없다. 국내 측은 별도 경로를 만들어야 한다.

국제판에는 함정이 하나 더 있다. `ibes.id`의 `CUSIP` 컬럼은 미국 기업에서만 CUSIP이고, **비미국 기업에서는 SEDOL이 들어간다.** 컬럼 이름만 보고 CUSIP으로 다루면 전부 실패한다.

연결은 3단 풀백으로 설계한다.

순 위	키	국내 대응	비고
1	OFTIC (거래소 티커) + COUNTRY	<code>security.short_code</code> 6자리	한국은 티커가 곧 종목코드라 적중률이 높을 가능성
2	SEDOL(<code>CUSIP</code> 컬럼)	별도 매핑 필요	ISIN↔SEDOL 대응표가 있어야 함
3	회사명 정규화 대조	<code>company.corp_name_eng</code>	최후 수단, 사람 확인

1번이 통하면 국내 연결은 사실상 공짜다. 확인 즉시 판가를 낸다. 결과는 D2에서 만들기로 한 식별자 이력 표에 `IBES_TICKER` 타입으로 넣으면 되고, 별도 표가 필요 없다.

3단계 — 국제판 고유 주의점

항목	내용
통화	추정치가 현지 통화(한국은 원)다. 미국판과 절대 섞지 않는다
회계기준	IFRS 전환기에는 기준이 다른 추정치가 섞인다. 요약 파일의 2차 평균이 소수 기준을 담으므로 어느 쪽을 쓰는지 명시
캐나다 중복	<code>ibes.id</code> 는 캐나다 기업을 <code>USFIRM=1</code> 과 <code>0</code> 두 행으로 담는다. 한국과 무관하지만 국제판 전체 집계 시 중복
미조정판	미조정 파일이 국제판에도 있는지 확인 필요. 없으면 I1을 적용할 수 없고 조정판의 반올림 문제를 안고 가야 함

항목	내용
결산월	12월 결산이 아닌 종목의 기간 라벨 정합

네 번째가 이 절에서 가장 중요한 확인 항목이다. 한국은 액면분할이 잦고 주가 수준이 높아, 조정판만 있다면 반올림 손실이 미국보다 클 수 있다.

4단계 — 커버리지가 부족할 때

대안	성격
에프앤가이드 컨센서스	국내 표준. 커버리지 가장 넓음
연합인포맥스	단말·데이터 제공
와이즈리포트	리포트 원문 기반
증권사 리포트 직접 파싱	비용은 낮지만 정합성 관리 부담이 큼

국내 벤더는 상업 이용 라이선스가 별도이므로, 앞서 정리한 학술·상업 이원화 판단과 같은 선상에서 본다.

판단 기준

측정 결과	결론
코스닥 포함 1,000종목 이상, 2010년 이후 연속	국제판으로 국내 추정치 측 확정
대형주 중심 수백 종목	KOSPI200 유니버스 전략에만 사용, 소형주는 결측 처리
커버리지 얇거나 최근만	국내 벤더 검토로 전환

어느 쪽이든 **결측을 0으로 채우지 않는다**. 커버리지가 없는 종목은 추정치 팩터에서 빠지는 것이지 추정치가 0인 것이 아니다.

I6. 사각지대

사각지대	내용
소형주 커버리지 없음	추정 애널리스트가 0인 종목은 팩터 자체가 결측. 결측을 0으로 채우면 안 됨
커버리지 중단	애널리스트가 커버를 그만두면 마지막 추정치가 남아 오래된 값이 최신처럼 보임. 유효기간 규칙 필요

사각지대	내용
과거 데이터 재작성	IBES 빈티지 간 실적치가 바뀐 사례가 보고됨. 정정 문제와 같은 구조
EPS 외 측정치	미조정판이 없어 I1을 적용할 수 없음

사례 — 분할이 낀 어닝 서프라이즈

단계	값
컨센서스 EPS(추정 시점 기준)	6.00
추정일과 발표일 사이 분할	2:1 후 3:1, 누적 6배
실제 EPS(발표 시점 기준)	1.10
그대로 비교한 서프라이즈	-81.7%
같은 기준으로 올린 뒤	$6.00 \div 6 = 1.00$ vs 1.10 → +10%

부호가 뒤집힌다. 큰 폭의 어닝 쇼크로 보이던 것이 실제로는 10% 상회다. 서프라이즈를 정렬 없이 계산하면 분할이 잦은 성장주에서 이런 오류가 체계적으로 쌓인다.

착수 순서

순위	항목
1	구독 범위 확인 — IBES US·International 각각
2	ICLINK으로 IBES TICKER ↔ permno 연결, score 0~2
3	미조정 <code>detu</code> · <code>actu</code> 적재 + <code>cfacshr</code> 환산
4	<code>ACTDATS</code> 기준 as-of 뷰
5	컨센서스·서프라이즈·분산 파생 계산
6	국제판 한국 종목 커버리지 점검

비용이 드는 단계는 없다. 1번의 결과에 따라 범위만 달라진다.

WRDS로 어디까지 해결되는가

기술적으로는 네 문제 모두 WRDS 안에 답이 있다. 다만 "WRDS에 있다"와 "우리가 쓸 수 있다"는 다르므로 세 층으로 나눠야 판단이 선다.

문제	WRDS 해결 수단	층
2024년 시세 단절	dsf_v2 전환	층1 — 지금 구독, 코드만, 비용 0
회사-종목 연결 43%	sec_idhist 개선 / CCM 구독	층1 + 층2
재무 PIT	Compustat Snapshot(1986~)	층2 — 추가 구독
분 단위 시세	TAQ	층2 — 추가 구독

층2에서 짚을 점

"해외 분봉은 소스 없음"은 정확하지 않다. TAQ는 WRDS의 주력 상품이고 Monthly TAQ가 1993-2014, Daily TAQ가 2003년 9월부터 현재까지 마이크로초 단위로 제공된다([WRDS TAQ](#)). 정확한 표현은 "미구독"이다. 다만 세 가지 각오가 필요하다.

- 틱 데이터라 1분봉으로 직접 집계해야 한다
- 용량이 크다 — 2004년 한 해가 225GB다
- TAQ는 13개 거래소·우선주·워런트까지 담고 CRSP는 5개 거래소 보통주 중심이라 커버리지가 달라 별도 링크 작업이 필요하다(WRDS가 TAQ-CRSP 링크 파일과 Intraday Indicators를 제공한다)

PIT은 1986년이 하한이다. comp.funda 가 1950년부터 있다는 것과 1950년 값을 PIT으로 쓸 수 있다는 것은 전혀 다르다.

층3 — WRDS가 해결하지 못하는 것

1. **라이선스.** 대학 WRDS 구독은 학술 연구·교육용이다. 이 DB를 상업적 백테스트와 라이브트레이딩에 쓴다면 계약 위반 소지가 있고, 데이터를 자체 DB에 적재·보관하는 지금의 아키텍처는 특히 그렇다. 코드나 예산으로 풀리는 문제가 아니라 먼저 확정해야 할 전제다. 물어야 할 질문은 "한양대가 CCM을 구독하는가"가 아니라 "이 용도에 대학 구독을 쓸 수 있는가"다.
2. **실시간.** WRDS는 배치 연구 플랫폼이다. Compustat은 현재 시점에서 두 달가량 지연되고 CRSP는 월 단위 갱신이다. 라이브트레이딩용 가격은 국내를 KIS로 붙이듯 해외도 브로커 API가 답이다.
3. **설계 판단.** 폐지 수익률 처리 규칙, 유니버스 정의, 매칭 실패군의 편향 검증은 데이터가 풀어주지 않는다. Q4가 여기 해당한다.

상업 전환 대비

현재는 학술 공동연구다. 상업용 데이터를 미리 살 이유는 없고, 전환 시점에 DB를 통째로 버리지 않아도 되게 설계를 조정하는 것이 지금 할 일이다. 비용은 거의 0이다.

전환할 때 가장 먼저 깨지는 것 셋

라이선스 태깅이 없다. `us_price_daily`·`us_financial_*` 에 "이 행이 어느 라이선스로 받은 것인가"를 기록하는 컬럼이 없다. 상업 전환 시 학술 라이선스로 받은 행만 골라 삭제·교체할 수 없으면 DB 전체를 폐기해야 한다. 컬럼 둘(`source` , `license_tier`) 추가로 끝나고, 지금은 33행이라 비용이 0이다.

permno 를 PK로 잡았다. `us_security` 의 PK가 CRSP 고유번호다. CRSP를 떠나는 순간 PK가 사라진다. 국내 `security` 는 내부 `security_id` 를 PK로 두고 `short_code`·`std_code` 를 속성으로 둔 올바른 구조인데 해외만 반대로 갔다. 해외도 내부 ID를 PK로 하고 `permno`·`gvkey`·티커·CUSIP을 `us_security_identifier(type, value, valid_from, valid_to)` 로 빼면 벤더 교체가 매핑 추가로 끝난다. Q2 매칭 문제도 같은 구조로 풀린다.

CUSIP 자체가 유료 식별자다. CUSIP은 CUSIP Global Services가 라이선스하는 지적재산이고, WRDS 학술 구독 안에서 쓰는 것과 상업 시스템에 저장·활용하는 것은 계약이 다르다. 해외 연결 설계 전체가 CUSIP8에 얹혀 있으므로 상업 경로에서는 FIGI(OpenFIGI, 무료·개방)나 CIK(SEC, 무료)를 1차 키로 두고 CUSIP을 보조로 내리는 편이 안전하다.

설계 원칙 다섯

원칙	지금 할 일
식별자 중립	내부 <code>security_id</code> PK + 외부 식별자 이력 표 분리
출처·라이선스 태깅	모든 사실 테이블에 <code>source</code> , <code>license_tier</code> , <code>ingested_at</code>
소스 어댑터 분리	내부 표준 스키마 + 벤더별 매퍼를 한 겹 더 (지금은 WRDS 원본 컬럼에 강결합)
원데이터/파생물 분리	시그널·팩터·백테스트 결과는 별도 스키마
회귀 검증 도구	같은 기간·종목을 두 소스로 적재해 대조

마지막 항목이 이 팀의 숨은 자산이다. `price_quality` 의 B/C/D/F/J/V 유형 분류는 원래 소스 검증용이지만 벤더 교체 검증 도구로 그대로 쓰인다. 해외에 같은 구조를 이식해 두면 전환 리스크가 크게 줄어든다.

소스 대안 — 미국 재무제표(PIT)

후보	커버리지	성격
SEC EDGAR XBRL	2009~	무료·재배포 자유. 접수번호 단위 원본 = 진짜 PIT. 표준화는 직접

후보	커버리지	성격
Sharadar SF1	1997.12~	16,000+ 기업(폐지 포함), 150개 지표. AR 차원 (ARQ/ARY/ART)이 as-reported PIT, MR 차원이 정정 반영본. datekey 가 그 값이 이용 가능해진 날을 표시. 99% 생존편향 제거
Compustat Snapshot 상업	1986~	S&P 직접 계약. 최고 깊이, 최고 비용
FactSet / LSEG	—	기관급, 별도 협상

EDGAR + Sharadar 조합을 권한다. Sharadar는 학술 Compustat이 주던 것(표준화·PIT·폐지종목)을 상업 라이선스로 거의 그대로 대체하면서 가격대가 완전히 다르다. AR 차원을 고르고 datekey <= 기준일 로 거르면 PIT 조인이 사실상 해결된다. 1997년 이전이 필요할 때만 Compustat을 논의하면 된다.

소스 대안 — 미국 시세

축	후보	성격
일별	Sharadar SEP	폐지종목 포함 EOD, 무조정/분할조정/분할+배당+분사조정 3종. SF1과 식별자 통일
일별	Norgate Data	폐지종목 포함, 백테스트 커뮤니티 표준, 저가
일별	Polygon.io · EODHD · Tiingo	API 중심, 상업 이용 명시, 실시간 연계 유리
일별	CRSP 상업	폐지 수익률 정본. 품질 최고, 비용 최고
분봉	Algoseek	1분봉 2007~, 상업 라이선스
분봉	Polygon.io	분봉·틱, 라이브 피드와 같은 벤더로 묶임
분봉	Databento	틱·MBO, 집행 연구용

식별자 통일 이점이 커서 Sharadar SEP+SF1 묶음이 관리상 가장 단순하다. CRSP의 폐지 수익률 정밀도가 꼭 필요한 장기 팩터 검증만 학술 트랙에 남기는 이원화가 현실적이다. 분봉은 상업 전환 시 TAQ보다 Polygon·Algoseek이 실용적이다 — 이미 1분봉으로 정리돼 있어 틱 집계 부담이 없다.

국내

DART OpenAPI는 공공데이터라 상업 이용 제약이 적고, KRX·KIS는 각각 이용약관 확인이 필요하다. 전환 리스크는 낮다. 유료 대안이 필요해지면 에프앤가이드 DataGuide, 코스콤, 딥서치, 연합인포맥스가 후보다.

권고 조합

티어	구성	용도
A (지금)	WRDS 학술 — CIZ 전환 + <code>sec_idhist</code> 매칭 + 구독 확장 협의	공동연구, 논문, 강의
B (전환 1단계)	EDGAR + Sharadar(SF1+SEP) + 국내 현행	상업 백테스트. 비용 최소, 라이선스 명확
C (운용 본격화)	B + Polygon/Algoseek + 필요 시 CRSP·Compustat 상업	라이브트레이딩

A에서 B로 갈 때 연구 코드는 대부분 살아남는다. 재무가 이미 EAV 구조라 Sharadar의 150개 지표도 같은 표에 들어가고, EDGAR는 국내 DART XBRL 파이프라인과 구조가 같다.

실행 로드맵

아래 작업 중 "전환을 위해서만" 하는 것은 라이선스 태깅 하나뿐이다. 나머지는 학술 연구 품질 자체를 올리는 작업이라 전환이 무산돼도 손해가 없다.

이번 분기 — 비용 0

- ☐ CIZ 전환 (`dsf_v2`, `stksecurityinfohist`) — 재무제표 EAV 수집 착수 전에
- ☐ 해외 PK를 내부 ID로 교체, 식별자 이력 표 신설
- ☐ 모든 사실 테이블에 `source`·`license_tier`·`ingested_at` 추가
- ☐ 해외에 상호 대사 로직 이식
- ☐ KIS 분봉을 1년 롤링에서 영구 축적으로 전환 — 하루 늦으면 하루치가 영구 소실
- ☐ `rdq` 기준 데이터 사용 규칙 적용
- ☐ 교집합 유니버스로 매칭률 재측정, 실패군 분포 확인

다음 분기 — 비용 0

- ☐ SEC EDGAR XBRL 파이프라인 구축 → 2009~ PIT 확보. 학술 트랙에서도 Compustat 정정 문제를 곧바로 해결하므로 전환용이 아니라 지금 필요한 작업이다
- ☐ Sharadar 무료 샘플(DJIA 30종목)로 어댑터 시험 적재 → 내부 스키마 매핑 검증
- ☐ `delisting` 에 `last_trade_date` 분리, 폐지 사유 소스 확보
- ☐ 폐지 종목 포함/제외 두 버전 백테스트로 편향 크기 측정

결정이 필요한 것

1. 이 DB는 학술 연구용인가, 상업 운용용인가. 학술이면 한양대 구독 확장 협의가 전부이고 네 문제가 모두 닫힌다. 상업이면 대학 경로를 전제한 설계를 재검토해야 한다.
2. 국내 재무제표 전종목 backfill(약 32만 쿼리, 16.8일) 실행 시점
3. 표준계정 7개 유지 여부와 축소 경위 문서화

부록 — 제안 요약

이 문서에서 원안에 대해 제안한 항목 전부다. 25건이며 이 중 21건은 새 데이터 소스나 추가 구독 없이 끝난다.

문제점 한눈에

심각도는 백테스트 결과를 얼마나 왜곡하는지로 매겼다. 방향이 있는 항목은 성과가 실제보다 높게 나오는지 낮게 나오는지를 적었다.

문제	백테스트 영향	방향	개선안	심각도
배당 축이 없음	총수익 자체를 못 잴. 배당수익률 4% 종목 10년이면 48%p	과소	E2	높음
as-of 조회 규칙 없음	정정보문을 보관해도 PIT이 집행되지 않음	과대	R2	높음
해외 시세 2024-12-31 단절	최근 2년 백테스트 불가	—	D1	높음
trade_halt 0행, 재개 탐지 없음	정지 구간을 청산 가능으로 처리	과대	E3 · O3	높음
폐지 수익률 없음	폐지 종목을 마지막 종가에 매도 처리	과대	E4	높음
재무 backfill 미실행	재무 팩터를 아직 쓸 수 없음	—	O2	높음
주식수비를 모든 이벤트에 우선 적용	자사주 소각·유상증자 구간 가격 왜곡	양방향	E1	중간
회사-종목 매칭 43~48%	해외 유니버스 자체를 신뢰할 수 없음	과대 추정	D3	중간
비교표시 재작성 미탐지	정정공시 없이 바뀐 과거 수치가 들어감	과대	R5	중간
라이선스 태깅 없음	상업 전환 시 DB 전체 폐기 위험	—	D4	중간
permno 를 PK로 사용	벤더 교체 시 PK 소멸	—	D2	중간
분봉 1년 롤링	하루 지날 때마다 하루치 영구 소실	—	O1	중간(시급)

문제	백테스트 영향	방향	개선안	심각도
정정 접두사 일괄 처리	첨부정정까지 정정으로 집계	—	R1	낮음
표준계정 7개로 축소, 경위 미기록	팩터 커버리지 제한	—	O4	낮음
이벤트가 표 4곳에 분산	조회 누락 시 조용히 지나감	—	E6	낮음
애널리스트 추정치 축 없음	수정·서프라이즈·분산 팩터를 만들 수 없음	—	I1~I6	중간

높음 여섯 중 넷(배당·as-of·재개·폐지수익률)이 성과를 실제보다 높게 만드는 방향이다. 지금 상태로 백테스트를 돌리면 결과가 좋게 나올 가능성이 크고, 그게 위험한 이유다.

A. 해외 데이터 기반

ID	원안의 현 상태	제안	비용
D1	crsp.dsf (SIZ) 사용, 2024-12-31 단절	crsp.dsf_v2 · stksecurityinfohist 로 전환	코드만
D2	us_security PK = permno	내부 security_id PK + us_security_identifier 이력 표	스키마, 33행뿐
D3	CUSIP8 단일 매칭 42.9~48.4%	sec_idhist 시점별 매칭 + 교집합 유니버스로 재 측정	쿼리
D4	출처·라이선스 컬럼 없음	모든 사실 테이블에 source · license_tier · ingested_at	컬럼 3개
D5	상호 대사가 국내 일별시세 전용	해외에 같은 대조 로직 이식	코드 이식

B. 재무 시점 재현(PIT)

ID	원안의 현 상태	제안	비용
P1	datadate 기준 사용 추정	rdq (실적발표일) 이후 데이터만 사용	규칙
P2	해외 PIT 불가로 규정	SEC EDGAR XBRL로 2009~ 자체 PIT 구축	파이프라인, 무료
R1	대괄호 유무로 is_correction	correction_tag 에 접두사 원문 보관	컬럼 1개
R2	최신본 뷰만 존재	v_fs_std_asof(d) , 부등호는 <	뷰 1개

ID	원안의 현 상태	제안	비용
R3	소급 정정 회수 경로 없음	매일 7일 창 폴링 + 주 1회 30일 창	배치
R4	수치 변경 판정 없음	표준계정 7개만 대조해 fs_changed	쿼리
R5	비교표시 재작성 미탐지	dart_filing_period 대조 → restatement_flag 기록만	쿼리 + 표 1개
R6	XBRL 복구 대상 미정	기재정정 AND fs_changed=true 로 한정	필터
R7	사각지대 미문서화	미탐지 케이스 표로 명시, 결과에 첨부	문서

C. 코퍼릿 액션

ID	원안의 현 상태	제안	비용
E1	주식수비 항상 우선	event_type 이 배울 방식을 결정, 미상이면 가격비	컬럼 1개
E2	배당 데이터 없음	dividend 표 신설, DART 배당결정 공시 수집	표 2개 + 새 소스
E3	end_date=NULL 고정	정지 후 첫 volume>0 을 재개일로, 공식 공시 우선	쿼리
E4	delist_date 하나	halt_start_date · last_trade_date · delist_date · delist_return 분해	컬럼 3개
E5	delisting.successor 한 컬럼	security_lineage 표로 1:N·N:1 표현	표 1개
E6	이벤트가 표 4곳에 분산	v_corporate_action UNION 뷰	뷰 1개
E7	이벤트 전후 검증 없음	±5거래일 3종 점검, price_quality 에 기록	배치
E8	사각지대 미문서화	2010년 이전·ETF 분배금 등 표로 명시	문서

C-2. 애널리스트 추정치(IBES)

ID	원안의 현 상태	제안	비용
I1	추정치 축 자체가 없음	미조정 detu · actu 적재 + cfacshr 로 직접 환산	적재, 추가 구독 없음

ID	원안의 현 상태	제안	비용
I2	—	추정치·실적을 누적조정계수 비율로 같은 주당 기준에 정렬	계산
I3	—	ACTDATS < d 기준 as-of 뷰(R2와 동일 규칙)	뷰 1개
I4	—	ICLINK으로 IBES TICKER ↔ permno, score 0~2 만	매크로
I5	국내 컨센서스 없음	IBES 국제판의 한국 커버리지 점검, 부족하면 국내 벤더	조사
I6	—	커버리지 없음·중단·빈티지 재작성을 사각지대 표에 명시	문서

D. 운영과 전환 대비

ID	원안의 현 상태	제안	비용
O1	분봉 1년 롤링	영구 축적으로 전환 — 하루 늦으면 하루치 영구 소실	설정
O2	재무 backfill 미실행	3,443개사·약 32만 콜 실행	16.8일
O3	trade_halt 0행	DERIVED 상시 탐지를 전종목에서 가동	코드 확장
O4	표준계정 20개→7개 축소 미문서화	축소 경위와 잔여 계획 기록	문서
O5	생존편향 크기 미측정	폐지 포함·제외 두 버전 백테스트로 CAGR 차이 제시	실행
T1	상업 전환 시 CUSIP 의존	FIGI·CIK를 1차 키로, CUSIP은 보조	설계
T2	원데이터·파생물 혼재	시그널·팩터·백테스트 결과를 별도 스키마로	스키마
T3	소스 교체 검증 도구 없음	두 소스 동시 적재 후 대조(price_quality 재사용)	코드

E. 우선순위

구간	항목	비고
2주 내, 비용 0	D1·D4·R1·R2·R7·O1	R2 하나로 PIT이 실제로 집행되기 시작

구간	항목	비고
1개월	D2 · D3 · E1 · E3 · R3 · R4	이미 수집 중인 데이터로 해결
분기 내	P1 · P2 · E2 · E4 · R5 · R6 · O5	E2만 새 소스가 붙음
조건부	O2 · O3 · E5 · E6 · E7 · T1~T3	용도 확정 후 판단

앞의 두 구간 12건은 전부 기존 구독과 기존 데이터 안에서 끝난다. 새 비용이 드는 것은 E2의 DART 배당 수집과, 선택 사항인 CCM·Compustat Snapshot·TAQ 구독뿐이다.

원자료

- 내부 이슈 「국내·해외 주식 데이터 아키텍처」 (2026.09.17)
- [CRSP CIZ 전환 공지](#) · [WRDS CRSP 변경 안내](#)
- [WRDS — Compustat 역사적 식별자로 CRSP 매칭](#)
- [WRDS NYSE TAQ 커버리지](#)
- [Sharadar 펀더멘털 문서](#)
- [Lyle & Yohn, Re-Standardized Financial Statement Data](#)