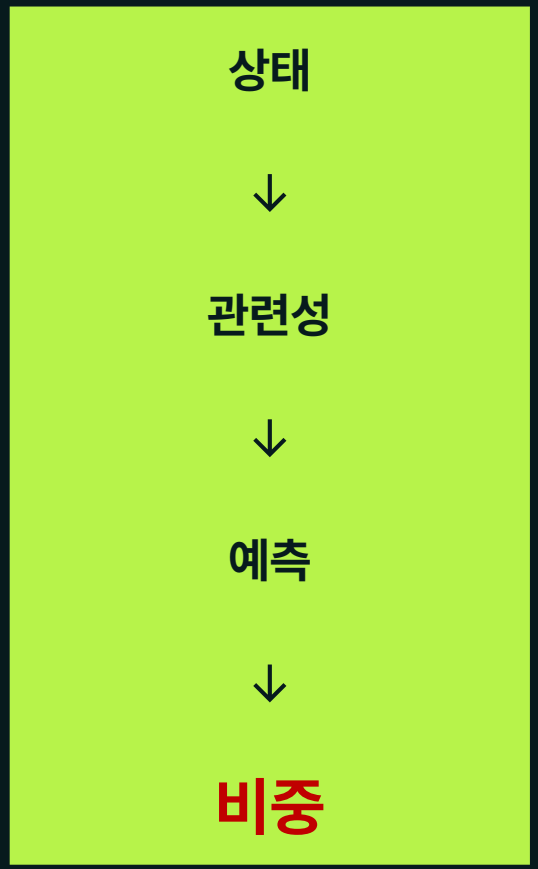
국면 기반 TDF
relevance 연속 배분

국면을 판정하지 않고, 지금과 닮은 과거로 직접 예측한다



국면 기반 TDF 시리즈 · B

국면의 이름을 붙이지 않고 비중을 연속으로 정하는 과정을 따라갑니다

01	기본 개념	**판정 없는 국면** 세 가지 국면 표현 · 마할라노비스 거리 · 상태벡터
02	relevance	**유사도 + 정보량** 정의와 정리형 · 부분 표본 · 조건부 예측 · fit
03	비중으로 옮기기	**다섯 단계 실행** 글라이드 앵커 · 수축 · 밴드 · 평활과 무거래 구간
04	실증과 한계	**실데이터와 가상 세계** Vanguard 백테스트 · 세 세계 비교 · 주의점

상태변수(x) → 관련성(r) → 조건부 예측(μ, Σ) → 비중(w)

01

기본 개념

국면에 이름을 붙이지 않고, 지금과 닮은 과거를 찾아 그 뒤에 일어난 일을 본다

국면을 표현하는 방식은 라벨, 확률, 점수의 세 가지입니다

Kritzman과 State Street 연구진의 흐름 — 임계값 판정에서 relevance로

접근	국면 표현	예측 방법	대표 연구
임계값 판정	0/1 라벨	라벨별 평균	Kritzman (2017)
HMM	K개 상태의 확률	상태별 분포 혼합	Kritzman 외 (2012)
relevance	시점별 연속 점수	관련성 가중평균	Czasonis 외 (2023)

Kritzman·Kulasekaran·Turkington(2023): 한 시점이 여러 국면에 동시에 정보를 줄 수 있습니다.

국면을 고르지 않으면 경계에서 왕복할 일도 없습니다.

닮음은 변수 간 상관까지 고려한 마할라노비스 거리로 잽니다

Ω = 상태변수의 공분산 행렬 — 함께 움직이는 변수의 중복을 덜어 낸다

두 시점 사이의 거리

$$\mathrm{dist}(x_i, x_t) = (x_i - x_t)^\top \Omega^{-1} (x_i - x_t)$$

상태벡터 예 — 터뷸런스 분해 · 흡수비율 변화 · 거품 단계(warp)

$$x_t = \left[\mathrm{Turb}_t^{mag},\ \mathrm{Turb}_t^{corr},\ \Delta AR_t,\ \mathrm{Warp}_t \right]$$

터뷸런스를 크기와 상관 성분으로 나누면 '무엇이 평소와 다른가'가 드러납니다.

이 덱의 가상 실험은 터뷸런스 z · ΔAR · 3개월 모멘텀 세 변수를 씁니다.

02

relevance

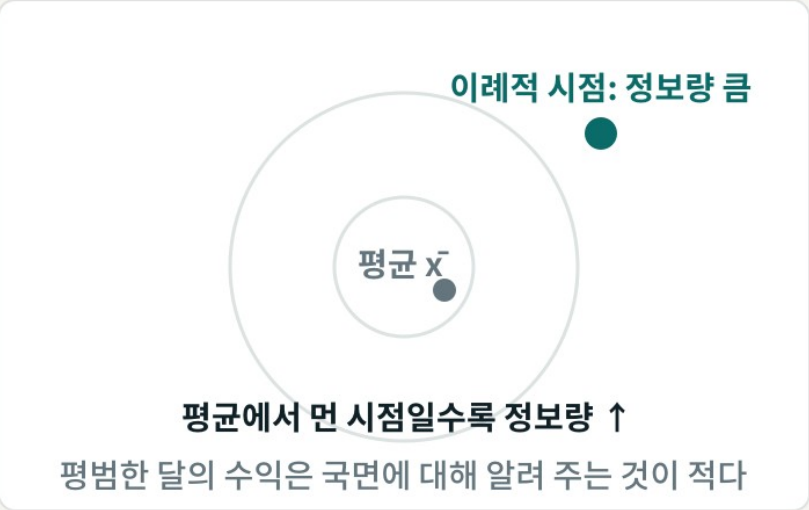
유사도와 정보량을 더한 점수로 과거의 각 시점에 가중치를 준다

relevance는 지금과 닮았을수록, 평소와 다를수록 높습니다

Czasonis·Kritzman·Turkington — 정규분포 우도와 정보 이론에서 유도한 점수

relevance = 유사도(지금과 닮았는가) + 정보량(평소와 다른 시점인가)





평범한 달은 국면에 대해 알려 주는 것이 적어 가중치가 작습니다.

지금과 닮은 이례적 시점이 예측을 이끕니다.

유사도와 정보량을 더하면 두 편차 벡터의 내적 하나로 정리됩니다

과거와 현재를 각각 평균에서 잰 편차로 바꾸면 이차항이 서로 상쇄된다

정의 — 유사도(거리의 음수) + 두 시점 정보량의 평균

$$r_{it} = \underbrace{-\tfrac{1}{2}(x_i - x_t)^\top \Omega^{-1}(x_i - x_t)}_{\text{similarity}} + \underbrace{\tfrac{1}{2}\left[(x_i - \bar{x})^\top \Omega^{-1}(x_i - \bar{x}) + (x_t - \bar{x})^\top \Omega^{-1}(x_t - \bar{x})\right]}_{\text{informativeness}}$$

정리형 — 이 시리즈의 계산식

$$r_{it} = (x_i - \bar{x})^\top \Omega^{-1} (x_t - \bar{x})$$

현재와 같은 방향으로 평균에서 멀리 떨어진 과거가 가장 높은 점수를 받습니다.

평균 근처의 평범한 달은 현재와 가까워도 점수가 낮습니다.

relevance 상위 25%만 남겨 예측에 씁니다

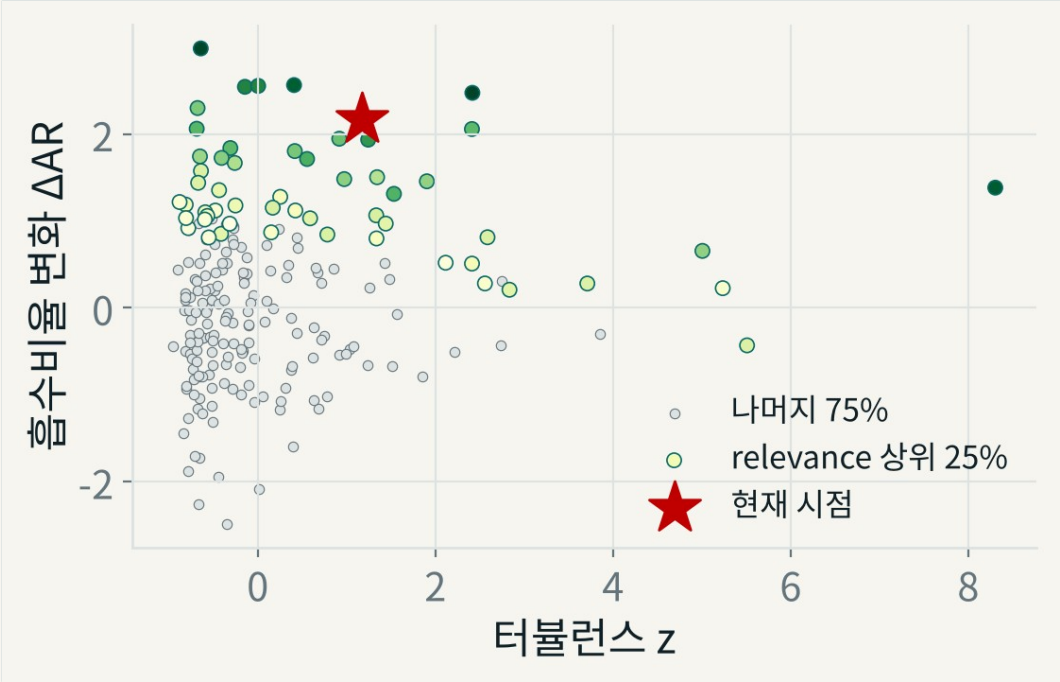
세계 A의 가상 경로 한 시점(취약 확률이 가장 높았던 달) · 세 상태변수 중 두 개만 그림

부분 표본 회귀

Partial Sample

- 상위 q%만 남김
- q는 홀드아웃으로

희석을 막는다



관련 없는 75%를 버려야 '지금 같은 때'의 결과가 평균에 묻히지 않습니다.

남긴 표본의 relevance로 가중한 평균과 공분산이 조건부 예측입니다

y(i+1) = 과거 시점 i 다음 달의 주식·채권 수익 — 시점 t에 이미 알려진 값만 쓴다

부분 표본과 가중치 — 이 시리즈의 단순화(최솟값 기준 이동)

$$\mathcal{S}_t = \{\, i : \; r_{it} \geq r_q^* \,\}, \qquad \omega_{it} = \frac{r_{it} - \min_{j \in \mathcal{S}_t} r_{jt}}{\sum_{i \in \mathcal{S}_t} \left(r_{it} - \min_{j \in \mathcal{S}_t} r_{jt} \right)}$$

조건부 평균과 공분산

$$\hat{\mu}_t = \sum\nolimits_{i \in \mathcal{S}_t} \omega_{it}\, y_{i+1}, \qquad \hat{\Sigma}_t = \sum\nolimits_{i \in \mathcal{S}_t} \omega_{it}\, (y_{i+1} - \hat{\mu}_t)(y_{i+1} - \hat{\mu}_t)^\top$$

국면 확률을 따로 계산하지 않습니다 — 닮은 과거가 곧 국면 혼합 역할을 합니다.

원 논문은 relevance 가중평균이 전체 표본 선형회귀 예측과 같음을 보였습니다.

fit은 이번 예측을 얼마나 믿을지 알려 주는 신뢰도입니다

원 논문의 fit = 가중치와 실현 결과의 상관 제곱 · 이 시리즈는 그 과거 순위를 신뢰도로 쓴다

fit과 신뢰도 순위

$$\mathrm{fit}_t = \rho^2\left(r_{it},\ y^{ex}_{i+1}\right)_{i\in\mathcal{S}_t}, \qquad c_t = \mathrm{rank}(\mathrm{fit}_t \mid \mathrm{fit}_{1:t-1}) \in [0,1]$$

fit 높음

닮은 과거의 결과가 일관

fit 낮음

결과가 엇갈림

처음 보는 상황

기본 경로로 복귀

과거에 비슷한 상황이 드물거나 결과가 엇갈리면 fit이 낮습니다.

신뢰도로 이탈 폭을 줄여, 낯선 상황에서는 기본 글라이드로 돌아갑니다.

03

비중으로 옮기기

조건부 예측을 글라이드패스에 묶고, 다섯 단계로 과잉 반응을 덜어 낸다

목표 비중은 글라이드 주변의 거래비용 벌점 평균-분산 문제로 정합니다

λ(τ) = 기본 글라이드를 최적해로 만드는 위험회피계수 · κ = 거래비용 벌점 · b(τ) = 허용 이탈 폭

원칙형 — 글라이드 앵커 + 이탈 제약 + 거래 벌점

$$w_t^* = \arg\max_w \ \hat{\mu}_t^\top w - \frac{\lambda(\tau)}{2} w^\top \hat{\Sigma}_t w - \kappa \left\| w - w_{t-1} \right\|_1 \quad \text{s.t. } \left| w - w_G(\tau) \right| \le b(\tau)$$

위험회피계수 역산 — 국면 정보가 없으면 해가 정확히 기본 글라이드

$$\lambda(\tau) = \frac{\bar{\mu}_e - \bar{\mu}_b}{w_G(\tau)\,\bar{V} + \bar{\sigma}_{eb} - \bar{\sigma}_b^2}, \qquad \bar{V} = \bar{\sigma}_e^2 + \bar{\sigma}_b^2 - 2\bar{\sigma}_{eb}$$

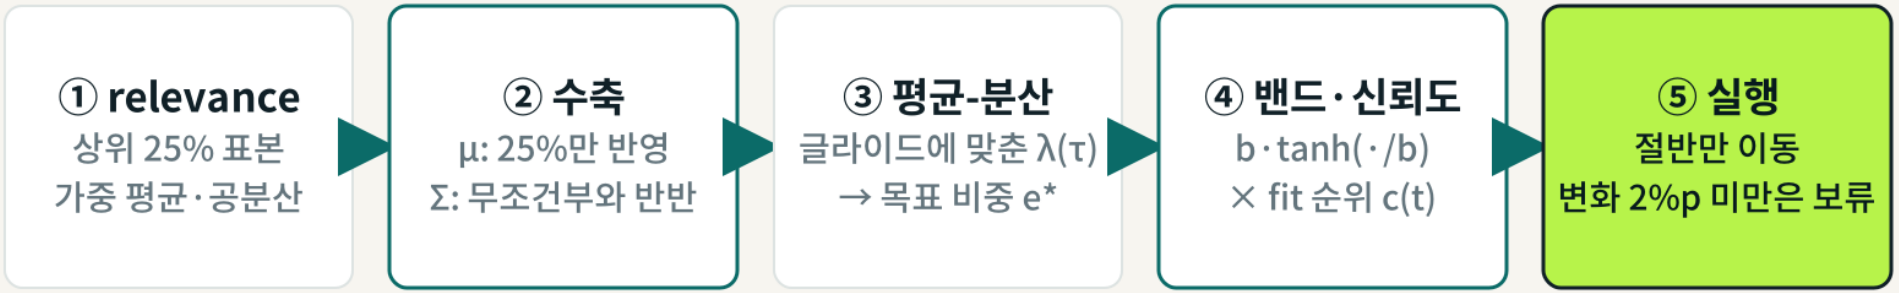
글라이드가 낮아질수록 역산된 λ(τ)가 커져, 목표일 근처에서는 같은 신호에도 덜 움직입니다.

조정분은 오직 relevance가 준 조건부 정보에서만 나옵니다.

다섯 단계가 추정 잡음을 한 겹씩 걸러 냅니다

가상 실험의 실제 처리 순서 — 원칙형 문제를 닫힌 형태로 근사한 것

조건부 추정을 비중으로 옮기는 다섯 단계 — 각 단계가 과잉 반응을 한 겹씩 덜어 낸다



노이즈 억제 장치: ② 수축 · ④ 밴드와 신뢰도 · ⑤ 평활과 무거래 구간

연속 반영 자체는 회전율을 줄이지 않는다 — ⑤가 없으면 매달 조금씩 사고팔게 된다

②·④는 '얼마나 믿을까', ⑤는 '얼마나 빨리 따라갈까'를 정합니다.

기대수익은 4분의 1만 반영하고, 비중 변화는 절반씩만 따라갑니다

조건부 평균은 추정오차가 커서 무조건부 쪽으로 강하게 수축(shrinkage)한다

② 수축 — 평균은 25%, 공분산은 50%만 조건부로

$$\mu_t^c = \bar{\mu} + 0.25\,(\hat{\mu}_t - \bar{\mu}), \qquad \Sigma_t^c = 0.5\,\hat{\Sigma}_t + 0.5\,\bar{\Sigma}$$

④·⑤ 신뢰도 · 밴드 · 지수평활 — 이 뒤에 무거래 구간 2%p

$$\theta_t = \tfrac{1}{2}\,\theta_{t-1} + \tfrac{1}{2}\,c_t\,b(\tau)\tanh\left(\frac{e_t^* - w_G(\tau)}{b(\tau)}\right), \qquad w_t = w_G(\tau) + \theta_t$$

위기 표본은 몇 건뿐이라 공분산을 반드시 무조건부와 섞어야 합니다.

지수평활이 없으면 연속 신호가 매달 조금씩 거래를 만듭니다.

연속 반영이 회전율을 줄이는 것은 평활이 있을 때뿐입니다

Δ = 국면 신호가 만드는 비중 차이 · N = 연간 전환 횟수 · Δp = 연속 신호의 월별 변화

회전율의 두 가지 근사

$$\mathrm{TO}_{\mathrm{binary}} \approx \Delta \times N_{\mathrm{switch}}, \qquad \mathrm{TO}_{\mathrm{cont}} \approx \Delta \times \sum_t |\Delta p_t|$$

이진 · 연 4회 전환

30%p × 4 = 120%p

연속 · 월 0.08 × 12

≈ 29%p

평활 없음

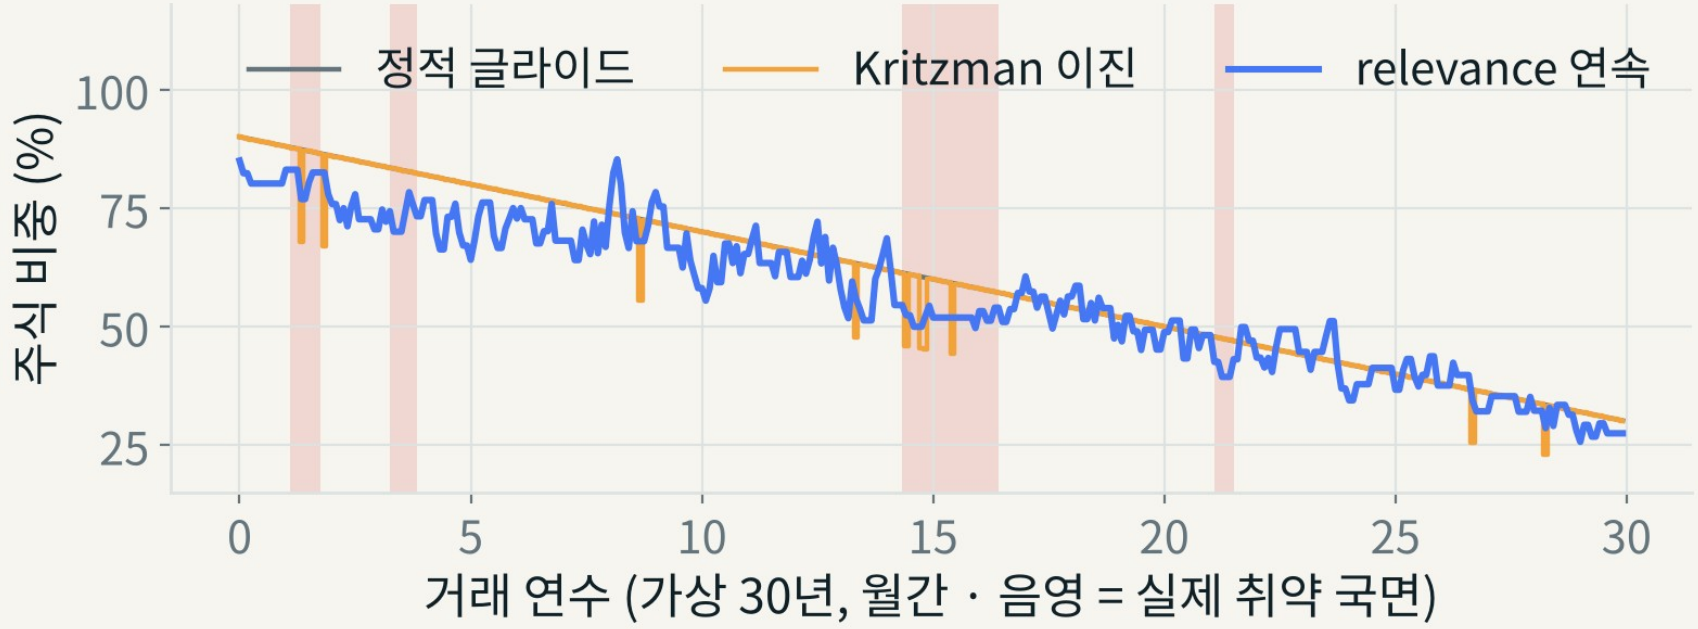
역전될 수 있다

실데이터 백테스트에서 평활 없는 연속 배분은 연 41%로 이진 전환(22%)보다 많이 거래했습니다.

‘연속이라 거래가 적다’는 말은 평활과 무거래 구간을 함께 둘 때만 맞습니다.

relevance 비중은 국면 경계에서 왕복하지 않고 연속으로 움직입니다

세계 A의 가상 30년 한 경로 · 음영 = 실제 취약 국면



취약 국면 진입을 대체로 따라가지만, 변동성 반등 국면에서도 비중을 낮춥니다.

국면 이름이 없으니 '평소와 다르다'는 사실 자체에 반응합니다 — 방향 변수가 중요합니다.

04

실증과 한계

실데이터 백테스트와 공통 가상 실험으로 강점과 비용을 확인한다

실데이터에서 연속 배분은 정적 경로를 이겼지만 이진 전환은 넘지 못했습니다

지난 W07 IV 노트북 · Vanguard 주식·채권 펀드 월간 자료(1996~) · 편도 10bp

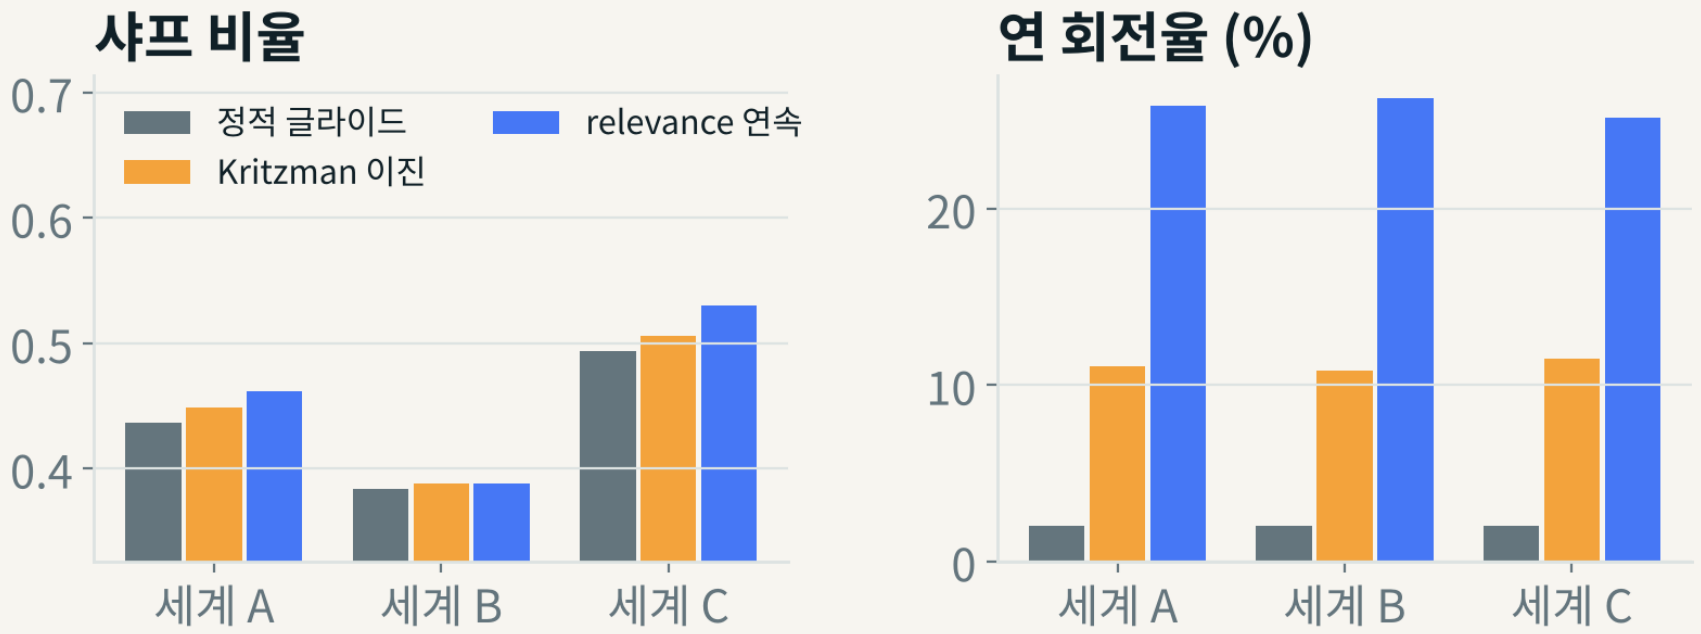
전략	샤프	비고
정적 글라이드	0.65	기준
이진 터뷸런스 전환	0.71	확장 창 80분위 임계
relevance 연속	0.68	평활 계수에 따라 회전율이 크게 달라짐

한 번의 실데이터 경로는 우연의 몫이 큽니다 — 그래서 가상 세계 150개 경로로 다시 봅니다.

※ 이전 노트북 실행 결과 — 데이터 구간·설정을 바꾸면 순위가 바뀔 수 있다.

가상 세계에서 relevance는 정적 경로를 이겼지만 개선 폭은 작았습니다

세 세계 × 150개 가상 경로 평균 · 편도 10bp 차감 후



샤프(A·B·C): relevance 0.462 · 0.388 · 0.530 / 정적 0.436 · 0.383 · 0.494

강한 수축과 신뢰도 할인 탓에 움직임이 작아, 낙폭(A -38.7%)만 조금 줄었습니다.

relevance의 약점은 반등 국면의 오경보입니다

세계 A · 취약/반등 조정 = 실제 그 국면 달의 평균 비중 조정(정적 글라이드 대비)

전략	샤프	변동성	연 회전율	취약 조정	반등 조정
정적 글라이드	0.436	10.8%	2%	+0.0%p	+0.0%p
Kritzman 이진	0.449	10.7%	11%	-2.0%p	-0.4%p
relevance 연속	0.462	10.2%	26%	-4.9%p	-3.5%p

relevance는 반등 국면에서도 평균 -3.5%p 줄였습니다 — 반등 달의 71%에서 오경보입니다.

지속성을 모르는 사례 기반 예측의 한계 — 덱 C에서 HMM과 묶어 보완합니다.

relevance를 쓸 때는 네 가지를 점검해야 합니다

원 논문과 이전 노트북에서 확인된 주의점

주의점	문제	대응
표본 겹침	결과 구간이 겹치면 실효 표본 감소	비중첩 표본 · Newey–West
극단 희소	위기 표본 몇 건으로 공분산 추정	무조건부 공분산으로 수축
변수 과적합	상태변수·q를 성과로 고름	adjusted fit · 홀드아웃
지속성 무시	한 달 상태만 보고 판단	HMM 확률을 상태변수로

마지막 줄의 처방이 덱 C 통합 설계의 첫 번째 장치입니다.

판단 문제로 정리합니다

풀이는 워크북 W5~W9

상황	답	근거
평범한 달이면 relevance 예측은?	**평균 근처**	**모든 점수가 작다**
q를 5%로 줄이면 예측은?	**불안정**	**표본 수 감소**
fit 순위가 0.1이면 비중 조정은?	**거의 없음**	**신뢰도로 이탈 축소**

relevance는 ‘어떤 과거를 믿을지’를 데이터가 정하게 하는 방법입니다.

국면에 이름을 붙이지 않아도 됩니다.

지금과 닮은 과거가 곧 국면입니다.

연속 배분은 평활이 있을 때만 거래를 줄입니다.

다음 덱 C
통합과 그 너머

A · HMM · B · relevance
C · 통합 · 손계산 워크북

※ 참고: Czasonis, Kritzman & Turkington (2023, JFDS) · Kritzman, Kulasekaran & Turkington (2023, JPM). 실험 수치는 가상.