두 방법의 통합과 그 너머

두 예측기를 모형 평균으로 묶고 세 축으로 넓힌다

비교

↓

통합

↓

검증

↓

확장

두 방법을 같은 틀에 놓고 묶은 뒤, 그 너머의 방향을 봅니다

01	두 방법의 비교	**같은 질문, 다른 기억** 원형 대 사례 · 혼합 예측의 공통 구조 · 강약점
02	통합 설계	**네 가지 장치** 상태변수 확장 · 재추정 · 모형 평균 · 실행
03	가상 실험	**세 세계 · 여섯 규칙** 샤프 · 회전율 · 모형 확률 · 최악 대비 손실
04	그 너머	**세 축 글라이드패스** 국면 수 추정 · 변화점 · 내 자산 · 도입

통합의 목표는 최고 모형을 이기는 것이 아니라, 어느 세계에서도 크게 지지 않는 것입니다.

01

두 방법의 비교

HMM은 과거를 국면 원형으로 압축하고, relevance는 과거 사례를 그대로 둔다

두 방법은 '지금과 닮은 과거'를 모으는 방식만 다릅니다

덱 A(HMM·베이지안 필터)와 덱 B(relevance)의 요약

같은 질문, 다른 기억 방식 — '지금과 닮은 과거'를 어떻게 모으는가

HMM · 베이지안 필터



과거를 K개 원형으로 압축

지금 각 원형일 확률 π로 섞는다

강점: 지속성(전이확률)을 안다

약점: 원형의 수·모양을 미리 정해야 한다

relevance (사례 기반)



과거 N개 사례를 그대로 둔다

지금과의 relevance로 가중평균

강점: 국면 정의·개수를 가정하지 않는다

약점: 지속성을 모르고, 드문 상황에 약하다

HMM은 끈적함을 알지만 국면의 모양을 가정하고, relevance는 가정이 없지만 끈적함을 모릅니다.

약점이 서로 엇갈리므로 묶을 이유가 있습니다.

두 예측은 모두 과거의 가중 혼합이라 같은 틀로 묶을 수 있습니다

HMM의 가중치는 다음 달 국면 확률, relevance의 가중치는 관련성 — 둘 다 예측분포를 낸다

같은 형태의 두 혼합 예측

$$\underbrace{\hat{\mu}_{t+1} = \sum_{k=1}^{K} \pi_{t+1|t}(k)\,\mu_k}_{\text{HMM: K prototypes}} \quad \longleftrightarrow \quad \underbrace{\hat{\mu}_{t+1} = \sum_{i \in \mathcal{S}_t} \omega_{it}\, y_{i+1}}_{\text{relevance: N episodes}}$$

HMM 가중치

π(t+1|t) — K개

relevance 가중치

ω(i,t) — N개

공통 출력

예측분포 (μ, Σ)

둘 다 예측분포를 내므로, 실현된 수익으로 매달 채점해 비교할 수 있습니다.

채점 결과로 두 모형의 비중을 정하는 것이 베이지안 모형 평균입니다.

강점과 약점이 엇갈려 서로를 보완합니다

같은 Kritzman 지표를 입력으로 쓰는 두 예측기

기준	HMM · 베이지안 필터	relevance
사전 가정	국면 수 · 분포 형태	상태변수 선택뿐
강점	지속성 · 전이 구조	모형 무가정 · 투명성
약점	오설정 · 모수 노후화	끈적함 무시 · 희소 상황
신뢰도	사후확률의 확신	fit 순위
거래 성향	확률이 매달 움직임	평활이 없으면 잦은 거래

공통 약점은 회전율입니다 — 예측 쪽이 아니라 실행 쪽에서 따로 다뤄야 합니다.

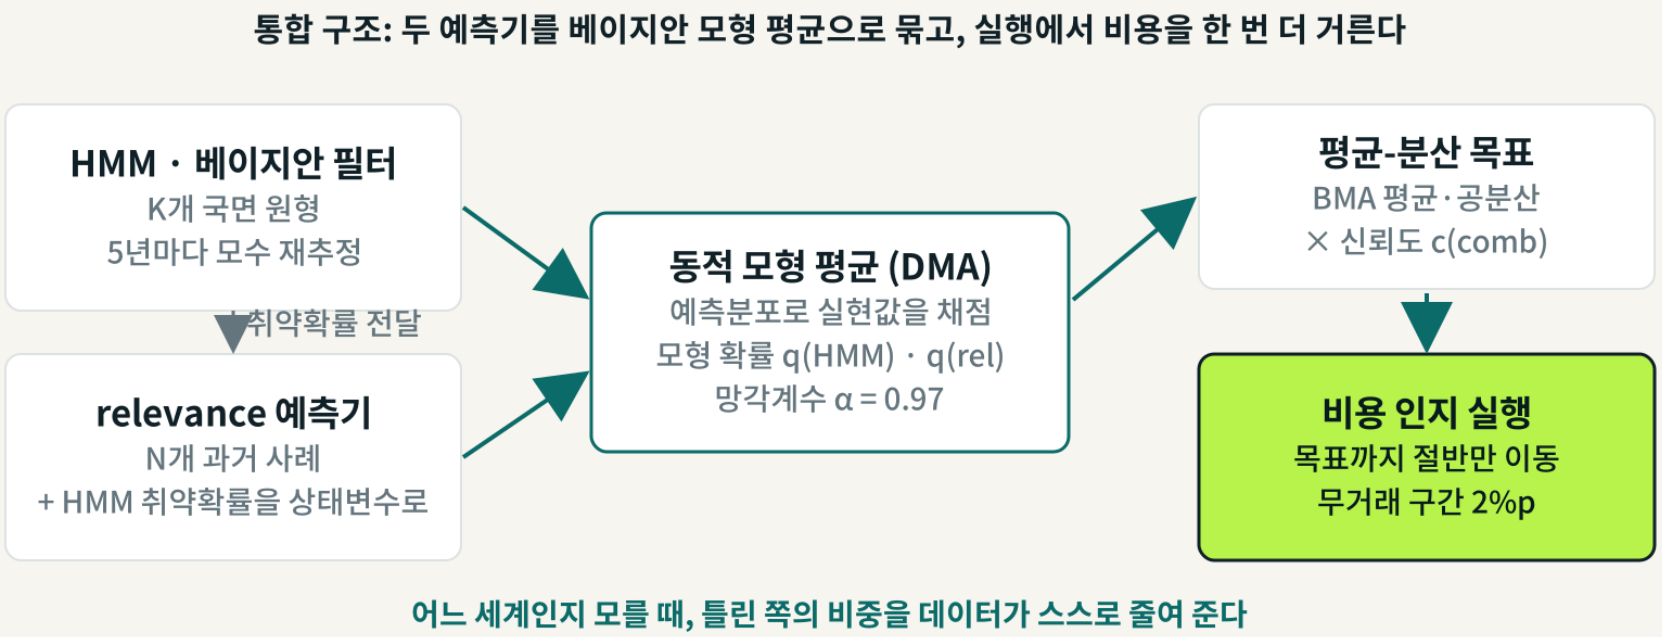
02

통합 설계

두 예측기를 경쟁시키고, 잘 맞힌 쪽에 더 많은 비중을 준다

통합 구조는 네 가지 장치로 이루어집니다

① 상태변수 확장 · ② 모수 재추정 · ③ 동적 모형 평균 · ④ 비용 인지 실행



①·②는 각 예측기를 고치고, ③은 둘을 묶고, ④는 거래를 거릅니다.

덱 A의 베이지안 갱신을 국면에서 모형으로 한 층 끌어올린 구조입니다.

취약 확률은 relevance에 넘기고, HMM 모수는 주기적으로 다시 추정합니다

relevance에 없던 지속성 정보를 상태변수로 전달하고, HMM에 없던 적응성을 재추정으로 보탠다

① 상태변수 확장 — 필터 확률 하나를 네 번째 변수로

$$x_t^+ = \left[\, x_t,\ \pi_{t|t}(\text{fragile}) \,\right]$$

② 5년마다 확장 창으로 재추정 — 모수 갱신의 간단한 근사

$$\theta^{(j)} = \arg\max_\theta \ \log p\left(y_{1:t_j} \mid \theta\right), \qquad t_j = t_0 + 60j$$

취약 확률은 '몇 달째 이어지는 중인가'를 요약하므로 사례 검색이 끈적함을 보게 됩니다.

완전한 베이지안 HMM이라면 재추정 대신 모수 사후분포를 매달 갱신합니다.

동적 모형 평균은 두 모형의 확률을 매달 베이즈 정리로 갱신합니다

Raftery·Kárný·Ettler(2010) Dynamic Model Averaging — 망각계수 α로 과거 성적을 서서히 잊는다

③ 모형 확률의 예측과 갱신 — x(t) = 실현된 주식−채권 초과수익

$$q_{t|t-1}(m) = \frac{q_{t-1}(m)^{\alpha}}{\sum_l q_{t-1}(l)^{\alpha}}, \qquad q_t(m) = \frac{q_{t|t-1}(m)\, p_m(x_t|\mathcal{F}_{t-1})}{\sum_l q_{t|t-1}(l)\, p_l(x_t|\mathcal{F}_{t-1})}$$

α = 1

고정 가중 BMA

α = 0.97

약 33개월 기억

α 작음

빠른 교체 · 잡음

예측분포가 실현값을 더 잘 맞힌 모형의 확률이 올라갑니다.

덱 A의 해밀턴 필터와 똑같은 구조를 '국면' 대신 '모형'에 적용한 것입니다.

모형 평균의 공분산에는 두 모형의 의견 차이가 위험으로 더해집니다

within = 각 모형이 보는 위험 · disagreement = 두 예측 평균이 서로 다른 정도

모형 평균 예측분포

$$\mu^{\mathrm{BMA}} = \sum_m q_t(m)\,\mu_m, \qquad \Sigma^{\mathrm{BMA}} = \underbrace{\sum_m q_t(m)\,\Sigma_m}_{\text{within}} + \underbrace{\sum_m q_t(m)\,(\mu_m - \mu^{\mathrm{BMA}})(\mu_m - \mu^{\mathrm{BMA}})^{\top}}_{\text{disagreement}}$$

신뢰도 — HMM 몫은 그대로, relevance 몫은 fit 순위로 할인

$$c_t^{\mathrm{comb}} = q_t(\mathrm{HMM}) \cdot 1 + q_t(\mathrm{rel}) \cdot c_t$$

두 모형이 서로 다른 말을 할수록 위험이 커 보여 비중을 덜 움직입니다.

모형 불확실성이 그대로 보수성으로 바뀝니다.

실행은 목표까지 일부만 이동하고, 비용이 클수록 무거래 구간을 넓힙니다

Gârleanu·Pedersen(2013)의 aim portfolio · 비례 거래비용에서 무거래 폭은 비용의 세제곱근에 비례

④ 부분 매매 — 이 실험은 κ = 0.5

$$w_t = w_{t-1} + \kappa\left(\mathrm{aim}_t - w_{t-1}\right), \qquad 0 < \kappa \le 1$$

무거래 폭의 비용 탄력성 — 비용 8배면 폭 2배

$$\delta^* \;\propto\; \left(\frac{c}{\lambda}\right)^{1/3}$$

신호가 좋아도 비용이 크면 천천히 따라가는 것이 최적입니다.

거래 빈도는 신호 품질이 아니라 비용 구조가 정해야 합니다.

03

가상 실험

모형이 맞는 세계 · 구조가 바뀐 세계 · 국면이 없는 세계에서 여섯 규칙을 비교한다

세 세계는 각 방법에 유리한 조건과 불리한 조건을 하나씩 담습니다

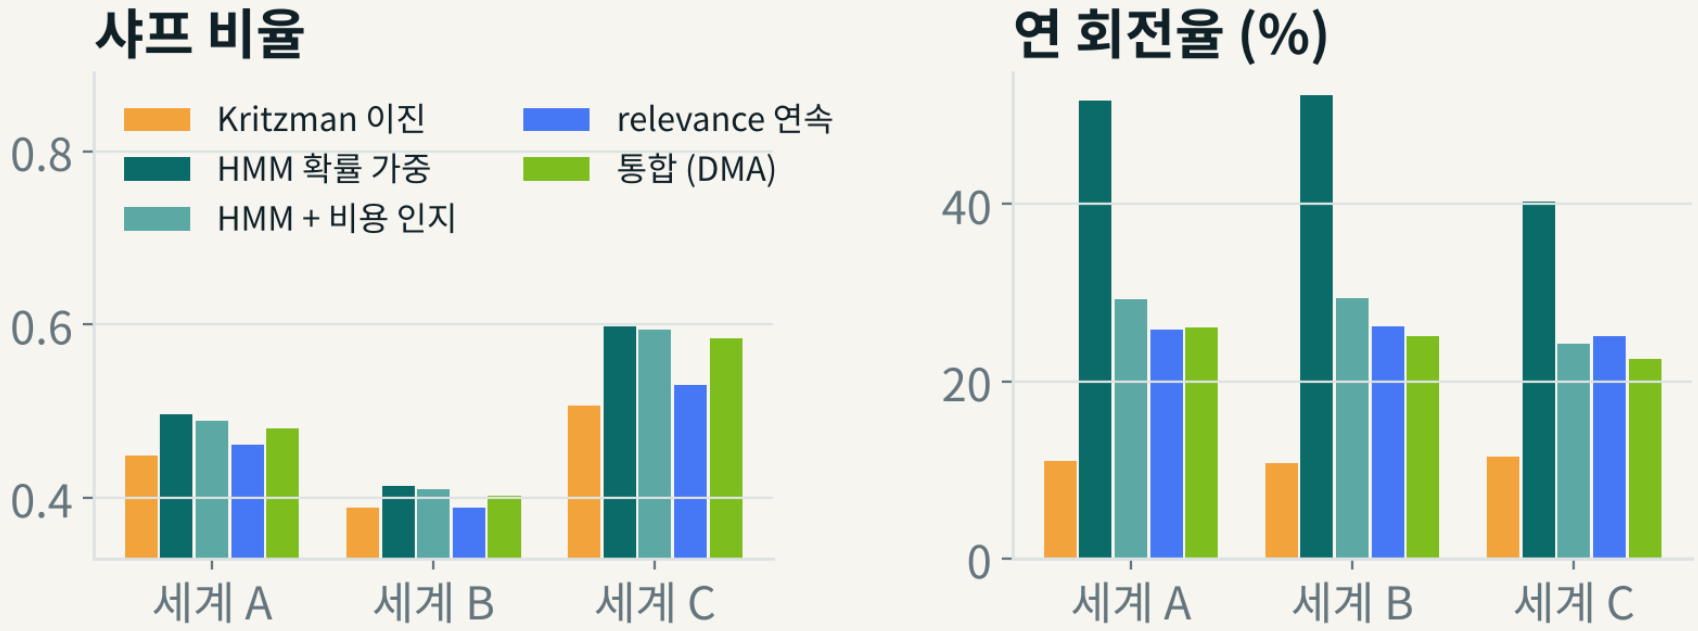
모든 수치는 수업용 가상 실험 — 경로 150개 · 사전 이력 20년 + 거래 30년 · 편도 10bp

세계	설정	유리한 쪽
A	**3국면 마르코프 전환 — 모형 그대로**	**HMM**
B	**거래 5년차부터 취약 국면이 주식·채권 동반 하락형**	**적응하는 쪽**
C	**국면 없이 연속 상태가 수익·위험을 결정**	**모형 무가정 쪽**

새로 더한 규칙은 ‘HMM + 비용 인지 실행’과 ‘통합(DMA)’ 두 가지입니다.

HMM이 샤프 최고, 통합은 그 근처에서 회전율을 절반으로 줄였습니다

세 세계 × 150개 가상 경로 평균 · 편도 10bp 차감 후



세계 A 샤프: HMM 0.496 · HMM+비용 0.488 · 통합 0.480 · relevance 0.462

연 회전율(A): HMM 52% → HMM+비용 29% · 통합 26%

통합은 어느 세계에서도 최고와의 차이가 작았습니다

최대 손실 = 세 세계 중 '그 세계의 최고 샤프 − 이 규칙의 샤프'가 가장 큰 값 (minimax regret)

규칙	샤프 A	샤프 B	샤프 C	회전율 A	최대 손실
정적 글라이드	0.436	0.383	0.494	2%	0.103
Kritzman 이진	0.449	0.388	0.506	11%	0.091
HMM 확률 가중	0.496	0.413	0.597	52%	0.000
HMM + 비용 인지	0.488	0.410	0.594	29%	0.008
relevance 연속	0.462	0.388	0.530	26%	0.067
통합 (DMA)	0.480	0.403	0.584	26%	0.016

HMM의 최대 손실은 0이지만, 이 실험의 세계가 대부분 HMM에 가까웠기 때문입니다.

relevance 단독(0.067)보다 통합(0.016)이 훨씬 안전합니다 — 모형을 모를 때의 보험입니다.

모형 확률은 시기마다 움직이며 한쪽으로 쏠리지 않았습니다

같은 시드의 가상 경로 하나 · 망각계수 0.97 · 위로 갈수록 HMM 예측을 더 믿는다



실현 수익 한 달로는 두 모형을 크게 구분하지 못해 확률이 천천히 움직입니다.

그래서 모형 평균은 '교체'라기보다 '분산 투자'에 가깝게 작동합니다.

실험에서 얻은 교훈은 세 가지입니다

결과를 과장하지 않기 위해, 통합이 이기지 못한 부분도 그대로 적는다

교훈	근거	실무 함의
실행 개선이 가장 싸다	HMM 회전율 52% → 29%, 샤프 차이 0.008	부분 매매부터 도입
모형이 맞으면 HMM이 강하다	세 세계 모두 HMM 샤프 최고	국면 구조가 뚜렷한 자산군
모를 때는 묶는다	최대 손실 0.016 대 0.067	그림자 운영으로 확인

relevance는 보수적 설정(평균 25%만 반영)이라 과소평가됐을 수 있습니다.

설정 민감도 점검이 다음 과제입니다.

04

그 너머

국면 축 하나를 넘어, 국면의 개수와 내 자산 수준까지 비중의 입력으로 삼는다

다섯 가지 확장이 세 축 글라이드패스로 모입니다

위 줄은 국면 추론을 고치고, 아래 줄은 목적함수를 넓힌다



위 줄은 '처음 보는 국면'에 대한 답이고, 아래 줄은 '누구의 TDF인가'에 대한 답입니다.

국면의 개수와 바뀌는 시점도 데이터가 정하게 할 수 있습니다

sticky HDP-HMM (Fox 외, 2011) · Bayesian Online Changepoint Detection (Adams·MacKay, 2007)

κ = 자기 전이에 더하는 가중 — 국면의 끈적함을 사전분포에 넣는다

$$p(s_t = j \mid s_{t-1} = k) \;\sim\; \mathrm{DP}\left(\alpha + \kappa,\; \frac{\alpha\beta + \kappa\,\delta_k}{\alpha + \kappa}\right)$$

run length ℓ = 마지막 변화점 이후 경과 기간의 사후분포

$$p(\ell_t \mid y_{1:t}) \;\propto\; \sum_{\ell_{t-1}} p(y_t \mid \ell_{t-1}, y^{(\ell)})\, p(\ell_t \mid \ell_{t-1})\, p(\ell_{t-1} \mid y_{1:t-1})$$

세계 B처럼 국면의 성격이 바뀌면 새 상태를 만들거나 변화점을 선언합니다.

고정된 K개 국면이라는 HMM의 가장 큰 가정을 푸는 방법입니다.

도착점은 남은 기간 · 내 자산 · 국면 확률의 세 축 글라이드패스입니다

W/W* = 목표 대비 현재 자산 — 적응형 글라이드패스(Forsyth·Vetzal, 2019)와 국면 확률의 결합

세 축 비중 함수 — 신경망 정책으로 직접 학습할 수 있다

$$w_t = w\left(\tau,\ \ W_t/W^*,\ \ \pi_{t+1|t}\right)$$

τ

회복할 시간

W/W*

목표와의 거리

π

지금 시장의 상태

같은 국면이라도 목표를 앞선 가입자는 위험을 덜 져야 합니다.

국면 정보는 세 축 중 하나일 뿐 — 목적함수가 결과를 정합니다.

도입은 한 단계씩, 앞 단계를 이길 때만 올라갑니다

채택 조건 = 같은 비용 조건의 홀드아웃 구간에서 앞 단계보다 샤프와 최대낙폭이 모두 나을 것

단계	얹는 것	점검 지표
1	정적 글라이드 + 리밸런싱 밴드	추적 오차
2	HMM 필터 확률 + 부분 매매	회전율 · 오경보율
3	relevance 예측기 그림자 운영	fit 분포 · 예측 점수
4	동적 모형 평균 통합	모형 확률 · 최대 손실
5	세 축 글라이드패스	목표 미달 확률

각 단계는 설명 가능한 형태로 투자위원회 승인을 받아야 합니다 — 복잡도는 이길 때만 늘립니다.

판단 문제로 정리합니다

풀이는 워크북 W10~W12

상황	답	근거
두 모형 예측이 엇갈리면 통합 비중은?	덜 움직인다	의견 차이가 위험에 더해짐
망각계수 α를 0.80으로 낮추면?	교체가 잦다	기억이 약 5개월
거래비용이 27배가 되면 무거래 폭은?	3배	세제곱근 법칙

통합의 핵심은 모형 하나를 믿지 않고, 믿음의 크기를 데이터로 정하는 것입니다.

두 방법은 같은 질문에 다르게 답합니다.

모를 때는 묶고, 묶음의 비중은 데이터가 정합니다.

거래는 신호가 아니라 비용이 정합니다.

다음

워크북 · 손계산 W1~W12

A · HMM · B · relevance

C · 통합 · 손계산 워크북

※ 참고: Raftery, Kárný & Ettler (2010, Technometrics) · Gârleanu & Pedersen (2013, JF) · Fox 외 (2011, AoAS) · Adams & MacKay (2007) · Forsyth & Vetzal (2019, AMF). 실험 수치는 가상.